

Probabilitat II

Santi Perez-Hoyos

21 juliol, 2026

Índex

Pla docent	2
Dades generals	2
Hores	2
Competències / Resultats d'aprenentatge que es desenvolupen	2
Objectius d'aprenentatge	3
Blocs Temàtics i Continguts Detallats	3
Metodologia i activitats formatives	4
Avaluació acreditativa dels aprenentatges	5
1 Variables aleatòries multivariants	5
1.1 Definició i conceptes bàsics: vectors aleatoris, espais de probabilitat	5
1.2 Funcions de densitat i de distribució conjuntes.	12
1.3 Funcions de densitat i de distribució marginals i condicionades.	21
1.4 Moments multivariants: vector d'esperances, matriu de variància-covariància	31
1.5 Transformacions de variables multivariants	35
2 Independència de variables aleatòries	39
2.1 Independència i dependència entre variables aleatòries.	40
2.2 Esperances i variàncies condicionades.	42
2.3 Conceptes de covariància, correlació i causalitat	49
3 Algunes distribucions multivariants	53
3.1 Distribució normal multivariant: definició, propietats i aplicacions.	54
3.2 Distribucions especials: Multinomial, t-Student multivariant, Khi-quadrat, Wishart i Dirichlet.	63
3.3 Propietat d'agregació de la distribució de Dirichlet	71
3.4 Generació de mostres de distribucions multivariants.	71

4	Processos estocàstics: Introducció i conceptes bàsics	76
4.1	Definició de procés estocàstic.	76
4.2	Exemple 5.2	78
4.3	Processos estocàstics discrets i continus.	82
4.4	Processos estocàstics estacionaris i no estacionaris.	82
5	Principals tipus de Processos estocàstics.	83
5.1	Cadenes de Markov.	83
5.2	Caminades aleatòries.	83
5.3	Processos de Poisson.	83
5.4	Moviment Brownià.	83

Pla docent

L'assignatura pretén proporcionar una base sòlida en l'estudi de variables aleatòries multivariants i processos estocàstics, amb èmfasi en la comprensió teòrica, les propietats fonamentals i les aplicacions pràctiques en camps com la ciència de dades, les finances, les biociències i l'enginyeria.

Dades generals

Nom de l'assignatura	Probabilitat II
Codi de l'assignatura	
Curs Acadèmic	2026/2027
Coordinació	Santi Pérez Hoyos
Departament	Departament de Genètica, Microbiologia i Estadística
Crèdits	6
Programa Únic	S

Hores

Activitats	Tipus de formació	Hores
Activitats presencials i/o no presencials		60
- Teoria	Presencial	30
- Pràctiques de problemes	Presencial	30
Treball tutelat/dirigit		40
Aprenentatge autònom		50

Competències / Resultats d'aprenentatge que es desenvolupen

- Competències

C05. - Aplicar los conocimientos y habilidades a situaciones prácticas

C12. Detectar situacions en què els models estadístics i d'investigació operativa poden ser útils per a la presa de decisions.

C14. Adaptar els models teòrics a les necessitats específiques de les diferents àrees d'aplicació.

- Habilitats i destreses

H04. Plantejar una pregunta científica en termes estadístics.

H06. Identificar les fonts de variabilitat i incertesa que afecten la presa de decisions

- Coneixements i continguts

K03. Reconèixer la teoria de la probabilitat com a fonament de les tècniques estadístiques.

Objectius d'aprenentatge

Referits a Coneixements	Referits a habilitats, destreses
- Conèixer els conceptes de variables aleatòries multivariants i les seves components - Conèixer els conceptes de independència, covariància i correlació - Conèixer les principals models multivariants i les seves propietats, i identificar els seus àmbits d'aplicació - Conèixer el concepte de procés estocàstic i les seves propietats bàsiques. - Conèixer els principals tipus de processos estocàstics i identificar les situacions reals a les quals són aplicables.	- Calcular probabilitats a partir dels models de vectors aleatoris - Calcular densitats marginals i conjuntes i funcions de vectors aleatoris - Calcular matrius de covariàncies, correlacions i moments de variables aleatòries multivariants - Calcular probabilitats i generar dades de les principals distribucions - Determinar matrius de transició d'una cadena de Markov amb epai d'estats finits - Aplicació dels principals tipus de processos estocàstics

Blocs Temàtics i Continguts Detallats

1. Variables aleatòries multivariants

- Definició i conceptes bàsics: vectors aleatoris, espais de probabilitat.
- Funcions de densitat i de distribució conjuntes.
- Funcions de densitat i de distribució marginals i condicionades.
- Moments multivariants: vector d'esperances, matriu de variància-covariància.
- Transformacions de variables multivariants.

2. Independència de variables aleatòries

- Independència i dependència entre variables aleatòries.
- Esperances i variàncies condicionades.
- Conceptes de covariància, correlació i causalitat.

3. Algunes distribucions multivariants

- Distribució normal multivariant: definició, propietats i aplicacions.
- Distribucions especials: Multinomial, t-Student multivariant, Wishart, Chi-quadrat i Dirichlet.
- Generació de mostres de distribucions multivariants.

4. Processos estocàstics: Introducció i conceptes bàsics

- Definició de procés estocàstic.
- Processos estocàstics discrets i continus.
- Processos estocàstics estacionaris i no estacionaris.

5. Principals tipus de Processos estocàstics.

- Cadenes de Markov.
- Caminades aleatòries.
- Processos de Poisson.
- Moviment Brownià.

Metodologia i activitats formatives

El pla docent es desglossa en els següents tipus metodològics bàsics: activitats presencials, treball dirigit (com ara el lliurament de problemes o l'estudi de casos pràctics de seguiment automatitzat) i treball autònom. Les categories desglossades són:

1. Clases de teoria. Dues sessions setmanals (durant 15 setmanes) en que es presenten els conceptes més teòrics de l'assignatura. Es miren amb detalls demostracions, contingut i desenvolupament amb la resolució de situacions o problemes típics amb un enfocament pràctic
2. Clases pràctiques. Sessions de dues hores setmanals (durant 15 setmanes) L'alumant disposa al principi de cada tema de una col·lecció de problemes i exercicis pràctics. A la finalització de cada tema es deixen les solucions en el Campus Virtual. El professorat comenta les diferents formes d'abordar els problemes i resol en la pissara un classe exercicis tipus. A vegades es deixa temps a la mateixa classe perquè l'alumant pugui resoldre algun problema.

Les sessions pràctiques tindran lloc durant 15 setmanes al semestre en una sessió setmanal de 2 hores. En aquestes sessions el grup es divideix en dos subgrups que rebran la docència al mateix horari per part de dos professors. L'assignació d'alumnes als grups la fa el professorat.

A més, regularment es proposen qüestionaris en el Campus Virtual que cal fer de manera telemàtica i lliurar a través del Campus Virtual la setmana següent. En alguns dels qüestionaris es demana que es lliurin els càlculs i procediments, que cal lliurar a les classes de problemes. Aquests lliuraments, igual que la resta de qüestionaris, s'avaluen.

3. Activitats no presencials dirigides. Amb el suport d'eines informàtiques amb correcció automatitzada (qüestionaris de Moodle que es duen a terme des del Campus Virtual), es fa un seguiment del treball autònom de l'estudiant (40 hores d'activitats dirigides no presencials en total).
4. Treball autònom de l'estudiant per acabar de consolidar tots els conceptes donats (50 hores en total).

Es fa servir el Campus Virtual com a repositori del material del curs i també per concretar les activitats proposades. Alguns dels lliuraments de feines es fan directament en el Campus Virtual.

S'espera que l'alumnat assisteixi a classe sempre, ja que una assistència irregular dificulta l'assoliment de les competències que l'assignatura es marca com a objectius.

Avaluació acreditativa dels aprenentatges

Avaluació continuada

Es l'opció recomanada per als estudiants que assisteixen regularment i que consta de tres parts.

- 1.- **Lliurament dels questionaris** proposats en el Campus Virtual (Quest)
- 2.- **Examen parcial** en acabar el tema 2 que no elimina materia (Parcial)
- 3.- **Examen final** que coincideix amb la data d'avaluació única segons la data marcada pel Consell Docent. (Final)

Els examens parcial i final tenen la mateixa estructura, amb una pregunta teòrica i entre 2 i 4 problemes. La teoria tindrà un valor entre el 20% el 30%.

La qualificació global de l'assignatura és:

$$\text{Global} = 0.1 \cdot \text{Màx}(\text{Quest}, \text{Final}) + 0.3 \cdot \text{Màx}(\text{Parcial}, \text{Final}) + 0.6 \cdot \text{Final}$$

sempre que la nota de l'examen final sigui com a mínim de 4 (sobre 10); en cas contrari la qualificació global de l'assignatura és la nota de l'examen final. Per tant, la nota dels lliuraments i la del parcial es tenen en compte (amb pesos respectius del 10 % i del 30 % de la qualificació global) només si són superiors a la nota de l'examen final.

La nota de la reavaluació no té en compte la nota dels lliuraments setmanals ni la de l'examen parcial; per tant, és simplement la nota de l'examen de reavaluació.

Avaluació única

L'alumnat pot optar entre dues formes d'avaluació: avaluació continuada o avaluació única. Qui vulgui renunciar a l'avaluació continuada i acollir-se a l'avaluació única ha de fer-ho abans de la data que s'estableixi, i que es fa pública amb antelació suficient.

La prova d'avaluació única consta de dues parts: teoria (amb un pes entre el 20% i el 30 %) i problemes (amb un pes entre el 70% i el 80 %). Els continguts d'aquesta prova són semblants (en temàtica i dificultat) als explicats a les classes presencials. Aquesta prova avalua les competències de l'assignatura i es fa en la data fixada pel Consell Docent (abans del període de matriculació de l'alumnat).

1 Variables aleatòries multivariants

1.1 Definició i conceptes bàsics: vectors aleatoris, espais de probabilitat

1.1.1 Introducció

A qualsevol que se li pregunti quin temps es triga en recórrer els 280 kilòmetres de distància entre Barcelona i Castelló, si es circula a una velocitat constant de 120km/h, ens indicaria que en 2 hores i 20 minuts arribaríem a la destinació. Ara be, si se li pregunta quin serà el resultat de llançar un dau no tindria una resposta clara.

- El primer resultat prové d'un fenomen o **experiència determinista**. Es prou en extreure de l'equació $e = v \cdot t$ el valor del temps
- El segon pertany a la categoria dels fenòmens o **experiències aleatòries**. Es coneixen tots els resultats possibles, un número del 1 al 6 en el cas del dau, però no quin resultat es produirà, ja que de repetició en repetició sortiran resultats diferents.

1.1.2 Conceptes bàsics: Experiment aleatori, mesura de probabilitat

Definició 1.1. Un **experiment** és una seqüència d'accions que, en repetir-se sota les mateixes condicions, produeix resultats observables. Direm que l'experiment es **aleatori** si, executat sota les mateixes condicions, pot donar lloc a un resultat w d'entre un conjunt de possibles resultats.

Definició 1.2. L'**espai mostral** d'un experiment, denotat per Ω , és el conjunt de tots els resultats possibles.

Definició 1.3. Un **esdeveniment** es una col·lecció de possibles resultats d'un experiment, es a dir un subconjunt de $A \subseteq \Omega$. Quan el resultat de l'experiment pertany al esdeveniment ($w \in A$), direm que a ocorregut l'esdeveniment.

Exemple 1.1. Així si l'experiment és llançar un dau, l'espai mostral és

$$\Omega = \{1, 2, 3, 4, 5, 6\}$$

i un esdeveniment pot ser $A = \text{Treure un número senar}$. Si al llançar el dau surt un 3, l'experiment A ha ocorregut.

Definició 1.4. Una col·lecció $\mathcal{A} \subseteq \mathcal{P}(\Omega)$ és una **-àlgebra** si:

1. $\Omega \in \mathcal{A}$
2. Si $A \in \mathcal{A}$, aleshores $A^c \in \mathcal{A}$
3. Si $A_1, A_2, \dots \in \mathcal{A}$, aleshores $\bigcup_n A_n \in \mathcal{A}$

La σ -lgebra representa "tot allò al que volem i podem assignar probabilitat".

Exemple 1.2. Si suposem un experiment és triar a l'atzar un número en l'interval $[0,1]$, l'interès es centra en conèixer si l'elecció pertany a qualsevol dels subconjunts de $[0,1]$. La σ -lgebra $\beta_{[0,1]}$ d'esdeveniments generada a partir de tots els possibles subintervalls de $[0,1]$, és coneguda com σ -lgebra de Borel estrictament menor que $\mathcal{P}(\Omega)$.

En resum, L'espai mostral ve acompanyat de la σ -lgebra mes convenient a l'experiment. La combinació $(\Omega, \mathcal{A})$ reb el nom d'**espai mesurable**

Definició 1.5. Mesura de Probabilitat

Donat un espai mostral Ω i una σ -lgebra $\mathcal{A}$ definim la mesura de probabilitat com una aplicació.

$$\begin{aligned} P : \mathcal{A} &\rightarrow \mathbb{R} \\ A &\mapsto Pr(A) \end{aligned}$$

on P compleix els axiomes de Kolmogorov

1. $P(A) \geq 0$, per tot $A \in \mathcal{A}$.
2. $P(\Omega) = 1$.
3. *Axioma d'additivitat numerable:*
Si $A_1, A_2, \dots, A_n \in \mathcal{A}$ es una succedció d'esdeveniments disjunts dos a dos, llavors

$$P\left(\bigcup_{i=1}^n A_i\right) = \sum_{i=1}^n P(A_i)$$

Dels axiomes anteriors es segueixen totes les propietats de qualsevol mesura de probabilitat. En particular que la probabilitat de un esdeveniment ha de ser un número entre 0 i 1.

$$0 \leq P(A) \leq 1 \quad \text{per a tot } A \in \mathcal{A}.$$

Definició 1.6. Espai de probabilitat

A la *terna* $(\Omega, \mathcal{A}, Pr)$ l'anomenarem ESPAI DE PROBABILITAT.

Exemple 1.3. Espai de probabilitat discret uniforme

Suposem un espai mostral Ω , numerable i com a σ *lgebra* la formada per tots els subconjunts de Ω . Definim un funció no negativa sobre tots els subconjunts de Ω on es verifica que $\sum_{w \in \Omega} p(w) = 1$. Si es defineix $P(A) = \sum_{w \in A} p(w)$, es pot comprobar que P es una probabilitat. Un cas particular son els espais de probabilitat discrets uniformes. Si $\Omega = w_1, w_2, \dots, w_n$ i $p(w_i) = \frac{1}{n}, \forall w_i \in \Omega$.

Si $A = w_1, w_2, \dots, w_m$ tenim que $P(A) = \frac{m}{n}$ (Fórmula de Laplace). Es diu uniforme per que la massa de probabilitat està repartida al ser constant en cada punt.

Per exemple imaginem que llancem dos daus. L'espai mostral serà $\Omega = (1, 1), (1, 2), (1, 3), \dots, (6, 5), (6, 6)$ format per les 36 parelles de resultats possibles. Si els daus no estan trucats, cada parella té la mateixa probabilitat $1/36$. Si es considera $A = \{\text{amb dues cares son senars}\}$ el número de possibilitats son 9 i per tant la probabilitat de A es $P(A) = 9/36 = 1/4$.

El resultat d'un experiment aleatori no es tant l'espai de probabilitat resultant, sino les característiques numèriques associades. Això implica passar de Ω a $\mathbb{R}$ o $\mathbb{R}^k$ on es més fàcil treballar. Com hem comentat en $\mathbb{R}$ podem parlar de la σ -*lgebra* de Borel β que és la menor que conté els intervals i que permet parlar del espai de probabilitat $(\mathbb{R}, \beta)$

1.1.3 Conceptes bàsics: Variable aleatòria, funcions de distribució i probabilitat.

Definició 1.7. Variable aleatòria

Si considerem dos espais probabilitzables $(\Omega, \mathcal{A})$ i $(\mathbb{R}, \beta)$, una **variable aleatòria** es una aplicació $X : \Omega \rightarrow \mathbb{R}$ que verifica que $X^{-1}(B) \in \mathcal{A} \quad \forall B \in \beta$

Exemple 1.4. Quan llencem una moneda, habitualment identifiquem les dues cares amb els valors 0 i 1. Aquesta identificació és, de fet, una variable aleatòria:

$$X : \Omega \longrightarrow \mathbb{R}$$

$$\text{Cara} \longmapsto 0$$

$$\text{Creu} \longmapsto 1$$

Si la moneda no està trucada la probabilitat de que sorti cara o creu al llançar la moneda és 0.5 respectivament, Així al fer la transferència entre espais de probabilitat $P(X = 0) = 0.5$ és el mateix que $P(X^{-1}(0) = P(\text{cara}) = 0.5$ i el mateix per $X=1$ $P(X = 1) = 0.5 = P(X^{-1}(1) = P(\text{cara})$.

Per expressar aquesta probabilitat podríem haver utilitzat un altra variable aleatòria que codificarà la cara com a 1 i la creu com a 2.

Definició 1.8. Distribució de probabilitat induïda Quan es fa intervenir una variable aleatòria és per que s'està en la presència d'un espai de probabilitat. La variable aleatòria trasllada la informació d'aquesta probabilitat de Ω a $\mathbb{R}$ mitjançant la probabilitat induïda coneguda com llei de probabilitat o distribució de probabilitat.

Així, la variable aleatòria X induïx sobre $(\mathbb{R}, \beta)$ la probabilitat P_X de la següent forma

$$P_X(A) = P(X^{-1}(A)) \quad \forall A \in \beta$$

P_X hereta les característiques de P a través de X . Sí X canvia a distribució de probabilitat pot canviar . Veïem-lo en un exemple.

Exemple 1.5. Si tornem a l'exemple de llançar dos daus podem definir dues variables aleatòries. X que sigui la suma dels resultats dels dos daus i Y que sigui la diferència dels resultats. Encara que les dues variables estàn definides en el mateix espai de probabilitat, P_X y P_Y son diferents per que estan induïdes per variables diferents.

En cap cas la suma de les dues cares de un dau son 0, però ens 6 situacions les dues cares poden ser iguals. Si calculem amb els dues distribucions la probabilitat de que la variable aleatòria sigui 0, dona resultats diferents.

$$P_X(0) = P(X^{-1}(0)) = P(\emptyset) = 0$$

$$P_Y(0) = P(Y^{-1}(0)) = P(\{1, 1\}, \{2, 2\}, \{3, 3\}, \{4, 4\}, \{5, 5\}, \{6, 6\}) = \frac{6}{36} = \frac{1}{6}$$

Les distribucions de probabilitat com la P_X , encara que ens presenta la informació necessària per obtenir les probabilitats, son objectes matemàtics complexes d'utilitzar i es recorre a dos tipus de funcions associades, la Funció de distribució de probabilitat o la funció de probabilitat o densitat de probabilitat, depenen de la natura de la variable.

Definició 1.9. Funció de distribució de probabilitat

A partir de la probabilitat induïda podem definir sobre $\mathbb{R}$ la següent funció

$$F_X(x) = P_X((-\infty, x]) = P(X^{-1}\{(-\infty, x]\}) = P(X \leq x) \quad \forall x \in \mathbb{R} \quad (1)$$

La funció de distribució te les següents propietats

1. És una funció no negativa per la propia definició
2. És una funció monòtona ja que $F_X(x_1) \leq F_X(x_2)$ si $x_1 \leq x_2$
3. És una funció continua per la dreta . Es a dir si es considera una successió de números reals $x_n \rightarrow x$ llavors $\lim_{n \rightarrow \infty} F_X(x_n) = F_X(x)$
4. $\lim_{x \rightarrow \infty} F_X(x) = 1$ y $\lim_{x \rightarrow -\infty} F_X(x) = 0$

Del punt 3 es dedueix que si $(-\infty, x] = \{x\} \cup \lim_{n \rightarrow \infty} (-\infty, x - \frac{1}{n})$ la funció de distribució en X es

$$F_X(x) = P(X \leq x) = P(X = x) + \lim_{n \rightarrow \infty} F_X(x - \frac{1}{n}) = P(X = x) + F(x^-)$$

y $F_X(x)$ es continua si $P(X=x)=0$

Directament es pot calcular la probabilitat d'un interval obert per l'esquerra com

$$P(a < X \leq b) = F_X(b) - F_X(a)$$

Exemple 1.6. Suposem que a un pacient se le indica que trie un nombre real entre 0 i 10 per indicar el seu nivell de dolor (Escala analògica Visual (EVA)) i que tots els valors tenen la mateixa probabilitat de ser triats.

Definim la variable aleatòria X com el nivell de dolor i es vol obtenir la funció de distribució que reflexa la probabilitat de que el nombre escollit sigui menor o igual que 3.

$$F_X(x) = P_X(X \leq x)$$

Si tots els valors son equiprobables la probabilitat seria la longitud de casos favorables partit per 10.

És a dir, si $x \in [0, 10]$ $F(x) = \frac{x}{10}$

La funció completa és

$$F_X(x) = \begin{cases} 0, & \text{si } x < 0 \\ \frac{x}{10}, & 0 \leq x \leq 10 \\ 0, & x > 10 \end{cases}$$

Definició 1.10. Funció de probabilitat d'una variable aleatòria discreta

X és una variable aleatòria discreta si $X(\Omega)$ es finit o numerable, és a dir es pot definir un conjunt suport $D_X = \{x_1, x_2, \dots, x_n\}$ tal que $P_X(D_X) = P(X \in D_X) = 1$ i $P(X = x) > 0$, $\forall x \in D_X$. Per tant es pot deduir que $P(X = x) = 0$, $\forall x \in D_X^c$

Així la funció de distribució de la variable aleatòria discreta és:

$$F_X(x) = \sum_{x \leq x_i} P(X = x_i) \tag{2}$$

Que serà una funció continua en els intervals $[x_i, x_{i+1}]$ si els valors x_i estan endreçats de menor a major i que tindrà una discontinuïtat de salt finit en cada punt x_i de Valor $F_X(x_i) - F_X(x_{i-1}) = P(X = x_i)$

Així a la variable X li podem associar la funció de probabilitat següent

$$f_X(x) = \begin{cases} P(X = x), & \text{si } x \in D_X \\ 0, & \text{en la resta} \end{cases}$$

Exemple 1.7. Alguns exemples de variables aleatòries discretes que venen definides per les seves funcions de probabilitat son les que tenen una distribució Poisson, Binomial, Hipergeomètrica ó binomial negativa. La seva definició es pot trobar en l'annex del tema.

Definició 1.11. Funció de densitat o probabilitat de una variable aleatòria continua

Una variable aleatòria X és continua si la seva funció de distribució F_X , es absolutament continua. A efectes pràctics disposem la funció de densitat $f_X(x)$, coneguda de manera que

$$F_X(x) = \int_{-\infty}^x f(t)dt$$

Així la probabilitat de qualsevol interval $]a, b]$ és

$$P(X \in]a, b]) = P(a < X \leq b) = \int_a^b f(x)dx$$

La funció de densitat $f_X(x)$ es no negativa i $P(X \in \mathbb{R}) = 1$

Per altra banda per una propietat de la integral de Riemann, la funció de densitat es la derivada de la Funció de distribució $f_X(x) = F'_X(x)$

Exemple 1.8. Alguns exemples de variables aleatòries continues que venen definides per les seves funcions de densitat probabilitat son les que tenen una distribució uniforme, Normal, Exponencial, Gamma entre altres. La seva definició es pot trobar en l'annex del tema.

1.1.4 Variable aleatòria k-dimensional o vector aleatori

Molts experiments aleatoris produeixen més d'una única quantitat rellevant, és a dir, més d'una variable aleatòria. Veïem alguns exemples

Exemple 1.9.

- Imaginem una situació on primer es llança una moneda amb resultats cara i creu, i després es llança un dau amb 6 resultats. Així tenim una variable aleatòria X_1 per a la moneda i una variable aleatòria X_2 per al dau. El vector en $\mathbb{R}^2$ (X_1, X_2) serà una variable aleatòria bidimensional compostat per dues variables aleatòries unidimensionals

Exemple 1.10.

- En economia podem estar interessants en conèixer la distribució d'ingressos d'una persona i per altra costat el % dels ingressos dedicats al pagament de la vivenda (lloger o hipoteca). Cada individu estarà representat per un vector compostat per dues variables unidimensionals

Exemple 1.11.

- En salut podem estar interessats en el resultat d'un experiment on es mesuren diferents paràmetres biomètrics com pes, alçada, índex cintura-maluc, índex de massa corporal, índex cintura-alçada, perímetre braquial, perímetre abdominal, superfície corporal, etc. Es tracta d'un vector multidimensional definit per k variables unidimensionals en $\mathbb{R}^k$.

Definició 1.12. Vector aleatori

Un vector aleatori $\mathbf{X} = (X_1, X_2, \dots, X_k)$, es una aplicació del espai mostral Ω en $\mathbb{R}^k$ tal que

$$\mathbf{X}^{-1}(B) \in \mathcal{A}, \quad \forall B \in \beta^K$$

On β^K es una *sigma - lgebra* de Borel en $\mathbb{R}^k$

$\mathbf{X}$ indueix sobre $(\mathbb{R}^k, \beta^K)$ una probabilitat P_X de la següent manera

$$P_X(B) = P(\mathbf{X}^{-1}(B)), \quad \forall B \in \beta^K$$

És senzill comprovar que P_X verifica els tres axiomes de probabilitat, pel que $(\mathbb{R}^k, \beta^K, P_X)$ permet indueix un espai de probabilitat amb les característiques de $(\Omega, \mathcal{A}, P)$ heretats mitjançant $\mathbf{X}$.

Definició 1.13. Variable aleatoria bidimensional o bivariant

Sigui $(\Omega, \mathcal{A}, P)$ un espai de probabilitat . Podem definir la variable aleatòria bivariant com

$$(X, Y) : \Omega \rightarrow \mathbb{R}^2$$

$$w \rightarrow (X, Y)(w) = (X(w), Y(w))$$

on

$$(X, Y)^{-1}((-\infty, x] \times (-\infty, y]) = \{w \in \Omega : X(w) \leq x \text{ i } Y(w) \leq y\} \in \mathcal{A} \quad \forall x \in \mathbb{R} \text{ i } \forall y \in \mathbb{R}$$

Com passa en el cas univariant es prou que $(X, Y)^{-1}((-\infty, x] \times (-\infty, y]) \in \mathcal{A} \quad \forall (x, y) \in \mathbb{R}^2$ per a garantir que $(X, Y)^{-1}(B) \in \mathcal{A} \quad \forall B \in \beta(\mathbb{R}^2)$

Per tant, qualsevol variable aleatòria bivariant (X, Y) indueix una mesura de probabilitat en $\mathbb{R}^2$ que permet assignar probabilitats a qualsevol subconjunt Borelià B de $\mathbb{R}^2$:

$$P_{(X, Y)}(B) = P((X, Y)^{-1}(B)) = P(\{w \in \Omega : (X(w), Y(w)) \in B\})$$

Aquesta mesura de probabilitat induïda s'anomena *distribució de probabilitat conjunta de (X, Y)*

Exemple 1.12. Tornem a l'exemple on llançàvem una moneda (X) i un dau (Y)

L'espai mostral es $\Omega = (\{cara, 1\}, \{creu, 1\}, \{cara, 2\}, \dots, \{creu, 6\})$ i la Variable aleatoria (X, Y) pren el valor $X = 0$ si és cara i $X = 1$ si és creu en la primera component X i el número que ha sortit al dau en la segona component Y .

Podem definir

$$P_{XY}(x, y) = \begin{cases} 1/2 \times 1/6 = 1/12, & \text{si } x \in \{0, 1\} \text{ i } y \in \{1, 2, 3, 4, 5, 6\} \\ 0, & \text{en la resta} \end{cases}$$

Es pot demostrar que P_{XY} es una mesura de probabilitat ja que compleix els axiomes de Kolmogorov.

Definició 1.14. Variable aleatòria k- dimensional o multivariant

Si enlloc de 2 variables aleatòries unidimensionals generalitzem a n variables aleatòries, estarem parlant de una Variable aleatòria n-dimensional o multivariant.

Sigui $(\Omega, \mathcal{A}, P)$ un espai de probabilitat . Podem definir la variable aleatòria multivariant $\vec{X} = (X_1, X_2, \dots, X_{k-1}, X_k)$

$$\begin{aligned} (\vec{X}) : \Omega &\rightarrow \mathbb{R}^k \\ w &\rightarrow (X_1, X_2, \dots, X_{k-1}, X_k)(w) = (X_1(w), X_2(w), \dots, X_{k-1}(w), X_k(w)) \end{aligned}$$

on

$$(\vec{X})^{-1}((-\infty, x_1] \times \dots \times (-\infty, x_k]) = \{w \in \Omega : X_1(w) \leq x_1 \quad i \quad \dots \quad i \quad X_k(w) \leq x_k\} \in \mathcal{A} \quad \forall x_i \in \mathbb{R}$$

Per tant qualsevol variable aleatòria multivariant $(\vec{X})$ indueix una mesura de probabilitat en $\mathbb{R}^k$ que permet assignar probabilitats a qualsevol subconjunt Borelià B de $\mathbb{R}^k$:

$$P_{(\vec{X})}(B) = P((\vec{X})^{-1}(B)) = P(\{w \in \Omega : (X_1(w), \dots, X_k(w)) \in B\})$$

El que hem de fer a partir d'ara es caracteritzar aquesta probabilitat conjunta a partir de les característiques de les variables aleatòries unidimensionals que la componen. Ja que si $(\vec{X})$ es mesurable també o es cadascuna de les seves components i viceversa. Per simplificar la nomenclatura definirem P_X a la probabilitat conjunta de la variable multidimensional $\vec{X}$ i per facilitar la comprensió utilitzarem la dimensió 2 i el vector aleatori $\vec{X} = (X, Y)$

1.2 Funcions de densitat i de distribució conjunes.

1.2.1 Funció de distribució conjunta

En els apartats anteriors hem definit la probabilitat conjunta associada a una variable multidimensional. Com en el cas unidimensional, podem caracteritzar aquesta probabilitat conjunta a partir de funcions conjunes de distribució o de densitat o de probabilitat segon siguin les variables.

Definició 1.15. Funció de distribució conjunta

Definim la funció de distribució associada a P_X a donat un punt de $\mathbb{R}^k$ $\mathbf{x} = (x_1, \dots, x_k)$ com

$$F_X(\mathbf{x}) = F_X(x_1, \dots, x_k) = P_X(S_x) = P(X \in S_x) = P\left(\bigcap_{i=1}^k \{X_i \leq x_i\}\right)$$

En la figura 1 es pot observar la diferència entre una distribució univariat que es una corba en dimensió 2 y o la funció de distribució conjunta bivariada $F(x, y) = P(X \leq x, Y \leq y)$ que es tracta de una superfície en dimensió 3.

De la definició de funció de distribució conjunta es deriven les següents propietats:

No negativitat




Figura 1: Distribució continua bivariada

Com a conseqüència que la funció de distribució conjunta es una probabilitat, pren valors entre 0 y 1 i per tant sempre seran valors no negatius.

Monotonia de cada component

Si $\mathbf{x} \leq \mathbf{y}$ es a dir $x_i \leq y_i$, $i = 1, \dots, k$, $S_x \subset S_y$ y $F_X(x) \leq F_Y(y)$

Continuïtat conjunta per la dreta

Si $\mathbf{x}^{(n)} \rightarrow \mathbf{x}$ entonces $F_X(\mathbf{x}^{(n)}) \rightarrow F_X(\mathbf{x})$

Valores límit

Al tendir a $\pm\infty$ les components del vector aleatori s'obté

$$\lim_{\forall x_i \rightarrow +\infty} F_X(x_1, \dots, x_k) = 1$$

ó

$$\lim_{\exists x_i \rightarrow -\infty} F_X(x_1, \dots, x_k) = 0$$

Aquestes propietats ja son conegudes per al cas unidimensional. Cal una cinquena propietat sense la que no es pot recórrer el camí invers d'obtenir P_X a partir de F_X i poder establir la desitjada equivalència entre tots dos conceptes que il·lustrarem en dimensió 2.

Proposició 1.1. Regla del rectangle

En aquesta regla calculem la probabilitat d'un rectangle a partir de les funcions de distribució conjunta en cada punt del rectangle que es pot veure en la figura 2

$$\left. \begin{array}{l} \forall (x, y) \in \mathbb{R}^2 \\ \forall h > 0 \\ \forall k > 0 \end{array} \right\} F_{X,Y}(x+h, y+k) - F_{X,Y}(x, y) - F_{X,Y}(x+h, y) - F_{X,Y}(x, y+k) = P_{X,Y}(A) = P_{X,Y}([x, x+h] \times [y, y+k]) > 0$$

Demostració.




Figura 2: Càlcul de la probabilitat d'un rectangle

$$S_{x+h, y+k} = S_{x, y} + A_1 + A_2 + A$$

on cadascú del conjunts de la part dreta son disjunts i per tant

$$P_{X,Y}(S_{x+h, y+k}) = P_{X,Y}(S_{x, y}) + P_{X,Y}(A_1) + P_{X,Y}(A_2) + P_{X,Y}(A)$$

si substituïm per la funció de distribució

$$\begin{aligned} F_{X,Y}(x+h, y+k) &= F_{X,Y}(x, y) + P_{X,Y}(A_1) + P_{X,Y}(A_2) + P_{X,Y}(A) \\ A_1 &= S_{x+h, y} - S_{x, y} \\ \text{i per tant } P_{X,Y}(A_1) &= F_{X,Y}(x+h, y) - F_{X,Y}(x, y) \\ \text{donat que } S_{X,Y}(x, y) &\subset S_{X,Y}(x+h, y) \\ A_2 &= S_{x, y+k} - S_{x, y} \\ \text{i per tant } P_{X,Y}(A_2) &= F_{X,Y}(x, y+k) - F_{X,Y}(x, y) \\ \text{donat que } S_{X,Y}(x, y) &\subset S_{X,Y}(x, y+k) \end{aligned}$$

Així, si substituïm

$$\begin{aligned} P_{X,Y}(A) &= F_{X,Y}(x+h, y+k) - F_{X,Y}(x, y) - P_{X,Y}(A_1) - P_{X,Y}(A_2) \\ &= F_{X,Y}(x+h, y+k) - F_{X,Y}(x, y) - (F_{X,Y}(x+h, y) - F_{X,Y}(x, y)) - (F_{X,Y}(x, y+k) - F_{X,Y}(x, y)) \\ &= F_{X,Y}(x+h, y+k) + F_{X,Y}(x, y) - (F_{X,Y}(x+h, y) + F_{X,Y}(x, y+k)) > 0 \end{aligned}$$

Quedant demostrada la proposició

□

1.2.2 Variables aleatòries multivariants discretes

Definició 1.16. Funció de probabilitat conjunta.

Sigui el vector aleatori $\vec{X} = (X_1, X_2, \dots, X_{k-1}, X_k)$, direm que es un vector aleatori discret si en el suport $D_X = (D_{X_1}, \dots, D_{X_k})$ cadascuna de les seves components D_{X_i} es una component numerable discreta. Així, es pot definir la funció de probabilitat conjunta associada i el seu valor per a cada punt de $\mathbb{R}^k$ ve donat per:

$$f_X(x_1, \dots, x_k) = \begin{cases} P(X_i = x_i), & \text{si } x = (x_1, \dots, x_k) \in D_X \\ 0, & \text{en la resta} \end{cases}$$

Com que es una probabilitat $f_X(x) \geq 0, \forall x \in \mathbb{R}^k$

Exemple 1.13. Si tornem a l'exemple del llençament de la moneda i el dau de l'exemple 1.9 podem definir la funció de probabilitat conjunta com el producte de la probabilitat d'obtenir el resultat al llençar la moneda ($1/2$) per la probabilitat de obtenir un resultat del dau, es a dir ($1/6$). Així $P_X Y(x_i, y_i) = 1/2 \times 1/6 = 1/12$

En la següent taula es mostra la funció de quantia o probabilitat. Per qualsevol valor no recollit en la taula $f_X Y(x, y) = 0$

$Y \backslash X$	Cara (0)	Creu (1)	$f_Y(y)$
1	1/12	1/12	1/6
2	1/12	1/12	1/6
3	1/12	1/12	1/6
4	1/12	1/12	1/6
5	1/12	1/12	1/6
6	1/12	1/12	1/6
$f_X(x)$	1/2	1/2	

Nota: en els marges de la taula es poden veure les funcions de probabilitat marginals que seran definides en la propera secció.

Proposició 1.2. Algunes propietats de la funció de probabilitat

Sigui $f(x, y)$ una funció de probabilitat de la variable bivariada (X, Y) tal que $(X, Y)(\Omega) = \{(x_i, y_i) \mid i \in I \subset \mathbb{N} \mid i, j \in J \subset \mathbb{N}\}$

$$\sum_{(X, Y) \in \mathbb{R}^2} f(x, y) = \sum_{i \in I, j \in J} f(x_i, y_j) = 1$$

$$\forall B \in \mathcal{B}^2 \quad P(B) = \sum_{(X, Y) \in B} f(x, y) = \sum_{(i, j) \mid (x_i, y_j) \in B} f(x_i, y_j)$$

$$\forall (x_0, y_0) \in \mathcal{B}^2 \quad F(x, y) = \sum_{x \leq x_0, y \leq y_0} f(x, y) = \sum_{(i, j) \mid (x_i, y_j) \leq (x_0, y_0)} f(x_i, y_j)$$

1.2.3 Variables aleatòries multivariants continues

Definició 1.17. Funció de densitat conjunta de probabilitat d'una variable aleatòria multivariat absolutament continua

Sigui $\vec{X} = (X_1, X_2, \dots, X_{k-1}, X_k)$ un vector aleatori on X_i es una variable aleatòria continua. Diguem que $\mathbf{X}$ és continu si i només si existeix una funció $f_X : \mathbb{R}^k \rightarrow [0, +\infty[$ tal que

$$P(X \in (a, b]) = P(a_i < X_i < b_i, i = 1, \dots, k) = \int_{a_k}^{b_k} \dots \int_{a_1}^{b_1} f_X(x_1, \dots, x_k) dx_1, \dots, dx_k$$

Com passava en el cas unidimensional aquesta funció té algunes propietats que cal remarcar.

$f_X(x)$ es no negativa

donat que $P(X \in \mathbb{R}^k) = 1$, llavors $\int_{-\infty}^{+\infty} \dots \int_{-\infty}^{+\infty} f_X(x_1, \dots, x_k) dx_1, \dots, dx_k = 1$

Com a conseqüència de la definició hi ha una relació entre la funció de distribució conjunta de probabilitat F_X i la funció de densitat conjunta de probabilitat f_X .

$$F_X(x_1, \dots, x_K) = P_X(S_X) = \int_{-\infty}^{x_k} \dots \int_{-\infty}^{x_1} f_X(t_1, \dots, t_k) dt_1 \dots dt_k$$

y si $x \in \mathbb{R}^k$ es un punt de continuïtat de f_X ,

$$f(x_1, \dots, x_k) = \frac{\partial^k F_X(x_1, \dots, x_k)}{\partial x_1 \dots \partial x_k}$$

Exemple 1.14. En la figura 3 es pot observar la representació de la funció de densitat $f_{XY}(x, y)$ d'una variable aleatòria continua bivariada. La superfície de la gràfica es el valor de la funció y la probabilitat ve determinada pel volum. Aquest volum ve calculat pel que s'anomena integral doble que te algunes especificitats que mostrarem en el següent apartat.




Figura 3: Funció de densitat conjunta bivariada

1.2.3.1 Integral doble Aquest apartat es pot considerar com un apèndix del contingut del temari. Introduïrem els conceptes d'integral doble, o més general d'integral de Lebesgue i com s'interpreta i com es calcula, ja que és necessari per obtenir la probabilitat en el cas de vectors aleatoris continus.

Definició 1.18. Sigui una funció $f : \mathbb{R}^2 \rightarrow \mathbb{R}$ una funció no negativa i D un subconjunt de $\mathbb{R}^2$. El volum sota el gràfic de la superfície que genera funció f restringida a aquest conjunt D (veure Figura 4) es pot obtenir calculant

$$\int \int_D f(x,y) dx dy = \int \int_D f(x,y) dy dx$$

que s'anomena Integral doble de f sobre D . El càlcul de les integrals dobles es un càlcul interactiu on es fan dues integrals simples, una darrera de l'altra. En la primera s'integra per una de les dues variables mantenint com constants els valors de la segona variable i després es fa una segona integració per la segona integració mantenint com a constant la primera variable. L'ordre de les variables es intercanvia obtenint els mateixos resultats.




Figura 4: Double integral

Exemple 1.15. Calculem el volum que la funció $f(x,y)=x+y$ deixa sota el rectangle sobre el rectangle $[1,2] \times [3,4]$, es a dir $1 \leq x \leq 2$ i $3 \leq y \leq 4$.

$$V = \int_1^2 \int_3^4 (x+y) dy dx = \int_3^4 \int_1^2 (x+y) dx dy$$

Si integren primer en funció de y la integral interior és, tenint en compte que x es constant :

$$V = \int_1^2 \int_3^4 (x+y) dy dx$$

$$\int (x+y) dy = xy + \frac{y^2}{2}$$

que avaluat en $y=3$ i $y=4$ dona

$$(4x + \frac{16}{2}) - (3x + \frac{9}{2}) = 4x - 3x - 9/2 = x + 7/2$$

Ara integrem respecte a x

$$\int (x + \frac{7}{2}) dx = \frac{x^2}{2} + \frac{7}{2}x$$

que avaluat en $x=1$ i $x=2$ dona

$$V = \left(\frac{2^2}{2} + \frac{7}{2}2\right) - \left(\frac{1^2}{2} + \frac{7}{2}1\right) = (2 + 7) - \left(\frac{1}{2} + \frac{7}{2}\right) = 9 - 4 = 5$$

Si canviem l'ordre d'integració i integrem primer en funció de x i després en funció de y

$$V = \int_3^4 \int_1^2 (x+y) dx dy$$

$$\int (x+y) dy = \frac{x^2}{2} + xy$$

que avaluat en $x=1$ y i $x=2$ dona

$$\frac{2^2}{2} + 2y - \frac{1^2}{2} + y = 2 + 2y - \frac{1}{2} - y = \frac{3}{2} + y$$

Ara integrem respecte a y

$$\int \left(\frac{3}{2} + y\right) dy = \frac{y^2}{2} + \frac{3}{2}y$$

que avaluat en $y=3$ i $y=4$ dona

$$V = \left(\frac{4^2}{2} + \frac{3}{2}4\right) - \left(\frac{3^2}{2} + \frac{3}{2}3\right) = (8 + 4) - \left(\frac{9}{2} + \frac{9}{2}\right) = 14 - 9 = 5$$

En conclusió de les dues maneres el valor del volumen sota la funció es de 5.

$$V = \int_1^2 \int_3^4 (x+y) dy dx = \int_3^4 \int_1^2 (x+y) dx dy = 5$$

Exemple 1.16. Considerem un cas on el recinte d'integració no és un rectangle i utilitzem la funció de l'exemple 1.15 $f(x,y)=x+y$

Sigui el triangle $A = \{(x,y) \in \mathbb{R}^2 : 2 \leq x \leq 4, 2 \leq y \leq x\}$ que és mostra en la figura 5

La integral doble en el recinte de la funció es pot calcular de dues maneres començant primer per x o per y

$$\iint_A x+y \, dy dx = \int_2^4 \int_2^x x+y \, dy dx = \int_2^4 \left(\int_2^x x+y \, dy \right) dx$$

Cal observar que la integral interna té el límit superior en funció de x on juga un paper de constant. si resollem primer la integral interna en funció de y obtenim

$$\int_2^4 \left(\int_2^x x+y \, dy \right) dx = \int_2^4 \left[xy + \frac{y^2}{2} \right]_2^x dx = \int_2^4 \left[\left(xx + \frac{x^2}{2} \right) - \left(2x + \frac{2^2}{2} \right) \right] dx = \int_2^4 \left(\frac{3x^2}{2} - 2x - 2 \right) dx$$

Si ara resollem la segona integral em funció de x

$$\int_2^4 \left(\frac{3x^2}{2} - 2x - 2 \right) dx = \left[\frac{3}{2} \frac{x^3}{3} - x^2 - 2x \right]_2^4 = \left(\frac{4^3}{2} - 4^2 - 2(4) \right) - \left(\frac{2^3}{2} - 2^2 - 2(2) \right) = 8 - (-4) = 12$$

obtenim que el valor de la integral en el triangle es 12. En aquest cas hem fixat x i hem trobat el rang de variació de y dins del recinte d'integració A en funció de x com es pot veure en la figura 5 esquerra.

Si integrem primer en funció de x i després de y hem de fixar y i després trobar la variació de x en funció de y es a dir $A = \{(x,y) \in \mathbb{R}^2 : 2 \leq y \leq 4, y \leq x \leq 4\}$




Figura 5: Dues maneres d'obtenir la densitat conjunta d'un triangle

$$\int_2^4 \left(\int_y^4 x + y \, dx \right) dy = \int_2^4 \left[\left(\frac{x^2}{2} + xy \right) \right]_y^4 dy = \int_2^4 \left[\left(\frac{4^2}{2} + 4y \right) - \left(\frac{y^2}{2} + y(y) \right) \right] dy = \int_2^4 \left(8 + 4y - \frac{3y^2}{2} \right) dy$$

Si ara resollem en funció de y

$$\int_2^4 \left(8 + 4y - \frac{3y^2}{2} \right) dy = \left[8y + 4 \frac{y^2}{2} - \frac{3}{2} \frac{y^3}{3} \right]_2^4 = \left[8y + 2y^2 - \frac{y^3}{2} \right]_2^4 = 8(4) + 2(4)^2 - \frac{4^3}{2} - \left(8(2) + 2(2)^2 - \frac{2^3}{2} \right) = 32 - 20 = 12$$

Començant primer per fixar la y , hem de avaluar el rang de variació de x i obtenim el mateix resultat al efectuar l'integració (Figura 5 dreta). Per lo que done igual per on començar a l'hora de fer l'integral doble. S'obtenen els mateixos resultats.

En la Figura 6 es pot veure el que significa el càlcul de la probabilitat, Es pot generar una quadrícula amb costats $[x, x + dx] \times [y, y + dy]$ en l'àrea de suport. El volum del prisma sobre aquest rectangle es la seva àrea per l'alçada de la funció de densitat en el limit. .

Així

$$\int_x^{x+dx} \int_y^{y+dy} f(u, v) dx dy \approx f(x, y) dx dy$$

donat que per la continuïtat de la funció f , aquesta es pràcticament constant al llarg de la superfície.

Com a conseqüència a partir de la notació diferencial

$$\begin{aligned} P\{x \leq X \leq x + dx, x \leq y \leq y + dy\} &= P\{(X, Y) \in (x, x + dx] \times (y, y + dy]\} \\ &= \int_x^{x+dx} \int_y^{y+dy} f(u, v) dx dy \approx f(x, y) dx dy \end{aligned}$$

Aleshores, es pot deduir que la unitat de mesura de la densitat de probabilitat és la probabilitat per unitat d'àrea.

$$f(x, y) \approx \frac{P\{x \leq X \leq x + dx, x \leq y \leq y + dy\}}{dx dy}$$

Així, qualsevol punt o successió infinita de punts té probabilitat 0, perquè al tenir àrea zero no es pot obtenir damunt un volum positiu.

Per altra banda qualsevol corba unidimensional té probabilitat 0. En particular la probabilitat d'una recta $P\{Y = a + bX\} = 0$ o una cercle $P\{X^2 + Y^2 = r^2\} = 0$ es 0.

Exemple 1.17. Per a que la funció que hem calculat la integral doble en l'exemple 1.15 hem de garantir que la integral en tot $\mathbb{R}^2$ sigui 1.

Per això definim la funció de densitat en funció d'una constant que hem de calcular

$$f(x, y) = \begin{cases} k(x + y) & \text{si } x \in [1, 2], y \in [3, 4] \\ 0, & \text{en altre cas} \end{cases}$$




Figura 6: Double integral

Aquesta funció també es pot escriure com

$$f(x, y) = k(x + y)I_{[1,2] \times [3,4]}(x, y) = k(x + y)I_{[1,2]}(x)I_{[3,4]}(y)$$

On utilitzem la funció indicadora d'un conjunt que sigui

$$\forall A \subseteq \Omega \text{ per a } \omega \in \Omega, \quad I_A(\omega) = \begin{cases} 1 & \text{si } \omega \in A \\ 0, & \text{si } \omega \notin A \end{cases}$$

donat que la funció $f(x, y) \leq 0$ per a tot $(x, y) \in \mathbb{R}^2$ serà de densitat si i només si

$$1 = \int_{\mathbb{R}} \int_{\mathbb{R}} f(x, y) dy dx = \int_{\mathbb{R}} \int_{\mathbb{R}} k(x + y)I_{[1,2]}(x)I_{[3,4]}(y) dy dx = k \int_1^2 \int_3^4 (x + y) dy dx = k5$$

El valor de k és per tant 1/5 per a que f(x,y) sigui una funció de densitat.

En la figura 7 es mostra la funció de densitat que val $(x+y)/5$ per als punts (x,y) en el rectangle A definit i 0 en la resta.

1.3 Funcions de densitat i de distribució marginals i condicionades.

1.3.1 Distribucions marginals.

Les distribucions marginals són les distribucions unidimensionals que ens informa de la distribució dels valors d'una variable prescindint dels valors de les altres.

$$f(x, y) = (x + y)/5$$




Figura 7: Funció de densitat $f(x, y)$

Definició 1.19. Funció de distribució marginal

Si $X = (X_1, \dots, X_k)$ es un vector aleatori amb funció de distribució F_X la funció de distribució marginal es defineix com la funció de distribució de probabilitat de cadascuna de les components del vector aleatori.

Cal tenir en compte que per una component

$$\lim_{x_j \rightarrow +\infty} \bigcap_{j=1}^k \{X_j \leq x_j\} = \{X_i \leq x_i\}$$

$$\forall i = 1, \dots, k \quad F_{X_i}(x_i) = \lim_{x_j \rightarrow +\infty} F_X(x_1, \dots, x_k) = F_X(+\infty, \dots, +\infty, x_i, +\infty, \dots, +\infty) \quad \forall x_i \in \mathbb{R}$$

El concepte de marginalitat pot aplicar-se a qualsevol subvector del vector original. Així per al subvector $X^l = (X_{i_1}, \dots, X_{i_l})$ on $l \leq k$ podem parlar de la distribució conjunta marginal de X^l a la expressió on es fixen les components del subvector i es fan tendir a l'infinit a la resta

$$F_{X^l}(X_{i_1}, \dots, X_{i_l}) = \lim_{x_j \rightarrow +\infty} F_X(x_1, \dots, x_k)$$

Exemple 1.18. Generem un triangle T amb vèrtexs en les coordenades (0,0), (1,0) y (0,2), como es veu en la figura 8. Repartim la masa de probabilitat uniformment en el triangle donat que l'elegim a l'atzar un punt del triangle. Per a un àrea qualsevol la probabilitat de aquella àrea es

$$P((X, Y) \in A) = \frac{\|A \cap T\|}{\|T\|}$$

on $\|A\|$ és l'àrea de B.

Així, la funció de distribució conjunta donat que l'àrea del triangle és 1

$$F_{X,Y}(x, y) = P((x, y) \in S_{xy}) = \|S_{xy} \cap T\|$$

on $S_{xy} = (-\infty, x] \times (-\infty, y]$.

Así podem obtenir la funció conjunta simplement aplicant una mica de geometria segons l'ubicació del punt (x,y) en el pla y aplicant la definició de la funció de distribució conjunta con la intersecció amb el triangle y que l'equació de la hipotenusa es $2x+y=2$

$$F_{XY}(x, y) = \begin{cases} 0, & \text{si } x < 0 \quad y < 0 \\ xy, & \text{si } (x, y) \in T \text{ (tipo 1)} \\ xy - (x + y/2 - 1)^2, & \text{si } (x, y) \notin T \quad \& \quad 0 < x \leq 1, 0 < y \leq 2 \text{ (tipo 2)} \\ 2x - x^2, & \text{si } (x, y) \notin T \quad \& \quad 0 < x \leq 1, 2 < y \text{ (tipo 3)} \\ y - y^2/4, & \text{si } (x, y) \notin T \quad \& \quad 1 < x, 0 < y \leq 2 \text{ (tipo 4)} \\ 1, & \text{si } x \geq 1 \quad y \geq 2 \end{cases}$$

Cal observar que les expressions de $F_{XY}(x, y)$ depenen només de x i de y . Si recordem com calculem les marginals tenim que

$$F_X(x) = F_X(x, y)$$




Figura 8: Dues maneres d'obtenir la densitat conjunta d'un triangle

- Si $x \leq 0$ per qualsevol y $F_x(x, y) = 0$ i per tant el limit quan $\lim_{y \rightarrow +\infty}$ es 0 - Si $0 < x < 1$ al fer que $y \rightarrow +\infty$ el punt es situa en la zona tipo 3 y per tant la funció val $2x - x^2$
- Si $x \geq 1$ al fer que $y \rightarrow +\infty$ el punt es situa sobre el triangle y la probabilitat aculuada es 1

$$F_X(x) = \begin{cases} 0, & \text{si } x \leq 0 \\ 2x - x^2, & \text{si } 0 < x < 1 \\ 1, & \text{si } x \geq 1 \end{cases}$$

Analogament podem obtenir la funció de distribució de Y on la diferència es que entre 0 i 2 quan $x \rightarrow +\infty$ estarem en punts tipus 4 y la funció valdrà $y - \frac{y^2}{4}$

$$F_Y(y) = \begin{cases} 0, & \text{si } y \leq 0 \\ y - \frac{y^2}{4}, & \text{si } 0 < y < 2 \\ 1, & \text{si } y \geq 2 \end{cases}$$

1.3.1.1 Distribucions marginals. Cas discret Sigui D_{X_i} el suport numerable de la component X_i d'un vector aleatori X discret, es verifica que

$$\{X_i = x_i\} = \bigcup_{x_j \in D_j, j \neq i} \left(\bigcap_{j=1}^k \{X_j = x_j\} \right)$$

com que els elements son disjunts podem obtenir la funció de probabilitat marginal com

$$f_{X_i}(x_i) = \sum_{x_j \in D_j, j \neq i} f_X(x_1, \dots, x_k)$$

Exemple 1.19. Si revisem la taula del exemple 1.13, on en primer lloc es llança una moneda y després un dau. Observem que la darrera fila conté les probabilitats marginals d'observar cara o creu, obtenint un valor de $1/2$ per cada columna. La darrera columna conté les marginals d'obtenir un resultat de les cares del dau, és a dir $1/6$ per cada fila.

$Y \backslash X$	Cara (0)	Creu (1)	$f_Y(y)$
1	1/12	1/12	1/6
2	1/12	1/12	1/6
3	1/12	1/12	1/6
4	1/12	1/12	1/6
5	1/12	1/12	1/6
6	1/12	1/12	1/6
$f_X(x)$	1/2	1/2	

1.3.1.2 Distribucions marginals. Cas continu Si les dues variables X i Y son contínues, com hem vist abans, per definició la distribució marginal de cadascuna de elles la podem escriure com:

$$F_X(x) = \lim_{x \rightarrow +\infty} F_{XY}(x, y) = \int_{-\infty}^x \int_{-\infty}^{+\infty} f(s, y) dy ds$$

$$F_Y(y) = \lim_{y \rightarrow +\infty} F_{XY}(x, y) = \int_{-\infty}^y \int_{-\infty}^{+\infty} f(t, x) dx dt$$

Es pot demostrar que tant $F_X(x)$ com $F_Y(y)$ son funcions de distribució . En el següent exemple

Exemple 1.20. En la figura 9 es mostra una representació de la distribució marginal. El diagrama de dispersió representa les coordenades (x, y) de les observacions. Si es projecten en l'eix Y totes les dades sense tenir en compte la component X , s'obté la funció de distribució marginal de Y .




Figura 9: Funció de distribució marginal de Y mostral

1.3.2 Distribucions condicionals

Sigui (X, Y) un vector aleatori bidimensional definit sobre $(\Omega, \mathcal{A}, P)$ i $F_{XY}(x, y)$ la seva funció de distribució conjunta. Sabent que ha ocorregut l'esdeveniment $Y \in B$, ens interessa calcular la probabilitat condicionada que $X \in A$

$$P\{\omega \in \Omega \text{ tq } X(\omega) \in A \text{ sabiendo } y \in B\}$$

$$P\{X \in A/Y \in B\} = \frac{P\{X \in A \cap Y \in B\}}{P\{Y \in B\}} = \frac{P\{X \in A, Y \in B\}}{P\{Y \in B\}} \quad \text{si } P\{Y \in B\} > 0$$

Si $A =]-\infty, x]$ i $B =]-\infty, y]$ i $F_Y(Y) > 0$

$$P(X \leq x|Y \leq y) = \frac{P(X \leq x, Y \leq y)}{P(Y \leq y)} = \frac{F_{XY}(x, y)}{F_Y(y)} = \frac{F_{XY}(x, y)}{\lim_{u \rightarrow +\infty} F_{XY}(u, y)}$$

1.3.2.1 Distribucions condicionals. Cas discret Considerem un vector aleatori bidimensional (X, Y) , amb suports discrets per cadascuna de les seves components $D_x = (x_1, \dots, k)$ i $D_y = (y_1, \dots, y_h)$ i una funció de probabilitat conjunta $f_{XY}(x, y)$

Definició 1.20. Funció de probabilitat condicionada

Es defineix la funció de probabilitat condicionada de X donat $(Y = y_j), y \in D_y$, on $P(Y = y_j) > 0$ com

$$f_{X|Y}(x_i|y_j) = f_{X|Y}(x_i|y_j) = P(X = x_i|Y = y_j) = \frac{P(X = x_i, Y = y_j)}{P(Y = y_j)} = \frac{f_{XY}(x_i, y_j)}{f_Y(y_j)}$$

Definició 1.21. Funció de distribució condicionada

A partir de la definició anterior, podem definir la funció de distribució condicionada de X donat que $(Y = y_j), y \in D_y$ com:

$$F_{X|Y} = P(X \leq x|Y = y_j) = \frac{\sum_{x_i \leq x} f_{XY}(x_i, y_j)}{f_Y(y_j)} = \sum_{x_i \leq x} f_{X|Y}(x_i|y_j)$$

$f_{X|Y}(x|y)$ es efectivament una funció de probabilitat per què compleix les dues propietats

- Es una funció no negativa la tractar-se d'una funció no neegativa
- y la suma sobre la funció de suport D_Y es l'a unitat

$$\sum_{x_i \in D_X} f_{X|Y}(x_i|y_j) = \frac{\sum_{x_i \in D_X} f_{XY}(x_i, y_j)}{f_Y(y_j)} = \frac{f_Y(y_j)}{f_Y(y_j)} = 1$$

Exemple 1.21. Tornem a l'exemple de la moneda i el dau i la taula de probabilitats que es mostra en l'exemple 1.19 on Y es el valor del dau y X es el resultat de la moneda.

Calculem la probabilitat de treure una cara donat que el dau ha resultat el valor 4.

Seguint la definci

$$P(x = cara|Y = 4) = \frac{P(X = cara, Y = 4)}{P(Y = 4)} = \frac{1/12}{1/6} = 1/2$$

En aquest cas la funció de probabilitat condicionada coincideix en la distribució marginal.

Si ho fessim a l'inrevés es a dir la probabilitat d'obtenir un valor del dau si ha sortit cara o ha sortit creu arribaríem a que $P(Y = y|x = cara) = 1/6$ que també coincideix amb la marginal.

Això serà rellevant més endavant quan parlem del concepte d'independència

1.3.2.2 Distributions conditionals. Cas continu

Definició 1.22. Funció de densitat condicional

Siguin X e Y dues variables aleatòries contínues on f_{XY} es la funció de densitat conjunta, i f_X i f_Y son les funcions de densitat marginal. Definim la densitat condicional de X donat que $Y = y$ a la funció

$$f_{X|Y=y}(x) = \frac{f_{XY}(x, y)}{f_Y(y)}, \text{ per a } -\infty \leq x \leq +\infty$$

- Cal notar que $f_{X|Y=y}$ no més està definida per valors de y on $f_Y(y) > 0$

- Sembla per la definició que estem condicionat per la probabilitat de que $Y = y$, però al tractar-se d'una variable continua aquesta probabilitat es 0. La funció de densitat condicional és el límit d'una probabilitat condicional a mesura que el radi de la regió circular de (x, y) tendeix a 0.

Anàlogament es pot definir la funció de densitat condicional de Y donat que $X = x$ a la funció

$$f_{Y|X=x}(y) = \frac{f_{XY}(x, y)}{f_X(x)}, \text{ per a } -\infty \leq y \leq +\infty$$

La funció $f_{X|Y=y}$ es una densitat ja que per definició es positiva i si la integrem dona 1.

$$\int_{-\infty}^{+\infty} f_{X|Y=y}(x) dx = \int_{-\infty}^{+\infty} \frac{f_{XY}(x, y)}{f_Y(y)} dx = \frac{1}{f_Y(y)} \int_{-\infty}^{+\infty} f_{XY}(x, y) \frac{1}{f_Y(y)} f_Y(y) = 1$$

Exemple 1.22. En la figura 10 es mostra una representació de la distribució condicionada de Y en funció de X . El diagrama de dispersió representa les coordenades (x, y) de les observacions. Si es projecten en l'eix Y els valors de la variable de Y per a les coordenades x incloses en l'interval $[a, a + \epsilon]$ e, S'obté la funció de distribució condicionada $Y|X = a$.

Exemple 1.23. Sigui la següent funció de densitat conjunta provinent de treure a l'atzar un punt sota una paràbola.

$$f_{XY}(x, y) = \begin{cases} 4xy^3, & \text{si } y \in (0, 1), xy \in (0, 1) \Leftrightarrow 0 < y < 1, 0 < x < \frac{1}{y} \\ 0, & \text{en la resta} \end{cases}$$

El la gràfica 11 es pot veure la representació de la funció de densitat conjunta.

Si calculem la funció de densitat marginal de Y obtenim una funció que es diferent de 0 si $y \in (0, 1)$

$$f_Y(y) = \int_{-\infty}^{+\infty} f_{XY}(x, y) dx = \begin{cases} 4y^3 \int_0^{1/y} x dx = y^3 \left[\frac{x^2}{2} \right]_0^{1/y} = 2y, & \text{si } y \in (0, 1) \\ 0, & \text{en la resta} \end{cases}$$

De la mateixa manera podem obtenir la funció de densitat marginal de X com




Figura 10: Funció de distribució condicionada de Y en funció de X mostrat

Representació tridimensional




Figura 11: Exemple de distribució conjunta

$$f_X(x) = \int_{-\infty}^{+\infty} f_{XY}(x, y) dy = \begin{cases} 4x \int_0^1 y^3 dy = 4x \left[\frac{y^4}{4} \right]_0^1 = x, & \text{si } x \in (0, 1) \\ 4x \int_0^{1/x} y^3 dy = 4x \left[\frac{y^4}{4} \right]_0^{1/x} = \frac{1}{x^3}, & \text{si } x > 1 \\ 0, & \text{en la resta} \end{cases}$$

Per obtenir la funció de densitat condicionada $f_{X|Y}$ només caldrà dividir la funció de densitat conjunta f_{XY} respecta a la marginal f_Y

$$f_{X|Y}(x) = \frac{f_{X,Y}(x, y)}{f_Y(y)} = \begin{cases} \frac{4xy^3}{2y} = 2xy^2, & \text{si } y \in (0, 1) \quad y \quad xy \in (0, 1) \\ 0, & \text{en la resta} \end{cases}$$

El la gràfica 12 es pot veure la representació de la funció de densitat condicional $X|Y$ per a cada valor de y .




Figura 12: Exemple de distribució condicionada $X|Y$

De forma anàloga es pot obtenir la funció de densitat condicionada $f_{Y|X}$ dividint la funció de densitat conjunta f_{XY} respecta a la marginal f_X

$$f_{Y|X}(y) = \frac{f_{X,Y}(x, y)}{f_X(x)} = \begin{cases} \frac{4xy^3}{x} = 4y^3, & \text{si } y \in (0, 1) \quad y \quad xy \in (0, 1) \\ \frac{4xy^3}{1/x^3} = 4x^4 y^3, & \text{si } y \in (0, 1) \quad y \quad xy \in (0, 1) \quad y \quad x > 1 \\ 0, & \text{en la resta} \end{cases}$$

1.4 Moments multivariants: vector d'esperances, matriu de variància-covariància

1.4.1 Moments univariants: Esperança i Variància

En el cas univariant podem parlar de certes característiques numèriques o constants lligades a les variables que ens permet caracteritzar-les. Son els moments, dels quals l'esperança i la variància son casos particulars.

Esperança d'una variable aleatòria discreta

Sigui X una variable aleatòria discreta on f_X es la seva funció de probabilitat i D_x el seu suport numerable. Si g es una funció mesurable definida de $(\mathbb{R}, \beta)$ en $(\mathbb{R}, \beta)$, tal que $\sum_{x_i \in D_x} |g(x_i)f_X(x_i)| < +\infty$ definim l'esperança de $g(X)$ a

$$E[g(X)] = \sum_{x_i \in D_x} g(x_i)f_X(x_i)$$

En particular, si $g(X) = X$

$$E[X] = \sum_{x_i \in D_x} x_i f_X(x_i)$$

que seria la mitjana poblacional de la distribució de la variable X

Esperança d'una variable aleatòria continua

Sigui X una variable aleatòria continua on f_X es la seva funció de densitat. Si g es una funció mesurable definida de $(\mathbb{R}, \beta)$ en $(\mathbb{R}, \beta)$, tal que $\int_{\mathbb{R}} |g(x)f_X(x)dx| < +\infty$ definim l'esperança de $g(X)$ a

$$E[g(X)] = \int_{-\infty}^{+\infty} g(x)f_X(x)dx$$

En particular, si $g(X) = X$

$$E[X] = \int_{-\infty}^{+\infty} x f_X(x)dx$$

que seria la mitjana poblacional de la distribució de la variable X

Formes particulars de $g(X)$ donen lloc a diferents moments de X en la següent taula es mostren els més utilitzats

	d'ordre k	absolut d'ordre k
Respecte del origen	X^k	$ X ^k$
Respecte de a	$(X - a)^k$	$ X - a ^k$
Factorials	$X(X - 1) \cdots (X - k + 1)$	$ X(X - 1) \cdots (X - k + 1) $

Així el moment d'ordre 1 es la $E[X] = \mu$ mitjana de la distribució i el moment central d'ordre 2 es la variància $Var[X] = \sigma_X^2 = E[(X - \mu)^2] = E[X^2] - (E[X])^2$.

1.4.2 Moments multivariants: Esperança i Variància

Esperança d'un vector aleatori discret

Sigui $X = (X_1, \dots, X_k)$ un vector aleatori discret, D_X el suport del vector i f_X es la seva funció de probabilitat conjunta. Si g es una funció mesurable definida de $\mathbb{R}^k$ en $\mathbb{R}$

$$E[g(X)] = \sum_{(x_1, \dots, x_k) \in D_x} g(x_1, \dots, x_k)f_X(x_1, \dots, x_k)$$

Esperança d'un vector aleatori continu

Sigui $X = (X_1, \dots, X_k)$ un vector aleatori continu f_X es la seva funció de densitat conjunta. Si g es una funció mesurable definida de $\mathbb{R}^k$ en $\mathbb{R}$

$$E[g(X)] = \int_{-\infty}^{+\infty} \dots \int_{-\infty}^{+\infty} g(x_1, \dots, x_k)f_X(x_1, \dots, x_k)dx_1, \dots, dx_k$$

En ambdós casos l'esperança està supeditada a que $|g(x)f(x)|$ sigui absolutament sumable o integrable.

Exemple 1.24. Una barra d'un metre es trenca aleatòriament en dos punts, generant tres peces. Quina és la llargada mitjana de la peça del mig?

Per estudiar el problema considerem dues variables aleatòries que segueixen una distribució uniforme $(U_1, U_2) \sim U([0, 1] \times [0, 1])$

Es a dir, la distribució conjunta ve definida per la densitat constant

$$f_{U_1, U_2}(u_1, u_2) = \begin{cases} 1, & \text{si } (u_1, u_2) \in [0, 1] \times [0, 1] \\ 0, & \text{en la resta} \end{cases}$$

La longitud de la peça central ve donada per la variable aleatòria $X = g(U_1, U_2) = |U_2 - U_1|$

LLavors seguint la definició d'esperança de la variable X obtenim el valor de la longitud de la peça central

$$\begin{aligned} E[|U_1 - U_2|] &= \int_{-\infty}^{+\infty} \dots \int_{-\infty}^{+\infty} g(u_1, u_2) f(u_1, u_2) du_1 du_2 = \int_0^1 \int_0^1 |u_1 - u_2| du_1 du_2 \\ &= \int_0^1 \int_0^1 1_{(u_1 \geq u_2)} (u_1 - u_2) du_1 du_2 + \int_0^1 \int_0^1 1_{(u_1 \leq u_2)} (u_2 - u_1) du_1 du_2 \\ &= \int_0^1 \int_0^{u_1} (u_1 - u_2) du_2 du_1 + \int_0^1 \int_{u_1}^1 (u_2 - u_1) du_2 du_1 \\ &= \int_0^1 \left[u_1 u_2 - \frac{u_2^2}{2} \right]_0^{u_1} du_1 + \int_0^1 \left[\frac{u_2^2}{2} - u_1 u_2 \right]_{u_1}^1 du_1 = \int_0^1 (u_1^2 - \frac{u_1^2}{2}) du_1 + \int_0^1 (\frac{1}{2} - u_1^2) du_1 \\ &= \int_0^1 (\frac{u_1^2}{2}) du_1 + \int_0^1 (\frac{1}{2} - u_1^2) du_1 = \left[\frac{u_1^3}{6} \right]_0^1 + \left[\frac{u_1}{2} - \frac{u_1^3}{3} \right]_0^1 = \frac{1}{6} + \frac{1}{2} - \frac{1}{3} = \frac{1}{3} \end{aligned}$$

que és un terç de la longitud de la barra.

Moments d'un vector aleatori En el cas de les variables aleatòries univariantes hem vist com determinades formes de la funció g donen lloc als anomenats moments que podem estendre al cas dels vectors aleatoris.

El moment d'ordre $(n_1, \dots, n_k)$ s'obté sempre que existix l'esperança

$$g(X_1, \dots, X_k) = X_1^{n_1} \dots X_k^{n_k}, n_i \geq 0$$

que dona lloc a $E[X_1^{n_1} \dots X_k^{n_k}]$ respecte a l'origen de cada component.

Un cas particular si $n_i = m$ i $n_j = 0, j \neq i$ dona que $E[X_1^{n_1} \dots X_k^{n_k}] = E[X_i^m]$

El moment conjunt central d'ordre k respecte de l'origen de cada component es un cas particular, que es pot obtenir sempre que l'esperança existisca

$$g(X_1, \dots, X_k) = (X_1 - E[X_1])^{n_1} \dots (X_k - E[X_k])^{n_k}, n_i \geq 0$$

La linealitat de l'esperança aplicada quan $g(X) = X_1 + \dots + X_k$ permet concloure que l'esperança de la suma de variables es la suma de les esperances.

$$E(X_1 + \dots + X_k) = \sum_{i=1}^k E(X_i)$$

Així mateix si $g(X) = \sum_{i=1}^k (a_i X_i)$ obtenim que l'esperança de una constant per una variable es la constant per l'esperança de la variable

$$E(a_1 X_1 + \dots + a_k X_k) = \sum_{i=1}^k a_i E(X_i)$$

1.4.3 Matriu de Variància-Covariància

Covariància

Un moment d'especial interès és el moment conjunt central que s'obté per a les variables X_i i X_j $n_i = 1, n_j = 1$ i $n_l = 0, l \neq (i, j)$ que anomenarem covariància

$$\text{cov}(X_i, X_j) = E[(X_i - E[X_i])(X_j - E[X_j])] = E[(X_i X_j)] - E[X_i]E[X_j]$$

Siguin X i Y variables aleatòries tals que $\sigma_X^2 < \infty$ i $\sigma_Y^2 < \infty$ llavors

$$\text{Cov}(X, Y) = E[(XY)] - E[X]E[Y]$$

Demostració

$$\begin{aligned} \text{Cov}(X, Y) &= E[(X - E[X])(Y - E[Y])] \\ &= E[(X - E[X])Y - (X - E[X])E[Y]] \\ &= E[(X - E[X])Y] - E[(X - E[X])E[Y]] \\ &= E[XY] - E[E[X]Y] - E[XE[Y]] + E[X]E[Y] \\ &= E[XY] - E[X]E[Y] - E[X]E[Y] + E[X]E[Y] \\ &= E[XY] - E[X]E[Y] \end{aligned}$$

Siguin (X, Y, Z) variables aleatòries amb variància finita i $a \in \mathbb{R}$.

1. La covariància és un operador simètric: $\text{Cov}(X, Y) = \text{Cov}(Y, X)$
2. La variància és un cas particular de covariància: $\text{Var}(X) = \text{Cov}(X, X)$
3. La covariància amb una constant és 0: $\text{Cov}(X, a) = 0$
4. La covariància és un operador bilineal, és a dir, és lineal en els seus dos arguments:

$$\text{Cov}(aX, Y) = \text{Cov}(X, aY) = a\text{Cov}(X, Y)$$

$$\text{Cov}(X + Y, Z) = \text{Cov}(X, Z) + \text{Cov}(Y, Z)$$

$$\text{Cov}(X, Y + Z) = \text{Cov}(X, Y) + \text{Cov}(X, Z)$$

$$5. \text{Var}(X + Y) = \text{Var}(X) + \text{Var}(Y) + 2\text{Cov}(X, Y)$$

$$6. \text{Var}(X - Y) = \text{Var}(X) + \text{Var}(Y) - 2\text{Cov}(X, Y)$$

Demostració:

$$\text{Cov}(aX, Y) = E[aXY] - E[aX]E[Y] = aE[XY] - aE[X]E[Y] = a(E[XY] - E[X]E[Y]) = a\text{Cov}(X, Y).$$

$$\begin{aligned}
Cov(X + Y, Z) &= E[(X + Y)Z] - E[X + Y]E[Z] \\
&= E[XZ] + E[YZ] - (E[X] + E[Y])E[Z] \\
&= E[XZ] + E[YZ] - E[X]E[Z] - E[Y]E[Z] \\
&= E[XZ] - E[X]E[Z] + E[YZ] - E[Y]E[Z] \\
&= Cov(X, Z) + Cov(Y, Z)
\end{aligned}$$

La demostració dels dos últims apartats es dedueix directament de la anterior escrivint $Var(X+Y)=Cov(X+Y,X+Y)$ i $Var(X-Y)=Cov(X-Y,X-Y)$

Un problema de la covariància com a mesura de força de la relació linial de dues variables aleatòries, és que la covariància depèn de les unitats en que es mesuren les variables. Si canviem les unitats canvia el valor de la covariància.

Matriu de Variància-Covariància

Si (X_1, X_2) es un vector de 2 variables aleatòries definim la matriu de convariances Σ a la matriu 2x2 amb les variàncies a la diagonal i les covariàncies del vector en les altres posicions

$$\Sigma = \begin{bmatrix} Var(X_1) & Cov(X_1, X_2) \\ Cov(X_1, X_2) & Var(X_2) \end{bmatrix} = \begin{bmatrix} \sigma_1^2 & \sigma_{12} \\ \sigma_{12} & \sigma_2^2 \end{bmatrix}$$

En general. Si $X = (X_1, \dots, X_k)$ és un vector aleatori de dimensió k la matriu de variancies-covariancies és

$$\Sigma = \begin{bmatrix} Var(X_1) & Cov(X_1, X_2) & \dots & Cov(X_1, X_{k-1}) & Cov(X_1, X_k) \\ Cov(X_1, X_2) & Var(X_2) & \dots & Cov(X_2, X_{k-1}) & Cov(X_2, X_k) \\ \vdots & \vdots & \ddots & \vdots & \vdots \\ Cov(X_1, X_{k-1}) & Cov(X_2, X_{k-1}) & \dots & Var(X_{k-1}) & Cov(X_{k-1}, X_k) \\ Cov(X_1, X_k) & Cov(X_2, X_k) & \dots & Cov(X_{k-1}, X_k) & Var(X_k) \end{bmatrix}$$

Podem simplificar l'expressió de la matriu utilitzant els valors σ_{ij} per $Cov(X_i, X_j)$ i σ_i^2 per $Var(X_i)$

$$\Sigma = \begin{bmatrix} \sigma_1^2 & \sigma_{12} & \dots & \sigma_{1(k-1)} & \sigma_{1k} \\ \sigma_{12} & \sigma_2^2 & \dots & \sigma_{2(k-1)} & \sigma_{2k} \\ \vdots & \vdots & \ddots & \vdots & \vdots \\ \sigma_{1(k-1)} & \sigma_{2(k-1)} & \dots & \sigma_{k-1}^2 & \sigma_{(k-1)k} \\ \sigma_{1k} & \sigma_{2k} & \dots & \sigma_{(k-1)k} & \sigma_k^2 \end{bmatrix}$$

1.5 Transformacions de variables multivariants

Theorem 1.1. *Si $X = (X_1, \dots, X_k)$ un vector aleatori continu amb suport D_X , és a dir $P((X_1, \dots, X_k) \in D_X) = 1$, i sigui $g = (g_1, \dots, g_k) : \mathbb{R}^k \rightarrow \mathbb{R}^k$ una funció vectorial que verifica:*

1. *g es uno a uno sobre D_X*
2. *el Jacobiano de g , $J = \frac{\partial(g_1, \dots, g_k)}{\partial(x_1, \dots, x_k)}$ es diferente de cero $\forall x \in D_X$*
3. *existeix $h = (h_1, \dots, h_k)$ inversa de g*

Llavors, $Y = g(X)$ es un vector aleatori continu amb densitat conjunta per a $y = (y_1, \dots, y_k) \in g(D_X)$ ve donada per

$$f_Y(y_1, \dots, y_k) = f_X(h_1(y_1, \dots, y_k), \dots, h_k(y_1, \dots, y_k)) |J^{-1}|$$

on $|J^{-1}| = \frac{\partial(h_1, \dots, h_k)}{\partial(y_1, \dots, y_k)}$ és el Jacobià de h .

La demostració d'aquest teorema no es més que el teorema del canvi de variable en una integral múltiple y la seva demostració rigorosa, pot trobar-se en qualsevol llibre d'Anàlisi Matemàtica.

Exemple 1.25. Sigui l'experiment aleatori triar un punt a l'atzar del cercle unitat C_1 , on podem definir sobre l'espai de probabilitat un vector aleatori de les coordenades del punt (X,Y) . L'elecció a l'atzar implica una probabilitat uniforme sobre C_1 . La densitat conjunta la podem expressar com

$$f_{XY}(x,y) = \begin{cases} \frac{1}{\pi}, & \text{si } (x,y) \in C_1 \\ 0, & \text{en la resta} \end{cases}$$

Considerem un canvi entre les coordenades cartesianes a les coordenades polars del punt del cercle.

En aquest cas la transformació a coordenades polars serà $R = \sqrt{X^2 + Y^2}$ i $\Theta = \arctan(Y/X)$.

Per obtenir la seva densitat conjunta necessitem les transformacions inverses de coordenades polars a euclídeas, $X = R\cos(\Theta)$ i $Y = R\sin(\Theta)$. Si es calcula el jacobià aquest val $J_1 = R$

Per tant segons el teorema 1.1 la densitat conjunta es

$$f_{R\Theta}(r,\theta) = \begin{cases} \frac{r}{\pi}, & \text{si } (r,\theta) \in [0,1] \times [0,2\pi] \\ 0, & \text{en la resta} \end{cases}$$

Amb facilitat es poden obtenir les marginals corresponents

$$f_R(r) = \begin{cases} 2r, & \text{si } r \in [0,1] \\ 0, & \text{en la resta} \end{cases}$$

$$f_\Theta(\theta) = \begin{cases} \frac{1}{2\pi}, & \text{si } \theta \in [0,2\pi] \\ 0, & \text{en la resta} \end{cases}$$

1.5.1 Suma de dues variables aleatòries

Sigui la variable aleatòria $Z = X + Y$ on (X,Y) es la distribució conjunta de les dues components aleatòria on es vol determinar la distribució de probabilitat de Z

Cas (X,Y) variable aleatòria bivariant discreta

Sigui $p(x_i, y_j)$ la funció de probabilitat conjunta de (X, Y)

$$p(x_i, y_j) = P(X = x_i, Y = y_j), \quad i = 1, 2, \dots \quad j = 1, 2, \dots$$

La variable aleatòria suma, $Z = X + Y$ és una variable aleatòria univariant discreta, ja que com a molt pot pendre els valors produïts per les combinacions dels valors de X e Y , es a dir

$$x_i + y_j, \quad i = 1, 2, \dots \quad j = 1, 2, \dots$$

Alguns dels valor poden estar repetits. Sigui z_ℓ algun dels valors possibles de $Z = X + Y$. La funció de probabilitat de Z és:

$$\begin{aligned}
\Pr(Z = z_\ell) &= \Pr(X + Y = z_\ell) \\
&= \sum_{i,j: x_i + y_j = z_\ell} \Pr(X = x_i, Y = y_j) \\
&= \sum_i \Pr(X = x_i, Y = z_\ell - x_i) \\
&= \sum_j \Pr(X = z_\ell - y_j, Y = y_j).
\end{aligned}$$

Cas (X,Y) variable aleatòria bivariant continua

Segui $f_{XY}(x, y)$ la funció de densitat conjunta de les variables aleatòries quantitatives (X, Y) , Definim $Z = X + Y$ funció de la que volem conèixer la seva densitat. Per poder utilitzar el teorema 1.1 és necessita una transformació bidimensional, el que podem obtenir utilitzant una nova variable $V = X$.

Així al vector (Z, V) li podem aplicar directament el teorema , amb les inverses $X = V$ i $Y = Z - V$ on el jacobià es :

$$J^{-1} = \det \begin{bmatrix} \frac{\partial v}{\partial z} & \frac{\partial v}{\partial (z-v)} \\ \frac{\partial (z-v)}{\partial z} & \frac{\partial (z-v)}{\partial (z-v)} \end{bmatrix} = \det \begin{bmatrix} 0 & 1 \\ 1 & -1 \end{bmatrix} = -1$$

Tindrem que $|J^{-1}| = 1$ i l'expressió de la distribució conjunta es.

$$f_{Z,V}(z, v) = f_{X,Y}(v, z - v)$$

y per obtenir la densitat marginal de la suma Z tenim

$$f_Z(z) = \int_{-\infty}^{+\infty} f_{X,Y}(v, z - v) dv = \int_{-\infty}^{+\infty} f_{X,Y}(x, z - x) dx$$

Exemple 1.26. Sigui X i Y dues variables aleatòries amb distribució uniforme al interval (0,1) i amb densitat conjunta

$$f_{X,Y}(x, y) = \begin{cases} 1, & \text{si } 0 < x < 1, 0 < y < 1, \\ 0, & \text{en la resta} \end{cases}$$

Si $Z=X+Y$ i utilitzant la transformació $V=X$ la funció de distribució conjunta serà

La densitat marginal de la suma Z segons hem vist és

$$f_Z(z) = \int_{-\infty}^{+\infty} f_{X,Y}(x, z - x) dx = \int_{\max(0, z-1)}^{\min(1, z)} 1 dx$$

donat que de e les condicions inicials, la funció està definida si $0 < x < 1$ i $0 < z - v < 1$. Es a dir $z - 1 < v < z$ i per tant $\max(0, z - 1) < v < \min(1, z)$

Així és distingeixen dos casos.

Si $0 < z < 1$

$$f_Z(z) = \int_0^z 1 dx = z$$

Si $1 \leq z < 2$

$$f_Z(z) = \int_{z-1}^1 1dx = 2 - z$$

Finalment

$$f_Z(z) = \begin{cases} z, & \text{si } 0 < z < 1, \\ 2 - z, & \text{si } 1 \leq z < 2, \\ 0, & \text{en la resta.} \end{cases}$$

Que es la coneguda distribució triangular resultat de sumar dues variables independents* $U(0,1)$

* Nota: El concepte de independència es veura en el tema següent

1.5.2 Producte de dues variables aleatòries

En el cas del producte $W=XY$ i com abans definint $V=X$ tenim que podem calcular la distribució conjunta (W,V) aplicant el teorema 1.1 partir de les funcions inverses $X=V$ i $Y=W/V$ i el Jacobià

$$J^{-1} = \det \begin{bmatrix} \frac{\partial v}{\partial(w/v)} & \frac{\partial v}{\partial(w/v)} \\ \frac{\partial w}{\partial(w/v)} & \frac{\partial v}{\partial(w/v)} \end{bmatrix} = \det \begin{bmatrix} 0 & 1 \\ \frac{1}{v} & -\frac{w}{v^2} \end{bmatrix} = -\frac{1}{v}$$

I per tant $|J^{-1}| = \frac{1}{|v|}$

La distribució conjunta de (W,V) és

$$f_{WV}(w, v) = \frac{1}{|v|} f_{XY}\left(\frac{w}{v}, v\right)$$

I la distribució marginal del producte s'obté integrant respecte a l'altra component

$$f_W(w) = \int_{-\infty}^{+\infty} \frac{1}{|v|} f_{XY}\left(v, \frac{w}{v}\right) dv$$

Exemple 1.27. Siguin les dues variables uniformes del exemple 1.26

Volem obtenir la densitat del producte $W = XY$ que seguint l'apartat anterior es pot obtenir com

$$f_W(w) = \int_{-\infty}^{+\infty} \frac{1}{|x|} f_{XY}\left(x, \frac{w}{x}\right) dx$$

Com que la densitat conjunta només és diferent de zero quan

$$0 < x < 1, \quad 0 < \frac{w}{x} < 1,$$

ha de complir-se

$$w < x < 1.$$

Així, si $0 < w < 1$,

$$f_W(w) = \int_w^1 \frac{1}{x} dx.$$

Finalment,

$$f_W(w) = [\ln(v)]_w^1 = \ln(1) - \ln(w) = -\ln(w).$$

Per tant, la densitat del producte és

$$f_W(w) = \begin{cases} -\ln(w), & \text{si } 0 < w < 1, \\ 0, & \text{en la resta} \end{cases}$$

1.5.3 Producte de dues variables aleatòries

En el cas del quocient $Q = XY$ i com abans definint $V=X$ tenim que podem calcular la distribució conjunta (Q,V) aplicant el teorema 1.1 partir de les funcions inverses $X=V$ i $Y=QV$ i el Jacobià

$$J^{-1} = \det \begin{bmatrix} \frac{\partial v}{\partial q} & \frac{\partial v}{\partial (qv)} \\ \frac{\partial (qv)}{\partial q} & \frac{\partial (qv)}{\partial v} \end{bmatrix} = \det \begin{bmatrix} 0 & 1 \\ v & q \end{bmatrix} = v$$

I per tant $|J^{-1}| = |v|$

La distribució conjunta de (W,V) és

$$f_{QV}(q, v) = |v| f_{XY}(v, qv)$$

I la distribució marginal del producte s'obté integrant respecte a l'altra component

$$f_W(w) = \int_{-\infty}^{+\infty} \frac{1}{|v|} f_{XY}\left(\frac{w}{v}, v\right) dv$$

2 Independència de variables aleatòries

La independència entre dos esdeveniments A i B , suposa que cap d'ells aporta informació d'interès alhora de calcular la probabilitat d'ells. Es a dir $P(A) = P(A/B)$ i per tant $P(B) = P(B/A)$. En aquest tema volrem traslladar el compte d'independència i algunes mesures relacionades als vectors aleatòris.

2.1 Independència i dependència entre variables aleatòries.

Definició 2.1. Variables aleatòries independents

Es diu que dos variables aleatòries X i Y son independents si, per a qualsevol conjunts A i B tal que $X \in A$ i $Y \in B$ es té que:

$$P(X \in A \cap Y \in B) = P(X \in A)P(Y \in B)$$

Com a conseqüència $P(X \leq x \text{ and } Y \leq y) = P(X \leq x)P(Y \leq y)$

En general es diu que les variables $X_i, i = 1, \dots, k$ son independents si les σ -lgebras que les indueixen s ho son

Aquesta definició implica que al pendre $A_i \in \sigma(X_i), i = 1, \dots, k$

$$P(A_{j_1} \cap \dots \cap A_{j_n}) = \prod_{l=1}^n P(A_{j_l}) \quad \forall (j_1, \dots, j_n) \in (1, \dots, k)$$

Tenint en compte com han estat induïdes les $\sigma(X_i)$ admet una expressió alternativa en funció de les diferents variables

$$P(A_{j_1} \cap \dots \cap A_{j_n}) = P(X_{j_l} \in B_{j_l}, l = 1, \dots, n) = \prod_{l=1}^n P(X_{j_l} \in B_{j_l}) \quad \forall (j_1, \dots, j_n) \in (1, \dots, k)$$

on $A_{j_1} = X^{-1}B_{j_1}$

Comprobar l'independència de variables aleatòries a partir de la equació (2.1) es complicat i es més fàcil caracteritzar l'independència a partir de les funcions de distribució i densitat conjunes i marginals.

Theorem 2.1. Teorema de factorització

Sigui $X = (X_1, \dots, X_k)$ un vector aleatori amb funció de distribució conjunta $F_X(x_1, \dots, x_k)$ i funció de densitat o probabilitat $f_X(x_1, \dots, x_k)$. Si $F_j(x_j) = f_j(x_j), j = 1, \dots, k$ con les funcions de distribució marginals i les funcions de densitat o probabilitat marginals de cada component del vector aleatori direm que les variables $X_1, \dots, X_k$ son independents si i només si es verifiquen les següents condicions equivalents:

1. $F_X(x_1, \dots, x_k) = \prod_{l=1}^k F_j(x_j), \quad \forall (x_1, \dots, x_k) \in \mathbb{R}^k$
2. $f_X(x_1, \dots, x_k) = \prod_{l=1}^k f_j(x_j), \quad \forall (x_1, \dots, x_k) \in \mathbb{R}^k$

Demostració

Suposem que les variables aleatòries contínues $(X_1, \dots, X_k)$ són independents. Per definició,

$$\prod_{j=1}^k \Pr(X_j \in A_j), \quad \forall, A_1, \dots, A_k \in \mathcal{B}(\mathbb{R}).$$

1.- Siguin els conjunts $A_j = (-\infty, x_j] \quad j = 1, \dots, k$

Aleshores,

$$\begin{aligned}
F_X(x_1, \dots, x_k) &= P(X_1 \leq x_1, \dots, X_k \leq x_k) \\
&= P(X_1 \in (-\infty, x_1], \dots, X_k \in (-\infty, x_k]) \\
&= \prod_{j=1}^k P(X_j \in (-\infty, x_j]) = \prod_{j=1}^k P(X_j \leq x_j) \\
&= \prod_{j=1}^k F_j(x_j)
\end{aligned}$$

2- A partir del càlcul de la densitat conjunta i tenim en compte que cada factor $F_j(x_j)$ només depen de la variable x_j

$$\begin{aligned}
f_X(x_1, \dots, x_k) &= \frac{\partial^k}{\partial x_1 \dots \partial x_k} F_X(x_1, \dots, x_k) \\
&= \frac{\partial^k}{\partial x_1 \dots \partial x_k} \left(\prod_{j=1}^k F_j(x_j) \right) \\
&= \frac{\partial}{\partial x_1} F_1(x_1) \cdot \frac{\partial}{\partial x_2} F_2(x_2) \dots \frac{\partial}{\partial x_k} F_k(x_k) \\
&= f_1(x_1) \cdot f_2(x_2) \dots f_k(x_k) \\
&= \prod_{j=1}^k f_j(x_j)
\end{aligned}$$

Com es va veure en el tema anterior a partir de la distribució conjunta d'un vector aleatori es poden obtenir les distribucions marginals de cadascuna de les seves components. Segons el teorema de factorització, es pot reconstruir la distribució conjunta multiplicant las distribucions marginales sempre que les variables siguin indepen dents.

Exemple 2.1. En l'exemple 1.25 del tema anterior varem veure que les coordenades de la distribució conjunta de un punt triat a l'atzar en el circle unitas C_1 tenia una densitat conjunta

$$f_{XY}(x, y) = \begin{cases} \frac{1}{\pi}, & \text{si } (x, y) \in C_1 \\ 0, & \text{en la resta} \end{cases}$$

I fàcilment i de forma simètrica, les marginals de X e Y son idèntiques i tenen la forma

$$f_X(x) = \begin{cases} \frac{2}{\pi} \sqrt{1-x^2}, & \text{si } |x| < 1 \\ 0, & \text{en la resta} \end{cases}$$

Directamente les dues variables X e Y no son independents donat que $f_{XY}(x, y) \neq f_X(x)f_Y(y)$

Definició 2.2. Mostra aleatoria

Considerem una distribució de probabilitat que ve representada per la seva funció de probabilitat o densitat de probabilitat segons sigui discreta o continua. Es diu que n variables aleatòries $X_1, \dots, X_n$ formen una mostra aleatòria d'aquesta distribució si les variables aleatòries son independents i la funció de probabilitat o densitat marginal de cada variable aleatòria X_i es f. Normalment a este conjunt de variables aleatòrias es diu que son independents i idènticament distribuïdes o abreviadament i.i.d". El nombre de variables aleatòries es la grandària o mida mostral.

D'aquesta definició es dedueix que les dades observades en una mostra de subjectes d'una població han estat generades per n variables i.i.d i que la seva funció de probabilitat conjunta es el producte de les densitats de cada individu $g(x_1, \dots, x_n) = f(x_1) \dots f(x_n)$

Proposició 2.1. Independència i Esperança

Si $X_1, \dots, X_k$ són independents, aleshores $E[X_1, \dots, X_k] = E[\prod_{j=1}^k X_j] = \prod_{j=1}^k E[X_j]$

Demostració

Utilitzant la definició de esperança d'un vector i la intercanviabilitat de les integrals i els productes de funcions pel teorema de Fubini podem demostrar

$$\begin{aligned} E[(X_1 \cdots X_k)] &= \int_{-\infty}^{\infty} \cdots \int_{-\infty}^{\infty} x_1 \cdots x_k f_X(x_1, \dots, x_k) dx_1 \cdots dx_k \\ &= \int_{-\infty}^{\infty} \cdots \int_{-\infty}^{\infty} \left(\prod_{i=1}^k x_i f_i(x_i) \right) dx_1 \cdots dx_k \\ &= \prod_{i=1}^k \left(\int_{-\infty}^{\infty} x_i f_i(x_i) dx_i \right) \\ &= \prod_{i=1}^k E(X_i). \end{aligned}$$

En el cas discret es pot demostrar de manera anàloga, canviant integrals per sumes.

De manera més general, el resultat anterior es pot generalitzar a les funcions $g_i, i = 1, \dots, k$ son mesurables, les $g_i(X_i)$ també son variables independents i es pot escriure:

$$E\left[\prod_{j=1}^k g(X_j)\right] = \prod_{j=1}^k E[g_j(X_j)]$$

∴{.corollary} Si les variables $X_1, \dots, X_k$ son independents, llavors $cov(X_i, X_j) = 0, \quad \forall i, j$ ∴

Corollari 2.1. Si les variables $X_1, \dots, X_k$ son independents i les seves variàncies existeixen, la variància de $S = \sum_{i=1}^k a_i X_i$, on a_i son qualsevol número real, existeix i ve donada per $V(S) = \sum_{i=1}^k a_i^2 Var(X_i)$

Aquests corollaris permeten obtenir esperances i variàncies de algunes variables conegudes de manera fàcil com verurem en el tema 3.

2.2 Esperances i variàncies condicionades.

En el tema anterior varem introduir el concepte d'esperança i variància de un vector aleatori, així com el concepte de distribució condicional. En aquest apartat introduïrem el concepte de esperança condicional i la seva relació amb el concepte d'independència.

Definició 2.3. Esperança condicionada

Sigui (X, Y) un vector aleatori definit sobre l'espai de probabilitat $(\Omega, \mathcal{A}, \mathbb{R})$ i sigui $P_{Y|X=x}$ la distribució de probabilitat de Y condicionada a $X=x$. Si g es una funció mesurable definida de $(\mathbb{R}, \beta)$ en $(\mathbb{R}, \beta)$ de manera que $E[g(Y)]$ existeix, l'esperança condicionada de $g(Y)$ donat X , $E[g(Y)|X]$ es una variable aleatòria que per $X = x$ pren el valor

$$E[g(Y) | X = x] = \int_{\Omega} g(y) dP_{Y|X=x}(y).$$

La forma de l'equació (2.3) depen de les característiques de la distribució del vector (X, Y)

- Si (X, Y) es un vector discret on $D_x = \{y; (x, y) \in D\}$, llavors

$$E[g(Y) | X = x] = \sum_{y \in D_x} g(y) P(Y = y | X = x) = \sum_{y \in D_x} g(y) f_{Y|X}(y | x)$$

- Si (X, Y) es un vector continu, llavors

$$E[g(Y) | X = x] = \int_{\mathbb{R}} g(y) f_{Y|X}(y | x) dy$$

Així si $g(Y) = y$ tenim

$$E[Y | X = x] = \begin{cases} \int_{-\infty}^{\infty} y f_{Y|X=x}(y) dy, & \text{en el cas continu,} \\ \sum_y y f_{Y|X=x}(y), & \text{en el cas discret.} \end{cases}$$

Quan el valor x de X varia, l'esperança condicionada de Y al valor de x també canvia. Així podem definir la funció

$$m_y = E[Y | X = x]$$

que estarà definida per a tot x tal que $f_X(x) > 0$ i que la funció de probabilitat o densitat condicionada $f_{Y|X=x}(y)$ tingui esperança finita

Definició 2.4. Funció de esperança condicionada o regressió

La funció $m_y = E[Y | X = x]$ s'anomena funció de esperança condicionada de Y donat X o també funció de regressió de Y sobre X .

Si disposem de dues variables X i Y independents amb distribució $\text{Bi}(n, p)$ es pot obtenir fàcilment la distribució de la variable $X+Y$ a partir de les definicions anteriors

$$\begin{aligned} f_{X+Y}(m) &= P\left(\bigcup_{k=0}^m \{X = k, Y = m - k\}\right) \\ &= \sum_{k=0}^m P(X = k, Y = m - k) \\ &= \sum_{k=0}^m P(X = k) P(Y = m - k) \\ &= \sum_{k=0}^m \binom{n}{k} p^k (1-p)^{n-k} \binom{n}{m-k} p^{m-k} (1-p)^{n-(m-k)} \\ &= p^m (1-p)^{2n-m} \sum_{k=0}^m \binom{n}{k} \binom{n}{m-k} \\ &= \binom{2n}{m} p^m (1-p)^{2n-m}. \end{aligned}$$

De donde se obtiene que:

$$X + Y \sim B(2n, p).$$

La distribució de condicionada de $Y|X + Y = m$ és

$$\begin{aligned} P(Y = k | X + Y = m) &= \frac{P(Y = k, X + Y = m)}{P(X + Y = m)} \\ &= \frac{P(Y = k, X = m - k)}{P(X + Y = m)} \\ &= \frac{\binom{n}{k} p^k (1 - p)^{n-k} \binom{n}{m-k} p^{m-k} (1 - p)^{n-(m-k)}}{\binom{2n}{m} p^m (1 - p)^{2n-m}} \\ &= \frac{\binom{n}{k} \binom{n}{m-k}}{\binom{2n}{m}}. \end{aligned}$$

És a dir,

$$Y | X + Y = m \sim H(m, 2n, n).$$

L'esperança condicional val:

$$E(Y | X + Y = m) = \frac{nm}{2n} = \frac{m}{2}.$$

Totes les operacions que es feiem en l'operador esperança es poden realitzar en l'esperança condicionada

1. L'esperança condicionada es un operador linial

$$E[ag_1(Y) + bg_2(Y) | X] = aE[g_1(Y) | X] + bE[g_2(Y) | X]$$

En particular,

$$E[aY + b | X] = aE(Y | X) + b.$$

- 2.

$$P(a \leq Y \leq b) = 1 \implies a \leq E(Y|X) \leq b$$

- 3.

$$P(g_1(Y) \leq g_2(Y)) = 1 \implies E[g_1(Y)|X] \leq E[g_2(Y)|X]$$

4. $E[c|X] = c$ para c constant.

Però hi ha algunes propietats que son específiques de de l'esperança condicional

LLei de l'esperança total

Si $E[g(Y)]$ existeix , llavors $E[E[g(Y)|X]] = E[g(Y)]$

Demostració:

$$\begin{aligned}
E(E[g(Y) \mid X]) &= \int_{\mathbb{R}} E[g(Y) \mid x] f_X(x) dx \\
&= \int_{\mathbb{R}} \left(\int_{\mathbb{R}} g(y) f_{Y|X}(y \mid x) dy \right) f_X(x) dx \\
&= \int_{\mathbb{R}} \left(\int_{\mathbb{R}} g(y) f_{XY}(x, y) dy \right) dx \\
&= \int_{\mathbb{R}} g(y) \left(\int_{\mathbb{R}} f_{XY}(x, y) dx \right) dy \\
&= \int_{\mathbb{R}} g(y) f_Y(y) dy \\
&= E[g(Y)].
\end{aligned}$$

Exemple 2.2. Considerem el vector (X, Y) amb densitat conjunta

$$f_{XY}(x, y) = \begin{cases} 1/x & 0 < y \leq x \leq 1 \\ 0 & \text{en la resta.} \end{cases}$$

Facilment obtenim que $X \sim U(0, 1)$ y que $Y|X = x \sim U(0, x)$

apolicant el resultat anteor podem obtenir $E[Y]$

$$E[Y] = \int_0^1 E(Y|x) f_X(x) dx = \int_0^1 \frac{1}{2} x dx = \frac{1}{4}$$

Exemple 2.3. Un treballador està encarregat del correcte funcionament de n màquines situades en línia recta i distants una de l'altra 1 metres. El treballador ha de reparar-les quan s'espatllen, el que succeeix amb la mateixa probabilitat per totes les màquines de manera independent una de l'altra. L'operari pot seguir dues estratègies.

1. Anar a reparar la màquina que s'espatlla i romandre al costat d'ella fins que un altra s'espatlle i anar llavors a reparar-la
2. Situar-se al punt mig de la línia de màquines i des de allí anar a la màquina espatllada i tornar al punt mig quan la màquina estigui reparada.

Si X es la distància que camina el treballador entre dues avaries consecutives, ¿Quina de les dues estratègies es la més convenient per caminar menys?

Per tant es tracta de obtenir el valor $E[X]$ amb les dues estratègies i triar la que tinga menys valor esperat. Designem $E_i[X]$ l'esperança que obetnim en cada estratègia $i = 1, 2$.

Estratègia 1

Si A_k es l'esdeveniment l'operari està en la màquina k . Per obtenir $E_1[X]$ recurrim a la propietat de l'esperança total, peròò tuilitzan com a distribució condicionada la que es deriva de condicionar respecte del succès A_k . Tindrem $E_1[X] = E[E(A_k)]$

Para obtenir $E[X | A_k]$, tinguem en compte que, si i és la pròxima màquina avariada, $P(A_i) = \frac{1}{n}$, $\forall i = 1, \dots, n$, i la distància a recórrer serà

$$X | A_k = \begin{cases} (k-i)l, & \text{si } i \leq k, \\ (i-k)l, & \text{si } i > k. \end{cases}$$

Així doncs,

$$\begin{aligned} E(X | A_k) &= \frac{1}{n} \left(\sum_{i=1}^k (k-i)l + \sum_{i=k+1}^n (i-k)l \right) \\ &= \frac{l}{2n} [2k^2 - 2(n+1)k + n(n+1)]. \end{aligned}$$

Utilitzant

$$\sum_{k=1}^n k^2 = \frac{n(n+1)(2n+1)}{6},$$

obtenim

$$E_1(X) = E(E(X | A_k)) = \frac{1}{n} \sum_{k=1}^n E(X | A_k) = \frac{l(n^2-1)}{3n}.$$

Estratègia 2

Per facilitar els càlculs, suposem que n és imparell, de manera que hi ha una màquina situada al punt mig de la línia, és a dir, la $\frac{n+1}{2}$ -èsima. Si la pròxima màquina avariada és la i -èsima, la distància a recórrer serà

$$X = \begin{cases} 2 \left(\frac{n+1}{2} - i \right) l, & \text{si } i \leq \frac{n+1}{2}, \\ 2 \left(i - \frac{n+1}{2} \right) l, & \text{si } i > \frac{n+1}{2}, \end{cases}$$

on el factor 2 es justifica perquè, en aquesta segona estratègia, l'operari torna sempre al punt mig de la línia de màquines.

L'esperança ve donada per

$$E_2(X) = \frac{2}{n} \sum_{i=1}^n \left| \frac{n+1}{2} - i \right| l = \frac{l(n-1)}{2}$$

Com que $E_1(X) \leq E_2(X) \iff \frac{n+1}{3n} \leq \frac{1}{2} \iff n \geq 2$, podem deduir que la primera estratègia és millor, excepte quan només hi ha una màquina.

Definició 2.5. Variància condicionada

Definim la variància condicionada $Var(Y|X)$ a la variable definida con una funció de la variable aleatòria X com la funció $v_Y(x)$

$$v_Y(x) = Var(Y|X=x) = E[Y^2|X] - (E[Y|X])^2$$

També és possible relacionar la variància absoluta amb la variància condicionada, encara que l'expressió no és tan directa com la que s'ha obtingut per a l'esperança.

Proposició 2.2. *** Llei de la variància total** Si $E[Y^2]$ existeix, llavors*

$$\text{var}(Y) = E(\text{var}[Y|X]) + \text{var}(E[Y|X])$$

Demostració

$$\begin{aligned} \text{Var}(Y) &= E[(Y - E(Y))^2] = E\{E[(Y - E(Y))^2 | X]\} \\ &= E\{E[Y^2 + (E(Y))^2 - 2Y E(Y) | X]\} \\ &= E\{E[Y^2 | X] + E(Y)^2 - 2E(Y) E[Y | X]\} \\ &= E\{\text{Var}(Y | X) + (E[Y | X])^2 + E(Y)^2 - 2E(Y) E[Y | X]\} \\ &= E\{\text{Var}(Y | X) + (E[Y | X] - E(Y))^2\} \\ &= E\{\text{Var}(Y | X)\} + E[(E[Y | X] - E(Y))^2] \\ &= E(\text{Var}(Y | X)) + \text{Var}(E[Y | X]) \end{aligned}$$

∴{.corollary}

Si $E[Y^2]$ existeix, per la propietat anterior $\text{Var}(Y) \geq \text{Var}(E[Y|X])$

∴

Exemple 2.4. Siguin (X, Y) variables aleatòries contínues amb densitat conjunta

$$f(x, y) = \begin{cases} e^{-y}, & 0 \leq x \leq y, \\ 0, & \text{en la resta} \end{cases}$$

(a) **Densitat marginal de X**

$$f_X(x) = \int_x^\infty f(x, y) dy = \int_x^\infty e^{-y} dy = [-e^{-y}]_x^\infty = e^{-x}$$

Per tant, $X \sim \text{Exp}(1)$

(b) **Densitat marginal de Y**

$$f_Y(y) = \int_0^y f(x, y) dx = \int_0^y e^{-y} dx = e^{-y} [x]_0^y = ye^{-y}$$

Per tant, $Y \sim \Gamma(\alpha = 2, \beta = 1)$

(c) **Densitat condicional de $(X | Y = y)$**

$$f_{X|Y=y}(x) = \frac{f(x, y)}{f_Y(y)} = \frac{e^{-y}}{ye^{-y}} = \frac{1}{y}, \quad 0 \leq x \leq y$$

Per tant $(X | Y = y) \sim U[0, y]$

(d) **Densitat condicional de $(Y | X = x)$**

$$f_{Y|X=x}(y) = \frac{f(x, y)}{f_X(x)} = \frac{e^{-y}}{e^{-x}} = e^{-(y-x)}, \quad y \geq x$$

Per tant, $(Y \mid X = x)$ segueix una exponencial desplaçada.

(e) Esperança i variància condicionades de $X \mid Y = y$

$$E(X \mid Y = y) = \int_0^y x \frac{1}{y} dx = \frac{1}{y} \left[\frac{x^2}{2} \right]_0^y = \frac{y}{2}$$

Com que $(X \mid Y = y) \sim U[0, y]$, podem obtenir directament les expressions de la variància i la esperança també tenim

$$\text{Var}(X \mid Y = y) = \frac{y^2}{12} \text{ i } E(X \mid Y) = \frac{Y}{2}$$

(f) Esperança i variància condicionades de $(Y \mid X = x)$

$$E(Y \mid X = x) = \int_x^\infty y e^{-(y-x)} dy = \left\{ \begin{array}{ll} u = y & du = 1 \\ dv = e^{-(y-x)} & v = -e^{-(y-x)} \end{array} \right\}$$

$$= e^x [-ye^{-y}]_x^\infty - \int_x^\infty e^{-y} dy = e^x (xe^{-x} + e^{-x}) = x + 1.$$

$$E(Y^2 \mid X = x) = \int_x^\infty y^2 e^{-(y-x)} dy = \left\{ \begin{array}{l} z = y - x \\ dz = dy \end{array} \right\}$$

$$\begin{aligned} E(Y^2 \mid X = x) &= \int_x^\infty y^2 e^{-(y-x)} dy = \left\{ \begin{array}{l} z = y - x \\ dz = dy \end{array} \right\} \\ &= \int_0^\infty (z+x)^2 e^{-z} dz = \int_0^\infty z^2 e^{-z} dz + x^2 \int_0^\infty e^{-z} dz + 2x \int_0^\infty z e^{-z} dz \\ &= \frac{\Gamma(2)}{1^2} \int_0^\infty \frac{1^2}{\Gamma(2)} z e^{-z} dz + x^2 + 2x \\ &= 2 + x^2 + 2x \\ &= (x+1)^2 + 1. \end{aligned}$$

On hem usat que si $X \sim \Gamma(\alpha, \beta)$ llavors $E[X] = \frac{\alpha}{\beta}$, $E[X^2] = \frac{\alpha(\alpha+1)}{\beta^2}$ i $\text{Var}[X] = \frac{\alpha}{\beta^2}$,

Amb aquests càlculs podem trobar la variable aleatòria $\text{Var}(Y|X)$ com $\text{Var}(Y|X = x) = 1 + (x+1)^2 - (x+1)^2 = 1$

Per tant

$$E(Y|X) = X + 1 \text{ i } \text{Var}(Y|X) = 1$$

(g) Variància de Y

Directamente de la definició

$$\text{Var}(Y) = \text{Var}(\Gamma(\alpha = 2, \beta = 1)) = \frac{2}{1^2} = 2.$$

Ara podem comprovar la segona part de la llei de la variància total:

$$\begin{aligned} \text{Var}(Y) &= E(\text{Var}(Y \mid X)) + \text{Var}(E(Y \mid X)) \\ &= E(1) + \text{Var}(X + 1) \\ &= 1 + \text{Var}(X) \\ &= 1 + 1 = 2. \end{aligned}$$

(h) Variància de X

$$\begin{aligned} 1 &= \text{Var}(X) \\ &= E(\text{Var}(X | Y)) + \text{Var}(E(X | Y)) \\ &= E\left(\frac{Y}{2}\right) + \text{Var}\left(\frac{Y}{2}\right) \\ &= \frac{1}{2}E(Y) + \frac{1}{4}\text{Var}(Y) \\ &= \frac{1}{2} \cdot 1 + \frac{1}{4} \cdot 2 \\ &= \frac{1}{2} + \frac{1}{2} = 1. \end{aligned}$$

2.3 Conceptes de covariància, correlació i causalitat

En el capítol anterior varem introduir el càlcul de la matriu de variàncies-covariàncies. En aquest apartat anem a discutir sobre la interpretació incloent conceptes com la correlació i la causalitat.

2.3.1 Desigualtats

En primer lloc anem a formular algunes desigualtats que són útils quan no coneixem la distribució de algunes variables, però sí que coneixem alguns dels seus moments o els estimem a partir de les observacions. En aquest cas les desigualtats permeten establir cotes de les probabilitats a partir dels moments i poden ajudar a demostrar alguns teoremes crucials com la llei dels grans números.

Per a una variable $X \geq 0$ existeix la seva esperança, sigui $\epsilon > 0$ podem escriure el valor de l'esperança com

$$E[X] = \int_0^{+\infty} P(X \geq x)dx = \int_0^\epsilon P(X \geq x)dx + \int_\epsilon^{+\infty} P(X \geq x)dx$$

Com que la segona integral es no negativa i la funció $P(X \geq \epsilon)$ es decreixent

$$E[X] \geq \int_0^\epsilon P(X \geq x)dx \geq \int_0^\epsilon P(X \geq \epsilon)dx = \epsilon P(X \geq \epsilon)$$

i d'ací

$$P(X \geq \epsilon) \leq \frac{E[X]}{\epsilon}$$

Aquest resultat dona lloc a dues conegudes desigualtats generals que proporcionen cotes superiors per a la probabilitat de certs conjunts i que són vàlides independentment de la distribució de la variable involucrada.

Desigualtat de Markov

Si en la desigualtat (2.3.1) substituïm X per $|X|^k$ i ϵ per ϵ^k tenim

$$P(|X| \geq \epsilon) = P(|X|^k \geq \epsilon^k) \leq \frac{E[|X|^k]}{\epsilon^k}$$

coneguda com a desigualtat de Markov.

Desigualtat de Tchebixev

Un cas especial de (2.3.1), que es coneix com la desigualtat de Tchebixev, és el cas en el que $k=2$ i $X=X-E[X]$

$$P(|X - E[X]| \geq \epsilon) \leq \frac{1}{\epsilon^2} \text{Var}(X)$$

Proposició 2.3. Si $V(X) = 0$ aleshores X es constant amb probabilitat 1.

Demostració

Suposem $E[X] = \mu$ i considerem els conjunts $A_n = |X - \mu| \geq 1/n$ aplicant la desigualtat de Tchebixev

$$P(A_n) = P(|X - \mu| \geq \frac{1}{n}) = 0 \forall n$$

d'ací obtenim que $P(\cup_n A_n) = 0$ i $P(\cap_n A_n^c) = 1$ Però

$$\bigcap_{n \geq 1} A_n^c = \bigcap_{n \geq 1} \{|X - \mu| \geq \frac{1}{n}\}^c = \{X = \mu\}$$

i per tant $P(X = \mu) = 1$

Desigualtat de Jensen

Si $g(X)$ es convexa sabem que $\forall a, \exists \lambda_a$ tal que $g(x) \geq g(a) + \lambda_a(x - a)$

Si es substitueix $a = E[X]$ llavors

$$g(X) \geq g(E[X]) + \lambda_a(X - E[X])$$

i calculant esperances de l'expressió anterior obtenim la coneguda com desigualtat de Jensen

$$E[g(X)] \geq g(E[X])$$

...{.Theorem #thm-cauchy} **Desigualtat de Cauchy-Schwarz**

Si X i Y son variables aleatòries amb variàncies finites. Aleshores, $\text{cov}(X, Y)$ existeix i es verifica que

$$(E[XY])^2 \leq E[X^2]E[Y^2]$$

verificant-se la igualtat si i només si existeix un nombre real tal que $P(\alpha X + Y = 0) = 1$::: **Demostració**
Per qualsevol nombre real a i b es verifica que:

$$|ab| \leq \frac{a^2 + b^2}{2}$$

el que significa que si $E[XY] < \infty$, $E[X^2] < \infty$ i $E[Y^2] < \infty$

Per altra banda per qualsevol real α es té que:

$$E[(\alpha X + Y)^2] = \alpha^2 E[X^2] + 2\alpha E[XY] + E[Y^2] \geq 0$$

que es tracta d'una equació de segon grau que té almenys una arrel i el seu discriminant no serà positiu. És a dir:

$$(E[XY])^2 \leq E[X^2]E[Y^2]$$

Si es donés el cas de la igualtat, l'equació tindria una arrel doble α_0 i $E[(\alpha_0 X + Y)^2] = 0$ de una funció no negativa que implica que $P(\alpha_0 X + Y = 0) = 1$

2.3.2 Covariància i Correlació

Si recordem del tema 1, la covariància entre dues variables es pot expressar com

$$\text{cov}(X_i, X_j) = E[(X_i - E[X_i])(X_j - E[X_j])] = E[(X_i X_j)] - E[X_i]E[X_j]$$

La covariància ens informa sobre el grau i tipus de dependència entre dues variables a través de la seva magnitud i signe, ja que la relació pot ser positiva o negativa. Tanmateix les unitats de mesura de les variables, alteren els valors de les covariancies. Si X es el pes i Y es l'alçada en centimetres i transformem l'alçada en metres multiplicant per 100 $\text{Cov}(X, 100Y) = 100\text{Cov}(X, Y)$ segons (1.4.3)

Definició 2.6. Coeficient de correlació

Si (X, Y) són variables aleatòries amb variances finites $\text{Var}(X) = \sigma_X^2$ i $\text{Var}(Y) = \sigma_Y^2$ la correlació $\rho(X, Y)$ entre X i Y es defineix com

$$\rho(X, Y) = \frac{\text{Cov}(X, Y)}{\sqrt{\text{Var}(X)\text{Var}(Y)}} = \frac{\sigma_{XY}}{\sigma_X \sigma_Y} = E \left[\left(\frac{X - E[X]}{\sigma_X} \right) \left(\frac{Y - E[Y]}{\sigma_Y} \right) \right] = \text{cov}(X_t, Y_t)$$

es a dir la covariància de les variables X i Y tipificades

Proposició 2.4. *Siguin X i Y dues variables aleatòries amb variancia finita llavors*

$$(\text{Cov}(X, Y))^2 \leq \sigma_X^2 \sigma_Y^2$$

i de aquí es depren que $\rho_{XY}^2 \leq 1$ i en particular $-1 \leq \rho_{XY} \leq 1$. A més desigualtat seria igualtat si i només si hi ha una constant α_0 tal que amb probabilitat 1, $P(\alpha_0 X + Y = 0) = 1$ el que implica que la correlació $\rho_{XY}^2 = 1$

Demostració

Considerem les variables centrades $X_c = X - E[X]$ i $Y_c = Y - E[Y]$

Per definició de covariància

$$\text{Cov}(X, Y) = E[X_c, Y_c]$$

.

A partir de la desigualtat de Cauchy-Schwartz (2.3.1) podem deduir que

$$(E[X_c Y_c])^2 \leq E[X_c^2] E[Y_c^2]$$

A més sabem que $E[X_c^2] = \text{Var}(X) = \sigma_X^2$ i $E[Y_c^2] = \text{Var}(Y) = \sigma_Y^2$

per tant

$$(\text{Cov}(X, Y))^2 = \sigma_{X,Y}^2 = (E[X_c Y_c])^2 \leq E[X_c^2] E[Y_c^2] = \sigma_X^2 \sigma_Y^2$$

Com a conseqüència si $\sigma_X > 0$ i $\sigma_Y > 0$ el coeficient de correlació es

$$\rho(X, Y) = \frac{\text{Cov}(X, Y)}{\sqrt{\text{Var}(X)\text{Var}(Y)}} = \frac{\sigma_{XY}}{\sigma_X \sigma_Y}$$

i elevat al quadrat

$$\rho_{X,Y}^2 = \frac{\sigma_{XY}^2}{\sigma_X^2 \sigma_Y^2} \leq \frac{\sigma_X^2 \sigma_Y^2}{\sigma_X^2 \sigma_Y^2} = 1$$

i per tant

$$-1 \leq \rho_{XY} \leq 1$$

En el cas de igualtat també per la desigualtat de Cauchy-Schwarz es sabe que existeix una constant α_0 tal que les variables centrades X_c i Y_c estan relacionades linealment amb probabilitat 1. $P(\alpha_0 X_c + Y_c = 0) = 1$ i per tant la correlació al quadrat valdria 1. És a dir $\rho_{XY} = -1$ ó $\rho_{XY} = 1$. En aquest cas es parla de relació lineal perfecta.

Si $\rho_{XY} > 0$ parlarem de que les variables estan positivament correlacionades i si $\rho_{XY} < 0$ direm que estan negativament correlacionades.

Si $\rho_{XY} = 0$ es diu que les variables estan incorrelades i a més a més la $Cov(X, Y) = 0$ i hi ha absència de correlació lineal.

Theorem 2.2. Si X_i i X_j son independents aleshores $Cov(X_i, X_j) = \rho_{X_i, X_j} = 0$

Demostració

Si dues variables son independents l'esperanza del producte es el producte d'esperances . Així

$$cov(X_i, X_j) = E[(X_i X_j)] - E[X_i]E[X_j] = E[X_i]E[X_j] - E[X_i]E[X_j] = 0$$

L'invers del teorema anterior no es compleix en general, es a dir dues variables poden estar incorrelades però no ser independents.

Exemple 2.5. Imaginem una variable aleatòria X que pren només tres valors $\{-1, 0, 1\}$ i que cadascú d'aquests valors te la mateixa probabilitat $(1/3)$. Imaginem la variable $Y = X^2$. Les dues variables clarament no son independents per definició ja que els valors de Y estan completament determinats pels valors de X .

Si calculem $E[XY] = E[X^3] = E[X] = 0$ ja que la variable X i X^3 son la mateixa que X . A més $E[X]E[Y] = 0$ ja que $E[X] = 0$.

Per tant

$$Cov(X, Y) = E[X, Y] - E[X]E[Y] = 0 - 0 = 0$$

Matriu de Correlació

Si (X_1, X_2) es un vector de 2 variables aleatòries definim la matriu de correlació R a la matriu 2x2 amb les correlacions entres els dues variable i 1 en la diagonal tenint en compte que la correlació $\rho_{11} = \rho_{22} = 1$

$$R = \begin{bmatrix} 1 & \rho_{12} \\ \rho_{21} & 1 \end{bmatrix}$$

En general. Si $X = (X_1, \dots, X_k)$ és un vector aleatori de dimensió k la matriu de correlacions és

$$R = \begin{bmatrix} 1 & \rho_{12} & \dots & \rho_{1(k-1)} & \rho_{1k} \\ \rho_{21} & 1 & \dots & \rho_{2(k-1)} & \rho_{2k} \\ \vdots & \vdots & \ddots & \vdots & \vdots \\ \rho_{(k-1)1} & \rho_{(k-1)2} & \dots & 1 & \rho_{(k-1)k} \\ \rho_{k1} & \rho_{k2} & \dots & \rho_{k(k-1)} & 1 \end{bmatrix}$$

La matriu de variàncies-covàncies Σ es relaciona directament amb la matriu de correlació R amb la següent fórmula:

$$\Sigma = D \cdot R \cdot D$$

i per tant

$$R = D^{-1} \cdot \Sigma \cdot D^{-1}$$

on D es la matriu diagonal de desviacions típiques

$$D = \begin{bmatrix} \sigma_1 & 0 & \dots & 0 & 0 \\ 0 & \sigma_2 & \dots & 0 & 0 \\ \vdots & \vdots & \ddots & \vdots & \vdots \\ 0 & 0 & \dots & \sigma_{n-1} & 0 \\ 0 & 0 & \dots & 0 & \sigma_n \end{bmatrix}$$

i D^{-1} es una matriu diagonal amb $\frac{1}{\sigma_i}$ en la diagonal

2.3.3 Causalitat i correlació.

Tal i com hem vist en apartata anterior diguem que dues variables estàn relacionades si existeix correlació entre les mateixes. Aquesta correlació es una mesura estadística que descriu una direcció de relació (positiva o negativa) i una intensitat que va entre 0 i 1 en valors absoluts. No obstant, aquesta correlació no implica que el canvi en una variable atue automàticament es vegi reflectit en el canvi d'una altra.

La causalitat implica que el canvi en la ocurrencia en una variable implica el canvi en una altra. Per exemple, si una variable és la quantitat de les hores treballades i l'altra es la quantitat de diners guanyats quan a un treballador se li paga per hores, està clar que un increment d'hores treballades implica un augment del diners rebuts.

A més de l'existència de relació entre dues variables com per exemple correlació lineal son necessaries algunes altres característiques com la seqüència temporal (la causa ha de existir abans de la conseqüència), la plausibilitat, la consistència, l'especificitat etc.

Per exemple, el consum de gelats té una bona correlació amb el nombre de ofegaments en piscines, platges, rius, etc. però està clar que el menjar-se un gelat no fa que t'ofegues en una piscina. Simplement hi ha una correlació temporal. Es messos d'estiu es quan més calor fa i es mengen més gelats i la gent es banya més amb risc d'ofegar-se. Al contrari passa al hivern, es mengen més gelats i com la gent no es banya disminueix el risc d'ofegament. En la següent figura es poden veure dades reals en USA on la correlació es 0.44 i està clar que no hi ha relació causal.

En la URL <https://tylervigen.com/spurious-correlations> es poden trobar nombroses correlacions espúries on estàn disponibles les dades. D'ací la famosa frase en estadística **Correlation is not causation**, la correlació no implica causalitat.

3 Algunes distribucions multivariants

En els dos temes anteriors s'ha introduït el concepte de vectors aleatoris i totes les funcions associades a les seves distribucions. En aquest tema introduïrem algunes de les distribucions de probabilitat més utilitzades. Dedicarem un apartat sencer a la distribució normal multivariant, introduïrem algunes de les distribucions discretes i contínues més utilitzades i en la tercera part del tema parlarem de la generació de distribucions multivariants.




Figura 13: Correlació espúria entre el consum de gelats i morts per ofegament en aigua en USA

3.1 Distribució normal multivariant: definició, propietats i aplicacions.

3.1.1 Distribució normal bivariant

Definició 3.1. Vector aleatori normal bivariant

El vector aleatori bidimensional (X, Y) té una distribució normal bivariant de paràmetres

$\mu_x \in \mathbb{R}, \mu_y \in \mathbb{R}, \sigma_x > 0, \sigma_y > 0$ i ρ tal que $|\rho| < 1$ si la funció de densitat conjunta és de la forma

$$f_{XY}(x, y) = \frac{1}{2\pi\sigma_x\sigma_y\sqrt{(1-\rho^2)}} e^{-\frac{q(x, y)}{2}}, (x, y) \in \mathbb{R}^2$$

on

$$q(x, y) = \frac{1}{1-\rho^2} \left\{ \left(\frac{x-\mu_x}{\sigma_x} \right)^2 - 2\rho \left(\frac{x-\mu_x}{\sigma_x} \right) \left(\frac{y-\mu_y}{\sigma_y} \right) + \left(\frac{y-\mu_y}{\sigma_y} \right)^2 \right\}$$

En la figura 14 es mostra en la part esquerra la distribució de densitat normal bivariant conjunta i en la part dreta es mostren les corbes de nivell. Es pot veure la forma el·líptica que té la figura que mostra el nivell de correlació entre les dues variables, que és molt estreta ja que la correlació és $\rho = 0.8$.

L'expressió de la densitat normal bivariant es pot enunciar d'una manera més compacta a partir de la matriu de variàncies-covariàncies

$$\Sigma = \begin{bmatrix} \sigma_x^2 & \sigma_{xy} \\ \sigma_{xy} & \sigma_y^2 \end{bmatrix}$$

$$f(x, y) = \frac{|\Sigma|^{-\frac{1}{2}}}{2\pi} e^{-\frac{1}{2}(\mathbf{x}-\boldsymbol{\mu})'\Sigma^{-1}(\mathbf{x}-\boldsymbol{\mu})}, (x, y) \in \mathbb{R}^2$$

On $\mathbf{x}' = (x, y)$ és el vector de variables aleatòries i $\boldsymbol{\mu}' = (\mu_x, \mu_y)$ és el vector de mitjanes o valors esperats i $|\Sigma|$ es el determinant de Σ que pren el valor




Figura 14: Densitat i corbes de nivell binormal amb $\mu_x = \mu_y = 0$, $\sigma_x = \sigma_y = 1$ i $\rho = 0.8$

$$|\Sigma| = \sigma_x^2 \sigma_y^2 - \sigma_{xy}^2 = \sigma_x^2 \sigma_y^2 (1 - \rho_{xy}^2)$$

Així en aquest cas es diu que $\mathbf{x}' = (x, y)$ té una distribució normal bivariant en vector d'esperances μ i matriu de variàncies-covariàncies Σ .

Escriurem

$$\begin{pmatrix} X \\ Y \end{pmatrix} \sim N \left(\mu = \begin{pmatrix} \mu_x \\ \mu_y \end{pmatrix}, \Sigma = \begin{pmatrix} \sigma_x^2 & \rho \sigma_x \sigma_y \\ \rho \sigma_x \sigma_y & \sigma_y^2 \end{pmatrix} \right)$$

Queda per al lector la comprovació de l'equivalència de les expressions de les funcions de densitat.

Definició 3.2. Distribució normal bivariant estàndard amb marginals independents

Sigui $Z_1 \sim N(0, 1)$ i $Z_2 \sim N(0, 1)$ amb Z_1 i Z_2 independents i per tant $\rho = 0$ Llavors

$$f_{Z_1, Z_2}(z_1, z_2) = f_{Z_1}(z_1) f_{Z_2}(z_2) = \frac{1}{\sqrt{2\pi}} e^{-\frac{z_1^2}{2}} \frac{1}{\sqrt{2\pi}} e^{-\frac{z_2^2}{2}} = \frac{1}{2\pi} e^{(-\frac{1}{2})(z_1^2 + z_2^2)} = \frac{1}{2\pi} e^{(-\frac{1}{2})(\mathbf{z}'\mathbf{z})}$$

amb $\mathbf{z} = (z_1, z_2)^T \in \mathbb{R}^2$

En la gràfica es mostra la densitat de la binormal estàndard amb mostres independents. S'observa que la corba de nivell està formada per isocrones de densitat en forma de cercles.




Figura 15: Densitat i corbes de nivell binormal amb $\mu_x = \mu_y = 0, \sigma_x = \sigma_y = 1$ i $\rho = 0$

Definició 3.3. Distribució normal bivariant estàndard amb marginals correlades

Sigui $Z_1 \sim N(0, 1)$ i $Z_2 \sim N(0, 1)$ amb Z_1 i Z_2 i la correlació $\rho \in (-1, 1)$ Llavors

$$f_{Z_1, Z_2}(z_1, z_2) = \frac{1}{2\pi\sqrt{1-\rho^2}} e^{(-\frac{1}{2(1-\rho^2)})(z_1^2 - 2\rho z_1 z_2 + z_2^2)} \quad (\#eq : fxybinormstandcorr)$$

es defineix com la funció de densitat conjunta de la distribució normal bivariant estàndard amb marginals correlades

Exemple 3.1. Per qüestions de conveniència formal hem introduït la distribució de les variables normals bivariants com a combinació de variables aleatòries normals independents. Cal remarcar que en nombroses ocasions aquesta distribució es fa de la manera habitual com es presenten les dades. De fet Karl Pearson a partir de les dades treballades de Francis Galton a finals del segle 19, planteja el coeficient de correlació entre les alçades dels pares i els fills, on hi ha una correlació diferent de 0 entre elles. Els pares alts tendeixen a tenir els fills alts i a l'inrevés en els baixets. Aquesta seria una distribució normal bivariant.

Proposició 3.1. Transformación de una normal bivalente estándar en una normal bivalente general

Sigui (Z_1, Z_2) un vector aleatori amb distribució normal bivariant estàndard:

$$\begin{pmatrix} Z_1 \\ Z_2 \end{pmatrix} \sim N \left(\begin{pmatrix} 0 \\ 0 \end{pmatrix}, \begin{pmatrix} 1 & \rho \\ \rho & 1 \end{pmatrix} \right)$$

i siguin $\mu_x, \mu_y \in \mathbb{R}$ y $\sigma_x, \sigma_y > 0$. Definim:

$$X = \mu_x + \sigma_x Z_1$$

$$Y = \mu_y + \sigma_y Z_2$$

Llavors el vector:

$$\begin{pmatrix} X \\ Y \end{pmatrix}$$

segueix una distribució normal bivalente general:

$$\begin{pmatrix} X \\ Y \end{pmatrix} \sim N \left(\begin{pmatrix} \mu_x \\ \mu_y \end{pmatrix}, \begin{pmatrix} \sigma_x^2 & \rho\sigma_x\sigma_y \\ \rho\sigma_x\sigma_y & \sigma_y^2 \end{pmatrix} \right)$$

És a dir, qualsevol normal bivariant pot obtenir-se a partir d'una normal bivariant estàndard mitjançant una transformació lineal de escala i translació

Demostració

La demostració es immediata utilitzant les propietats de l'esperança, variància i covariància.

Per l'esperança:

$$E(X) = E(\mu_x + \sigma_x Z_1) = \mu_x + \sigma_x E(Z_1) = \mu_x$$

donat que $E(Z_1) = 0$. Analogament:

$$E(Y) = E(\mu_y + \sigma_y Z_2) = \mu_y$$

Per a les variàncies:

$$Var(X) = Var(\mu_x + \sigma_x Z_1) = \sigma_x^2 Var(Z_1) = \sigma_x^2$$

i:

$$Var(Y) = Var(\mu_y + \sigma_y Z_2) = \sigma_y^2 Var(Z_2) = \sigma_y^2$$

Finalment, per a la covariància:

$$Cov(X, Y) = Cov(\mu_x + \sigma_x Z_1, \mu_y + \sigma_y Z_2)$$

Com que les constants no afecten a la covariància:

$$Cov(X, Y) = \sigma_x \sigma_y Cov(Z_1, Z_2)$$

i, donat que: $Cov(Z_1, Z_2) = \rho$ s'obté:

$$Cov(X, Y) = \rho \sigma_x \sigma_y$$

Per tant, la matriu de variàncies-covariàncies del vector (X, Y) és:

$$\Sigma = \begin{pmatrix} \sigma_x^2 & \rho \sigma_x \sigma_y \\ \rho \sigma_x \sigma_y & \sigma_y^2 \end{pmatrix}$$

amb el que queda demostrat que:

$$\begin{pmatrix} X \\ Y \end{pmatrix} \sim N \left(\begin{pmatrix} \mu_x \\ \mu_y \end{pmatrix}, \Sigma \right)$$

3.1.2 Distribucions marginals i condicional de una normal bivariant.

Distribucions marginals

Sigui (X, Y) un vector aleatori que segueix una distribució normal bivariant amb paràmetres $\mu_x, \mu_y \in \mathbb{R}$ y $\sigma_x, \sigma_y > 0$ i $\rho \in [-1, 1]$. que tal com hem vist podem representar com la combinació de distribucions normals estàndard Z_1, Z_2 . Per aixó X e Y segueixen una distribució normal $X \sim N(\mu_x, \sigma_x)$ i $Y \sim N(\mu_y, \sigma_y)$

En la figura 16 es mostren les distribucions marginals de la distribució normal bivariant que cp, es veu segueixen una distribució normal.




Figura 16: Marginals de la distribució continua bivalent

Proposició 3.2. Independència i correlació en una distribució normal bivalent

Siguin X i Y dues variables aleatòries amb distribució normal bivalent bivalent:

$$\begin{pmatrix} X \\ Y \end{pmatrix} \sim N \left(\begin{pmatrix} \mu_x \\ \mu_y \end{pmatrix}, \begin{pmatrix} \sigma_x^2 & \rho\sigma_x\sigma_y \\ \rho\sigma_x\sigma_y & \sigma_y^2 \end{pmatrix} \right)$$

LLavors X i Y son independents si i només si $\rho = 0$. És a dir , en una distribució normal bivalent, la absència de correlació equival a la independència.

Demostració

La funció de densitat d'una distribució normal bivalent és

$$f_{X,Y}(x,y) = \frac{1}{2\pi\sigma_x\sigma_y\sqrt{1-\rho^2}} \exp \left(-\frac{1}{2(1-\rho^2)} \left[\frac{(x-\mu_x)^2}{\sigma_x^2} - 2\rho\frac{(x-\mu_x)(y-\mu_y)}{\sigma_x\sigma_y} + \frac{(y-\mu_y)^2}{\sigma_y^2} \right] \right)$$

A més, les distribucions marginals són

$$X \sim N(\mu_x, \sigma_x^2), \quad Y \sim N(\mu_y, \sigma_y^2),$$

amb densitats

$$f_X(x) = \frac{1}{\sqrt{2\pi}\sigma_x} \exp \left(-\frac{(x-\mu_x)^2}{2\sigma_x^2} \right)$$

i

$$f_Y(y) = \frac{1}{\sqrt{2\pi}\sigma_y} \exp \left(-\frac{(y-\mu_y)^2}{2\sigma_y^2} \right)$$

Cal demostrar les dues implicacions.

$\Rightarrow$ Si (X) i (Y) són independents, aleshores $\rho = 0$

Si (X) i (Y) són independents, $f_{X,Y}(x, y) = f_X(x)f_Y(y)$

D'altra banda,

$$\text{Cov}(X, Y) = E[(X - \mu_x)(Y - \mu_y)] = E(X - \mu_x)E(Y - \mu_y) = 0$$

ja que l'esperança del producte es factoritza per la independència.

Com que

$\text{Cov}(X, Y) = \rho\sigma_x\sigma_y$ i $\sigma_x, \sigma_y > 0$, s'obté $\rho = 0$

$\Leftarrow$ Si $\rho = 0$, aleshores (X) i (Y) són independents

Suposem ara que $\rho = 0$. La densitat conjunta esdevé

$$f_{X,Y}(x, y) = \frac{1}{2\pi\sigma_x\sigma_y} \exp \left[-\frac{1}{2} \left(\frac{(x - \mu_x)^2}{\sigma_x^2} + \frac{(y - \mu_y)^2}{\sigma_y^2} \right) \right].$$

Utilitzant que $e^{a+b} = e^a e^b$

$$f_{X,Y}(x, y) = \left[\frac{1}{\sqrt{2\pi}\sigma_x} \exp \left(-\frac{(x - \mu_x)^2}{2\sigma_x^2} \right) \right] \left[\frac{1}{\sqrt{2\pi}\sigma_y} \exp \left(-\frac{(y - \mu_y)^2}{2\sigma_y^2} \right) \right] = f_X(x)f_Y(y)$$

La densitat conjunta factoritza com el producte de les densitats marginals. Per la caracterització de la independència mitjançant les densitats, es conclou que (X) i (Y) són independents.

Per tant,

$$X \perp Y \iff \rho = 0$$

Així, en una distribució normal bivariant, la incorrelació és equivalent a la independència.

Theorem 3.1. *Distribucions condicionals*

Sigui (X, Y) un vector aleatori que segueix una distribució normal bivariant amb paràmetres $\mu_x, \mu_y \in \mathbb{R}$ y $\sigma_x, \sigma_y > 0$ i $\rho \in [-1, 1]$ amb la funció de densitat definida en (3.1) corresponent a una distribució normal bivariant. La distribució condicional de y donat que $X = x$ es una distribució normal amb la esperança i variància següent:

$$E(Y|X = x) = \mu_Y + \rho\sigma_Y \left(\frac{X - \mu_X}{\sigma_X} \right)$$

$$\text{Var}(Y|X = x) = (1 - \rho^2)\sigma_Y^2$$

Demostració

Utilitzant l'expressió $X = \mu_X + \sigma_X Z_1$ i $Y = \mu_Y + \sigma_Y (\rho Z_1 + \sqrt{1 - \rho^2} Z_2)$ on $Z_1, Z_2 \sim N(0, 1)$ podem trobar $E(Y | X)$ com

$$\begin{aligned}
E[Y | X = x] &= E \left[\mu_Y + \sigma_Y \left(\rho Z_1 + \sqrt{1 - \rho^2} Z_2 \right) \middle| X = x \right] \\
&= E \left[\mu_Y + \sigma_Y \left(\rho \frac{x - \mu_X}{\sigma_X} + \sqrt{1 - \rho^2} Z_2 \right) \middle| X = x \right] \\
&= \mu_Y + \sigma_Y \left(\rho \frac{x - \mu_X}{\sigma_X} + \sqrt{1 - \rho^2} E[Z_2 | X = x] \right) \\
&= \mu_Y + \rho \sigma_Y \left(\frac{x - \mu_X}{\sigma_X} \right)
\end{aligned}$$

Per simetria,

$$E[X | Y = y] = \mu_X + \sigma_X \rho \left(\frac{y - \mu_Y}{\sigma_Y} \right)$$

Tambè podem trobar $\text{Var}(Y | X)$

$$\begin{aligned}
\text{Var}(Y | X = x) &= \text{Var} \left[\mu_Y + \sigma_Y \left(\rho Z_1 + \sqrt{1 - \rho^2} Z_2 \right) \middle| X = x \right] \\
&= \text{Var} \left[\mu_Y + \sigma_Y \left(\rho \frac{x - \mu_X}{\sigma_X} + \sqrt{1 - \rho^2} Z_2 \right) \middle| X = x \right] \\
&= \text{Var} \left[\sigma_Y \sqrt{1 - \rho^2} Z_2 \middle| X = x \right] \\
&= \sigma_Y^2 (1 - \rho^2)
\end{aligned}$$

Per simetria

$$\text{Var}(X | Y = y) = \sigma_X^2 (1 - \rho^2)$$

Observacions

1- Observem que la variància condicional o funció de regressió es lineal

$$E[Y | X = x] = \mu_Y + \rho \frac{\sigma_Y}{\sigma_X} (x - \mu_X) = \beta_0 + \beta_1 x$$

2- La variància condicionada no depèn del valor pel que condicinem

$$\text{Var}(Y | X = x) = (1 - \rho^2) \sigma_Y^2$$

3- Observem que la variable aleatòria esperança condicional $E[Y | X]$ segueix una idistribució normal

$$E[Y | X] \sim N(\mu_X, \rho^2 \sigma_Y^2)$$

4- Per la llei de la variància iterada

$$\text{Var}(Y) = \underbrace{E(\text{Var}(Y | X))}_{VNE} + \underbrace{\text{Var}(E(Y | X))}_{VE} \quad \text{on} \quad \rho^2 = \frac{VE}{VNE + VE}$$

El històric anàlisi de les dades de Francis Galton que posteriorment va formalitzar Karl Pearson sobre les estatures des pares i fills mesurades en polsades. Es sap que la distribució conjunta (X, Y) de les dues alçades de pares i fills segueix una llei normal bivariant. Estem interessats en predir l'alçada de un fill Y en dues situacions:

1- No tenim més informació que la distribució conjunta i per tant la predicció es μ_Y amb una variància σ_Y^2
 2- Coneixem l'alçada del pare $X=X$, llavors la predicció serà $E[Y | X = x] = \mu_Y + \sigma_Y \rho \frac{x - \mu_X}{\sigma_X}$ i variància $\sigma_Y^2(1 - \rho^2) < \sigma_Y^2$. La variància no depen de x i per tant l'error es independent de l'alçada del pare.

Asumim els valors de la distribució normal bivariada $\mu_X = 68.3, \sigma_X = 10.8, \mu_Y = 68.1, \sigma_Y = 2.5$ i $\rho = 0.5$ la distribució és:

$$\begin{pmatrix} X \\ Y \end{pmatrix} \sim N \left(\begin{pmatrix} 68.3 \\ 68.1 \end{pmatrix}, \begin{pmatrix} 1.8^2 & 0.5 \times 1.8 \times 2.5 \\ 0.5 \times 1.8 \times 2.5 & 2.5^2 \end{pmatrix} \right)$$

Si resollem les qüestions pendents

1- El pes mitjà predit és 68.1 polsades amb una variància de $2.5^2 = 6.25$ 2- Suposant que l'alçada del pare es de 69 polsades, llavors la predicció de l'alçada del fill es $y = 68.1 + 2.5 \cdot 0.5 \frac{69 - 68.1}{1.8} = 68.725$ amb variància $2.5^2 \cdot (1 - 0.5^2) = 4.6875$

3.1.3 Distribució normal multivariant

Definició 3.4. Distribució normal multivariant

Sigui un vector aleatori $X = (X_1, \dots, X_n)$ on $\mu' = (\mu_1, \dots, \mu_n)$ és el vector de mitjanes o valors esperats i $|\Sigma|$ es el determinant de la matriu de variàncies covariàncies Σ que pren el valor

$$\Sigma = \begin{bmatrix} \sigma_1^2 & \sigma_{12} & \dots & \sigma_{1(n-1)} & \sigma_{1n} \\ \sigma_{12} & \sigma_2^2 & \dots & \sigma_{2(n-1)} & \sigma_{2n} \\ \vdots & \vdots & \ddots & \vdots & \vdots \\ \sigma_{1(n-1)} & \sigma_{2(n-1)} & \dots & \sigma_{n-1}^2 & \sigma_{(n-1)n} \\ \sigma_{1n} & \sigma_{2n} & \dots & \sigma_{(n-1)n} & \sigma_n^2 \end{bmatrix}$$

Podem generalitzar la distribució de densitat normal bivariada al cas multivariant com

$$f(x_1, \dots, x_n) = \frac{|\Sigma|^{-\frac{1}{2}}}{(2\pi)^{\frac{n}{2}}} e^{-\frac{1}{2}(\mathbf{x}-\mu)'\Sigma^{-1}(\mathbf{x}-\mu)}, \quad (x_1, \dots, x_n) \in \mathbb{R}^n$$

Si les components del vector son independents, les covariàncies sontotes nul·les i Σ es una matriu diagonal amb elements les variancies de cada component . Així $|\Sigma|^{-1} = \frac{1}{\sigma_1^2 \sigma_2^2 \dots \sigma_n^2}$ A més la forma quadràtica de la equació (3.4) es simplifica i la densitat és:

$$f(x_1, x_2, \dots, x_n) = \frac{1}{\prod_{i=1}^n (2\pi\sigma_i^2)^{\frac{1}{2}}} e^{-\frac{1}{2}\sum_{i=1}^n \left(\frac{x_i - \mu_i}{\sigma_i}\right)^2} = \prod_{i=1}^n \left[\frac{1}{\sqrt{2\pi\sigma_i^2}} e^{-\frac{1}{2}\left(\frac{x_i - \mu_i}{\sigma_i}\right)^2} \right]$$

que no es més que el producte de les densitats de les normals de cadascuna de les components. Per tant en el cas multivariant també la incorrelació implica independència.

La forma quadràtica de l'exponent en una distribució normal multivariant (coneguda com la distància de Mahalanobis) es redueix a la suma clàssica de residus al quadrat ponderats per la variància:

$$(\mathbf{x} - \mu)^T \Sigma^{-1} (\mathbf{x} - \mu) = \sum_{i=1}^n \left(\frac{x_i - \mu_i}{\sigma_i} \right)^2$$

3.2 Distribucions especials: Multinomial, t-Student multivariant, Khi-quadrat, Wishart i Dirichlet.

3.2.1 Distribució Multinomial

En nombroses ocasions observem dades discretes que tenen tres o més valors possibles. La família de distribucions multinomial es una extensió de la família de distribucions binomial, conduint a una distribució multivariant.

Exemple 3.2. Es coneix que hi ha quatre tipus de sang humana, O, A, B i AB. Es selecciona una mostra de persones donants de sang al atzar i podem estar interessats en conèixer la probabilitat de observar un número determinat de cada tipus de sang.

En general, suposem que la població conté k ítems diferents ($k \geq 2$) i la proporció en la població de cada tipus i és $p_i, i = 1, \dots, k$. Assumim que $p_i > 0$ i $\sum_{i=1}^k p_i = 1$. Així, $\mathbf{p} = (p_1, \dots, p_k)$ és el vector de probabilitats. Sigui X_i la variable aleatòria que quantifica el número de ítems seleccionats en n extraccions del tipus i . Si les n extraccions s'han seleccionat amb repetició, la selecció serà independent una d'altra. Si tenim x_i observacions de tipus i en un determinat ordre, al ser independents les extraccions, la probabilitat de la seqüència és $p_1^{x_1} p_2^{x_2} \dots p_k^{x_k}$.

El número de seqüències diferents amb $x_1, x_2, \dots, x_k$ de cada tipus és

$$\binom{n}{x_1, x_2, \dots, x_k} = \frac{n!}{x_1! x_2! \dots x_k!}$$

Definició 3.5. Distribució multinomial

Sigui $\mathbf{X} = (X_1, \dots, X_k)$ el vector aleatori discret on $\mathbf{x} = (x_1, \dots, x_k)$ és el vector de recomptes observats de cada tipus $i, i = 1, \dots, k$ on $\mathbf{p} = (p_1, \dots, p_k)$ és el vector de probabilitat de cadascuna dels ítems. Direm que $\mathbf{X}$ segueix una distribució multinomial amb paràmetres n i $\mathbf{p}$ si la funció de distribució conjunta és:

$$f(\mathbf{x}|n, \mathbf{p}) = \Pr(\mathbf{X} = \mathbf{x}) = \Pr(X_1 = x_1, \dots, X_k = x_k)$$

$$= \begin{cases} \binom{n}{x_1, \dots, x_k} p_1^{x_1} \dots p_k^{x_k} & \text{if } x_1 + \dots + x_k = n, \\ 0 & \text{en la resta} \end{cases}$$

Exemple 3.3. Si recordem l'exemple 3.2 i es sap que $P(O) = 0.479, P(A) = 0.360, P(B) = 0.123$ i $P(AB) = 0.038$ i es seleccionen dues persones de la població, quina és la probabilitat de que les dues siguin del mateix tipus. A partir de la definició de probabilitat

$$P(X_O = 2) + P(X_A = 2) + P(X_B = 2) + P(X_{AB} = 2) = \binom{2}{2, 0, 0, 0} (0.479^2 + 0.360^2 + 0.123^2 + 0.038^2) = 0.376$$

Theorem 3.2. Supposem el vector aleatori $\mathbf{X} = (X_1, X_2)$ que té una distribució multinomial amb $n = 2$ i $\mathbf{p} = (p_1, p_2)$ llavors $X_1 \sim \text{Bi}(n, p_1)$ i $X_2 = n - X_1$

Demostració

De la definició de distribució binomial esta clar que $X_2 = n - X_1$ i $p_2 = 1 - p_1$. Així que el vector $\mathbf{X}$ està actualment determinat per una variable singular X_1 . A partir de la distribució binomial s'observa que X_1 que és la variable que representa el número de ítems tipus 1 seleccionats de n ítems on hi han 2 tipus de ítems. Així X_1 es el número d'esdeveniments de n experiments Bernoulli amb probabilitat del èxit de cada experiment de p_1 . Així es segueix que $X_1 \sim Bi(n, p_1)$

Corollary 3.1. *Si $\mathbf{X} = (X_1, \dots, X_k)$ es un vector aleatorio amb parametres n i $\mathbf{p} = (p_1, \dots, p_k)$. La distribució marginal de cada variable $X_i, i = 1, \dots, k$ segueix una distribució binomial amb parametre n i p_i*

Corollary 3.2. *Si $\mathbf{X} = (X_1, \dots, X_k)$ es un vector aleatorio amb parametres n i $\mathbf{p} = (p_1, \dots, p_k)$ amb $k \geq 2$. Si $\ell < k$ i $i_1, \dots, i_\ell$ un subconjunt de elements de $(1, \dots, k)$ La distribució de $Y = Y_1 + \dots + Y_k$ segueix una distribució binomial amb parametre n i $p_{i_1} + \dots + p_{i_\ell}$*

Theorem 3.3. Esperances, Variàncies i covariàncies

Suposem el vector aleatori $\mathbf{X} = (X_1, \dots, X_k)$ que té una distribució multinomial amb parametres n i $\mathbf{p} = (p_1, \dots, p_k)$ amb $k \geq 2$, llavors els valors esperats, variàncies i covariàncies son

$$\begin{aligned} E[X_i] &= np_i \\ \text{Var}(X_i) &= np_i(1 - p_i) \\ \text{Cov}(X_i, X_j) &= -np_i p_j \end{aligned}$$

Segons hem vist en el corol·lari 3.1 la distribució marginal de cada component es binomial i el valor de l'esperança i la variància son els de l'enunciat del teorema.

Per el corol·lari @ref(cor:agregació) sabem que $X_i + X_j$ segueix una distribució binomial amb parametres n i $p_i + p_j$. D'ací

$$\text{Var}(X_i + X_j) = n(p_i + p_j)(1 - p_i - p_j)$$

Per altra banda de la equació (1.4.3) sabem que

$$\begin{aligned} \text{Var}(X_i + X_j) &= \text{Var}(X_i) + \text{Var}(X_j) + 2\text{Cov}(X_i, X_j) \\ &= np_i(1 - p_i) + np_j(1 - p_j) + 2\text{Cov}(X_i, X_j) \end{aligned}$$

igualant les equacions anterior i despejant $\text{Cov}(X_i, X_j)$ obtenim el resultat desitjat

$$\begin{aligned} \text{Cov}(X_i, X_j) &= \frac{1}{2}n(p_i + p_j)(1 - p_i - p_j) - np_i(1 - p_i) - np_j(1 - p_j) \\ &= \frac{n}{2}[(p_i + p_j) - (p_i + p_j)^2 - p_i + p_i^2 - p_j + p_j^2] \\ &= \frac{n}{2}[(p_i + p_j - p_i^2 - p_j^2 - 2p_i p_j - p_i + p_i^2 - p_j + p_j^2)] \\ &= \frac{n}{2}(-2p_i p_j) = -np_i p_j \end{aligned}$$

Cal reseñar que la covariància de la distribució multinomial és negativa, el que és natural donat que les n observacions s'han de distribuir en k tipus de ítems. Si augmenta el número de observacions d'un tipus ha de disminuir el de l'altre donat que la grandària es fixa.

3.2.2 Distribució t-student multivariant

La distribució t-Student multivariant es una generalització de la distribució t-de Student unidimensional. Al igual que aquella serveix pel càlcul de intervals de confiança per a vectors però també per l'ús como distribuciones posteriores en estadísticas bayesianes i el anàlisis conjunt de variables biomèdiques i de finances.

Definició 3.6. Distribució t-student multivariant

Segui $\mathbf{X} = (X_1, \dots, X_n)$ un vector aleatori de dimensió n , direm que $\mathbf{X}$ segueix una distribució t-multivariant amb mitjana el vector $\mu = (\mu_1, \dots, \mu_n)$, amb la matriu de variàncies-covariàncies Σ i ν graus de llibertat

$$\mathbf{X} \sim t(\mu, \Sigma, \nu)$$

si i només si la funció de densitat de probabilitat és:

$$t(x; \mu, \Sigma, \nu) = \sqrt{\frac{1}{(\nu\pi)^n |\Sigma|}} \frac{\Gamma((\nu+n)/2)}{\Gamma(\nu/2)} \left[1 + \frac{1}{\nu} (x - \mu)^T \Sigma^{-1} (x - \mu) \right]^{-(\nu+n)/2}$$

on $\Gamma(\cdot)$ es la funció Gamma $\Gamma(z) = \int_0^\infty x^{z-1} e^{-x} dx$

Proposició 3.3. Si el vector aleatori $\mathbf{X} \sim t(\mu, \Sigma, \nu)$ és distribuït com una distribució t-multivariant, la distribució marginal de qualsevol subvector m -dimensional $\mathbf{X}_s$ subconjunt del vector $\mathbf{X}$ segueix una distribució t-multivariant amb vector de mitjanes μ_s i una matriu de variàncies Σ eliminant els valors de les variables no incloses en el subvector.

Demostració

Definim els subconjunt de dimensió $m \times n$ tal que $s_{ij} = 1$ si el j -èsim element de $\mathbf{X}_s$ correspon al i -èsim element de $\mathbf{X}$ i 0 en altre cas. Així $\mathbf{X}_s = S\mathbf{X}$

Podem aplicar el teorema de la transformació lineal a l'expressió anterior així

$$\mathbf{X}_s \sim t(S\mu, S\Sigma S^T, \nu)$$

Si operem es pot veure que $S\mu = \mu_s$ i $S\Sigma S^T = \Sigma_s$

Corol·lari 3.3. Si $m=1$ en la proposició @marginalt implica que la distribució marginal de una t-multivariant es una distribució t amb mitjana μ_i i variància σ_i^2

Definició 3.7. Segui $\mathbf{X} = (X_1, \dots, X_n)$ un vector aleatori de dimensió n , direm que $\mathbf{X}$ segueix una distribució t-multivariant standard amb ν graus de llibertat, si la funció de densitat es

$$t(x; n) = \sqrt{\frac{1}{(\nu\pi)^n}} \frac{\Gamma((\nu+n)/2)}{\Gamma(\nu/2)} \left[1 + \frac{1}{\nu} x^T x \right]^{-(\nu+n)/2}$$

La distribució de la distribució t-multivariant standard es una distribució t-univariada standar amb ν graus de llibertat. Es pot deduir directament que el valor esperat es el vector nul $E[\mathbf{X}] = \mathbf{0}$ i que la matriu de variància es $Var(\mathbf{X}) = \frac{\nu}{\nu-2} I$ on I es la matriu identitat $k \times k$

3.2.3 Distribució khi-quadrat

La distribució khi-quadrat (χ^2) és una distribució de probabilitat molt utilitzada en la resolució de tests de bondat d'ajustament i en altres proves estadístiques. S'utilitza principalment per comparar les freqüències observades amb les freqüències esperades, analitzant les diferències entre ambdues de manera quadràtica. En aquesta secció introduïrem la distribució a partir de vectors aleatoris.

Definició 3.8. Distribució Khi-quadrat Segui $\mathbf{X} = (X_1, \dots, X_k)$ un vector aleatori de variables aleatòries normals amb mitjana $\mu_i = 0$ i variància $\sigma_i^2 = 1$ es a dir $X_i \sim N(0, 1)$ i $\mathbf{X} \sim N_n(0, \mathbf{I})$ llavors

$$Y = \mathbf{X}^T \mathbf{X} = \sum_{i=1}^k X_i^2 \sim \chi^2(k) \quad 0 < k < \infty$$

Theorem 3.4. La funció de densitat de la variable definida en (3.8) viene definida por

$$f_Y(y) = \frac{1}{2^{k/2}\Gamma(k/2)} y^{k/2-1} \exp[-y/2]$$

Demostració

Per fer la demostració en primer lloc demostrarem que la distribució χ_1^2 és un cas particular de una distribució Gamma con paràmetres $\alpha = \beta = 1/2$

1. Cas Base ($k = 1$): Densitat de $Y = X_1^2$

Sigui $X_1 \sim N(0, 1)$ on la seva funció de densitat serà:

$$f_{X_1}(x) = \frac{1}{\sqrt{2\pi}} e^{-x^2/2}$$

Volem trobar la densitat de la transformació $Y = X_1^2$. Llavors la funció de probabilitat acumulada serà $y > 0$:

$$F_Y(y) = P(Y \leq y) = P(X_1^2 \leq y) = P(-\sqrt{y} \leq X_1 \leq \sqrt{y})$$

Per la simetria respecte al zero de la distribució normal estàndard, podem reescriure-ho com:

$$F_Y(y) = 2 \cdot P(0 \leq X_1 \leq \sqrt{y}) = 2 \int_0^{\sqrt{y}} \frac{1}{\sqrt{2\pi}} e^{-x^2/2} dx$$

Derivem respecte a y per obtenir la seva densitat $f_Y(y)$:

$$f_Y(y) = \frac{d}{dy} F_Y(y) = 2 \cdot \left(\frac{1}{\sqrt{2\pi}} e^{-(\sqrt{y})^2/2} \right) \cdot \frac{d}{dy} (\sqrt{y})$$

$$f_Y(y) = \frac{2}{\sqrt{2\pi}} e^{-y/2} \cdot \frac{1}{2\sqrt{y}} = \frac{1}{\sqrt{2\pi}} y^{-1/2} e^{-y/2}$$

Sabent que la funció Gamma compleix que $\Gamma(1/2) = \sqrt{\pi}$ i que $\sqrt{2} = 2^{1/2}$, podem reescriure l'expressió anterior com:

$$f_Y(y) = \frac{1}{2^{1/2}\Gamma(1/2)} y^{1/2-1} e^{-y/2}$$

Aquesta expressió coincideix exactament amb la definició d'una distribució **Gamma** amb paràmetre de forma $\alpha = 1/2$ i paràmetre d'escala $\beta = 1/2$. Per tant:

$$Y = X_1^2 \sim \text{Gamma} \left(\alpha = \frac{1}{2}, \beta = 2 \right)$$

2. Generalització per a k variables (La variable d'interès és la suma de k normals estàndard al quadrat independents:

$$Y = \sum_{i=1}^k X_i^2$$

Atès que cada component $X_i^2 \sim \text{Gamma}(\frac{1}{2}, \frac{1}{2})$, apliquem la propietat d'additivitat per a variables Gamma independents. Quan s'utilitza la parametrizació per escala, la suma de variables amb la mateixa escala β dona lloc a una nova variable Gamma on els paràmetres de forma α se sumen i els de escala β es manté constant:

$$\alpha_{\text{total}} = \sum_{i=1}^k \alpha_i = \sum_{i=1}^k \frac{1}{2} = \frac{k}{2} \quad \text{i} \quad \beta = \frac{1}{2}$$

D'aquesta manera, obtenim que la suma total es distribueix com:

$$Y \sim \text{Gamma}\left(\alpha = \frac{k}{2}, \beta = \frac{1}{2}\right)$$

Substituïm finalment els paràmetres $\alpha = \frac{k}{2}$ i $\beta = \frac{1}{2}$ en la definició original $f(y|\alpha, \beta) = \frac{\beta^\alpha}{\Gamma(\alpha)} y^{\alpha-1} e^{-\beta y}$:

$$f_Y(y) = \frac{(1/2)^{k/2}}{\Gamma(k/2)} y^{k/2-1} e^{-\frac{1}{2}y}$$

Operant el terme constant del numerador $(\frac{1}{2})^{k/2} = \frac{1}{2^{k/2}}$, arribem exactament a l'expressió del Teorema

$$f_Y(y) = \frac{1}{2^{k/2} \Gamma(k/2)} y^{k/2-1} \exp[-y/2]$$

El valor esperat de la distribució $Y \sim \chi^2(k)$ és $E[Y] = k$ i $\text{Var}(Y) = 2k$

3.2.4 Distribució de Whishart

La distribució de Whishart, que deu el seu nom al estadístic escocès John Whishart que la va formular en 1928, es molt utilitzada en el anàlisi de matrius de covariància estimadas i en estadística Bayesiana. La distribució de Whishart es la generalització multivariant de la distribució χ^2 univariada.

Definició 3.9. Distribució de Whishart Sigui $\mathbf{X}$ una matriu $n \times p$ que segueix una distribució de matriu normal amb mitjana 0, independent a lo llarg de les files i covarianza entre les columnes Σ es a dir

$$\mathbf{X} \sim \mathcal{MN}_{n \times p}(\mathbf{0}, \mathbf{I}_n, \Sigma)$$

Definim la matriu $\mathbf{S}$ com el producte de $\mathbf{X}$ i la seva trasposada

$$\mathbf{S} = \mathbf{X}^T \mathbf{X} = \sum_{i=1}^n \mathbf{x}_i^T \mathbf{x}_i$$

Llavors la matriu $\mathbf{S}$ es diu que segueix la funció de distribució Wishart amb escala la matriu $\mathbf{V}$ i el graus de llibertat n

$$\mathbf{S} \sim \mathcal{W}_p(\Sigma, n)$$

On $n > p-1$ i $\mathbf{V}$ es una matriu simetrica definida positiva $p \times p$

Exemple 3.4. Suposem que volem estudiar **3 característiques físiques** de **5 persones**:

- Alçada (cm)
- Pes (kg)
- Pressió arterial sistòlica (mmHg)

Les dades observades són:

Persona	Alçada (cm)	Pes (kg)	Pressió (mmHg)
1	170	68	120
2	165	62	118
3	180	80	130
4	175	75	125
5	168	65	119

En aquest cas:

- $n = 5$: nombre d'observacions (persones).
- $p = 3$: nombre de variables.

La matriu de dades és

$$X = \begin{pmatrix} 170 & 68 & 120 \\ 165 & 62 & 118 \\ 180 & 80 & 130 \\ 175 & 75 & 125 \\ 168 & 65 & 119 \end{pmatrix}.$$

Per poder assumir que la matriu segueix una distribució normal matricial amb mitjana nul·la, primer es centren les dades restant la mitjana de cada columna.

Les mitjanes són:

- Alçada: 171.6 cm,
- Pes: 70 kg,
- Pressió: 122.4 mmHg.

La matriu centrada és

$$X_c = \begin{pmatrix} -1.6 & -2 & -2.4 \\ -6.6 & -8 & -4.4 \\ 8.4 & 10 & 7.6 \\ 3.4 & 5 & 2.6 \\ -3.6 & -5 & -3.4 \end{pmatrix}.$$

En aquesta matriu:

- cada **fila** representa una persona;
- les **files** es consideren independents entre si;
- les **columnes** poden estar correlacionades. Per exemple, persones més altes acostumen a tenir també un pes més elevat. Aquesta dependència queda descrita per la matriu de covariàncies Σ .

Finalment, es calcula

$$S = X_c^T X_c,$$

que és una matriu 3×3 de sumes de productes creuats. Si les files de X_c segueixen una distribució normal multivariant,

$$X_i \sim N_3(0, \Sigma)$$

aleshores

$$S \sim W_3(5, \Sigma)$$

és a dir, S segueix una distribució de **Wishart** amb 5 graus de llibertat i matriu de covariàncies Σ .

Si $\mathbf{S} \sim \mathcal{W}_p(\Sigma, n)$ llavors

$$E[M] = n\Sigma$$

i si σ_{ij} es l'element ij - *sim* de Σ i el ij - *sim* element de $\mathbf{S}$ es s_{ij} llavors

$$\text{Var}(m_{ij}) = n(\sigma_{ij}^2 + \sigma_{ii}\sigma_{jj})$$

La demostració surt directament de la definició de la variable

Si $\mathbf{S} \sim \mathcal{W}_p(\Sigma, n)$ i $\mathbf{A}$ és una matriu es fixa $q \times p$ llavors

$$\mathbf{A}\mathbf{S}\mathbf{A}^T \sim \mathcal{W}_q(\mathbf{A}\Sigma\mathbf{A}^T, n)$$

Demostració

De la definició, sea $s = \sum_{i=1}^n X_i X_i^T$ on $X_i \sim N_p(\mathbf{0}, \Sigma)$ llavors ## Propietats de la Distribució Wishart

$$\mathbf{A}\mathbf{S}\mathbf{A}^T = \mathbf{A} \left(\sum_{i=1}^n \mathbf{x}_i \mathbf{x}_i^T \right) \mathbf{A}^T = \sum_{i=1}^n (\mathbf{A}\mathbf{x}_i)(\mathbf{A}\mathbf{x}_i)^T = \sum_{i=1}^n \mathbf{y}_i \mathbf{y}_i^T$$

on definim els nous vectors com:

$$\mathbf{y}_i = \mathbf{A}\mathbf{x}_i \sim N_q(\mathbf{0}, \mathbf{A}\mathbf{A}^T)$$

Aplicant la definició de la distribució Wishart als vectors independents $\mathbf{y}_1, \dots, \mathbf{y}_n$, obtenim directament que:

$$\sum_{i=1}^n \mathbf{y}_i \mathbf{y}_i^T \sim W_q(\mathbf{A}\mathbf{A}^T, n)$$

:::{.proposition}

Si $\mathbf{M}_1 \sim W_p(, n_1)$ i $\mathbf{M}_2 \sim W_p(, n_2)$ són dues matrius aleatòries independents, aleshores:

::: **Demostració**

$$\mathbf{M}_1 + \mathbf{M}_2 \sim W_p(, n_1 + n_2)$$

A partir de la definició de la distribució Wishart, podem representar la primera matriu $\mathbf{M}_1$ com:

$$\mathbf{M}_1 = \sum_{i=1}^{n_1} \mathbf{x}_i \mathbf{x}_i^\top$$

I la segona matriu $\mathbf{M}_2$ (que és independent) com:

$$\mathbf{M}_2 = \sum_{i=n_1+1}^{n_1+n_2} \mathbf{x}_i \mathbf{x}_i^\top$$

on tots els vectors $\mathbf{x}_i \sim N_p(\mathbf{0}, \Sigma)$ són independents i idènticament distribuïts per a $i = 1, \dots, n_1 + n_2$.

Si sumem ambdues matrius, obtenim:

$$\mathbf{M}_1 + \mathbf{M}_2 = \sum_{i=1}^{n_1} \mathbf{x}_i \mathbf{x}_i^\top + \sum_{i=n_1+1}^{n_1+n_2} \mathbf{x}_i \mathbf{x}_i^\top = \sum_{i=1}^{n_1+n_2} \mathbf{x}_i \mathbf{x}_i^\top$$

Atès que aquesta expressió és la suma de productes externs de $n_1 + n_2$ vectors normals multivariants independents de mitjana zero i matriu de covariàncies Σ , per la definició mateixa de la distribució Wishart es compleix que:

$$\mathbf{M}_1 + \mathbf{M}_2 \sim W_p(\Sigma, n_1 + n_2) \quad \blacksquare$$

3.2.5 Distribució Dirichlet

La distribució de Dirichlet $Dir(\alpha)$ és una família de probabilitat multivariant parametritzada per un vector α de reals positius. Aquesta distribució es una generalització de la distribució Beta univariant i el seu ús es molt habitual como prior en estadística bayesiana, en l'ús de processament del llenguatge natural (NLP) ó en estudis de simulació d'utilització de recursos.

Definició 3.10. Distribució de Dirichlet

Sigui $\mathbf{X} = (X_1, \dots, X_k)$ un vector aleatori de dimensió k tal que $x_i \in [0, 1] \quad \forall i \in (1, \dots, k] \quad i \quad \sum_{i=1}^k x_i = 1$. Aquest vector segueix una distribució de Dirichlet $\mathbf{X} \sim Dir(\alpha)$ on $\alpha = (\alpha_1, \dots, \alpha_k)$ si la funció de densitat ve donada per

$$f(x_1, \dots, x_k; \alpha_1, \dots, \alpha_k) = \frac{1}{B(\alpha)} \prod_{i=1}^k x_i^{\alpha_i-1}$$

on

$$B(\alpha) = \frac{\prod_{i=1}^k \Gamma(\alpha_i)}{\Gamma(\sum_{i=1}^k \alpha_i)}$$

i Γ es la funció Gamma

Els moments de la distribució Dirichlet son els següents. Per simplificar les expressions utilitzarem $\{ \theta \}_{i=1}^k$

$$E[X_i] = \frac{\alpha_i}{\sum_{i=1}^k \alpha_i} = \frac{\alpha_i}{\alpha_0}$$

$$\begin{aligned} Var[X_i] &= \frac{\alpha_i(\sum_{i=1}^k \alpha_i - \alpha_i)}{(\sum_{i=1}^k \alpha_i)^2(\sum_{i=1}^k \alpha_i + 1)} = \frac{\alpha_i(\alpha_0 - \alpha_i)}{\alpha_0^2(\alpha_0 + 1)} \\ Cov[X_i, X_j] &= \frac{-\alpha_i \alpha_j}{(\sum_{i=1}^k \alpha_i)^2(\sum_{i=1}^k \alpha_i + 1)} = \frac{-\alpha_i \alpha_j}{\alpha_0^2(\alpha_0 + 1)} \end{aligned}$$

Finalment la distribució marginal de les components de la distribució de Dirichlet són distribucions Beta.

$$X_i \sim \text{Beta}(\alpha_i, \alpha_0 - \alpha_i)$$

El resultat s'obté directament de la proposició de la propietat d'agregació de la distribució Dirichlet.

Proposició 3.4. Propietat de agregació *Si $\mathbf{X}$ un vector aleatori de dimensió k que segueix una distribució de Dirichlet $(X_1, \dots, X_k) \sim \text{Dir}(\alpha_1, \dots, \alpha_k)$. Si les variables i i j són eliminades i reemplaçades per la seva suma la variable resultant es una distribució Dirichlet també.*

$$(X_1, \dots, X_i + X_j, \dots, X_k) \sim Dir(\alpha_1, \dots, \alpha_i + \alpha_j, \alpha_k)$$

3.3 Propietat d'aggregació de la distribució de Dirichlet

Resta provar aquest lema. Sense pèrdua de generalitat, només cal demostrar-ho per a $r = 2$. Calculem directament la funció de densitat de probabilitat (FDP) de $Y = (X_1 + X_2, X_3, \dots, X_K)$:

$$f_Y(y_1, x_3, \dots, x_{K-1}) = \int_0^{y_1} f_X(y_1 - x_2, x_2, x_3, \dots, x_{K-1}) dx_2$$

Aplicant el canvi de variable $x_2 = y_1 u$ (on $dx_2 = y_1 du$), obtenim:

$$\begin{aligned} f_Y(y_1, x_3, \dots, x_{K-1}) &= \frac{\Gamma(\sum_{i=1}^K \alpha_i)}{\prod_{i=1}^K \Gamma(\alpha_i)} \left(\prod_{i=3}^{K-1} x_i^{\alpha_i-1} \right) x_K^{\alpha_K-1} \int_0^1 (y_1 - y_1 u)^{\alpha_1-1} (y_1 u)^{\alpha_2-1} y_1 du \\ &= \frac{\Gamma(\sum_{i=1}^K \alpha_i)}{\prod_{i=1}^K \Gamma(\alpha_i)} \left(\prod_{i=3}^{K-1} x_i^{\alpha_i-1} \right) x_K^{\alpha_K-1} y_1^{\alpha_1+\alpha_2-1} \int_0^1 u^{\alpha_2-1} (1-u)^{\alpha_1-1} du \\ &= \frac{\Gamma(\sum_{i=1}^K \alpha_i)}{\Gamma(\alpha_1 + \alpha_2) \prod_{i=3}^K \Gamma(\alpha_i)} y_1^{\alpha_1+\alpha_2-1} \left(\prod_{i=3}^{K-1} x_i^{\alpha_i-1} \right) x_K^{\alpha_K-1} \end{aligned}$$

la qual cosa implica que Y segueix la distribució $\text{Dir}(\alpha_1 + \alpha_2, \alpha_3, \dots, \alpha_K)$. ■

3.4 Generació de mostres de distribucions multivariants.

3.4.1 Revisió de mètodes de generació de mostres de variables aleatòries univariants

En l'assignatura de probabilitat I es van introduir els principals mètodes de generació de mostres de variables aleatòries univariants. En aquest apartat anem a generalitzar aquests mètodes al cas multivariant a més de introduir-ne d'algun nou. En general qualsevol algorisme de generació de dades aleatòries segueix el mateix esquema.

- 1- Generem una o més números aleatories provinents de distribucions uniformes i.i.d. $U(0,1)$
- 2- Transformem i relacionem els valors de la distribució uniforme depenen de la distribució a estudi

3- Retornem el valor X de la distribució desitjada

Mètode de la inversió

Aquest mètode es basa en generar un número aleatori u entre 0 i 1 a partir de la distribució uniforme $U(0, 1)$ i de la trobar X tal que la funció de distribució acumulada $F_X(x) = U$, es a dir que $X = F_X^{-1}(u)$.

El principal problema d'aquest mètode es la disposició de una formulació directa de la inversa de la funció de distribució.

Així, l'algorisme és:

1- Genera un valor u de una distribució $U(0, 1)$

2.- Obten el valor $x = F_X^{-1}(u)$

Mètode de la acceptació-rebuig

Aquest mètode s'utilitza quan no es pot (o no es vol) invertir la funció de distribució F_X . Sigui $f(x)$ la funció de densitat de la distribució de la que es vol generar una mostra. Suposem que tenim un altre tipus de variable aleatòria Y amb una densitat $g()$ que es fàcil de simular, per exemple una distribució Normal o Uniforme. A més es sap que existeix una constant M . Tal que

$$\frac{f(x)}{g(x)} \leq M \quad \forall x, \text{ és a dir } f(x) \leq M g(x)$$

L'algorisme segueix els següents passos

1- Genera el valor y de la v.a. Y

2- Genera un valor u de una $U(0,1)$

3- Si $u \leq \frac{f(y)}{Mg(y)}$ accepta $x=y$

4- En cas contrari torna al pas 1 i torna a seleccionar un valor aleatori.

Mètodes de transformacions específics

Mètode de Box-Muller

El algorisme utilitza 2 i.i.d. $U(0, 1)$ per produir 2 i.i.d. $N(0, 1)$:

1- Genera U_1 i U_2 de dos distribucione i.i.d. $U(0, 1)$

2- Calcula $X = \sqrt{-2\log(U(0, 1)\cos(2\pi U_2))}$ i $Y = \sqrt{-2\log(U(0, 1)\sin(2\pi U_2))}$ on Z_1 i Z_2 son dues $N(0, 1)$

Transformació Gamma com a suma d'exponencials (convolució)

Es sap que si $E_i \sim \text{Exp}(\lambda)$, llavors $\sum_{i=1}^k E_i \sim \text{Gamma}(k, \lambda)$

El algorisme serà el següent

1- Obten k valors de una $U(0, 1)$

2- Utilitzant el mètode de la inversió obten k valors e_i de una $\text{Exp}(\lambda)$

3- Suma els valors e_i y obten el valor $x = \sum_{i=1}^k e_i$ de la distribució Gamma

Métodos de MonteCarlo

Realment no son uns mètodes de càlcul de mostra sino que son tècniques de simulació per aproximar quantitats com probabilitats, valors esperats, integrals , variàncies a partir de mostres simulades.

La idea bàsica es que si $\{X_1, \dots, X_N\}$ son variables i.i.d llavors

$$E[h(x)] \approx \frac{1}{N} \sum_{i=1}^N h(X_i)$$

3.4.2 Generació de variables aleatòries multivariants utilitzant distribució condicional

Suposem que donat un Vector aleatori $(X_1, \dots, X_k)$ coneguem la funció de distribució conjunta i les distribucions marginals $F_i(x_i), i = 1, \dots, k$ i les distribucions condicionals $F_j(x_j | X_1, \dots, X_{j-1})$

El algorisme es el següent utilitzant en cada pas l'algorisme d'inversió univariant

- 1- Genera x_1 (marginalment) de $F_1(x_1)$
- 2- Genera x_2 (condicionalment de $F_2(x_2 | x_1)$)
- 3- Genera x_3 (condicionalment de $F_3(x_3 | x_1, x_2)$...
- k- Genera x_k (condicionalment de $F_k(x_k | x_1, x_2, \dots, x_{k-1})$)
- k+1- Retorna el vector $\mathbf{x} = (x_1, \dots, x_k)^T$

Exemple 3.5. Normal Bivariant

Volem generar observacions d'un vector aleatori bidimensional $(X_1, X_2)^T \sim N_2(\mu, \Sigma)$ amb:

$$\mu = \begin{pmatrix} 0 \\ 0 \end{pmatrix}, \quad \Sigma = \begin{pmatrix} 1 & \rho \\ \rho & 1 \end{pmatrix} \quad (|\rho| < 1)$$

Sabem que

- Marginal de X_1 : $X_1 \sim N(0, 1) \implies F_1(x_1) = \Phi(x_1)$
- Condicional de $X_2 | X_1 = x_1$: $X_2 | X_1 = x_1 \sim N(\rho x_1, 1 - \rho^2)$

Si apliquem la generalització del algorisme d'inversió condicional

Per generar un parell (x_1, x_2) :


1. **Pas 1 (Generar x_1):**
 - Generem $U_1 \sim U(0, 1)$.
 - Apliquem la inversió: $x_1 = F_1^{-1}(U_1) = \Phi^{-1}(U_1)$.
2. **Pas 2 (Generar $x_2 | X_1 = x_1$):**
 - Generem $U_2 \sim U(0, 1)$ independent de U_1 .
 - Apliquem la inversió ajustant per x_1 :

$$x_2 = F_2^{-1}(U_2 | x_1) = \rho x_1 + \sqrt{1 - \rho^2} \cdot \Phi^{-1}(U_2)$$

Implementació en R

```
##           X1           X2
## X1 0.9436775 0.7727192
## X2 0.7727192 0.9971821
```

Simulació i Contorns d'una Normal Bivariant (rho = 0.8)



3.4.3 Generació de vectors aleatoris de una distribució normal multivariant

Suposem que desitjem generar $\mathbf{X} = (X_1, \dots, X_k)$ on $X \sim MN_k(\mathbf{0}, \Sigma)$. Si els valors esperats no són zero no més caldria centrar cadascuna de les variables X_i per que siguin 0 els valors esperats. Sigui $\mathbf{Z} = (Z_1, \dots, Z_k)^T$ on Z_i són i.i.d $N(0, 1)$ per $i = 1, \dots, k$. Si $\mathbf{C}$ és una matriu $(k \times k)$ es segueix que

$$\mathbf{C}^T \mathbf{Z} \sim MVN(\mathbf{0}, \mathbf{C}^T \mathbf{C})$$

L'únic problema és trobar una funció $\mathbf{C}$ tal que $\mathbf{C}^T \mathbf{C} = \Sigma$. Podem utilitzar la descomposició de Cholesky de Σ per trobar la matriu $\mathbf{C}$.

Descomposició de Cholesky de una matriu simètrica definida positiva

Un resultat conegut de l'àlgebra que una matriu simètrica definida-positiva M , pot escriure's com $M = U^T D U$ on U és una matriu triangular superior i D és una matriu diagonal amb elements diagonals positius. Com que M és definida positiva

$$= U^T D U = (U^T \sqrt{D})(\sqrt{D} U) = (\sqrt{D} U)^T (\sqrt{D} U)$$

Així la matriu $\mathbf{C} = \sqrt{D} U$ que satisfà $\mathbf{C}^T \mathbf{C} = \Sigma$ que és la descomposició de Cholesky.

Així a l'hora de simular la distribució el algoritme funciona de la següent manera.

- 1- Genera el vector de normals estàndard $Z_i \sim N(0, 1) i = 1, \dots, k$
- 2- Calcula $\mathbf{C}$ según la descomposició de Cholesky tal que $\Sigma = \mathbf{C} \mathbf{C}^T$

3.- Calcula $\mathbf{X} = \mathbf{C}^\top \mathbf{Z}$

Simulació d'una Normal Bivariant mitjançant la Descomposició de Cholesky

Assumim les dades del exemple 3.5 on simulavem dades d'una distribució binormal

Donada la matriu de covariàncies $\Sigma = \begin{pmatrix} 1 & \rho \\ \rho & 1 \end{pmatrix}$, la seva factorització de Cholesky $\Sigma = \mathbf{C}\mathbf{C}^\top$ produeix la matriu triangular inferior:

$$\mathbf{C} = \begin{pmatrix} 1 & 0 \\ \rho & \sqrt{1-\rho^2} \end{pmatrix}$$

Multiplicant aquesta matriu per un vector $\mathbf{Z} = (Z_1, Z_2)^\top$ de normals estàndard independents ($Z_1, Z_2 \stackrel{iid}{\sim} N(0, 1)$), s'obté:

$$\begin{pmatrix} X_1 \\ X_2 \end{pmatrix} = \mathbf{C} \begin{pmatrix} Z_1 \\ Z_2 \end{pmatrix} = \begin{pmatrix} Z_1 \\ \rho Z_1 + \sqrt{1-\rho^2} Z_2 \end{pmatrix}$$


(Observem que s'obté exactament la mateixa relació que en el mètode de les condicionals).

Implementació en R

```
##           X1           X2
## X1 0.9598590 0.7725724
## X2 0.7725724 0.9671766
```

Simulació Normal Bivariant via Descomposició de Cholesky

$\mu = (0,0)$, $\rho = 0.8$



4 Processos estocàstics: Introducció i conceptes bàsics

4.1 Definició de procés estocàstic.

En el curs de probabilitat I es van estudiar les successions de variables aleatòries, es a dir col·leccions infinites numerables de variables aleatòries i es va centrar l'interès en les diferents convergències d'aquestes variables, sobretot utilitzant la llei dels grans nombres i el teorema central del Límit. En aquell moment no es varen analitzar les relacions entre les variables de la successió i altres. En aquest tema introduïrem el concepte de procés estocàstic. De tota manera cal resenyar que el concepte de procés estocàstic va més enllà de les successions de variables. Es tracta d'un conjunt de variables aleatòries on pot estar indexat per un conjunt no numerable.

Un exemple seria l'estudi de l'ocurrència de un mateix esdeveniment al llarg del temps. Si aquestes ocurrences són independents i el tema d'interès es el temps que transcorreix entre esdeveniments, parlarem de la successió $\{X_n\}$ on X_i =(temps que passa entre l'esdeveniment i - i el $i+1$). Però si el que ens interessa es el nombre de vegades que l'esdeveniment ha succeït en l'interval $[0, t]$, la família a considerar es N_t , amb $t > 0$ desde luego no es numerable.

Definició 4.1. Procés estocàstic

Un procés estocàstic es una col·lecció de variables aleatòries $\{X_t, t \in T\}$ definides sobre un espai de probabilitat $(\Omega, \mathcal{A}, P)$.

T es un subconjunt de $\mathbb{R}$ que s'anomena **conjunt d'índexs**. S'utilitza la lletra t donat que l'estudi de processos estocàstics surt del estudi de l'evolució temporal de fenòmens aleatoris.

El conjunt de valors $S \subseteq \mathbb{R}$ que poden prendre les variables aleatòries X_t s'anomena **espai d'estats** del procés.

Amb freqüència l'índex $t \in T$ que ordena les variables aleatòries del procés correspon al temps i X_t és l'estat del sistema en estudi a l'instant t .

Exemple 4.1. En una botiga de roba el 65% de les persones que entren compren algo. En una hora entren 30 clients en la botiga. El proceso que indica si el client compra o no compra es un procés estocàstic bernoulli

$$X_t = \begin{cases} 1, & \text{si el client } t \text{ realitza una compra,} \\ 0, & \text{si el client } t \text{ no realitza una compra.} \end{cases}$$

Si històricament el 65 % dels clients realitzen una compra i suposem que les decisions de comprar dels clients es independent una de l'altra, aleshores

$$X_t \sim \text{Bernoulli}(0.65),$$

Els resultats es mostren en el següent gràfic.

Exemple 4.2.




Figura 17: Exemple Commpra Botiga de roba

4.2 Exemple 5.2

Un jugador comença amb **10 euros** i juga consecutivament **20 partides**. En cada partida aposta 1 euro a cara o creu.

Denotem per X_t els diners que té el jugador després d'haver jugat t partides, on

$$t = 0, 1, \dots, 20. \quad X_0 = 10$$

En cada partida:

- amb probabilitat $1/2$ guanya 1 euro;
- amb probabilitat $1/2$ perd 1 euro.

Per tant,

$$X_{t+1} = \begin{cases} X_t + 1, & \text{amb probabilitat } 1/2, \\ X_t - 1, & \text{amb probabilitat } 1/2. \end{cases}$$

En aquest exemple s'observen dues possibles realitzacions del procés estocàstic. Tot i que els dos jugadors comencen amb el mateix capital inicial i juguen el mateix nombre de partides, les seves trajectòries són diferents perquè el resultat de cada partida és aleatori.




Figura 18: Exemple de proceso del jugador arruinado

Exemple 4.3. Suposem que els pacients arriben a un servei d'urgències d'un hospital de manera aleatòria al llarg del temps. Sigui

$$X(t) = \text{nombre de pacients arribats fins a l'instant } t, \quad t \geq 0.$$

Si les arribades segueixen una distribució de Poisson amb una intensitat $\lambda = 3$ pacients per hora, com que t es continu $X(t) \sim \text{Poisson}(\lambda t)$

En el gràfic es mostra una realització del procés en les primeres 8 hores. La trajectòria és una funció esglaiada: roman constant entre dues arribades consecutives i augmenta una unitat cada vegada que arriba un nou pacient.




Figura 19: Exemple de nombre d'urgències per temps

Exemple 4.4. En una prova d'esforç es mesura el consum d'oxigen d'un esportista (VO_2) cada segon durant 10 minuts i es recull en un procés estocàstic $X(t) = \text{valor del } VO_2 \text{ en l'instant } t$

En aquest exemple suposem que el consum d'oxigen augmenta progressivament durant l'exercici i que presenta fluctuacions aleatòries.

La línia blava representa una possible realització del procés corresponent a les mesures de VO_2 . La línia vermella discontinua representa la tendència mitjana esperada durant l'exercici. En aquest cas es representa una sèrie temporal biomèdica on clarament les observacions no són independents

Evolució del consum d'oxigen durant una prova d'esforç




Figura 20: Exemple de nombre d'urgències per temps

Un procés estocàstic també pot ser considerat com una funció aleatòria de doble argument $\{X(t, \omega), t \in T, \omega \in \Omega\}$. Si fixem $\omega = \omega_0$ tindrem una *realització* del procés $X(., \omega_0)$ cuya representació gràfica son les anomenades *trajectòries del procés* que hem representant en els 4 gràfics anteriors.

Si per contra fixem $t = t_0$ estarem parlant de la variable aleatòria $X_{t_0} = X(t_0, .)$ que es la distribució de la variable de interès en el punt d'observació t

4.2.1 Funcions de moment un procés estocàstic

Com a variable aleatòria de dos dimensions podem definir les següents funcions característiques de un procés estocàstic $\mathbf{X} = \{X_t\}_{t \in T}$

Funció mitjana d'un procés estocàstic

Es defineix com la funció

$$\mu_X(t) = E[X_t], t \in T = \begin{cases} \sum_{x \in D_{X_t}} x P(X_t = x) & \text{si } X_t \text{ és discret} \\ \int_{-\infty}^{+\infty} x f_t(x) dx & \text{si } X_t \text{ és continu} \end{cases}$$

Funció de autocorrelació

La funció de autocorrelació del procés $\mathbf{X} = \{X_t\}_{t \in T}$ es defineix com el valor esperat del producte de les variables aleatòries X_{t_1} i X_{t_2} en els instants t_1 i t_2 respectivament, és a dir

$$R(t_1, t_2) = E[X_{t_1} X_{t_2}] = \begin{cases} \sum_{x_1 \in D_{X_{t_1}}, x_2 \in D_{X_{t_2}}} x_1 x_2 P(X_{t_1} = x_1, X_{t_2} = x_2), & \text{si } X_t \text{ és discret,} \\ \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} x_1 x_2 f_{X_{t_1}, X_{t_2}}(x_1, x_2) dx_1 dx_2, & \text{si } X_t \text{ és continu.} \end{cases}$$

Funció de autocovariància

A partir del moment central conjunt de dues variables associades a dos temps qualsevol, t_1 i t_2 , l'autocovariància és

$$C(t_1, t_2) = E[(X_{t_1} - \mu(t_1))(X_{t_2} - \mu(t_2))]$$

ràpidament es dedueix la relació entre la autocorrelació i la autocovariància

$$C(t_1, t_2) = R(t_1, t_2) - \mu(t_1)\mu(t_2)$$

en el cas particular que $t_1 = t_2 = t$ parem de la *funció de variància* $\sigma^2(t) = C(t, t)$

Finalment definim la funció de correlació com

$$\rho(t_1, t_2) = \frac{C(t_1, t_2)}{\sqrt{\sigma^2(t_1)\sigma^2(t_2)}}$$

que obviamente pren valors entre $[-1, 1]$ - En el cas de les series temporals es reserva el nom de autocorrelació per aquesta funció.

4.3 Processos estocàstics discrets i continus.

Els processos estocàstics es poden classificar en funció del tipus de variables T i X_t

X_t	T Discret	T Continu
Discret	Cadena	Proc. puntual
Continu	Suc. de v.a.	Proc. continu

-Un procés discret amb el temps discret, que s'anomena cadena, seria l'exemple 4.1 on es veia en 30 clients que entraven en una botiga si compraven o no

-Un procés continu en un temps discret s'anomena un succeïció de variables. Si en el cas anterior en lloc de mesurar si compra o no compra haguessim mesurat l'alçada o el pes del client seria un bon exemple

-Un procés puntual com el de l'exemple 4.3 on es mesura el número de urgències en un determinat temps és el cas on el procés es discret però el temps és continu.

-El procés continu és aquell en el que la variable és continua i el temps també. És el cas de l'exemple 4.4 on es mesura el VO_2 d'un esportista en 10 minuts d'esforç

4.4 Processos estocàstics estacionaris i no estacionaris.

Definició 4.2. Distribucions finito-dimensionals En general les variables aleatòries del procés $\mathbf{X} = \{X_t\}_{t \in T}$ no són independents entre elles. Si $\{t_1, t_2, \dots, t_n\} \subset T$ és un subconjunt finit de qualsevol dels índexs, la distribució conjunta del vector $(X_{t_1}, X_{t_2}, \dots, X_{t_n})$ vindrà donada per

$$F_{t_1, t_2, \dots, t_n}(x_1, \dots, x_n) = P(X_{t_1} \leq x_1, X_{t_2} \leq x_2, \dots, X_{t_n} \leq x_n)$$

Aquesta distribució rep el nom de distribució finito-dimensional del procés. També es poden expressar aquestes distribucions a partir de les funcions de densitat i probabilitat conjuntes del vector.

Un procés estocàstic es pot descriure especificant les seves distribucions finito-dimensionals, que permeten obtenir la probabilitat de qualsevol esdeveniment involucrat en el procés. Cal remarcar que el conjunt de distribucions finito-dimensionals no determinen per complet les característiques del procés, i en ocasions cal definir certes característiques o propietats addicionals. Si el procés es pot especificar completament a partir de les distribucions finites, es diu que el procés és *separable*.

Definició 4.3. Processos de variables independents

Sea $\mathbf{X} = \{X_t\}_{t \in T}$ es diu que és un procés estocàstic de variables aleatòries independents si X_m i X_n són independents per a tota $n, m \in T$ amb $n \neq m$

L'exemple 4.1 del procés on es vol saber si un client que entra en una botiga compra o no es tracta de un procés de variables independents

Definició 4.4. Processos amb increments independents

Sea $\mathbf{X} = \{X_t\}_{t \in T}$ es diu que és un procés estocàstic que té increments independents si per a qualsevol $t_0 < t_1 < \dots < t_n$, $t_i \in T$ les variables aleatòries:

$$X_{t_1} - X_{t_0}, X_{t_2} - X_{t_1}, \dots, X_{t_n} - X_{t_{n-1}}$$

són independents.

En l'exemple 4.3 sobre el nombre d'urgències, el número de urgències en la primera hora és independent del de la segona hora i de la tercera hora.

Definició 4.5. Processos estacionaris forts

El procés $\mathbf{X} = \{X_t\}_{t \in T}$ es fortament estacionari si les famílies de les variables aleatòries

$$(X_{t_1}, X_{t_2}, \dots, X_{t_n}) \quad (i) \quad (X_{t_1+h}, X_{t_2+h}, \dots, X_{t_n+h})$$

tenen la mateixa distribució conjunta per a tot $h > 0$, tots $\{t_1, \dots, t_n\} \subset T$ i $n \geq 1$

Theorem 4.1. *La funció mitjana d'un procés estocàstic estacionari es constant*

Demostració

$$\mu_X(t) = \int_{-\infty}^{+\infty} x f_t(x) dx = \int_{-\infty}^{+\infty} x f(x) dx = m(x)$$

Més en general, qualsevol propietat de una variable singular d'un procés estacionari es invariant al temps

Definició 4.6. Processos estacionaris dèbil

El procés $\mathbf{X} = \{X_t\}_{t \in T}$ es dèbilment estacionari si per a tot t_1 i $t_2 \in T$ i tot $h > 0$,

$$E[X_{t_1}] = E[X_{t_2}] \quad \text{i} \quad Cov(X_{t_1}, X_{t_2}) = Cov(X_{t_1+h}, X_{t_2+h})$$

– Una forma equivalent de definir l'estacionarietat dèbil és dir que un procés es dèbilment estacionari si i només si te esperança constant i la covariància entre X_{t_1} i X_{t_2} només depen de $t_2 - t_1$. La estacionarietat dèbil implica la estacionarietat forta.

5 Principals tipus de Processos estocàstics.

5.1 Cadenes de Markov.

Text aquí.

5.2 Caminades aleatòries.

Text aquí.

5.3 Processos de Poisson.

Text aquí.

5.4 Moviment Brownià.

Text aquí.