

Probabilitat II

Santi Perez-Hoyos

Índex

Pla docent	2
Dades generals	2
Hores	2
Competències / Resultats d'aprenentatge que es desenvolupen	2
Objectius d'aprenentatge	3
Blocs Temàtics i Continguts Detallats	3
Metodologia i activitats formatives	4
Avaluació acreditativa dels aprenentatges	4
1 Variables aleatòries multivariades	6
1.1 Definició i conceptes bàsics: vectors aleatoris, espais de probabilitat	6
1.2 Funcions de densitat i de distribució conjuntes.	13
1.3 Funcions de densitat i de distribució marginals i condicionades.	22
1.4 Moments multivariants: vector d'esperances, matriu de variància-covariància	31
1.5 Transformacions de variables multivariants	35
2 Independència de variables aleatòries	40
2.1 Independència i dependència entre variables aleatòries.	40
2.2 Esperances i variàncies condicionades.	42
2.3 Conceptes de covariància, correlació i causalitat	49
3 Algunes distribucions multivariants	54
3.1 Distribució normal multivariant: definició, propietats i aplicacions.	54
3.2 Distribucions especials: Multinomial, t-Student multivariant, Khi-quadrat, Wishart i Dirichlet.	62
3.3 Generació de mostres de distribucions multivariants.	71
4 Processos estocàstics: Introducció i conceptes bàsics	76
4.1 Definició de procés estocàstic.	76
4.2 Processos estocàstics discrets i continus.	81
4.3 Processos estocàstics estacionaris i no estacionaris.	82

5 Principals tipus de Processos estocàstics.	83
5.1 Cadenes de Markov.	83
5.2 Passeig o Caminades aleatòries.	95
5.3 Processos de Poisson.	100
5.4 Moviment Brownià.	104

Pla docent

L'assignatura pretén proporcionar una base sòlida en l'estudi de variables aleatòries multivariants i processos estocàstics, amb èmfasi en la comprensió teòrica, les propietats fonamentals i les aplicacions pràctiques en camps com la ciència de dades, les finances, les biociències i l'enginyeria.

Dades generals

Nom de l'assignatura	Probabilitat II
Codi de l'assignatura	
Curs Acadèmic	2026/2027
Coordinació	Santi Pérez Hoyos
Departament	Departament de Genètica, Microbiologia i Estadística
Crèdits	6
Programa Únic	S

Hores

Activitats	Tipus de formació	Hores
Activitats presencials i/o no presencials		60
- Teoria	Presencial	30
- Pràctiques de problemes	Presencial	30
Treball tutelat/dirigit		40
Aprenentatge autònom		50

Competències / Resultats d'aprenentatge que es desenvolupen

- Competències

C05. - Aplicar los conocimientos y habilidades a situaciones prácticas

C12. Detectar situacions en què els models estadístics i d'investigació operativa poden ser útils per a la presa de decisions.

C14. Adaptar els models teòrics a les necessitats específiques de les diferents àrees d'aplicació.

- Habilitats i destreses

H04. Plantejar una pregunta científica en termes estadístics.

H06. Identificar les fonts de variabilitat i incertesa que afecten la presa de decisions

- Coneixements i continguts

K03. Reconèixer la teoria de la probabilitat com a fonament de les tècniques estadístiques.

Objectius d'aprenentatge

Referits a Coneixements	Referits a habilitats, destreses
- Conèixer els conceptes de variables aleatòries multivariants i les seves components - Conèixer els conceptes de independència, covariància i correlació - Conèixer les principals models multivariants i les seves propietats, i identificar els seus àmbits d'aplicació - Conèixer el concepte de procés estocàstic i les seves propietats bàsiques. - Conèixer els principals tipus de processos estocàstics i identificar les situacions reals a les quals són aplicables.	- Calcular probabilitats a partir dels models de vectors aleatoris - Calcular densitats marginals i conjuntes i funcions de vectors aleatoris - Calcular matrius de covariàncies, correlacions i moments de variables aleatòries multivariants - Calcular probabilitats i generar dades de les principals distribucions - Determinar matrius de transició d'una cadena de Markov amb epai d'estats finits - Aplicació dels principals tipus de processos estocàstics

Blocs Temàtics i Continguts Detallats

1. Variables aleatòries multivariants

- Definició i conceptes bàsics: vectors aleatoris, espais de probabilitat.
- Funcions de densitat i de distribució conjuntes.
- Funcions de densitat i de distribució marginals i condicionades.
- Moments multivariants: vector d'esperances, matriu de variància-covariància.
- Transformacions de variables multivariants.

2. Independència de variables aleatòries

- Independència i dependència entre variables aleatòries.
- Esperances i variàncies condicionades.
- Conceptes de covariància, correlació i causalitat.

3. Algunes distribucions multivariants

- Distribució normal multivariant: definició, propietats i aplicacions.
- Distribucions especials: Multinomial, t-Student multivariant, Wishart, Chi-quadrat i Dirichlet.
- Generació de mostres de distribucions multivariants.

4. Processos estocàstics: Introducció i conceptes bàsics

- Definició de procés estocàstic.
- Processos estocàstics discrets i continus.
- Processos estocàstics estacionaris i no estacionaris.

5. Principals tipus de Processos estocàstics.

- Cadenes de Markov.
- Caminades aleatòries.
- Processos de Poisson.
- Moviment Brownià.

Metodologia i activitats formatives

El pla docent es desglossa en els següents tipus metodològics bàsics: activitats presencials, treball dirigit (com ara el lliurament de problemes o l'estudi de casos pràctics de seguiment automatitzat) i treball autònom. Les categories desglossades són:

1. Classes de teoria. Dues sessions setmanals (durant 15 setmanes) en que es presenten els conceptes més teòrics de l'assignatura. Es miren amb detalls demostracions, contingut i desenvolupament amb la resolució de situacions o problemes típics amb un enfocament pràctic
2. Classes pràctiques. Sessions de dues hores setmanals (durant 15 setmanes) L'alumant disposa al principi de cada tema de una col·lecció de problemes i exercicis pràctics. A la finalització de cada tema es deixen les solucions en el Campus Virtual. El professorat comenta les diferents formes d'abordar els problemes i resol en la pissara un classe exercicis tipus. A vegades es deixa temps a la mateixa classe perquè l'alumant pugui resoldre algun problema.

Les sessions pràctiques tindran lloc durant 15 setmanes al semestre en una sessió setmanal de 2 hores. En aquestes sessions el grup es divideix en dos subgrups que rebran la docència al mateix horari per part de dos professors. L'assignació d'alumnes als grups la fa el professorat.

A més, regularment es proposen qüestionaris en el Campus Virtual que cal fer de manera telemàtica i lliurar a través del Campus Virtual la setmana següent. En alguns dels qüestionaris es demana que es lliurin els càlculs i procediments, que cal lliurar a les classes de problemes. Aquests lliuraments, igual que la resta de qüestionaris, s'avaluen.

3. Activitats no presencials dirigides. Amb el suport d'eines informàtiques amb correcció automatitzada (qüestionaris de Moodle que es duen a terme des del Campus Virtual), es fa un seguiment del treball autònom de l'estudiant (40 hores d'activitats dirigides no presencials en total).
4. Treball autònom de l'estudiant per acabar de consolidar tots els conceptes donats (50 hores en total).

Es fa servir el Campus Virtual com a repositori del material del curs i també per concretar les activitats proposades. Alguns dels lliuraments de feines es fan directament en el Campus Virtual.

S'espera que l'alumnat assisteixi a classe sempre, ja que una assistència irregular dificulta l'assoliment de les competències que l'assignatura es marca com a objectius.

Avaluació acreditativa dels aprenentatges

Avaluació continuada

Es l'opció recomanada per als estudiants que assisteixen regularment i que consta de tres parts.

- 1.- **Lliurament dels questionaris** proposats en el Campus Virtual (Quest)

2.- **Examen parcial** en acabar el tema 2 que no elimina materia (Parcial)

3.- **Examen final** que coincideix amb la data d'avaluació única segons la data marcada pel Consell Docent. (Final)

Els examens parcial i final tenen la mateixa estructura, amb una pregunta teòrica i entre 2 i 4 problemes. La teoria tindrà un valor entre el 20% el 30%.

La qualificació global de l'assignatura és:

$$\text{Global} = 0.1 \cdot \text{Màx}(\text{Quest}, \text{Final}) + 0.3 \cdot \text{Màx}(\text{Parcial}, \text{Final}) + 0.6 \cdot \text{Final}$$

sempre que la nota de l'examen final sigui com a mínim de 4 (sobre 10); en cas contrari la qualificació global de l'assignatura és la nota de l'examen final. Per tant, la nota dels lliuraments i la del parcial es tenen en compte (amb pesos respectius del 10 % i del 30 % de la qualificació global) només si són superiors a la nota de l'examen final.

La nota de la reavaluació no té en compte la nota dels lliuraments setmanals ni la de l'examen parcial; per tant, és simplement la nota de l'examen de reavaluació.

Avaluació única

L'alumnat pot optar entre dues formes d'avaluació: avaluació continuada o avaluació única. Qui vulgui renunciar a l'avaluació continuada i acollir-se a l'avaluació única ha de fer-ho abans de la data que s'estableixi, i que es fa pública amb antelació suficient.

La prova d'avaluació única consta de dues parts: teoria (amb un pes entre el 20% i el 30 %) i problemes (amb un pes entre el 70% i el 80 %). Els continguts d'aquesta prova són semblants (en temàtica i dificultat) als explicats a les classes presencials. Aquesta prova avalua les competències de l'assignatura i es fa en la data fixada pel Consell Docent (abans del període de matriculació de l'alumnat).

1 Variables aleatòries multivariades

1.1 Definició i conceptes bàsics: vectors aleatoris, espais de probabilitat

1.1.1 Introducció

A qualsevol que se li preguntí quin temps es triga en recórrer els 280 quilòmetres de distància entre Barcelona i Castelló, si es circula a una velocitat constant de 120km/h, ens indicaria que en 2 hores i 20 minuts arribaríem a la destinació. Ara bé, si se li pregunta quin serà el resultat de llançar un dau no tindria una resposta clara.

- El primer resultat prové d'un fenomen o **experiència determinista**. N'hi ha prou amb extreure de l'equació $e = v \cdot t$ el valor del temps
- El segon pertany a la categoria dels fenòmens o **experiències aleatòries**. Es coneixen tots els resultats possibles, un número del 1 al 6 en el cas del dau, però no quin resultat es produirà, ja que de repetició en repetició sortiran resultats diferents.

1.1.2 Conceptes bàsics: Experiment aleatori, mesura de probabilitat

Definició 1.1. Un **experiment** és una seqüència d'accions que, en repetir-se sota les mateixes condicions, produeix resultats observables. Direm que l'experiment és **aleatori** si, executat sota les mateixes condicions, pot donar lloc a un resultat w d'entre un conjunt de possibles resultats.

Definició 1.2. L'**espai mostral** d'un experiment, denotat per Ω , és el conjunt de tots els resultats possibles.

Definició 1.3. Un **esdeveniment** es una col·lecció de possibles resultats d'un experiment, és a dir un subconjunt de $A \subseteq \Omega$. Quan el resultat de l'experiment pertany al esdeveniment ($w \in A$), direm que a ocorregut l'esdeveniment.

Exemple 1.1. Així si l'experiment és llançar un dau, l'espai mostral és

$$\Omega = \{1, 2, 3, 4, 5, 6\}$$

i un esdeveniment pot ser $A = \text{Treure un número senar}$. Si al llançar el dau surt un 3, l'experiment A ha ocorregut.

Definició 1.4. Una col·lecció $\mathcal{A} \subseteq \mathcal{P}(\Omega)$ és una **-àlgebra** si:

1. $\Omega \in \mathcal{A}$
2. Si $A \in \mathcal{A}$, aleshores $A^c \in \mathcal{A}$
3. Si $A_1, A_2, \dots \in \mathcal{A}$, aleshores $\bigcup_n A_n \in \mathcal{A}$

La σ -àlgebra representa “tot allò al que volem i podem assignar probabilitat”.

Exemple 1.2. Si suposem un experiment és triar a l'atzar un número en l'interval $[0,1]$, l'interès es centra en conèixer si l'elecció pertany a qualsevol dels subconjunts de $[0,1]$. La σ -lgebra $\beta_{[0,1]}$ d'esdeveniments generada a partir de tots els possibles subinterval de $[0,1]$, és coneguda com σ -lgebra de Borel estrictament menor que $\mathcal{P}(\Omega)$.

En resum, L'espai mostral ve acompanyat de la σ -lgebra mes convenient a l'experiment. La combinació $(\Omega, \mathcal{A})$ rep el nom d'**espai mesurable**

Definició 1.5. Mesura de Probabilitat

Donat un espai mostral Ω i una σ -lgebra $\mathcal{A}$ definim la mesura de probabilitat com una aplicació.

$$\begin{aligned} P : \mathcal{A} &\rightarrow \mathbb{R} \\ A &\mapsto Pr(A) \end{aligned}$$

on P compleix els axiomes de Kolmogorov

1. $P(A) \geq 0$, per tot $A \in \mathcal{A}$.
2. $P(\Omega) = 1$.
3. *Axioma d'additivitat numerable:*
Si $A_1, A_2, \dots, A_n \in \mathcal{A}$ es una successió d'esdeveniments disjunts dos a dos, llavors

$$P\left(\bigcup_{i=1}^n A_i\right) = \sum_{i=1}^n P(A_i)$$

Dels axiomes anteriors es segueixen totes les propietats de qualsevol mesura de probabilitat. En particular que la probabilitat de un esdeveniment ha de ser un número entre 0 i 1.

$$0 \leq P(A) \leq 1 \quad \text{per a tot } A \in \mathcal{A}.$$

Definició 1.6. Espai de probabilitat

A la terna $(\Omega, \mathcal{A}, Pr)$ l'anomenarem **ESPAI DE PROBABILITAT**.

Exemple 1.3. Espai de probabilitat discret uniforme

Suposem un espai mostral Ω , numerable i com a σ -lgebra la formada per tots els subconjunts de Ω . Definim un funció no negativa sobre tots els subconjunts de Ω on es verifica que $\sum_{w \in \Omega} p(w) = 1$. Si es defineix $P(A) = \sum_{w \in A} p(w)$, es pot comprovar que P es una probabilitat. Un cas particular son els espais de probabilitat discrets uniformes. Si $\Omega = w_1, w_2, \dots, w_n$ i $p(w_i) = \frac{1}{n}, \forall w_i \in \Omega$.

Si $A = w_1, w_2, \dots, w_m$ tenim que $P(A) = \frac{m}{n}$ (Fórmula de Laplace). Es diu uniforme per que la massa de probabilitat està repartida al ser constant en cada punt.

Per exemple imaginem que llancem dos daus. L'espai mostral serà $\Omega = (1, 1), (1, 2), (1, 3), \dots, (6, 5), (6, 6)$ format per les 36 parelles de resultats possibles. Si els daus no estan trucats, cada parella te la mateixa probabilitat $1/36$. Si es considera $A = \{\text{amb dues cares son senars}\}$ el número de possibilitats son 9 i per tant la probabilitat de A es $P(A) = 9/36 = 1/4$.

El resultat d'un experiment aleatori no es tant l'espai de probabilitat resultant, sino les característiques numèriques associades. Això implica passar de Ω a $\mathbb{R}$ o $\mathbb{R}^k$ on es més fàcil treballar. Com hem comentat en $\mathbb{R}$ podem parlar de la σ -lgebra de Borel β que és la menor que conté els intervals i que permet parlar de l'espai de probabilitat $(\mathbb{R}, \beta)$

1.1.3 Conceptes bàsics: Variable aleatòria, funcions de distribució i probabilitat.

Definició 1.7. Variable aleatòria

Si considerem dos espais de probabilitat $(\Omega, \mathcal{A})$ i $(\mathbb{R}, \beta)$, una **variable aleatòria** es una aplicació $X : \Omega \rightarrow \mathbb{R}$ que verifica que $X^{-1}(B) \in \mathcal{A} \ \forall B \in \beta$

Exemple 1.4. Quan llencem una moneda, habitualment identifiquem les dues cares amb els valors 0 i 1. Aquesta identificació és, de fet, una variable aleatòria:

$$X : \Omega \longrightarrow \mathbb{R}$$

$$\text{Cara} \longmapsto 0$$

$$\text{Creu} \longmapsto 1$$

Si la moneda no esta trucada la probabilitat de que sorti cara o creu al llançar la moneda es 0.5 respectivament, Així al fer la transferència entre espais de probabilitat $P(X = 0) = 0.5$ es el mateix que $P(X^{-1}(0) = P(\text{cara}) = 0.5$ i el mateix per $X=1$ $P(X = 1) = 0.5 = P(X^{-1}(1) = P(\text{creu})$.

Per expressar aquesta probabilitat podríem haver utilitzat un altra variable aleatòria que codificarà la cara com a 1 i la creu com a 2.

Definició 1.8. Distribució de probabilitat induïda Quan es fa intervenir una variable aleatòria és per que s'està en la presència d'un espai de probabilitat. La variable aleatòria trasllada la informació d'aquesta probabilitat de Ω a $\mathbb{R}$ mitjançant la probabilitat induïda coneguda com llei de probabilitat o distribució de probabilitat.

Així, la variable aleatòria X induïx sobre $(\mathbb{R}, \beta)$ la probabilitat P_X de la següent forma

$$P_X(A) = P(X^{-1}(A)) \quad \forall A \in \beta$$

P_X hereta les característiques de P a través de X . Sí X canvia a distribució de probabilitat pot canviar . Mirem-ho en un exemple.

Exemple 1.5. Si tornem a l'exemple de llançar dos daus podem definir dues variables aleatòries. X que sigui la suma dels resultats dels dos daus i Y que sigui la diferència dels resultats. Encara que les dues variables estan definides en el mateix espai de probabilitat, P_X i P_Y son diferents per que estan induïdes per variables diferents.

En cap cas la suma de les dues cares de un dau son 0, però ens 6 situacions les dues cares poden ser iguals. Si calculem amb els dues distribucions la probabilitat de que la variable aleatòria sigui 0, dona resultats diferents.

$$P_X(0) = P(X^{-1}(0)) = P(\emptyset) = 0$$

$$P_Y(0) = P(Y^{-1}(0)) = P(\{1, 1\}, \{2, 2\}, \{3, 3\}, \{4, 4\}, \{5, 5\}, \{6, 6\}) = \frac{6}{36} = \frac{1}{6}$$

Les distribucions de probabilitat com la P_X , encara que ens presenta la informació necessària per obtenir les probabilitats, son objectes matemàtics complexos d'utilitzar i es recorre a dos tipus de funcions associades, la Funció de distribució de probabilitat o la funció de probabilitat o densitat de probabilitat, depenen de la natura de la variable.

Definició 1.9. Funció de distribució de probabilitat

A partir de la probabilitat induïda podem definir sobre $\mathbb{R}$ la següent funció

$$F_X(x) = P_X((-\infty, x]) = P(X^{-1}\{(-\infty, x]\}) = P(X \leq x) \quad \forall x \in \mathbb{R} \quad (1)$$

La funció de distribució te les següents propietats

1. És una funció no negativa per la propia definició
2. És una funció monòtona ja que $F_X(x_1) \leq F_X(x_2)$ si $x_1 \leq x_2$
3. És una funció continua per la dreta . Es a dir si es considera una successió de números reals $x_n \rightarrow x$ llavors $\lim_{n \rightarrow \infty} F_X(x_n) = F_X(x)$
4. $\lim_{x \rightarrow \infty} F_X(x) = 1$ i $\lim_{x \rightarrow -\infty} F_X(x) = 0$

Del punt 3 es dedueix que si $(-\infty, x] = \{x\} \cup \lim_{n \rightarrow \infty} (-\infty, x - \frac{1}{n})$ la funció de distribució en X es

$$F_X(x) = P(X = x) + \lim_{n \rightarrow \infty} F_X(x - \frac{1}{n}) = P(X = x) + F(x^-)$$

y $F_X(x)$ es continua si $P(X=x)=0$

Directament es pot calcular la probabilitat d'un interval obert per l'esquerra com

$$P(a < X \leq b) = F_X(b) - F_X(a)$$

Exemple 1.6. Suposem que a un pacient se li indica que triï un nombre real entre 0 i 10 per indicar el seu nivell de dolor (Escala analògica Visual (EVA)) i que tots els valors tenen la mateixa probabilitat de ser triats.

Definim la variable aleatòria X com el nivell de dolor i es vol obtenir la funció de distribució que reflexa la probabilitat de que el nombre escollit sigui menor o igual que 3.

$$F_X(x) = P_X(X \leq x)$$

Si tots els valors son equiprobables la probabilitat seria la longitud de casos favorables partit per 10.

És a dir, si $x \in [0, 10]$ $F(x) = \frac{x}{10}$

La funció completa és

$$F_X(x) = \begin{cases} 0, & \text{si } x < 0 \\ \frac{x}{10}, & 0 \leq x \leq 10 \\ 1, & x > 10 \end{cases}$$

Definició 1.10. Funció de probabilitat d'una variable aleatòria discreta

X és una variable aleatòria discreta si $X(\Omega)$ es finit o numerable, és a dir es pot definir un conjunt suport $D_X = \{x_1, x_2, \dots, x_n\}$ tal que $P_X(D_X) = P(X \in D_X) = 1$ i $P(X = x) > 0$, $\forall x \in D_X$. Per tant es pot deduir que $P(X = x) = 0$, $\forall x \in D_X^c$.

Així la funció de distribució de la variable aleatòria discreta és:

$$F_x(x) = \sum_{x \leq x_i} P(X = x_i) \quad (2)$$

Que serà una funció continua en els intervals $[x_i, x_{i+1}[$ si els valors x_i estan endreçats de menor a major i que tindrà una discontinuïtat de salt finit en cada punt x_i de Valor $F_X(x_i) - F_X(x_{i-1}) = P(X = x_i)$

Així a la variable X li podem associar la funció de probabilitat següent

$$f_X(x) = \begin{cases} P(X = x), & \text{si } x \in D_X \\ 0, & \text{en la resta} \end{cases}$$

Exemple 1.7. Alguns exemples de variables aleatòries discretes que venen definides per les seves funcions de probabilitat son les que tenen una distribució Poisson, Binomial, Hipergeomètrica ó binomial negativa. La seva definició es pot trobar en l'annex del tema.

Definició 1.11. Funció de densitat o probabilitat d'una variable aleatòria continua

Una variable aleatòria X és continua si la seva funció de distribució F_X , es absolutament continua. A efectes pràctics disposem la funció de densitat $f_X(x)$, coneguda de manera que

$$F_X(x) = \int_{-\infty}^x f(t)dt$$

Així la probabilitat de qualsevol interval $]a, b]$ és

$$P(X \in]a, b]) = P(a < X \leq b) = \int_a^b f(x)dx$$

La funció de densitat $f_X(x)$ es no negativa i $P(X \in \mathbb{R}) = 1$

Per altra banda per una propietat de la integral de Riemann, la funció de densitat es la derivada de la Funció de distribució $f_X(x) = F'_X(x)$

Exemple 1.8. Alguns exemples de variables aleatòries continues que venen definides per les seves funcions de densitat probabilitat son les que tenen una distribució uniforme, Normal, Exponencial, Gamma entre altres. La seva definició es pot trobar en l'annex del tema.

1.1.4 Variable aleatòria k-dimensional o vector aleatori

Molts experiments aleatoris produeixen més d'una única quantitat rellevant, és a dir, més d'una variable aleatòria. Veïem alguns exemples

Exemple 1.9.

- Imaginem una situació on primer es llança una moneda amb resultats cara i creu, i després es llança un dau amb 6 resultats. Així tenim una variable aleatòria X_1 per a la moneda i una variable aleatòria X_2 per al dau. El vector en $\mathbb{R}^2$ (X_1, X_2) serà una variable aleatòria bidimensional compostat per dues variables aleatòries unidimensionals

Exemple 1.10.

- En economia podem estar interessats en conèixer la distribució d'ingressos d'una persona i per altra costat el % dels ingressos dedicats al pagament del habitatge (lloguer o hipoteca). Cada individu estarà representat per un vector compostat per dues variables unidimensionals

Exemple 1.11.

- En salut podem estar interessats en el resultat d'un experiment on es mesuren diferents paràmetres biomètrics com pes, alçada, índex cintura-maluc, índex de massa corporal, índex cintura-alçada, perímetre braquial, perímetre abdominal, superfície corporal, etc. Es tracta d'un vector multidimensional definit per k variables unidimensionals en $\mathbb{R}^k$.

Definició 1.12. Vector aleatori

Un vector aleatori $\mathbf{X} = (X_1, X_2, \dots, X_k)$, es una aplicació de l'espai mostral Ω en $\mathbb{R}^k$ tal que

$$\mathbf{X}^{-1}(B) \in \mathcal{A}, \quad \forall B \in \beta^K$$

On β^K es una *sigma - lgebra* de Borel en $\mathbb{R}^k$

$\mathbf{X}$ indueix sobre $(\mathbb{R}^k, \beta^K)$ una probabilitat P_X de la següent manera

$$P_X(B) = P(\mathbf{X}^{-1}(B)), \quad \forall B \in \beta^K$$

És senzill comprovar que P_X verifica els tres axiomes de probabilitat, pel que $(\mathbb{R}^k, \beta^K, P_X)$ permet indueix un espai de probabilitat amb les característiques de $(\Omega, \mathcal{A}, P)$ heretats mitjançant $\mathbf{X}$.

Definició 1.13. Variable aleatòria bidimensional o bivariant

Sigui $(\Omega, \mathcal{A}, P)$ un espai de probabilitat . Podem definir la variable aleatòria bivariant com

$$(X, Y) : \Omega \rightarrow \mathbb{R}^2$$
$$w \rightarrow (X, Y)(w) = (X(w), Y(w))$$

on

$$(X, Y)^{-1}((-\infty, x] \times (-\infty, y]) = \{w \in \Omega : X(w) \leq x \text{ i } Y(w) \leq y\} \in \mathcal{A} \quad \forall x \in \mathbb{R} \text{ i } \forall y \in \mathbb{R}$$

Com passa en el cas univariant es prou que $(X, Y)^{-1}((-\infty, x] \times (-\infty, y]) \in \mathcal{A} \quad \forall (x, y) \in \mathbb{R}^2$ per a garantir que $(X, Y)^{-1}(B) \in \mathcal{A} \quad \forall B \in \beta(\mathbb{R}^2)$

Per tant, qualsevol variable aleatòria bivariant (X, Y) induïx una mesura de probabilitat en $\mathbb{R}^2$ que permet assignar probabilitats a qualsevol subconjunt Borelià B de $\mathbb{R}^2$:

$$P_{(X, Y)}(B) = P((X, Y)^{-1}(B)) = P(\{w \in \Omega : (X(w), Y(w)) \in B\})$$

Aquesta mesura de probabilitat induïda s'anomena *distribució de probabilitat conjunta de (X, Y)*

Exemple 1.12. Tornem a l'exemple on llançàvem una moneda (X) i un dau (Y)

L'espai mostrat es $\Omega = (\{cara, 1\}, \{creu, 1\}, \{cara, 2\}, \dots, \{creu, 6\})$ i la Variable aleatòria (X, Y) pren el valor $X=0$ si és cara i $X=1$ si és creu en la primera component X i el número que ha sortit al dau en la segona component Y .

Podem definir

$$P_{XY}(x, y) = \begin{cases} 1/2 \times 1/6 = 1/12, & \text{si } x \in \{0, 1\} \text{ i } y \in \{1, 2, 3, 4, 5, 6\} \\ 0, & \text{en la resta} \end{cases}$$

Es pot demostrar que P_{XY} es una mesura de probabilitat ja que compleix els axiomes de Kolmogorov.

Definició 1.14. Variable aleatòria k- dimensional o multivariant

Si enlloc de 2 variables aleatòries unidimensionals generalitzem a n variables aleatòries, estarem parlant d'una Variable aleatòria n -dimensional o multivariant.

Sigui $(\Omega, \mathcal{A}, P)$ un espai de probabilitat . Podem definir la variable aleatòria multivariant $\vec{X} = (X_1, X_2, \dots, X_{k-1}, X_k)$

$$\begin{aligned} (\vec{X}) : \Omega &\rightarrow \mathbb{R}^k \\ w &\rightarrow (X_1, X_2, \dots, X_{k-1}, X_k)(w) = (X_1(w), X_2(w), \dots, X_{k-1}(w), X_k(w)) \end{aligned}$$

on

$$(\vec{X})^{-1}((-\infty, x_1] \times \dots \times (-\infty, x_k]) = \{w \in \Omega : X_1(w) \leq x_1 \text{ i } \dots \text{ i } X_k(w) \leq x_k\} \in \mathcal{A} \quad \forall x_i \in \mathbb{R}$$

Per tant qualsevol variable aleatòria multivariant $(\vec{X})$ induïx una mesura de probabilitat en $\mathbb{R}^k$ que permet assignar probabilitats a qualsevol subconjunt Borelià B de $\mathbb{R}^k$:

$$P_{(\vec{X})}(B) = P((\vec{X})^{-1}(B)) = P(\{w \in \Omega : (X_1(w), \dots, X_k(w)) \in B\})$$

El que hem de fer a partir d'ara es caracteritzar aquesta probabilitat conjunta a partir de les característiques de les variables aleatòries unidimensionals que la componen. Ja que si $(\vec{X})$ es mesurable també o es cadascuna de les seves components i viceversa. Per simplificar la nomenclatura definirem P_X a la probabilitat conjunta de la variable multidimensional $\vec{X}$ i per facilitar la comprensió utilitzarem la dimensió 2 i el vector aleatori $\vec{X} = (X, Y)$

1.2 Funcions de densitat i de distribució conjunes.

1.2.1 Funció de distribució conjunta

En els apartats anteriors hem definit la probabilitat conjunta associada a una variable multidimensional. Com en el cas unidimensional, podem caracteritzar aquesta probabilitat conjunta a partir de funcions conjunes de distribució o de densitat o de probabilitat segon siguin les variables.

Definició 1.15. Funció de distribució conjunta

Definim la funció de distribució associada a P_X a donat un punt de $\mathbb{R}^k$ $\mathbf{x} = (x_1, \dots, x_k)$ com

$$F_X(\mathbf{x}) = F_X(x_1, \dots, x_k) = P_X(S_x) = P(X \in S_x) = P\left(\bigcap_{i=1}^k \{X_i \leq x_i\}\right)$$

En la figura 1 es pot observar la diferència entre una distribució univariada que es una corba en dimensió 2 o la funció de distribució conjunta bivariada $F(x, y) = P(X \leq x, Y \leq y)$ que es tracta d'una superfície en dimensió 3.




Figura 1: Distribució continua bivariada

De la definició de funció de distribució conjunta es deriven les següents propietats:

No negativitat

Com a conseqüència que la funció de distribució conjunta es una probabilitat, pren valors entre 0 i 1 i per tant sempre seran valors no negatius.

Monotonia de cada component

Si $\mathbf{x} \leq \mathbf{y}$ es a dir $x_i \leq y_i$, $i = 1, \dots, k$, $S_x \subset S_y$ i $F_X(x) \leq F_Y(y)$

Continuïtat conjunta per la dreta

Si $\mathbf{x}(n) \rightarrow \mathbf{x}$ entones $F_X(\mathbf{x}^{(n)}) \rightarrow F_X(\mathbf{x})$

Valores límit

Al tendir a $\pm\infty$ les components del vector aleatori s'obté

$$\lim_{\forall x_i \rightarrow +\infty} F_X(x_1, \dots, x_k) = 1$$

ó

$$\lim_{\exists x_i \rightarrow -\infty} F_X(x_1, \dots, x_k) = 0$$

Aquestes propietats ja son conegudes per al cas unidimensional. Cal una cinquena propietat sense la que no es pot recórrer el camí invers d'obtenir P_X a partir de F_X i poder establir la desitjada equivalència entre tots dos conceptes que il·lustrarem en dimensió 2.

Proposició 1.1. *Regla del rectangle*

En aquesta regla calculem la probabilitat d'un rectangle a partir de les funcions de distribució conjunta en cada punt del rectangle que es pot veure en la figura 2

$$\left. \begin{array}{l} \forall (x, y) \in \mathbb{R}^2 \\ \forall h > 0 \\ \forall k > 0 \end{array} \right\} F_{X,Y}(x+h, y+k) - F_{X,Y}(x, y) - F_{X,Y}(x+h, y) - F_{X,Y}(x, y+k) = P_{X,Y}(A) = P_{X,Y}([x, x+h] \times [y, y+k]) > 0$$

Demostració.




Figura 2: Càlcul de la probabilitat d'un rectangle

$$S_{x+h,y+k} = S_{x,y} + A_1 + A_2 + A$$

on cadascú del conjunts de la part dreta son disjunts i per tant

$$P_{X,Y}(S_{x+h,y+k}) = P_{X,Y}(S_{x,y}) + P_{X,Y}(A_1) + P_{X,Y}(A_2) + P_{X,Y}(A)$$

si substituïm per la funció de distribució

$$\begin{aligned}
F_{X,Y}(x+h, y+k) &= F_{X,Y}(x, y) + P_{X,Y}(A_1) + P_{X,Y}(A_2) + P_{X,Y}(A) \\
A_1 &= S_{x+h, y} - S_{x, y} \\
\text{i per tant } P_{X,Y}(A_1) &= F_{X,Y}(x+h, y) - F_{X,Y}(x, y) \\
\text{donat que } S_{X,Y}(x, y) &\subset S_{X,Y}(x+h, y) \\
A_2 &= S_{x, y+k} - S_{x, y} \\
\text{i per tant } P_{X,Y}(A_2) &= F_{X,Y}(x, y+k) - F_{X,Y}(x, y) \\
\text{donat que } S_{X,Y}(x, y) &\subset S_{X,Y}(x, y+k)
\end{aligned}$$

Així, si substituïm

$$\begin{aligned}
P_{X,Y}(A) &= F_{X,Y}(x+h, y+k) - F_{X,Y}(x, y) - P_{X,Y}(A_1) - P_{X,Y}(A_2) \\
&= F_{X,Y}(x+h, y+k) - F_{X,Y}(x, y) - (F_{X,Y}(x+h, y) - F_{X,Y}(x, y)) - (F_{X,Y}(x, y+k) - F_{X,Y}(x, y)) \\
&= F_{X,Y}(x+h, y+k) + F_{X,Y}(x, y) - (F_{X,Y}(x+h, y) + F_{X,Y}(x, y)) - (F_{X,Y}(x, y+k) - F_{X,Y}(x, y)) > 0
\end{aligned}$$

Quedant demostrada la proposició

□

1.2.2 Variables aleatòries multivariants discretes

Definició 1.16. Funció de probabilitat conjunta.

Segui el vector aleatori $\vec{X} = (X_1, X_2, \dots, X_{k-1}, X_k)$, direm que es un vector aleatori discret si en el suport $D_X = (D_{X_1}, \dots, D_{X_k})$ cadascuna de les seves components D_{X_i} es una component numerable discreta. Així, es pot definir la funció de probabilitat conjunta associada i el seu valor per a cada punt de $\mathbb{R}^k$ ve donat per:

$$f_X(x_1, \dots, x_k) = \begin{cases} P(X_i = x_i), & \text{si } x = (x_1, \dots, x_k) \in D_X \\ 0, & \text{en la resta} \end{cases}$$

Com que es una probabilitat $f_X(x) \geq 0, \forall x \in \mathbb{R}^k$

Exemple 1.13. Si tornem a l'exemple del llençament de la moneda i el dau de l'exemple 1.9 podem definir la funció de probabilitat continua com el producte de la probabilitat d'obtenir el resultat al llençar la moneda ($1/2$) per la probabilitat de obtenir un resultat del dau, es a dir ($1/6$). Així $P_X Y(x_i, y_i) = 1/2 \times 1/6 = 1/12$

En la següent taula es mostra la funció de quantia o probabilitat. Per qualsevol valor no recollit en la taula $f_X Y(x, y) = 0$

$Y \backslash X$	Cara (0)	Creu (1)	$f_Y(y)$
1	1/12	1/12	1/6
2	1/12	1/12	1/6
3	1/12	1/12	1/6
4	1/12	1/12	1/6
5	1/12	1/12	1/6
6	1/12	1/12	1/6
$f_X(x)$	1/2	1/2	

Nota: en els marges de la taula es poden veure les funcions de probabilitat marginals que seran definides en la propera secció.

Proposició 1.2. Algunes propietats de la funció de probabilitat

Sigui $f(x, y)$ una funció de probabilitat de la variable bivariada (X, Y) tal que $(X, Y)(\Omega) = \{(x_i, y_i) \mid i \in I \subset \mathbb{N} \text{ i } j \in J \subset \mathbb{N}\}$

$$\sum_{(X, Y) \in \mathbb{R}^2} f(x, y) = \sum_{i \in I, j \in J} f(x_i, y_j) = 1$$

$$\forall B \in \mathcal{B}^2 \quad P(B) = \sum_{(X, Y) \in B} f(x, y) = \sum_{(i, j) \mid (x_i, y_j) \in B} f(x_i, y_j)$$

$$\forall (x_0, y_0) \in \mathcal{B}^2 \quad F(x, y) = \sum_{x \leq x_0, y \leq y_0} f(x, y) = \sum_{(i, j) \mid (x_i, y_j) \leq (x_0, y_0)} f(x_i, y_j)$$

1.2.3 Variables aleatòries multivariants continues**Definició 1.17. Funció de densitat conjunta de probabilitat d'una variable aleatòria multivariat absolutament continua**

Sigui $\vec{X} = (X_1, X_2, \dots, X_{k-1}, X_k)$ un vector aleatori on X_i es una variable aleatòria continua. Diguem que $\mathbf{X}$ és continu si i només si existeix una funció $f_X : \mathbb{R}^k \rightarrow [0, +\infty[$ tal que

$$P(X \in (a, b]) = P(a_i < X_i < b_i, i = 1, \dots, k) = \int_{a_k}^{b_k} \dots \int_{a_1}^{b_1} f_X(x_1, \dots, x_k) dx_1, \dots, dx_k$$

Com passava en el cas unidimensional aquesta funció té algunes propietats que cal remarcar.

$f_X(x)$ es no negativa

$$\text{donat que } P(X \in \mathbb{R}^k) = 1, \text{ llavors } \int_{-\infty}^{+\infty} \dots \int_{-\infty}^{+\infty} f_X(x_1, \dots, x_k) dx_1, \dots, dx_k = 1$$

Com a conseqüència de la definició hi ha una relació entre la funció de distribució conjunta de probabilitat F_X i la funció de densitat conjunta de probabilitat f_X .

$$F_X(x_1, \dots, x_k) = P_X(S_X) = \int_{-\infty}^{x_k} \dots \int_{-\infty}^{x_1} f_X(t_1, \dots, t_k) dt_1 \dots dt_k$$

y si $x \in \mathbb{R}^k$ es un punt de continuïtat de f_X ,

$$f(x_1, \dots, x_k) = \frac{\partial^k F_X(x_1, \dots, x_k)}{\partial x_1 \dots \partial x_k}$$

Exemple 1.14. En la figura 3 es pot observar la representació de la funció de densitat $f_{XY}(x, y)$ d'una variable aleatòria continua bivariada. La superfície de la gràfica es el valor de la funció la probabilitat ve determinada pel volum. Aquest volum ve calculat pel que s'anomena integral doble que te algunes especificitats que mostrarem en el següent apartat.

1.2.3.1 Integral doble Aquest apartat es pot considerar com un apèndix del contingut del temari. Introduïrem els conceptes d'integral doble, o més general d'integral de Lebesgue i com s'interpreta i com es calcula, ja que és necessari per obtenir la probabilitat en el cas de vectors aleatoris continus.

Definició 1.18. Sigui una funció $f : \mathbb{R}^2 \rightarrow \mathbb{R}$ una funció no negativa i D un subconjunt de $\mathbb{R}^2$. El volum sota el gràfic de la superfície que genera funció f restringida a aquest conjunt D (veure Figura 4) es pot obtenir calculant

$$\int \int_D f(x, y) dx dy = \int \int_D f(x, y) dy dx$$




Figura 3: Funció de densitat conjunta bivariada

que s'anomena Integral doble de f sobre D . El càlcul de les integrals dobles es un càlcul interactiu on es fan dues integrals simples, una darrera de l'altra. En la primera s'integra per una de les dues variables mantenint com constants els valors de la segona variable i després es fa una segona integració per la segona integració mantenint com a constant la primera variable. L'ordre de les variables es intercanvia obtenint els mateixos resultats.

Exemple 1.15. Calculem el volum que la funció $f(x,y)=x+y$ deixa sota el rectangle sobre el rectangle $[1,2] \times [3,4]$, es a dir $1 \leq x \leq 2$ i $3 \leq y \leq 4$.

$$V = \int_1^2 \int_3^4 (x+y) dy dx = \int_3^4 \int_1^2 (x+y) dx dy$$

Si integren primer en funció de y la integral interior és, tenint en compte que x es constant :

$$V = \int_1^2 \int_3^4 (x+y) dy dx$$

$$\int (x+y) dy = xy + \frac{y^2}{2}$$

que avaluat en $y=3$ i $y=4$ dona

$$(4x + \frac{16}{2}) - (3x + \frac{9}{2}) = 4x - 3x - \frac{9}{2} = x + \frac{7}{2}$$

Ara integrem respecte a x

$$\int (x + \frac{7}{2}) dx = \frac{x^2}{2} + \frac{7}{2}x$$

que avaluat en $x=1$ i $x=2$ dona

$$V = (\frac{2^2}{2} + \frac{7}{2}2) - (\frac{1^2}{2} + \frac{7}{2}1) = (2 + 7) - (\frac{1}{2} + \frac{7}{2}) = 9 - 4 = 5$$

Si canviem l'ordre d'integració i integrem primer en funció de x i després en funció de y

$$V = \int_3^4 \int_1^2 (x+y) dx dy$$




Figura 4: Double integral

$$\int (x + y) dy = \frac{y^2}{2} + xy$$

que avaluat en $x=1$ i $x=2$ dona

$$\frac{2^2}{2} + 2y - \frac{1^2}{2} - y = 2 + 2y - \frac{1}{2} - y = \frac{3}{2} + y$$

Ara integrem respecte a y

$$\int (\frac{3}{2} + y) dy = \frac{y^2}{2} + \frac{3}{2}y$$

que avaluat en $y=3$ i $y=4$ dona

$$V = (\frac{4^2}{2} + \frac{3}{2}4) - (\frac{3^2}{2} + \frac{3}{2}3) = (8 + 4) - (\frac{9}{2} + \frac{9}{2}) = 14 - 9 = 5$$

En conclusió de les dues maneres el valor del volumen sota la funció es de 5.

$$V = \int_1^2 \int_3^4 (x + y) dy dx = \int_3^4 \int_1^2 (x + y) dx dy = 5$$

Exemple 1.16. Considerem un cas on el recinte d'integració no és un rectangle i utilitzem la funció de l'exemple 1.15 $f(x,y)=x+y$

Sigui el triangle $A = \{(x, y) \in \mathbb{R}^2 : 2 \leq x \leq 4, 2 \leq y \leq x\}$ que és mostra en la figura 5

La integral doble en el recinte de la funció es pot calcular de dues maneres començant primer per x o per y




Figura 5: Dues maneres d'obtenir la densitat conjunta d'un triangle

$$\int \int_A x + y \, dy dx = \int_2^4 \int_2^x x + y \, dy dx = \int_2^4 \left(\int_2^x x + y \, dy \right) dx$$

Cal observar que la integral interna té el límit superior en funció de x on juga un paper de constant. si resollem primer la integral interna en funció de y obtenim

$$\int_2^4 \left(\int_2^x x + y \, dy \right) dx = \int_2^4 \left[xy + \frac{y^2}{2} \right]_2^x dx = \int_2^4 \left[(xx + \frac{x^2}{2}) - (2x + \frac{2^2}{2}) \right] dx = \int_2^4 \left(\frac{3x^2}{2} - 2x - 2 \right) dx$$

Si ara resollem la segona integral en funció de x

$$\int_2^4 \left(\frac{3x^2}{2} - 2x - 2 \right) dx = \left[\frac{3}{2} \frac{x^3}{3} - x^2 - 2x \right]_2^4 = \left(\frac{4^3}{2} - 4^2 - 2(4) \right) - \left(\frac{2^3}{2} - 2^2 - 2(2) \right) = 8 - (-4) = 12$$

obtenim que el valor de la integral en el triangle es 12. En aquest cas hem fixat x i hem trobat el rang de variació de y dins del recinte d'integració A en funció de x com es pot veure en la figura 5 esquerra.

Si integrem primer en funció de x i després de y hem de fixar y i després trobar la variació de x en funció de y es a dir $A = \{(x, y) \in \mathbb{R}^2 : 2 \leq y \leq 4, y \leq x \leq 4\}$

$$\int_2^4 \left(\int_y^4 x + y \, dx \right) dy = \int_2^4 \left[\frac{x^2}{2} + xy \right]_y^4 dy = \int_2^4 \left[\left(\frac{4^2}{2} + 4y \right) - \left(\frac{y^2}{2} + y(y) \right) \right] dy = \int_2^4 \left(8 + 4y - \frac{3y^2}{2} \right) dy$$

Si ara resollem en funció de y

$$\int_2^4 \left(8 + 4y - \frac{3y^2}{2} \right) dy = \left[8y + 4 \frac{y^2}{2} - \frac{3}{2} \frac{y^3}{3} \right]_2^4 = \left[8y + 2y^2 - \frac{y^3}{2} \right]_2^4 = 8(4) + 2(4)^2 - \frac{4^3}{2} - (8(2) + 2(2)^2 - \frac{2^3}{2}) = 32 - 20 = 12$$

Començant primer per fixar la y , hem de avaluar el rang de variació de x i obtenim el mateix resultat al efectuar la integració (Figura 5 dreta) Per lo que dona igual per on començar a l'hora de fer la integral doble. S'obtenen els mateixos resultats.

En la Figura 6 es pot veure el que significa el càlcul de la probabilitat, Es pot generar una quadrícula amb costats $[x, x + dx] \times [y, y + dy]$ en l'àrea de suport. El volum del prisma sobre aquest rectangle es la seva àrea per l'alçada de la funció de densitat en el límit.

Així

$$\int_x^{x+dx} \int_y^{y+dy} f(u, v) dx dy \approx f(x, y) dx dy$$

donat que per la continuïtat de la funció f , aquesta es pràcticament constant al llarg de la superfície.

Com a conseqüència a partir de la notació diferencial

$$\begin{aligned} P\{x \leq X \leq x + dx, x \leq y \leq y + dy\} &= P\{(X, Y) \in (x, x + dx] \times (y, y + dy]\} \\ &= \int_x^{x+dx} \int_y^{y+dy} f(u, v) dx dy \approx f(x, y) dx dy \end{aligned}$$




Figura 6: Double integral

Aleshores, es pot deduir que la unitat de mesura de la densitat de probabilitat és la probabilitat per unitat d'àrea.

$$f(x, y) \approx \frac{P\{x \leq X \leq x + dx, x \leq y \leq y + dy\}}{dxdy}$$

Així, qualsevol punt o successió infinita de punts té probabilitat 0, perquè al tenir àrea zero no es pot obtenir damunt un volum positiu.

Per altra banda qualsevol corba unidimensional té probabilitat 0. En particular la probabilitat d'una recta $P\{Y = a + bX\} = 0$ o una cercle $P\{X^2 + Y^2 = r^2\} = 0$ es 0.

Exemple 1.17. Per a que la funció que hem calculat la integral doble en l'exemple 1.15 hem de garantir que la integral en tot $\mathbb{R}^2$ sigui 1.

Per això definim la funció de densitat en funció d'una constant que hem de calcular

$$f(x, y) = \begin{cases} k(x + y) & \text{si } x \in [1, 2], y \in [3, 4] \\ 0, & \text{en altre cas} \end{cases}$$

Aquesta funció també es pot escriure com

$$f(x, y) = k(x + y)I_{[1,2] \times [3,4]}(x, y) = k(x + y)I_{[1,2]}(x)I_{[3,4]}(y)$$

On utilitzem la funció indicadora d'un conjunt que sigui

$$\forall A \subseteq \Omega \text{ per a } \omega \in \Omega, \quad I_A(\omega) = \begin{cases} 1 & \text{si } \omega \in A \\ 0, & \text{si } \omega \notin A \end{cases}$$

donat que la funció $f(x, y) \geq 0$ per a tot $(x, y) \in \mathbb{R}^2$ serà de densitat si i només si

$$1 = \int_{\mathbb{R}} \int_{\mathbb{R}} f(x, y) dy dx = \int_{\mathbb{R}} \int_{\mathbb{R}} k(x+y) I_{[1,2]}(x) I_{[3,4]}(y) dy dx = k \int_1^2 \int_3^4 (x+y) dy dx = k5$$

El valor de k és per tant 1/5 per a que f(x,y) sigui una funció de densitat.

En la figura 7 es mostra la funció de densitat que val $(x+y)/5$ per als punts (x,y) en el rectangle A definit i 0 en la resta.

$$f(x, y) = (x+y)/5$$




Figura 7: Funció de densitat $f(x,y)$

1.3 Funcions de densitat i de distribució marginals i condicionades.

1.3.1 Distribucions marginals.

Les distribucions marginals són les distribucions unidimensionals que ens informa de la distribució dels valors d'una variable prescindint dels valors de les altres.

Definició 1.19. Funció de distribució marginal

Si $X = (X_1, \dots, X_k)$ es un vector aleatori amb funció de distribució F_X la funció de distribució marginal es defineix com la funció de distribució de probabilitat de cadascuna de les components del vector aleatori.

Cal tenir en compte que per una component

$$\lim_{x_j \rightarrow +\infty} \bigcap_{j=1}^k \{X_j \leq x_j\} = \{X_i \leq x_i\}$$

$$\forall i = 1, \dots, k \quad F_{X_i}(x_i) = \lim_{x_j \rightarrow +\infty} F_X(x_1, \dots, x_k) = F_X(+\infty, \dots, +\infty, x_i, +\infty, \dots, +\infty) \quad \forall x_i \in \mathbb{R}$$

El concepte de marginalitat pot aplicar-se a qualsevol subvector del vector original . Així per al subvector $X^l = (X_{i_1}, \dots, X_{i_l})$ on $l \leq k$ podem parlar de la distribució conjunta marginal de X^l a la expressió on es fixen les components del subvector i es fan tendir a l'infinit a la resta

$$F_{X^l}(X_{i_1}, \dots, X_{i_l}) = \lim_{x_j \rightarrow +\infty} F_X(x_1, \dots, x_k)$$

Exemple 1.18. Generem un triangle T amb vèrtexs en les coordenades (0,0), (1,0) (0,2), como es veu en la figura 8. Repartim la massa de probabilitat uniformement en el triangle donat que l'elegim a l'atzar un punt del triangle. Per a un àrea qualsevol la probabilitat de aquella àrea es

$$P((X, Y) \in A) = \frac{\|A \cap T\|}{\|T\|}$$

on $\|A\|$ és l'àrea de B.

Així, la funció de distribució conjunta donat que l'àrea del triangle és 1

$$F_{X,Y}(x, y) = P((x, y) \in S_{xy}) = \|S_{xy} \cap T\|$$

on $S_{xy} = (-\infty, x] \times (-\infty, y]$.

Així podem obtenir la funció conjunta simplement aplicant una mica de geometria segons la ubicació del punt (x,y) en el pla aplicant la definició de la funció de distribució conjunta con la intersecció amb el triangle que la equació de la hipotenusa es $2x+y=2$

$$F_{XY}(x, y) = \begin{cases} 0, & \text{si } x < 0 \quad y < 0 \\ xy, & \text{si } (x, y) \in T \text{ (tipus 1)} \\ xy - (x + y/2 - 1)^2, & \text{si } (x, y) \notin T \quad \& \quad 0 < x \leq 1, 0 < y \leq 2 \text{ (tipus 2)} \\ 2x - x^2, & \text{si } (x, y) \notin T \quad \& \quad 0 < x \leq 1, 2 < y \text{ (tipus 3)} \\ y - y^2/4, & \text{si } (x, y) \notin T \quad \& \quad 1 < x, 0 < y \leq 2 \text{ (tipus 4)} \\ 1, & \text{si } x \geq 1 \quad y \geq 2 \end{cases}$$

Cal observar que les expressions de $F_{XY}(x,y)$ depenen només de x i de y . Si recordem com calculem les marginals tenim que

$$F_X(x) = F_X(x, y)$$




Figura 8: Dues maneres d'obtenir la densitat conjunta d'un triangle

- Si $x \leq 0$ per qualsevol y $F_x(x, y) = 0$ i per tant el límit quan $\lim_{y \rightarrow +\infty}$ es 0
- Si $0 < x < 1$ al fer que $y \rightarrow +\infty$ el punt es situa en la zona tipus 3 y per tant la funció val $2x - x^2$
- Si $x \geq 1$ al fer que $y \rightarrow +\infty$ el punt es situa sobre el triangle y la probabilitat aculada es 1

$$F_X(x) = \begin{cases} 0, & \text{si } x \leq 0 \\ 2x - x^2, & \text{si } 0 < x < 1 \\ 1, & \text{si } x \geq 1 \end{cases}$$

Analògament podem obtenir la funció de distribució de Y on la diferència es que entre 0 i 2 quan $x \rightarrow +\infty$ estarem en punts tipus 4 i la funció valdrà $y - \frac{y^2}{4}$

$$F_Y(y) = \begin{cases} 0, & \text{si } y \leq 0 \\ y - \frac{y^2}{4}, & \text{si } 0 < y < 2 \\ 1, & \text{si } y \geq 2 \end{cases}$$

1.3.1.1 Distribucions marginals. Cas discret Sigui D_{X_i} el suport numerable de la component X_i d'un vector aleatori X discret, es verifica que

$$\{X_i = x_i\} = \bigcup_{x_j \in D_j, j \neq i} \left(\bigcap_{j=1}^k \{X_j = x_j\} \right)$$

com que els elements son disjunts podem obtenir la funció de probabilitat marginal com

$$f_{X_i}(x_i) = \sum_{x_j \in D_j, j \neq i} f_X(x_1, \dots, x_k)$$

Exemple 1.19. Si revisem la taula del exemple 1.13, on en primer lloc es llança una moneda i després un dau. Observem que la darrera fila conté les probabilitats marginals d'observar cara o creu, obtenint un valor de 1/2 per cada columna. La darrera columna conté les marginals d'obtenir un resultat de les cares del dau, és a dir 1/6 per cada fila.

$Y \backslash X$	Cara (0)	Creu (1)	$f_Y(y)$
1	1/12	1/12	1/6
2	1/12	1/12	1/6
3	1/12	1/12	1/6
4	1/12	1/12	1/6
5	1/12	1/12	1/6
6	1/12	1/12	1/6
$f_X(x)$	1/2	1/2	

1.3.1.2 Distribucions marginals. Cas continu Si les dues variables X i Y son contínues, com hem vist abans, per definició la distribució marginal de cadascuna de elles la podem escriure com:

$$F_X(x) = \lim_{x \rightarrow +\infty} F_{XY}(x, y) = \int_{-\infty}^x \int_{-\infty}^{+\infty} f(s, y) dy ds$$

$$F_Y(y) = \lim_{y \rightarrow +\infty} F_{XY}(x, y) = \int_{-\infty}^y \int_{-\infty}^{+\infty} f(t, x) dx dt$$

Es pot demostrar que tant $F_X(x)$ com $F_Y(y)$ son funcions de distribució . En el següent exemple

Exemple 1.20. En la figura 9 es mostra una representació de la distribució marginal. El diagrama de dispersió representa les coordenades (x, y) de les observacions. Si es projecten en l'eix Y totes les dades sense tenir en compte la component X , s'obté la funció de distribució marginal de Y .




Figura 9: Funció de distribució marginal de Y mostrat

1.3.2 Distribucions condicionals

Sigui (X, Y) un vector aleatori bidimensional definit sobre $(\Omega, \mathcal{A}, P)$ i $F_{XY}(x, y)$ la seva funció de distribució conjunta. Sabent que ha ocorregut l'esdeveniment $Y \in B$, ens interessa calcular la probabilitat condicionada que $X \in A$

$$P\{\omega \in \Omega \text{ tq } X(\omega) \in A \text{ sabiendo } y \in B\}$$

$$P\{X \in A/Y \in B\} = \frac{P\{X \in A \cap Y \in B\}}{P\{Y \in B\}} = \frac{P\{X \in A, Y \in B\}}{P\{Y \in B\}} \quad \text{si } P\{Y \in B\} > 0$$

Si $A =]-\infty, x]$ i $B =]-\infty, y]$ i $F_Y(Y) > 0$

$$P(X \leq x|Y \leq y) = \frac{P(X \leq x, Y \leq y)}{P(Y \leq y)} = \frac{F_{XY}(x, y)}{F_Y(y)} = \frac{F_{XY}(x, y)}{\lim_{u \rightarrow +\infty} F_{XY}(u, y)}$$

1.3.2.1 Distribucions condicionals. Cas discret Considerem un vector aleatori bidimensional (X, Y) , amb suports discrets per cadascuna de les seves components $D_x = (x_1, \dots, k)$ i $D_y = (y_1, \dots, y_h)$ i una funció de probabilitat conjunta $f_{XY}(x, y)$

Definició 1.20. Funció de probabilitat condicionada

Es defineix la funció de probabilitat condicionada de X donat $(Y = y_j), y \in D_y$, on $P(Y = y_j) > 0$ com

$$f_{X|Y}(x_i|y_j) = f_{X|Y}(x_i|y_j) = P(X = x_i|Y = y_j) = \frac{P(X = x_i, Y = y_j)}{P(Y = y_j)} = \frac{f_{XY}(x_i, y_j)}{f_Y(y_j)}$$

Definició 1.21. Funció de distribució condicionada

A partir de la definició anterior, podem definir la funció de distribució condicionada de X donat que $(Y = y_j), y \in D_y$ com:

$$F_{X|Y} = P(X \leq x|Y = y_j) = \frac{\sum_{x_i \leq x} f_{XY}(x_i, y_j)}{f_Y(y_j)} = \sum_{x_i \leq x} f_{X|Y}(x_i|y_j)$$

$f_{X|Y}(x|y)$ es efectivament una funció de probabilitat per què compleix les dues propietats

- Es una funció no negativa la tractar-se d'una funció no neegativa
- i la suma sobre la funció de suport D_Y es l'a unitat

$$\sum_{x_i \in D_X} f_{X|Y}(x_i|y_j) = \frac{\sum_{x_i \in D_X} f_{XY}(x_i, y_j)}{f_Y(y_j)} = \frac{f_Y(y_j)}{f_Y(y_j)} = 1$$

Exemple 1.21. Tornem a l'exemple de la moneda i el dau i la taula de probabilitats que es mostra en l'exemple 1.19 on Y es el valor del dau i X es el resultat de la moneda.

Calculem la probabilitat de treure una cara donat que el dau ha resultat el valor 4.

Seguint la definci

$$P(x = cara|Y = 4) = \frac{P(X = cara, Y = 4)}{P(Y = 4)} = \frac{1/12}{1/6} = 1/2$$

En aquest cas la funció de probabilitat condicionada coincideix en la distribució marginal.

Si ho fessim a l'inrevés es a dir la probabilitat d'obtenir un valor del dau si ha sortit cara o ha sortit creu arribaríem a que $P(Y = y|x = cara) = 1/6$ que també coincideix amb la marginal.

Això serà rellevant més endavant quan parlem del concepte d'independència

1.3.2.2 Distributions conditionals. Cas continu

Definició 1.22. Funció de densitat condicional

Siguin X i Y dues variables aleatòries contínues on f_{XY} es la funció de densitat conjunta, i f_X i f_Y son les funcions de densitat marginal. Definim la densitat condicional de X donat que $Y = y$ a la funció

$$f_{X|Y=y}(x) = \frac{f_{XY}(x, y)}{f_Y(y)}, \text{ per a } -\infty \leq x \leq +\infty$$

- Cal notar que $f_{X|Y=y}$ no més està definida per valors de y on $f_Y(y) > 0$

- Sembla per la definició que estem condicionat per la probabilitat de que $Y = y$, però al tractar-se d'una variable continua aquesta probabilitat es 0. La funció de densitat condicional és el límit d'una probabilitat condicional a mesura que el radi de la regió circular de (x, y) tendeix a 0.

anàlogament es pot definir la funció de densitat condicional de Y donat que $X = x$ a la funció

$$f_{Y|X=x}(y) = \frac{f_{XY}(x, y)}{f_X(x)}, \text{ per a } -\infty \leq y \leq +\infty$$

La funció $f_{X|Y=y}$ es una densitat ja que per definició es positiva i si la integrem dona 1.

$$\int_{-\infty}^{+\infty} f_{X|Y=y}(x) dx = \int_{-\infty}^{+\infty} \frac{f_{XY}(x, y)}{f_Y(y)} dx = \frac{1}{f_Y(y)} \int_{-\infty}^{+\infty} f_{XY}(x, y) \frac{1}{f_Y(y)} f_Y(y) = 1$$

Exemple 1.22. En la figura 10 es mostra una representació de la distribució condicionada de Y en funció de X . El diagrama de dispersió representa les coordenades (x, y) de les observacions. Si es projecten en l'eix Y els valors de la variable de Y per a les coordenades x incloses en l'interval $[a, a + \epsilon]$ e, S'obté la funció de distribució condicionada $Y|X = a$.

Exemple 1.23. Sigui la següent funció de densitat conjunta provinent de treure a l'atzar un punt sota una paràbola.

$$f_{XY}(x, y) = \begin{cases} 4xy^3, & \text{si } y \in (0, 1), xy \in (0, 1) \Leftrightarrow 0 < y < 1, 0 < x < \frac{1}{y} \\ 0, & \text{en la resta} \end{cases}$$

El la gràfica 11 es pot veure la representació de la funció de densitat conjunta.

Si calculem la funció de densitat marginal de Y obtenim una funció que es diferent de 0 si $y \in 1$

$$f_Y(y) = \int_{-\infty}^{+\infty} f_{XY}(x, y) dx = \begin{cases} 4y^3 \int_0^{1/y} x dx = y^3 \left[\frac{x^2}{2} \right]_0^{1/y} = 2y, & \text{si } y \in (0, 1) \\ 0, & \text{en la resta} \end{cases}$$

De la mateixa manera podem obtenir la funció de densitat marginal de X com




Figura 10: Funció de distribució condicionada de Y en funció de X mostrat

Representació tridimensional




Figura 11: Exemple de distribució conjunta

$$f_X(x) = \int_{-\infty}^{+\infty} f_{XY}(x, y) dy = \begin{cases} 4x \int_0^1 y^3 dy = 4x \left[\frac{y^4}{4} \right]_0^1 = x, & \text{si } x \in (0, 1) \\ 4x \int_0^{1/x} y^3 dy = 4x \left[\frac{y^4}{4} \right]_0^{1/x} = \frac{1}{x^3}, & \text{si } x > 1) \\ 0, & \text{en la resta} \end{cases}$$

Per obtenir la funció de densitat condicionada $f_{X|Y}$ només caldrà dividir la funció de densitat conjunta f_{XY} respecta a la marginal f_Y

$$f_{X|Y}(x) = \frac{f_{X,Y}(x, y)}{f_Y(y)} = \begin{cases} \frac{4xy^3}{2y} = 2xy^2, & \text{si } y \in (0, 1) \quad y \quad xy \in (0, 1) \\ 0, & \text{en la resta} \end{cases}$$

El la gràfica 12 es pot veure la representació de la funció de densitat condicional $X|Y$ per a cada valor de y .




Figura 12: Exemple de distribució condicionada $X|Y$

De forma anàloga es pot obtenir la funció de densitat condicionada $f_{Y|X}$ dividint la funció de densitat conjunta f_{XY} respecta a la marginal f_X

$$f_{Y|X}(y) = \frac{f_{X,Y}(x, y)}{f_X(x)} = \begin{cases} \frac{4xy^3}{x} = 4y^3, & \text{si } y \in (0, 1) \quad y \quad xy \in (0, 1) \\ \frac{4xy^3}{1/x^3} = 4x^4 y^3, & \text{si } y \in (0, 1) \quad y \quad xy \in (0, 1) \quad y \quad x > 1 \\ 0, & \text{en la resta} \end{cases}$$

1.4 Moments multivariants: vector d'esperances, matriu de variància-covariància

1.4.1 Moments univariants: Esperança i Variància

En el cas univariant podem parlar de certes característiques numèriques o constants lligades a les variables que ens permet caracteritzar-les. Son els moments, dels quals l'esperança i la variància son casos particulars.

Esperança d'una variable aleatòria discreta

Sigui X una variable aleatòria discreta on f_X es la seva funció de probabilitat i D_x el seu suport numerable. Si g es una funció mesurable definida de $(\mathbb{R}, \beta)$ en $(\mathbb{R}, \beta)$, tal que $\sum_{x_i \in D_x} |g(x_i)f_X(x_i)| < +\infty$ definim l'esperança de $g(X)$ a

$$E[g(X)] = \sum_{x_i \in D_x} g(x_i)f_X(x_i)$$

En particular, si $g(X) = X$

$$E[X] = \sum_{x_i \in D_x} x_i f_X(x_i)$$

que seria la mitjana poblacional de la distribució de la variable X

Esperança d'una variable aleatòria continua

Sigui X una variable aleatòria continua on f_X es la seva funció de densitat. Si g es una funció mesurable definida de $(\mathbb{R}, \beta)$ en $(\mathbb{R}, \beta)$, tal que $\int_{\mathbb{R}} |g(x)f_X(x)|dx < +\infty$ definim l'esperança de $g(X)$ a

$$E[g(X)] = \int_{-\infty}^{+\infty} g(x)f_X(x)dx$$

En particular, si $g(X) = X$

$$E[X] = \int_{-\infty}^{+\infty} x f_X(x)dx$$

que seria la mitjana poblacional de la distribució de la variable X

Formes particulars de $g(X)$ donen lloc a diferents moments de X en la següent taula es mostren els més utilitzats

	d'ordre k	absolut d'ordre k
Respecte del origen	X^k	$ X ^k$
Respecte de a	$(X - a)^k$	$ X - a ^k$
Factorials	$X(X - 1) \cdots (X - k + 1)$	$ X(X - 1) \cdots (X - k + 1) $

Així el moment d'ordre 1 es la $E[X] = \mu$ mitjana de la distribució i el moment central d'ordre 2 es la variància $Var[X] = \sigma_X^2 = E[(X - \mu)^2] = E[X^2] - (E[X])^2$.

1.4.2 Moments multivariants: Esperança i Variància

Esperança d'un vector aleatori discret

Sigui $X = (X_1, \dots, X_k)$ un vector aleatori discret, D_X el suport del vector i f_X es la seva funció de probabilitat conjunta. Si g es una funció mesurable definida de $\mathbb{R}^k$ en $\mathbb{R}$

$$E[g(X)] = \sum_{(x_1, \dots, x_k) \in D_x} g(x_1, \dots, x_k)f_X(x_1, \dots, x_k)$$

Esperança d'un vector aleatori continu

Sigui $X = (X_1, \dots, X_k)$ un vector aleatori continu f_X es la seva funció de densitat conjunta. Si g es una funció mesurable definida de $\mathbb{R}^k$ en $\mathbb{R}$

$$E[g(X)] = \int_{-\infty}^{+\infty} \dots \int_{-\infty}^{+\infty} g(x_1, \dots, x_k)f_X(x_1, \dots, x_k)dx_1, \dots, dx_k$$

En ambdós casos l'esperança està supeditada a que $|g(x)f(x)|$ sigui absolutament sumable o integrable.

Exemple 1.24. Una barra d'un metre es trenca aleatòriament en dos punts, generant tres peces. Quina és la llargada mitjana de la peça del mig?

Per estudiar el problema considerem dues variables aleatòries que segueixen una distribució uniforme $(U_1, U_2) \sim U([0, 1] \times [0, 1])$

Es a dir, la distribució conjunta ve definida per la densitat constant

$$f_{U_1, U_2}(u_1, u_2) = \begin{cases} 1, & \text{si } (u_1, u_2) \in [0, 1] \times [0, 1] \\ 0, & \text{en la resta} \end{cases}$$

La longitud de la peça central ve donada per la variable aleatòria $X = g(U_1, U_2) = |U_2 - U_1|$

LLavors seguint la definició d'esperança de la variable X obtenim el valor de la longitud de la peça central

$$\begin{aligned} E[|U_1 - U_2|] &= \int_{-\infty}^{+\infty} \dots \int_{-\infty}^{+\infty} g(u_1, u_2) f(u_1, u_2) du_1 du_2 = \int_0^1 \int_0^1 |u_1 - u_2| du_1 du_2 \\ &= \int_0^1 \int_0^1 1_{(u_1 \geq u_2)} (u_1 - u_2) du_1 du_2 + \int_0^1 \int_0^1 1_{(u_1 \leq u_2)} (u_2 - u_1) du_1 du_2 \\ &= \int_0^1 \int_0^{u_1} (u_1 - u_2) du_2 du_1 + \int_0^1 \int_0^{u_2} (u_2 - u_1) du_1 du_2 \\ &= \int_0^1 \left[u_1 u_2 - \frac{u_2^2}{2} \right]_0^{u_1} du_1 + \int_0^1 \left[u_2 u_1 - \frac{u_1^2}{2} \right]_0^{u_2} du_2 = \int_0^1 (u_1^2 - \frac{u_1^2}{2}) du_1 + \int_0^1 (u_2^2 - \frac{u_2^2}{2}) du_2 \\ &= \int_0^1 (\frac{u_1^2}{2}) du_1 + \int_0^1 (\frac{u_2^2}{2}) du_2 = \left[\frac{u_1^3}{2 \times 3} \right]_0^1 + \left[\frac{u_2^3}{2 \times 3} \right]_0^1 = \frac{1}{2 \times 3} + \frac{1}{2 \times 3} = \frac{1}{3} \end{aligned}$$

que és un terç de la longitud de la barra.

Moments d'un vector aleatori En el cas de les variables aleatòries univariants hem vist com determinades formes de la funció g donen lloc als anomenats moments que podem estendre al cas dels vectors aleatoris.

El moment d'ordre $(n_1, \dots, n_k)$ s'obté sempre que existix l'esperança

$$g(X_1, \dots, X_k) = X_1^{n_1} \dots X_k^{n_k}, n_i \geq 0$$

que dona lloc a $E[X_1^{n_1} \dots X_k^{n_k}]$ respecte a l'origen de cada component.

Un cas particular si $n_i = m$ i $n_j = 0, j \neq i$ dona que $E[X_1^{n_1} \dots X_k^{n_k}] = E[X_i^m]$

El moment conjunt central d'ordre k respecte de l'origen de cada component es un cas particular, que es pot obtenir sempre que l'esperança existisca

$$g(X_1, \dots, X_k) = (X_1 - E[X_1])^{n_1} \dots (X_k - E[X_k])^{n_k}, n_i \geq 0$$

La linealitat de l'esperança aplicada quan $g(X) = X_1 + \dots + X_k$ permet concloure que l'esperança de la suma de variables es la suma de les esperances.

$$E(X_1 + \dots + X_k) = \sum_{i=1}^k E(X_i)$$

Així mateix si $g(X) = \sum_{i=1}^k (a_i X_i)$ obtenim que l'esperança de d'una constant per una variable es la constant per l'esperança de la variable

$$E(a_1 X_1 + \dots + a_k X_k) = \sum_{i=1}^k a_i E(X_i)$$

1.4.3 Matriu de Variància-Covariància

Covariància

Un moment d'especial interès és el moment conjunt central que s'obté per a les variables X_i i X_j $n_i = 1, n_j = 1$ i $n_l = 0, l \neq (i, j)$ que anomenarem covariància

$$\text{cov}(X_i, X_j) = E[(X_i - E[X_i])(X_j - E[X_j])] = E[(X_i X_j)] - E[X_i]E[X_j]$$

Siguin X i Y variables aleatòries tals que $\sigma_X^2 < \infty$ i $\sigma_Y^2 < \infty$ llavors

$$\text{Cov}(X, Y) = E[(XY)] - E[X]E[Y]$$

Demostració

$$\begin{aligned} \text{Cov}(X, Y) &= E[(X - E[X])(Y - E[Y])] \\ &= E[(X - E[X])Y - (X - E[X])E[Y]] \\ &= E[(X - E[X])Y] - E[(X - E[X])E[Y]] \\ &= E[XY] - E[E[X]Y] - E[XE[Y]] + E[X]E[Y] \\ &= E[XY] - E[X]E[Y] - E[X]E[Y] + E[X]E[Y] \\ &= E[XY] - E[X]E[Y] \end{aligned}$$

Siguin (X, Y, Z) variables aleatòries amb variància finita i $a \in \mathbb{R}$.

1. La covariància és un operador simètric: $\text{Cov}(X, Y) = \text{Cov}(Y, X)$
2. La variància és un cas particular de covariància: $\text{Var}(X) = \text{Cov}(X, X)$
3. La covariància amb una constant és 0: $\text{Cov}(X, a) = 0$
4. La covariància és un operador bilineal, és a dir, és lineal en els seus dos arguments:

$$\text{Cov}(aX, Y) = \text{Cov}(X, aY) = a\text{Cov}(X, Y)$$

$$\text{Cov}(X + Y, Z) = \text{Cov}(X, Z) + \text{Cov}(Y, Z)$$

$$\text{Cov}(X, Y + Z) = \text{Cov}(X, Y) + \text{Cov}(X, Z)$$

$$5. \text{Var}(X + Y) = \text{Var}(X) + \text{Var}(Y) + 2\text{Cov}(X, Y)$$

$$6. \text{Var}(X - Y) = \text{Var}(X) + \text{Var}(Y) - 2\text{Cov}(X, Y)$$

Demostració:

$$\text{Cov}(aX, Y) = E[aXY] - E[aX]E[Y] = aE[XY] - aE[X]E[Y] = a(E[XY] - E[X]E[Y]) = a\text{Cov}(X, Y).$$

$$\begin{aligned}
Cov(X + Y, Z) &= E[(X + Y)Z] - E[X + Y]E[Z] \\
&= E[XZ] + E[YZ] - (E[X] + E[Y])E[Z] \\
&= E[XZ] + E[YZ] - E[X]E[Z] - E[Y]E[Z] \\
&= E[XZ] - E[X]E[Z] + E[YZ] - E[Y]E[Z] \\
&= Cov(X, Z) + Cov(Y, Z)
\end{aligned}$$

La demostració dels dos últims apartats es dedueix directament de la anterior escrivint $Var(X+Y)=Cov(X+Y,X+Y)$ i $Var(X-Y)=Cov(X-Y,X-Y)$

Un problema de la covariància com a mesura de força de la relació lineal de dues variables aleatòries, és que la covariància depèn de les unitats en que es mesuren les variables. Si canviem les unitats canvia el valor de la covariància.

Matriu de Variància-Covariància

Si (X_1, X_2) es un vector de 2 variables aleatòries definim la matriu de convariances Σ a la matriu 2x2 amb les variàncies a la diagonal i les covariàncies del vector en les altres posicions

$$\Sigma = \begin{bmatrix} Var(X_1) & Cov(X_1, X_2) \\ Cov(X_1, X_2) & Var(X_2) \end{bmatrix} = \begin{bmatrix} \sigma_1^2 & \sigma_{12} \\ \sigma_{12} & \sigma_2^2 \end{bmatrix}$$

En general. Si $X = (X_1, \dots, X_k)$ és un vector aleatori de dimensió k la matriu de variàncies-covariàncies és

$$\Sigma = \begin{bmatrix} Var(X_1) & Cov(X_1, X_2) & \dots & Cov(X_1, X_{k-1}) & Cov(X_1, X_k) \\ Cov(X_1, X_2) & Var(X_2) & \dots & Cov(X_2, X_{k-1}) & Cov(X_2, X_k) \\ \vdots & \vdots & \ddots & \vdots & \vdots \\ Cov(X_1, X_{k-1}) & Cov(X_2, X_{k-1}) & \dots & Var(X_{k-1}) & Cov(X_{k-1}, X_k) \\ Cov(X_1, X_k) & Cov(X_2, X_k) & \dots & Cov(X_{k-1}, X_k) & Var(X_k) \end{bmatrix}$$

Podem simplificar l'expressió de la matriu utilitzant els valors σ_{ij} per $Cov(X_i, X_j)$ i σ_i^2 per $Var(X_i)$

$$\Sigma = \begin{bmatrix} \sigma_1^2 & \sigma_{12} & \dots & \sigma_{1(k-1)} & \sigma_{1k} \\ \sigma_{12} & \sigma_2^2 & \dots & \sigma_{2(k-1)} & \sigma_{2k} \\ \vdots & \vdots & \ddots & \vdots & \vdots \\ \sigma_{1(k-1)} & \sigma_{2(k-1)} & \dots & \sigma_{k-1}^2 & \sigma_{(k-1)k} \\ \sigma_{1k} & \sigma_{2k} & \dots & \sigma_{(k-1)k} & \sigma_k^2 \end{bmatrix}$$

1.5 Transformacions de variables multivariants

Theorem 1.1. *Sigui $X = (X_1, \dots, X_k)$ un vector aleatori continu amb soport D_X , és a dir $P((X_1, \dots, X_k) \in D_X) = 1$, i sigui $g = (g_1, \dots, g_k) : \mathbb{R}^k \rightarrow \mathbb{R}^k$ una funció vectorial que verifica:*

1. *g es unívoca sobre D_X*
2. *el Jacobiano de g , $J = \frac{\partial(g_1, \dots, g_k)}{\partial(x_1, \dots, x_k)}$ es diferente de cero $\forall x \in D_X$*
3. *existeix $h = (h_1, \dots, h_k)$ inversa de g*

Llavors, $Y = g(X)$ es un vector aleatori continu amb densitat conjunta per a $y = (y_1, \dots, y_k) \in g(D_X)$ ve donada per

$$f_Y(y_1, \dots, y_k) = f_X(h_1(y_1, \dots, y_k), \dots, h_k(y_1, \dots, y_k)) |J^{-1}|$$

on $|J^{-1}| = \frac{\partial(h_1, \dots, h_k)}{\partial(y_1, \dots, y_k)}$ és el Jacobià de h .

La demostració d'aquest teorema no es més que el teorema del canvi de variable en una integral múltiple i la seva demostració rigorosa, pot trobar-se en qualsevol llibre d'Anàlisi Matemàtica.

Exemple 1.25. Sigui l'experiment aleatori triar un punt a l'atzar del cercle unitat C_1 , on podem definir sobre l'espai de probabilitat un vector aleatori de les coordenades del punt (X,Y) . L'elecció a l'atzar implica una probabilitat uniforme sobre C_1 . La densitat conjunta la podem expressar com

$$f_{XY}(x,y) = \begin{cases} \frac{1}{\pi}, & \text{si } (x,y) \in C_1 \\ 0, & \text{en la resta} \end{cases}$$

Considerem un canvi entre les coordenades cartesianes a les coordenades polars del punt del cercle.

En aquest cas la transformació a coordenades polars serà $R = \sqrt{X^2 + Y^2}$ i $\Theta = \arctan(Y/X)$.

Per obtenir la seva densitat conjunta necessitem les transformacions inverses de coordenades polars a euclídiades, $X = R\cos(\Theta)$ i $Y = R\sin(\Theta)$. Si es calcula el jacobià aquest val $J_1 = R$

Per tant segons el teorema 1.1 la densitat conjunta es

$$f_{R\Theta}(r,\theta) = \begin{cases} \frac{r}{\pi}, & \text{si } (r,\theta) \in [0,1] \times [0,2\pi] \\ 0, & \text{en la resta} \end{cases}$$

Amb facilitat es poden obtenir les marginals corresponents

$$f_R(r) = \begin{cases} 2r, & \text{si } r \in [0,1] \\ 0, & \text{en la resta} \end{cases}$$

$$f_\Theta(\theta) = \begin{cases} \frac{1}{2\pi}, & \text{si } \theta \in [0,2\pi] \\ 0, & \text{en la resta} \end{cases}$$

1.5.1 Suma de dues variables aleatòries

Sigui la variable aleatòria $Z = X + Y$ on (X,Y) es la distribució conjunta de les dues components aleatòria on es vol determinar la distribució de probabilitat de Z

Cas (X,Y) variable aleatòria bivariant discreta

Sigui $p(x_i, y_j)$ la funció de probabilitat conjunta de (X, Y)

$$p(x_i, y_j) = P(X = x_i, Y = y_j), \quad i = 1, 2, \dots \quad j = 1, 2, \dots$$

La variable aleatòria suma, $Z = X + Y$ és una variable aleatòria univariant discreta, ja que com a molt pot pendre els valors produïts per les combinacions dels valors de X e Y , es a dir

$$x_i + y_j, \quad i = 1, 2, \dots \quad j = 1, 2, \dots$$

Alguns dels valor poden estar repetits. Sigui z_ℓ algun dels valors possibles de $Z = X + Y$. La funció de probabilitat de Z és:

$$\begin{aligned}
\Pr(Z = z_\ell) &= \Pr(X + Y = z_\ell) \\
&= \sum_{i,j: x_i + y_j = z_\ell} \Pr(X = x_i, Y = y_j) \\
&= \sum_i \Pr(X = x_i, Y = z_\ell - x_i) \\
&= \sum_j \Pr(X = z_\ell - y_j, Y = y_j).
\end{aligned}$$

Cas (X,Y) variable aleatòria bivariant continua

Segui $f_{XY}(x, y)$ la funció de densitat conjunta de les variables aleatòries quantitatives (X, Y) , Definim $Z = X + Y$ funció de la que volem conèixer la seva densitat. Per poder utilitzar el teorema 1.1 és necessita una transformació bidimensional, el que podem obtenir utilitzant una nova variable $V = X$.

Així al vector (Z, V) li podem aplicar directament el teorema , amb les inverses $X = V$ i $Y = Z - V$ on el jacobià es :

$$J^{-1} = \det \begin{bmatrix} \frac{\partial v}{\partial z} & \frac{\partial v}{\partial(z-v)} \\ \frac{\partial(z-v)}{\partial z} & \frac{\partial(z-v)}{\partial v} \end{bmatrix} = \det \begin{bmatrix} 0 & 1 \\ 1 & -1 \end{bmatrix} = -1$$

Tindrem que $|J^{-1}| = 1$ i l'expressió de la distribució conjunta es.

$$f_{Z,V}(z, v) = f_{X,Y}(v, z - v)$$

y per obtenir la densitat marginal de la suma Z tenim

$$f_Z(z) = \int_{-\infty}^{+\infty} f_{X,Y}(v, z - v) dv = \int_{-\infty}^{+\infty} f_{X,Y}(x, z - x) dx$$

Exemple 1.26. Sigui X i Y dues variables aleatòries amb distribució uniforme al interval (0,1) i amb densitat conjunta

$$f_{X,Y}(x, y) = \begin{cases} 1, & \text{si } 0 < x < 1, 0 < y < 1, \\ 0, & \text{en la resta} \end{cases}$$

Si $Z=X+Y$ i utilitzant la transformació $V=X$ la funció de distribució conjunta serà

La densitat marginal de la suma Z segons hem vist és

$$f_Z(z) = \int_{-\infty}^{+\infty} f_{X,Y}(x, z - x) dx = \int_{\max(0, z-1)}^{\min(1, z)} 1 dx$$

donat que de e les condicions inicials, la funció està definida si $0 < x < 1$ i $0 < z - v < 1$. Es a dir $z - 1 < v < z$ i per tant $\max(0, z - 1) < v < \min(1, z)$

Així és distingeixen dos casos.

Si $0 < z < 1$

$$f_Z(z) = \int_0^z 1 dx = z$$

Si $1 \leq z < 2$

$$f_Z(z) = \int_{z-1}^1 1dx = 2 - z$$

Finalment

$$f_Z(z) = \begin{cases} z, & \text{si } 0 < z < 1, \\ 2 - z, & \text{si } 1 \leq z < 2, \\ 0, & \text{en la resta.} \end{cases}$$

Que es la coneguda distribució triangular resultat de sumar dues variables independents* $U(0,1)$

* Nota: El concepte de independència es veurà en el tema següent

1.5.2 Producte de dues variables aleatòries

En el cas del producte $W=XY$ i com abans definint $V=X$ tenim que podem calcular la distribució conjunta (W,V) aplicant el teorema 1.1 partir de les funcions inverses $X=V$ i $Y=W/V$ i el Jacobià

$$J^{-1} = \det \begin{bmatrix} \frac{\partial v}{\partial(w/v)} & \frac{\partial v}{\partial(w/v)} \\ \frac{\partial w}{\partial(w/v)} & \frac{\partial v}{\partial(w/v)} \end{bmatrix} = \det \begin{bmatrix} 0 & 1 \\ \frac{1}{v} & -\frac{w}{v^2} \end{bmatrix} = -\frac{1}{v}$$

I per tant $|J^{-1}| = \frac{1}{|v|}$

La distribució conjunta de (W,V) és

$$f_{WV}(w, v) = \frac{1}{|v|} f_{XY}\left(\frac{w}{v}, v\right)$$

I la distribució marginal del producte s'obté integren respecte a l'altra component

$$f_W(w) = \int_{-\infty}^{+\infty} \frac{1}{|v|} f_{XY}\left(v, \frac{w}{v}\right) dv$$

Exemple 1.27. Siguin les dues variable uniformes del exemple 1.26

Volem obtenir la densitat del producte $W = XY$ que seguint l'apartat anterior es pot obtenir com

$$f_W(w) = \int_{-\infty}^{+\infty} \frac{1}{|x|} f_{XY}\left(x, \frac{w}{x}\right) dx$$

Com que la densitat conjunta només és diferent de zero quan

$$0 < x < 1, \quad 0 < \frac{w}{x} < 1,$$

ha de complir-se

$$w < x < 1.$$

Així, si $0 < w < 1$,

$$f_W(w) = \int_w^1 \frac{1}{x} dx.$$

Finalment,

$$f_W(w) = [\ln(v)]_w^1 = \ln(1) - \ln(w) = -\ln(w).$$

Per tant, la densitat del producte és

$$f_W(w) = \begin{cases} -\ln(w), & \text{si } 0 < w < 1, \\ 0, & \text{en la resta} \end{cases}$$

1.5.3 Quocient de dues variables aleatòries

En el cas del quocient $Q = XY$ i com abans definint $V=X$ tenim que podem calcular la distribució conjunta (Q,V) aplicant el teorema 1.1 partir de les funcions inverses $X=V$ i $Y=QV$ i el Jacobià

$$J^{-1} = \det \begin{bmatrix} \frac{\partial v}{\partial q} & \frac{\partial v}{\partial v} \\ \frac{\partial(qv)}{\partial q} & \frac{\partial(qv)}{\partial v} \end{bmatrix} = \det \begin{bmatrix} 0 & 1 \\ v & q \end{bmatrix} = v$$

I per tant $|J^{-1}| = |v|$

La distribució conjunta de (W,V) és

$$f_{QV}(q, v) = |v| f_{XY}(v, qv)$$

I la distribució marginal del producte s'obté integren respecte a l'altra component

$$f_Q(q) = \int_{-\infty}^{+\infty} \frac{1}{|v|} f_{XY}\left(\frac{q}{v}, v\right) dv$$

2 Independència de variables aleatòries

La independència entre dos esdeveniments A i B, suposa que cap d'ells aporta informació d'interés alhora de calcular la probabilitat d'ells. Es a dir $P(A) = P(A/B)$ i per tant $P(B) = P(B/A)$. En aquest tema volem traslladar el compte d'independència i algunes mesures relacionades als vectors aleatoris.

2.1 Independència i dependència entre variables aleatòries.

Definició 2.1. Variables aleatòries independents

Es diu que dos variables aleatòries X i Y son independents si, per a qualsevol conjunts A i B tal que $X \in A$ i $Y \in B$ es té que:

$$P(X \in A \cap Y \in B) = P(X \in A)P(Y \in B)$$

Com a conseqüència $P(X \leq x \text{ and } Y \leq y) = P(X \leq x)P(Y \leq y)$

En general es diu que les variables $X_i, i = 1, \dots, k$ son independents si les σ -lgebras que les indueixen s ho son

Aquesta definició implica que al pendre $A_i \in \sigma(X_i), i = 1, \dots, k$

$$P(A_{j_1} \cap \dots \cap A_{j_n}) = \prod_{l=1}^n P(A_{j_l}) \quad \forall (j_1, \dots, j_n) \in (1, \dots, k)$$

Tenint en compte com han estat induïdes les $\sigma(X_i)$ admet una expressió alternativa en funció de les diferents variables

$$P(A_{j_1} \cap \dots \cap A_{j_n}) = P(X_{j_l} \in B_{j_l}, l = 1, \dots, n) = \prod_{l=1}^n P(X_{j_l} \in B_{j_l}) \quad \forall (j_1, \dots, j_n) \in (1, \dots, k)$$

on $A_{j_1} = X^{-1}B_{j_1}$

Comprovar la independència de variables aleatòries a partir de la equació (2.1) es complicat i es més fàcil caracteritzar la independència a partir de les funcions de distribució i densitat conjuntes i marginals.

Theorem 2.1. Teorema de factorització

Sigui $X = (X_1, \dots, X_k)$ un vector aleatori amb funció de distribució conjunta $F_X(x_1, \dots, x_k)$ i funció de densitat o probabilitat $f_X(x_1, \dots, x_k)$. Si $F_j(x_j)$ i $f_j(x_j), j = 1, \dots, k$ con les funcions de distribució marginals i les funcions de densitat o probabilitat marginals de cada component del vector aleatori direm que les variables $X_1, \dots, X_k$ son independents si i només si es verifiquen les següents condicions equivalents:

1. $F_X(x_1, \dots, x_k) = \prod_{l=1}^k F_j(x_j), \quad \forall (x_1, \dots, x_k) \in \mathbb{R}^k$
2. $f_X(x_1, \dots, x_k) = \prod_{l=1}^k f_j(x_j), \quad \forall (x_1, \dots, x_k) \in \mathbb{R}^k$

Demostració

Suposem que les variables aleatòries contínues $(X_1, \dots, X_k)$ són independents. Per definició,

$$\prod_{j=1}^k \Pr(X_j \in A_j), \quad \forall, A_1, \dots, A_k \in \mathcal{B}(\mathbb{R}).$$

1.- Siguin els conjunts $A_j = (-\infty, x_j]$ $j = 1, \dots, k$

Aleshores,

$$\begin{aligned} F_X(x_1, \dots, x_k) &= P(X_1 \leq x_1, \dots, X_k \leq x_k) \\ &= P(X_1 \in (-\infty, x_1], \dots, X_k \in (-\infty, x_k]) \\ &= \prod_{j=1}^k P(X_j \in (-\infty, x_j]) = \prod_{j=1}^k P(X_j \leq x_j) \\ &= \prod_{j=1}^k F_j(x_j) \end{aligned}$$

2- A partir del càlcul de la densitat conjunta i tenim en compte que cada factor $F_j(x_j)$ només depèn de la variable x_j

$$\begin{aligned} f_X(x_1, \dots, x_k) &= \frac{\partial^k}{\partial x_1 \dots \partial x_k} F_X(x_1, \dots, x_k) \\ &= \frac{\partial^k}{\partial x_1 \dots \partial x_k} \left(\prod_{j=1}^k F_j(x_j) \right) \\ &= \frac{\partial}{\partial x_1} F_1(x_1) \cdot \frac{\partial}{\partial x_2} F_2(x_2) \dots \frac{\partial}{\partial x_k} F_k(x_k) \\ &= f_1(x_1) \cdot f_2(x_2) \dots f_k(x_k) \\ &= \prod_{j=1}^k f_j(x_j) \end{aligned}$$

Com es va veure en el tema anterior a partir de la distribució conjunta d'un vector aleatori es poden obtenir les distribucions marginals de cadascuna de les seves components. Segons el teorema de factorització, es pot reconstruir la distribució conjunta multiplicant las distribucions marginals sempre que les variables siguin independents.

Exemple 2.1. En l'exemple 1.25 del tema anterior vàrem veure que les coordenades de la distribució conjunta de un punt triat a l'atzar en el cercle unitats C_1 tenia una densitat conjunta

$$f_{XY}(x, y) = \begin{cases} \frac{1}{\pi}, & \text{si } (x, y) \in C_1 \\ 0, & \text{en la resta} \end{cases}$$

I fàcilment i de forma simètrica, les marginals de X e Y son idèntiques i tenen la forma

$$f_X(x) = \begin{cases} \frac{2}{\pi} \sqrt{1-x^2}, & \text{si } |x| < 1 \\ 0, & \text{en la resta} \end{cases}$$

Directamente les dues variables X e Y no son independents donat que $f_{XY}(x, y) \neq f_X(x)f_Y(y)$

Definició 2.2. Mostra aleatòria

Considerem una distribució de probabilitat que ve representada per la seva funció de probabilitat o densitat de probabilitat segons sigui discreta o continua. Es diu que n variables aleatòries $X_1, \dots, X_n$ formen una mostra aleatòria d'aquesta distribució si les variables aleatòries són independents i la funció de probabilitat o densitat marginal de cada variable aleatòria X_i és f . Normalment a este conjunt de variables aleatòries es diu que són independents i idènticament distribuïdes o abreviadament i.i.d. El nombre de variables aleatòries és la grandària o mida mostral.

D'aquesta definició es dedueix que les dades observades en una mostra de subjectes d'una població han estat generades per n variables i.i.d i que la seva funció de probabilitat conjunta és el producte de les densitats de cada individu $g(x_1, \dots, x_n) = f(x_1) \dots f(x_n)$

Proposició 2.1. Independència i Esperança

Si $X_1, \dots, X_k$ són independents, aleshores $E[X_1, \dots, X_k] = E[\prod_{j=1}^k X_j] = \prod_{j=1}^k E[X_j]$

Demostració

Utilitzant la definició de esperança d'un vector i la intercanviabilitat de les integrals i els productes de funcions pel teorema de Fubini podem demostrar

$$\begin{aligned} E[(X_1 \dots X_k)] &= \int_{-\infty}^{\infty} \dots \int_{-\infty}^{\infty} x_1 \dots x_k f_X(x_1, \dots, x_k) dx_1 \dots dx_k \\ &= \int_{-\infty}^{\infty} \dots \int_{-\infty}^{\infty} \left(\prod_{i=1}^k x_i f_i(x_i) \right) dx_1 \dots dx_k \\ &= \prod_{i=1}^k \left(\int_{-\infty}^{\infty} x_i f_i(x_i) dx_i \right) \\ &= \prod_{i=1}^k E(X_i). \end{aligned}$$

En el cas discret es pot demostrar de manera anàloga, canviant integrals per sumes.

De manera més general, el resultat anterior es pot generalitzar a les funcions $g_i, i = 1, \dots, k$ són mesurables, les $g_i(X_i)$ també són variables independents i es pot escriure:

$$E\left[\prod_{j=1}^k g_j(X_j)\right] = \prod_{j=1}^k E[g_j(X_j)]$$

∴ {corollari} Si les variables $X_1, \dots, X_k$ són independents, llavors $cov(X_i, X_j) = 0, \quad \forall i, j$ ∴

Corollari 2.1. Si les variables $X_1, \dots, X_k$ són independents i les seves variàncies existeixen, la variància de $S = \sum_{i=1}^k a_i X_i$, on a_i són qualsevol número real, existeix i ve donada per $V(S) = \sum_{i=1}^k a_i^2 Var(X_i)$

Aquests corollaris permeten obtenir esperances i variàncies de algunes variables conegudes de manera fàcil com veurem en el tema 3.

2.2 Esperances i variàncies condicionades.

En el tema anterior varem introduir el concepte d'esperança i variància de un vector aleatori, així com el concepte de distribució condicional. En aquest apartat introduïrem el concepte de esperança condicional i la seva relació amb el concepte d'independència.

Definició 2.3. Esperança condicionada

Sigui (X, Y) un vector aleatori definit sobre l'espai de probabilitat $(\Omega, \mathcal{A}, \mathbb{R})$ i sigui $P_{Y|X=x}$ la distribució de probabilitat de Y condicionada a $X=x$. Si g és una funció mesurable definida de $(\mathbb{R}, \beta)$ en $(\mathbb{R}, \beta)$ de manera que $E[g(Y)]$ existeix, l'esperança condicionada de $g(Y)$ donat X , $E[g(Y)|X]$ és una variable aleatòria que per a $X = x$ pren el valor

$$E[g(Y) | X = x] = \int_{\Omega} g(y) dP_{Y|X=x}(y).$$

La forma de l'equació (2.3) depen de les característiques de la distribució del vector (X, Y)

- Si (X, Y) és un vector discret on $D_x = \{y; (x, y) \in D\}$, llavors

$$E[g(Y) | X = x] = \sum_{y \in D_x} g(y) P(Y = y | X = x) = \sum_{y \in D_x} g(y) f_{Y|X}(y | x)$$

- Si (X, Y) és un vector continu, llavors

$$E[g(Y)|X = x] = \int_{\mathbb{R}} g(y) f_{Y|X}(y|x) dy$$

Així si $g(Y)=y$ tenim

$$E[Y | X = x] = \begin{cases} \int_{-\infty}^{\infty} y f_{Y|X=x}(y) dy, & \text{en el cas continu,} \\ \sum_y y f_{Y|X=x}(y), & \text{en el cas discret.} \end{cases}$$

Quan el valor x de X varia, l'esperança condicionada de Y al valor de x també canvia. Així podem definir la funció

$$m_y = E[Y | X = x]$$

que estarà definida per a tot x tal que $f_X(x) > 0$ i que la funció de probabilitat o densitat condicionada $f_{Y|X=x}(y)$ tingui esperança finita

Definició 2.4. Funció de esperança condicionada o regressió

La funció $m_y = E[Y | X = x]$ s'anomena funció de esperança condicionada de Y donat X o també funció de regressió de Y sobre X .

Si disposem de dues variables X i Y independents amb distribució $Bi(n, p)$ es pot obtenir fàcilment la distribució de la variable $X+Y$ a partir de les definicions anteriors

$$\begin{aligned}
f_{X+Y}(m) &= P\left(\bigcup_{k=0}^m \{X = k, Y = m - k\}\right) \\
&= \sum_{k=0}^m P(X = k, Y = m - k) \\
&= \sum_{k=0}^m P(X = k)P(Y = m - k) \\
&= \sum_{k=0}^m \binom{n}{k} p^k (1-p)^{n-k} \binom{n}{m-k} p^{m-k} (1-p)^{n-(m-k)} \\
&= p^m (1-p)^{2n-m} \sum_{k=0}^m \binom{n}{k} \binom{n}{m-k} \\
&= \binom{2n}{m} p^m (1-p)^{2n-m}.
\end{aligned}$$

D'on s'obté que:

$$X + Y \sim B(2n, p).$$

La distribució de condicionada de $Y|X + Y = m$ és

$$\begin{aligned}
P(Y = k | X + Y = m) &= \frac{P(Y = k, X + Y = m)}{P(X + Y = m)} \\
&= \frac{P(Y = k, X = m - k)}{P(X + Y = m)} \\
&= \frac{\binom{n}{k} p^k (1-p)^{n-k} \binom{n}{m-k} p^{m-k} (1-p)^{n-(m-k)}}{\binom{2n}{m} p^m (1-p)^{2n-m}} \\
&= \frac{\binom{n}{k} \binom{n}{m-k}}{\binom{2n}{m}}.
\end{aligned}$$

És a dir,

$$Y | X + Y = m \sim H(m, 2n, n).$$

L'esperança condicional val:

$$E(Y | X + Y = m) = \frac{nm}{2n} = \frac{m}{2}.$$

Totes les operacions que es feien en l'operador esperança es poden realitzar en l'esperança condicionada

1. L'esperança condicionada es un operador lineal

$$E[(ag_1(Y) + bg_2(Y)) | X] = aE[g_1(Y) | X] + bE[g_2(Y) | X]$$

En particular,

$$E[(aY + b) | X] = aE(Y | X) + b.$$

2.

$$P(a \leq Y \leq b) = 1 \implies a \leq E(Y|X) \leq b$$

3.

$$P(g_1(Y) \leq g_2(Y)) = 1 \implies E[g_1(Y)|X] \leq E[g_2(Y)|X]$$

4. $E[c|X] = c$ para c constant.

Però hi ha algunes propietats que son específiques de de l'esperança condicional

Llei de l'esperança total

Si $E[g(Y)]$ existeix , llavors $E[E[g(Y)|X]] = E[g(Y)]$

Demostració:

$$\begin{aligned} E(E[g(Y) | X]) &= \int_{\mathbb{R}} E[g(Y) | x] f_X(x) dx \\ &= \int_{\mathbb{R}} \left(\int_{\mathbb{R}} g(y) f_{Y|X}(y | x) dy \right) f_X(x) dx \\ &= \int_{\mathbb{R}} \left(\int_{\mathbb{R}} g(y) f_{XY}(x, y) dy \right) dx \\ &= \int_{\mathbb{R}} g(y) \left(\int_{\mathbb{R}} f_{XY}(x, y) dx \right) dy \\ &= \int_{\mathbb{R}} g(y) f_Y(y) dy \\ &= E[g(Y)]. \end{aligned}$$

Exemple 2.2. Considerem el vector (X, Y) amb densitat conjunta

$$f_{XY}(x, y) = \begin{cases} 1/x & 0 < y \leq x \leq 1 \\ 0 & \text{en la resta.} \end{cases}$$

Fàcilment obtenim que $X \sim U(0, 1)$ i que $Y|X = x \sim U(0, x)$

aplicant el resultat anterior podem obtenir $E[Y]$

$$E[Y] = \int_0^1 E(Y|x) f_X(x) dx = \int_0^1 \frac{1}{2} x dx = \frac{1}{4}$$

Exemple 2.3. Un treballador està encarregat del correcte funcionament de n màquines situades en línia recta i distants una de l'altra l metres. El treballador ha de reparar-les quan s'espantllen, el que succeeix amb la mateixa probabilitat per totes les màquines de manera independent una de l'altra. L'operari pot seguir dues estratègies.

1. Anar a reparar la màquina que s'espallí i romandre al costat d'ella fins que un altra s'espallí i anar llavors a reparar-la
2. Situar-se al punt mig de la línia de màquines i des de allí anar a la màquina espallada i tornar al punt mig quan la màquina estigui reparada.

Si X es la distància que camina el treballador entre dues avaries consecutives, ¿Quina de les dues estratègies es la més convenient per caminar menys?

Per tant es tracta de obtenir el valor $E[X]$ amb les dues estratègies i triar la que tingui menys valor esperat. Designem $E_i[X]$ l'esperança que obtenim en cada estratègia $i = 1, 2$.

Estratègia 1

Si A_k es l'esdeveniment l'operari està en la màquina k . Per obtenir $E_1[X]$ recorrem a la propietat de l'esperança total, però utilitzan com a distribució condicionada la que es deriva condicionar respecte de l'esdeveniment A_k . Tindrem $E_1[X] = E[E(X | A_k)]$

Para obtenir $E(X | A_k)$, tinguem en compte que, si i és la pròxima màquina avariada, $P(A_i) = \frac{1}{n}$, $\forall i = 1, \dots, n$, i la distància a recórrer serà

$$X | A_k = \begin{cases} (k-i)l, & \text{si } i \leq k, \\ (i-k)l, & \text{si } i > k. \end{cases}$$

Així doncs,

$$\begin{aligned} E(X | A_k) &= \frac{1}{n} \left(\sum_{i=1}^k (k-i)l + \sum_{i=k+1}^n (i-k)l \right) \\ &= \frac{l}{2n} [2k^2 - 2(n+1)k + n(n+1)]. \end{aligned}$$

Utilitzant

$$\sum_{k=1}^n k^2 = \frac{n(n+1)(2n+1)}{6},$$

obtenim

$$E_1(X) = E(E(X | A_k)) = \frac{1}{n} \sum_{k=1}^n E(X | A_k) = \frac{l(n^2-1)}{3n}.$$

Estratègia 2

Per facilitar els càlculs, suposem que n és imparell, de manera que hi ha una màquina situada al punt mig de la línia, és a dir, la $\frac{n+1}{2}$ -èsima. Si la pròxima màquina avariada és la i -èsima, la distància a recórrer serà

$$X = \begin{cases} 2 \left(\frac{n+1}{2} - i \right) l, & \text{si } i \leq \frac{n+1}{2}, \\ 2 \left(i - \frac{n+1}{2} \right) l, & \text{si } i > \frac{n+1}{2}, \end{cases}$$

on el factor 2 es justifica perquè, en aquesta segona estratègia, l'operari torna sempre al punt mig de la línia de màquines.

L'esperança ve donada per

$$E_2(X) = \frac{2}{n} \sum_{i=1}^n \left| \frac{n+1}{2} - i \right| l_i = \frac{l(n-1)}{2}$$

Com que $E_1(X) \leq E_2(X) \iff \frac{n+1}{3n} \leq \frac{1}{2} \iff n \geq 2$, podem deduir que la primera estratègia és millor, excepte quan només hi ha una màquina.

Definició 2.5. Variància condicionada

Definim la variància condicionada $Var(Y|X)$ a la variable definida con una funció de la variable aleatòria X com la funció $v_Y(x)$

$$v_Y(x) = Var(Y|X = x) = E[Y^2|X] - (E[Y|X])^2$$

També és possible relacionar la variància absoluta amb la variància condicionada, encara que l'expressió no és tan directa com la que s'ha obtingut per a l'esperança.

Proposició 2.2. *** Llei de la variància total** Si $E[Y^2]$ existeix, llavors*

$$var(Y) = E(var[Y|X]) + var(E[X|Y])$$

Demostració

$$\begin{aligned} Var(Y) &= E[(Y - E(Y))^2] = E\{E[(Y - E(Y))^2 | X]\} \\ &= E\{E[Y^2 + (E(Y))^2 - 2YE(Y) | X]\} \\ &= E\{E[Y^2 | X] + E(Y)^2 - 2E(Y)E[Y | X]\} \\ &= E\{Var(Y | X) + (E[Y | X])^2 + E(Y)^2 - 2E(Y)E[Y | X]\} \\ &= E\{Var(Y | X) + (E[Y | X] - E(Y))^2\} \\ &= E\{Var(Y | X)\} + E[(E[Y | X] - E(Y))^2] \\ &= E(Var(Y | X)) + Var(E[Y | X]) \end{aligned}$$

∴{.corollary}

Si $E[Y^2]$ existeix, per la propietat anterior $Var(Y) \geq Var(E[Y|X])$

∴

Exemple 2.4. Siguin (X, Y) variables aleatòries contínues amb densitat conjunta

$$f(x, y) = \begin{cases} e^{-y}, & 0 \leq x \leq y, \\ 0, & \text{en la resta} \end{cases}$$

(a) Densitat marginal de X

$$f_X(x) = \int_x^\infty f(x, y) dy = \int_x^\infty e^{-y} dy = [-e^{-y}]_x^\infty = e^{-x}$$

Per tant, $X \sim \text{Exp}(1)$

(b) Densitat marginal de Y

$$f_Y(y) = \int_0^y f(x, y) dx = \int_0^y e^{-y} dx = e^{-y} [x]_0^y = ye^{-y}$$

Per tant, $Y \sim \Gamma(\alpha = 2, \beta = 1)$

(c) Densitat condicional de $(X \mid Y = y)$

$$f_{X|Y=y}(x) = \frac{f(x, y)}{f_Y(y)} = \frac{e^{-y}}{ye^{-y}} = \frac{1}{y}, \quad 0 \leq x \leq y$$

Per tant $(X \mid Y = y) \sim U[0, y]$

(d) Densitat condicional de $(Y \mid X = x)$

$$f_{Y|X=x}(y) = \frac{f(x, y)}{f_X(x)} = \frac{e^{-y}}{e^{-x}} = e^{-(y-x)}, \quad y \geq x$$

Per tant, $(Y \mid X = x)$ segueix una exponencial desplaçada.

(e) Esperança i variància condicionades de $X \mid Y = y$

$$E(X \mid Y = y) = \int_0^y x \frac{1}{y} dx = \frac{1}{y} \left[\frac{x^2}{2} \right]_0^y = \frac{y}{2}$$

Com que $(X \mid Y = y) \sim U[0, y]$, podem obtenir directament les expressions de la variància i la esperança també tenim

$$\text{Var}(X \mid Y = y) = \frac{y^2}{12} \text{ i } E(X \mid Y) = \frac{Y}{2}$$

(f) Esperança i variància condicionades de $(Y \mid X = x)$

$$E(Y \mid X = x) = \int_x^\infty ye^{-(y-x)} dy = \left\{ \begin{array}{ll} u = y & du = 1 \\ dv = e^{-(y-x)} & v = -e^{-(y-x)} \end{array} \right\}$$

$$= e^x [-ye^{-y}]_x^\infty - \int_x^\infty e^{-y} dy = e^x (xe^{-x} + e^{-x}) = x + 1.$$

$$E(Y^2 \mid X = x) = \int_x^\infty y^2 e^{-(y-x)} dy = \left\{ \begin{array}{l} z = y - x \\ dz = dy \end{array} \right\}$$

$$\begin{aligned} E(Y^2 \mid X = x) &= \int_x^\infty y^2 e^{-(y-x)} dy = \left\{ \begin{array}{l} z = y - x \\ dz = dy \end{array} \right\} \\ &= \int_0^\infty (z+x)^2 e^{-z} dz = \int_0^\infty z^2 e^{-z} dz + x^2 \int_0^\infty e^{-z} dz + 2x \int_0^\infty ze^{-z} dz \\ &= \frac{\Gamma(2)}{1^2} \int_0^\infty \frac{1^2}{\Gamma(2)} ze^{-z} dz + x^2 + 2x \\ &= 2 + x^2 + 2x \\ &= (x+1)^2 + 1. \end{aligned}$$

On hem usat que si $X \sim \Gamma(\alpha, \beta)$ llavors $E[X] = \frac{\alpha}{\beta}$, $E[X^2] = \frac{\alpha(\alpha+1)}{\beta^2}$ i $\text{Var}[X] = \frac{\alpha}{\beta^2}$,

Amb aquests càlculs podem trobar la variable aleatòria $\text{Var}(Y|X)$ com $\text{Var}(Y|X = x) = 1 + (x + 1)^2 - (x + 1)^2 = 1$

Per tant

$$E(Y|X) = X + 1 \text{ i } \text{Var}(Y|X) = 1$$

(g) Variància de Y

Directamente de la definició

$$\text{Var}(Y) = \text{Var}(\Gamma(\alpha = 2, \beta = 1)) = \frac{2}{1^2} = 2.$$

Ara podem comprovar la segona part de la llei de la variància total:

$$\begin{aligned} \text{Var}(Y) &= E(\text{Var}(Y | X)) + \text{Var}(E(Y | X)) \\ &= E(1) + \text{Var}(X + 1) \\ &= 1 + \text{Var}(X) \\ &= 1 + 1 = 2. \end{aligned}$$

(h) Variància de X

$$\begin{aligned} 1 &= \text{Var}(X) \\ &= E(\text{Var}(X | Y)) + \text{Var}(E(X | Y)) \\ &= E\left(\frac{Y}{2}\right) + \text{Var}\left(\frac{Y}{2}\right) \\ &= \frac{1}{2}E(Y) + \frac{1}{4}\text{Var}(Y) \\ &= \frac{1}{2} \cdot 1 + \frac{1}{4} \cdot 2 \\ &= \frac{1}{2} + \frac{1}{2} = 1. \end{aligned}$$

2.3 Conceptes de covariància, correlació i causalitat

En el capítol anterior vàrem introduir el càlcul de la matriu de variàncies-covariàncies. En aquest apartat anem a discutir sobre la interpretació incloent conceptes com la correlació i la causalitat.

2.3.1 Desigualtats

En primer lloc anem a formular algunes desigualtats que són útils quan no coneixem la distribució de algunes variables, però sí que coneixem alguns dels seus moments o els estimem a partir de les observacions. En aquest cas les desigualtats permeten establir cotes de les probabilitats a partir dels moments i poden ajudar a demostrar alguns teoremes crucials com la llei dels grans números.

Per a una variable $X \geq 0$ existeix la seva esperança, sigui $\epsilon > 0$ podem escriure el valor de l'esperança com

$$E[X] = \int_0^{+\infty} P(X \geq x)dx = \int_0^{\epsilon} P(X \geq x)dx + \int_{\epsilon}^{+\infty} P(X \geq x)dx$$

Com que la segona integral es no negativa i la funció $P(X \geq \epsilon)$ es decreixent

$$E[X] \geq \int_0^\epsilon P(X \geq x) dx \geq \int_0^\epsilon P(X \geq \epsilon) dx = \epsilon P(X \geq \epsilon)$$

i d'ací

$$P(X \geq \epsilon) \leq \frac{E[X]}{\epsilon}$$

Aquest resultat dona lloc a dues conegudes desigualtats generals que proporcionen cotes superiors per a la probabilitat de certs conjunts i que són vàlides independentment de la distribució de la variable involucrada.

Desigualtat de Markov

Si en la desigualtat (2.3.1) substituïm X per $|X|^k$ i ϵ per ϵ^k tenim

$$P(|X| \geq \epsilon) = P(|X|^k \geq \epsilon^k) \leq \frac{E[|X|^k]}{\epsilon^k}$$

coneguda com a desigualtat de Markov.

Desigualtat de Tchebixev

Un cas especial de (2.3.1), que es coneix com la desigualtat de Tchebixev, és el cas en el que $k=2$ i $X=X-E[X]$

$$P(|X - E[X]| \geq \epsilon) \leq \frac{1}{\epsilon^2} \text{Var}(X)$$

Proposició 2.3. Si $V(X) = 0$ aleshores X es constant amb probabilitat 1.

Demostració

Suposem $E[X] = \mu$ i considerem els conjunts $A_n = |X - \mu| \geq 1/n$ aplicant la desigualtat de Tchebixev

$$P(A_n) = P(|X - \mu| \geq \frac{1}{n}) = 0 \forall n$$

d'ací obtenim que $P(\cup_n A_n) = 0$ i $P(\cap_n A_n^c) = 1$ Però

$$\bigcap_{n \geq 1} A_n^c = \bigcap_{n \geq 1} \{|X - \mu| \geq \frac{1}{n}\}^c = \{X = \mu\}$$

i per tant $P(X = \mu) = 1$

Desigualtat de Jensen

Si $g(X)$ es convexa sabem que $\forall a, \exists \lambda_a$ tal que $g(x) \geq g(a) + \lambda_a(x - a)$

Si es substitueix $a = E[X]$ llavors

$$g(X) \geq g(E[X]) + \lambda_a(X - E[X])$$

i calculant esperances de l'expressió anterior obtenim la coneguda com desigualtat de Jensen

$$E[g(X)] \geq g(E[X])$$

...{.Theorem #thm-cauchy} **Desigualtat de Cauchy-Schwarz**

Si X i Y son variables aleatòries amb variàncies finites. Aleshores, $\text{cov}(X, Y)$ existeix i es verifica que

$$(E[XY])^2 \leq E[X^2]E[Y^2]$$

verificant-se la igualtat si i només si existeix un nombre real tal que $P(\alpha X + Y = 0) = 1$::: **Demostració**
Per qualsevol nombre real a i b es verifica que:

$$|ab| \leq \frac{a^2 + b^2}{2}$$

el que significa que si $E[XY] < \infty$, $E[X^2] < \infty$ i $E[Y^2] < \infty$

Per altra banda per qualsevol real α es té que:

$$E[(\alpha X + Y)^2] = \alpha^2 E[X^2] + 2\alpha E[XY] + E[Y^2] \geq 0$$

que es tracta d'una equació de segon grau que té almenys una arrel i el seu discriminant no serà positiu. És a dir:

$$(E[XY])^2 \leq E[X^2]E[Y^2]$$

Si es donés el cas de la igualtat, l'equació tindria una arrel doble α_0 i $E[(\alpha_0 X + Y)^2] = 0$ de una funció no negativa que implica que $P(\alpha_0 X + Y = 0) = 1$

2.3.2 Covariància i Correlació

Si recordem del tema 1, la covariància entre dues variables es pot expressar com

$$\text{cov}(X_i, X_j) = E[(X_i - E[X_i])(X_j - E[X_j])] = E[(X_i X_j)] - E[X_i]E[X_j]$$

La covariància ens informa sobre el grau i tipus de dependència entre dues variables a través de la seva magnitud i signe, ja que la relació pot ser positiva o negativa. Tanmateix les unitats de mesura de les variables, alteren els valors de les covariàncies. Si X és el pes i Y és l'alçada en centímetres i transformem l'alçada en metres multiplicant per 100 $\text{Cov}(X, 100Y) = 100\text{Cov}(X, Y)$ segons (1.4.3)

Definició 2.6. Coeficient de correlació

Si (X, Y) són variables aleatòries amb variàncies finites $\text{Var}(X) = \sigma_X^2$ i $\text{Var}(Y) = \sigma_Y^2$ la correlació $\rho(X, Y)$ entre X i Y es defineix com

$$\rho(X, Y) = \frac{\text{Cov}(X, Y)}{\sqrt{\text{Var}(X)\text{Var}(Y)}} = \frac{\sigma_{XY}}{\sigma_X \sigma_Y} = E \left[\left(\frac{X - E[X]}{\sigma_X} \right) \left(\frac{Y - E[Y]}{\sigma_Y} \right) \right] = \text{cov}(X_t, Y_t)$$

és a dir la covariància de les variables X i Y tipificades

Proposició 2.4. *Siguin X i Y dues variables aleatòries amb variància finita llavors*

$$(\text{Cov}(X, Y))^2 \leq \sigma_X^2 \sigma_Y^2$$

i d'ací es desprèn que $\rho_{XY}^2 \leq 1$ i en particular $-1 \leq \rho_{XY} \leq 1$. A més la desigualtat seria igualtat si i només si hi ha una constant α_0 tal que amb probabilitat 1, $P(\alpha_0 X + Y = 0) = 1$ el que implica que la correlació $\rho_{XY}^2 = 1$

Demostració

Considerem les variables centrades $X_c = X - E[X]$ i $Y_c = Y - E[Y]$

Per definició de covariància

$$\text{Cov}(X, Y) = E[X_c, Y_c]$$

A partir de la desigualtat de Cauchy-Schwartz (2.3.1) podem deduir que

$$(E[X_c Y_c])^2 \leq E[X_c^2] E[Y_c^2]$$

A més sabem que $E[X_c^2] = Var(X) = \sigma_X^2$ i $E[Y_c^2] = Var(Y) = \sigma_Y^2$

per tant

$$(Cov(X, Y))^2 = \sigma_{X,Y}^2 = (E[X_c Y_c])^2 \leq E[X_c^2] E[Y_c^2] = \sigma_X^2 \sigma_Y^2$$

Com a conseqüència si $\sigma_X > 0$ i $\sigma_Y > 0$ el coeficient de correlació es

$$\rho(X, Y) = \frac{Cov(X, Y)}{Var(X)Var(Y)} = \frac{\sigma_{XY}}{\sigma_X \sigma_Y}$$

i elevat al quadrat

$$\rho_{X,Y}^2 = \frac{\sigma_{XY}^2}{\sigma_X^2 \sigma_Y^2} \leq \frac{\sigma_X^2 \sigma_Y^2}{\sigma_X^2 \sigma_Y^2} = 1$$

i per tant

$$-1 \leq \rho_{XY} \leq 1$$

En el cas de igualtat també per la desigualtat de Cauchy-Schwarz es sabe que existeix una constant α_0 tal que les variables centrades X_c i Y_c estan relacionades linealment amb probabilitat 1. $P(\alpha_0 X_c + Y_c = 0) = 1$ i per tant la correlació al quadrat valdrà 1. És a dir $\rho_{XY} = -1$ ó $\rho_{XY} = 1$. En aquest cas es parla de relació lineal perfecta.

Si $\rho_{XY} > 0$ parlarem de que les variables estan positivament correlacionades i si $\rho_{XY} < 0$ direm que estan negativament correlacionades.

Si $\rho_{XY} = 0$ es diu que les variables estan incorrelades i a més a més la $Cov(X, Y) = 0$ i hi ha absència de correlació lineal.

Theorem 2.2. Si X_i i X_j son independents aleshores $Cov(X_i, X_j) = \rho_{X_i, X_j} = 0$

Demostració

Si dues variables son independents l'esperança del producte es el producte d'esperances .

Així

$$cov(X_i, X_j) = E[(X_i X_j)] - E[X_i]E[X_j] = E[X_i]E[X_j] - E[X_i]E[X_j] = 0$$

L'invers del teorema anterior no es compleix en general, es a dir dues variables poden estar incorrelades però no ser independents.

Exemple 2.5. Imaginem una variable aleatòria X que pren només tres valors $\{-1, 0, 1\}$ i que cadascú d'aquests valors te la mateixa probabilitat (1/3). Imaginem la variable $Y = X^2$. Les dues variables clarament no son independents per definició ja que els valors de Y estan completament determinats pels valors de X .

Si calculem $E[XY] = E[X^3] = E[X] = 0$ ja que la variable X i X^3 son la mateixa que X . A més $E[X]E[Y] = 0$ ja que $E[X] = 0$.

Per tant

$$Cov(X, Y) = E[X, Y] - E[X]E[Y] = 0 - 0 = 0$$

Matriu de Correlació

Si (X_1, X_2) es un vector de 2 variables aleatòries definim la matriu de correlació R a la matriu 2x2 amb les correlacions entre les dues variables i 1 en la diagonal tenint en compte que la correlació $\rho_{12} = \rho_{21}$

$$R = \begin{bmatrix} 1 & \rho_{12} \\ \rho_{21} & 1 \end{bmatrix}$$

En general. Si $X = (X_1, \dots, X_k)$ és un vector aleatori de dimensió k la matriu de correlacions és

$$R = \begin{bmatrix} 1 & \rho_{12} & \dots & \rho_{1(k-1)} & \rho_{1k} \\ \rho_{21} & 1 & \dots & \rho_{2(k-1)} & \rho_{2k} \\ \vdots & \vdots & \ddots & \vdots & \vdots \\ \rho_{(k-1)1} & \rho_{(k-1)2} & \dots & 1 & \rho_{(k-1)k} \\ \rho_{k1} & \rho_{k2} & \dots & \rho_{k(k-1)} & 1 \end{bmatrix}$$

La matriu de variàncies-covariàncies Σ es relaciona directament amb la matriu de correlació R amb la següent fórmula:

$$\Sigma = D \cdot R \cdot D$$

i per tant

$$R = D^{-1} \cdot \Sigma \cdot D^{-1}$$

on D es la matriu diagonal de desviacions típiques

$$D = \begin{bmatrix} \sigma_1 & 0 & \dots & 0 & 0 \\ 0 & \sigma_2 & \dots & 0 & 0 \\ \vdots & \vdots & \ddots & \vdots & \vdots \\ 0 & 0 & \dots & \sigma_{n-1} & 0 \\ 0 & 0 & \dots & 0 & \sigma_n \end{bmatrix}$$

i D^{-1} es una matriu diagonal amb $\frac{1}{\sigma_i}$ en la diagonal

2.3.3 Causalitat i correlació.

Tal i com hem vist en apartat anterior deïem que dues variables estan relacionades si existeix correlació entre les mateixes. Aquesta correlació es una mesura estadística que descriu una direcció de relació (positiva o negativa) i una intensitat que va entre 0 i 1 en valors absoluts. No obstant, aquesta correlació no implica que el canvi en una variable automàticament es vegi reflectit en el canvi d'un altra.

La causalitat implica que el canvi en la ocurrència en una variable implica el canvi en l'altra. Per exemple, si una variable és la quantitat de les hores treballades i l'altra es la quantitat de diners guanyats quan a un treballador se li paga per hores, està clar que un increment d'hores treballades implica un augment del diners rebuts.

A més de l'existència de relació entre dues variables com per exemple correlació lineal son necessàries algunes altres característiques com la seqüència temporal (la causa ha d'existir abans de la conseqüència), la plausibilitat, la consistència, l'especificitat etc.

Per exemple, el consum de gelats te una bona correlació amb el nombre de ofegaments en piscines, platges, rius, etc. però està clar que el menjar-es un gelat no fa que t'ofegues en una piscina. Simplemet hi ha una

correlació temporal. Es messos d'estiu es quan més calor fa i es mengen més gelats i la gent es banya més amb risc d'ofegar-se. Al contrari passa al hivern, es mengen més gelats i como la gent no es banya disminueix el risc d'ofegament. En la següent figura es poden veure dades reals en USA on la correlació es 0.44 i està clar que no hi ha relació causal.




Figura 13: Correlació espúria entre el consum de gelats i morts per ofegament en aigua en USA

En la URL <https://tylervigen.com/spurious-correlations> es poden trobar nombroses correlacions espúries on estan disponibles les dades. D'ací la famosa frase en estadística **Correlation is not causation**, la correlació no implica causalitat.

3 Algunes distribucions multivariants

En els dos temes anteriors s'ha introduït el concepte de vectors aleatoris i totes les funcions associades a les seves distribucions. En aquest tema introduïrem algunes de les distribucions de probabilitat més utilitzades. Dedicarem un apartat sencer a la distribució normal multivariant, introduïrem algunes de les distribucions discretes i contínues més utilitzades i en la tercera part del tema parlarem de la generació de distribucions multivariants.

3.1 Distribució normal multivariant: definició, propietats i aplicacions.

3.1.1 Distribució normal bivariant

Definició 3.1. Vector aleatori normal bivariant

El vector aleatori bidimensional (X, Y) té una distribució normal bivariant de paràmetres

$\mu_x \in \mathbb{R}, \mu_y \in \mathbb{R}, \sigma_x > 0, \sigma_y > 0$ i ρ tal que $|\rho| < 1$ si la funció de densitat conjunta és de la forma

$$f_{XY}(x, y) = \frac{1}{2\pi\sigma_x\sigma_y\sqrt{(1-\rho^2)}} e^{-\frac{q(x, y)}{2}}, (x, y) \in \mathbb{R}^2$$

on

$$q(x, y) = \frac{1}{1 - \rho^2} \left\{ \left(\frac{x - \mu_x}{\sigma_x} \right)^2 - 2\rho \left(\frac{x - \mu_x}{\sigma_x} \right) \left(\frac{y - \mu_y}{\sigma_y} \right) + \left(\frac{y - \mu_y}{\sigma_y} \right)^2 \right\}$$

En la figura 14 es mostra en la part esquerra la distribució de densitat normal bivariant conjunta i en la part dreta es mostren les corbes de nivell. Es pot veure la forma el·líptica que té la figura que mostra el nivell de correlació entre les dues variables, que és molt estreta ja que la correlació és $\rho = 0.8$.




Figura 14: Densitat i corbes de nivell binormal amb $\mu_x = \mu_y = 0$, $\sigma_x = \sigma_y = 1$ i $\rho = 0.8$

L'expressió de la densitat normal bivariant es pot enunciar d'una manera més compacta a partir de la matriu de variàncies-covariàncies

$$\Sigma = \begin{bmatrix} \sigma_x^2 & \sigma_{xy} \\ \sigma_{xy} & \sigma_y^2 \end{bmatrix}$$

$$f(x, y) = \frac{|\Sigma|^{-\frac{1}{2}}}{2\pi} e^{-\frac{1}{2}(\mathbf{x}-\boldsymbol{\mu})'\Sigma^{-1}(\mathbf{x}-\boldsymbol{\mu})}, \quad (x, y) \in \mathbb{R}^2$$

On $\mathbf{x}' = (x, y)$ és el vector de variables aleatòries i $\boldsymbol{\mu}' = (\mu_x, \mu_y)$ és el vector de mitjanes o valors esperats i $|\Sigma|$ es el determinant de Σ que pren el valor

$$|\Sigma| = \sigma_x^2 \sigma_y^2 - \sigma_{xy}^2 = \sigma_x^2 \sigma_y^2 (1 - \rho_{xy}^2)$$

Així en aquest cas es diu que $\mathbf{x}' = (x, y)$ té una distribució normal bivariant en vector d'esperances $\boldsymbol{\mu}$ i matriu de variàncies-covariàncies Σ .

Escriurem

$$\begin{pmatrix} X \\ Y \end{pmatrix} \sim N\left(\mu = \begin{pmatrix} \mu_x \\ \mu_y \end{pmatrix}, \Sigma = \begin{pmatrix} \sigma_x^2 & \rho\sigma_x\sigma_y \\ \rho\sigma_x\sigma_y & \sigma_y^2 \end{pmatrix}\right)$$

Queda per al lector la comprovació de l'equivalència de les expressions de les funcions de densitat.

Definició 3.2. Distribució normal bivariant estàndard amb marginal independents

Sigui $Z_1 \sim N(0, 1)$ i $Z_2 \sim N(0, 1)$ amb Z_1 i Z_2 independents i per tant $\rho = 0$ Llavors

$$f_{Z_1, Z_2}(z_1, z_2) = f_{Z_1}(z_1)f_{Z_2}(z_2) = \frac{1}{\sqrt{2\pi}}e^{-\frac{z_1^2}{2}} \frac{1}{\sqrt{2\pi}}e^{-\frac{z_2^2}{2}} = \frac{1}{2\pi}e^{(-\frac{1}{2})(z_1^2+z_2^2)} = \frac{1}{2\pi}e^{(-\frac{1}{2})(\mathbf{z}'\mathbf{z})}$$

amb $\mathbf{z} = (z_1, z_2)^T \in \mathbb{R}^2$

En la gràfica es mostra la densitat de la binormal estàndard amb mostres independents. S'observa que la corba de nivell està formada per isòcrones de densitat en forma de cercles.




Figura 15: Densitat i corbes de nivell binormal amb $\mu_x = \mu_y = 0, \sigma_x = \sigma_y = 1$ i $\rho = 0$

Definició 3.3. Distribució normal bivariant estàndard amb marginals correlades

Sigui $Z_1 \sim N(0, 1)$ i $Z_2 \sim N(0, 1)$ amb Z_1 i Z_2 i la correlació $\rho \in (-1, 1)$ Llavors

$$f_{Z_1, Z_2}(z_1, z_2) = \frac{1}{2\pi\sqrt{1-\rho^2}}e^{(-\frac{1}{2(1-\rho^2)})(z_1^2-2\rho z_1 z_2+z_2^2)} (\#eq : fxybinormstandcorr$$

es defineix com la funció de densitat conjunta de la distribució normal bivariant estàndard amb marginals correlades

Exemple 3.1. Per qüestions de conveniència formal hem introduït la distribució de les variables normals bivariants com a combinació de variables aleatòries normals independents. Cal remarcar que en nombroses ocasions aquesta distribució es la manera habitual com es presenten les dades. De fet Karl Pearson a partir de les dades treballades de Francis Galton a finals del segle 19, planteja el coeficient de correlació entre les alçades dels pares i els fills, on hi ha una correlació diferent de 0 entre elles. Els pares alts tendeixen a tenir els fills alts i a l'inrevés en els baixets. Aquesta seria una distribució normal bivariant.

Proposició 3.1. *Transformació d'una normal bivariant estàndard en una normal bivariant general*

Sigui (Z_1, Z_2) un vector aleatori amb distribució normal bivariant estàndard:

$$\begin{pmatrix} Z_1 \\ Z_2 \end{pmatrix} \sim N \left(\begin{pmatrix} 0 \\ 0 \end{pmatrix}, \begin{pmatrix} 1 & \rho \\ \rho & 1 \end{pmatrix} \right)$$

i siguin $\mu_x, \mu_y \in \mathbb{R}$ y $\sigma_x, \sigma_y > 0$. Definim:

$$X = \mu_x + \sigma_x Z_1$$

$$Y = \mu_y + \sigma_y Z_2$$

Lavors el vector:

$$\begin{pmatrix} X \\ Y \end{pmatrix}$$

segueix una distribució normal bivariate general:

$$\begin{pmatrix} X \\ Y \end{pmatrix} \sim N \left(\begin{pmatrix} \mu_x \\ \mu_y \end{pmatrix}, \begin{pmatrix} \sigma_x^2 & \rho\sigma_x\sigma_y \\ \rho\sigma_x\sigma_y & \sigma_y^2 \end{pmatrix} \right)$$

És a dir, qualsevol normal bivariant pot obtenir-se a partir d'una normal bivariant estàndard mitjançant una transformació lineal de escala i translació

Demostració

La demostració es immediata utilitzant les propietats de l'esperança, variància i covariància.

Per l'esperança:

$$E(X) = E(\mu_x + \sigma_x Z_1) = \mu_x + \sigma_x E(Z_1) = \mu_x$$

donat que $E(Z_1) = 0$. Analogament:

$$E(Y) = E(\mu_y + \sigma_y Z_2) = \mu_y$$

Per a les variàncies:

$$Var(X) = Var(\mu_x + \sigma_x Z_1) = \sigma_x^2 Var(Z_1) = \sigma_x^2$$

i:

$$Var(Y) = Var(\mu_y + \sigma_y Z_2) = \sigma_y^2 Var(Z_2) = \sigma_y^2$$

Finalment, per a la covariància:

$$Cov(X, Y) = Cov(\mu_x + \sigma_x Z_1, \mu_y + \sigma_y Z_2)$$

Com que les constants no afecten a la covariància:

$$Cov(X, Y) = \sigma_x \sigma_y Cov(Z_1, Z_2)$$

i, donat que: $Cov(Z_1, Z_2) = \rho$ s'obté:

$$Cov(X, Y) = \rho \sigma_x \sigma_y$$

Per tant, la matriu de variàncies-covariàncies del vector (X, Y) és:

$$\Sigma = \begin{pmatrix} \sigma_x^2 & \rho \sigma_x \sigma_y \\ \rho \sigma_x \sigma_y & \sigma_y^2 \end{pmatrix}$$

amb el que queda demostrat que:

$$\begin{pmatrix} X \\ Y \end{pmatrix} \sim N \left(\begin{pmatrix} \mu_x \\ \mu_y \end{pmatrix}, \Sigma \right)$$

3.1.2 Distribucions marginals i condicional de una normal bivariant.

Distribucions marginals

Sigui (X, Y) un vector aleatori que segueix una distribució normal bivariant amb paràmetres $\mu_x, \mu_y \in \mathbb{R}$ y $\sigma_x, \sigma_y > 0$ i $\rho \in [-1, 1]$. que tal com hem vist podem representar com la combinació de distribucions normals estàndard Z_1, Z_2 . Per això X i Y segueixen una distribució normal $X \sim N(\mu_x, \sigma_x)$ i $Y \sim N(\mu_y, \sigma_y)$

En la figura 16 es mostren les distribucions marginals de la distribució normal bivariant que es veu segueixen una distribució normal.

Proposició 3.2. Independència i correlació en una distribució normal bivariant

Siguin X i Y dues variables aleatòries amb distribució normal bivariant:

$$\begin{pmatrix} X \\ Y \end{pmatrix} \sim N \left(\begin{pmatrix} \mu_x \\ \mu_y \end{pmatrix}, \begin{pmatrix} \sigma_x^2 & \rho \sigma_x \sigma_y \\ \rho \sigma_x \sigma_y & \sigma_y^2 \end{pmatrix} \right)$$

Llavors X i Y son independents si i només si $\rho = 0$. És a dir , en una distribució normal bivariant, la absència de correlació equival a la independència.




Figura 16: Marginals de la distribució continua bivariant

Demostració

La funció de densitat d'una distribució normal bivariant és

$$f_{X,Y}(x,y) = \frac{1}{2\pi\sigma_x\sigma_y\sqrt{1-\rho^2}} \exp\left(-\frac{1}{2(1-\rho^2)} \left[\frac{(x-\mu_x)^2}{\sigma_x^2} - 2\rho\frac{(x-\mu_x)(y-\mu_y)}{\sigma_x\sigma_y} + \frac{(y-\mu_y)^2}{\sigma_y^2} \right]\right)$$

A més, les distribucions marginals són

$$X \sim N(\mu_x, \sigma_x^2), \quad Y \sim N(\mu_y, \sigma_y^2),$$

amb densitats

$$f_X(x) = \frac{1}{\sqrt{2\pi}\sigma_x} \exp\left(-\frac{(x-\mu_x)^2}{2\sigma_x^2}\right)$$

i

$$f_Y(y) = \frac{1}{\sqrt{2\pi}\sigma_y} \exp\left(-\frac{(y-\mu_y)^2}{2\sigma_y^2}\right)$$

Cal demostrar les dues implicacions.

⇒ Si (X) i (Y) són independents, aleshores $\rho = 0$

Si (X) i (Y) són independents, $f_{X,Y}(x,y) = f_X(x)f_Y(y)$

D'altra banda,

$$\text{Cov}(X,Y) = E[(X-\mu_x)(Y-\mu_y)] = E(X-\mu_x)E(Y-\mu_y) = 0$$

ja que l'esperança del producte es factoritza per la independència.

Com que

$\text{Cov}(X, Y) = \rho \sigma_x \sigma_y$ i $\sigma_x, \sigma_y > 0$, s'obté $\rho = 0$

$\Leftarrow$ Si $\rho = 0$, aleshores (X) i (Y) són independents

Suposem ara que $\rho = 0$. La densitat conjunta esdevé

$$f_{X,Y}(x, y) = \frac{1}{2\pi\sigma_x\sigma_y} \exp \left[-\frac{1}{2} \left(\frac{(x - \mu_x)^2}{\sigma_x^2} + \frac{(y - \mu_y)^2}{\sigma_y^2} \right) \right].$$

Utilitzant que $e^{a+b} = e^a e^b$

$$f_{X,Y}(x, y) = \left[\frac{1}{\sqrt{2\pi}\sigma_x} \exp \left(-\frac{(x - \mu_x)^2}{2\sigma_x^2} \right) \right] \left[\frac{1}{\sqrt{2\pi}\sigma_y} \exp \left(-\frac{(y - \mu_y)^2}{2\sigma_y^2} \right) \right] = f_X(x) f_Y(y)$$

La densitat conjunta factoritza com el producte de les densitats marginals. Per la caracterització de la independència mitjançant les densitats, es conclou que (X) i (Y) són independents.

Per tant,

$$X \perp Y \iff \rho = 0$$

Així, en una distribució normal bivariant, la incorrelació és equivalent a la independència.

Theorem 3.1. *Distribucions condicionals*

Sigui (X, Y) un vector aleatori que segueix una distribució normal bivariant amb paràmetres $\mu_x, \mu_y \in \mathbb{R}$ y $\sigma_x, \sigma_y > 0$ i $\rho \in [-1, 1]$ amb la funció de densitat definida en (3.1) corresponent a una distribució normal bivariant. La distribució condicional de y donat que $X = x$ es una distribució normal amb la esperança i variància següent:

$$E(Y|X = x) = \mu_Y + \rho \sigma_Y \left(\frac{X - \mu_X}{\sigma_X} \right)$$

$$\text{Var}(Y|X = x) = (1 - \rho^2) \sigma_Y^2$$

Demostració

Utilitzant l'expressió $X = \mu_X + \sigma_X Z_1$ i $Y = \mu_Y + \sigma_Y (\rho Z_1 + \sqrt{1 - \rho^2} Z_2)$ on $Z_1, Z_2 \sim N(0, 1)$ podem trobar $E(Y | X)$ com

$$\begin{aligned} E[Y | X = x] &= E \left[\mu_Y + \sigma_Y (\rho Z_1 + \sqrt{1 - \rho^2} Z_2) \mid X = x \right] \\ &= E \left[\mu_Y + \sigma_Y \left(\rho \frac{x - \mu_X}{\sigma_X} + \sqrt{1 - \rho^2} Z_2 \right) \mid X = x \right] \\ &= \mu_Y + \sigma_Y \left(\rho \frac{x - \mu_X}{\sigma_X} + \sqrt{1 - \rho^2} E[Z_2 | X = x] \right) \\ &= \mu_Y + \rho \sigma_Y \left(\frac{x - \mu_X}{\sigma_X} \right) \end{aligned}$$

Per simetria,

$$E[X | Y = y] = \mu_X + \sigma_X \rho \left(\frac{y - \mu_Y}{\sigma_Y} \right)$$

Tambè podem trobar $Var(Y | X)$

$$\begin{aligned} Var(Y | X = x) &= Var \left[\mu_Y + \sigma_Y \left(\rho Z_1 + \sqrt{1 - \rho^2} Z_2 \right) \middle| X = x \right] \\ &= Var \left[\mu_Y + \sigma_Y \left(\rho \frac{x - \mu_X}{\sigma_X} + \sqrt{1 - \rho^2} Z_2 \right) \middle| X = x \right] \\ &= Var \left[\sigma_Y \sqrt{1 - \rho^2} Z_2 \middle| X = x \right] \\ &= \sigma_Y^2 (1 - \rho^2) \end{aligned}$$

Per simetria

$$Var(X | Y = y) = \sigma_X^2 (1 - \rho^2)$$

Observacions

1- Observem que la variància condicional o funció de regressió es lineal

$$E[Y | X = x] = \mu_Y + \rho \frac{\sigma_Y}{\sigma_X} (X - \mu_X) = \beta_0 + \beta_1 x$$

on $\beta_1 = \frac{\sigma_{XY}}{\sigma_X^2}$ i $\beta_0 = \mu_Y - \mu_X \beta_1$

2- La variància condicionada no depèn del valor pel que condicionem

$$Var(Y | X = x) = (1 - \rho^2) \sigma_Y^2$$

3- Observem que la variable aleatòria esperança condicional $E[Y | X]$ segueix una distribució normal

$$E[Y | X] \sim N(\mu_X, \rho^2 \sigma_Y^2)$$

4- Per la llei de la variància iterada

$$Var(Y) = \underbrace{E(Var(Y|X))}_{VNE} + \underbrace{Var(E(Y|X))}_{VE} \quad \text{on} \quad \rho^2 = \frac{VE}{VNE + VE}$$

El històric anàlisi de les dades de Francis Galton que posteriorment va formalitzar Karl Pearson sobre les estatures des pares i fills mesurades en polsades. Es sap que la distribució conjunta (X, Y) de les dues alçades de pares i fills segueix una llei normal bivariant. Estem interessats en predir l'alçada de un fill Y en dues situacions:

1- No tenim més informació que la distribució conjunta i per tant la predicció es μ_Y amb una variància σ_Y^2

2- Coneixem l'alçada del pare $X=x$, llavors la predicció serà $E[Y | X = x] = \mu_Y + \sigma_Y \rho \frac{x - \mu_X}{\sigma_X}$ i variància $\sigma_Y^2 (1 - \rho^2) < \sigma_Y^2$. La variància no depen de x i per tant l'error es independent de l'alçada del pare.

Asumim els valors de la distribució normal bivariada $\mu_X = 68.3, \sigma_X = 10.8, \mu_Y = 68.1, \sigma_Y = 2.5$ i $\rho = 0.5$ la distribució és:

$$\begin{pmatrix} X \\ Y \end{pmatrix} \sim N \left(\begin{pmatrix} 68.3 \\ 68.1 \end{pmatrix}, \begin{pmatrix} 1.8^2 & 0.5 \times 1.8 \times 2.5 \\ 0.5 \times 1.8 \times 2.5 & 2.5^2 \end{pmatrix} \right)$$

Si resollem les qüestions pendents

1- El pes mitjà predit és 68.1 polsades amb una variància de $2.5^2 = 6.25$ 2- Suposant que l'alçada del pare es de 69 polsades, llavors la predicció de l'alçada del fill es $y = 68.1 + 2.5 \cdot 0.5 \frac{69 - 68.1}{1.8} = 68.725$ amb variància $2.5^2 \cdot (1 - 0.5^2) = 4.6875$

3.1.3 Distribució normal multivariant

Definició 3.4. Distribució normal multivariant

Sigui un vector aleatori $X = (X_1, \dots, X_n)$ on $\mu' = (\mu_1, \dots, \mu_n)$ és el vector de mitjanes o valors esperats i $|\Sigma|$ es el determinant de la matriu de variàncies covariàncies Σ que pren el valor

$$\Sigma = \begin{bmatrix} \sigma_1^2 & \sigma_{12} & \dots & \sigma_{1(n-1)} & \sigma_{1n} \\ \sigma_{12} & \sigma_2^2 & \dots & \sigma_{2(n-1)} & \sigma_{2n} \\ \cdot & \cdot & \cdot & \cdot & \cdot \\ \sigma_{1(n-1)} & \sigma_{2(n-1)} & \dots & \sigma_{n-1}^2 & \sigma_{(n-1)n} \\ \sigma_{1n} & \sigma_{2n} & \dots & \sigma_{(n-1)n} & \sigma_n^2 \end{bmatrix}$$

Podem generalitzar la distribució de densitat normal bivariada al cas multivariant com

$$f(x_1, \dots, x_n) = \frac{|\Sigma|^{-\frac{1}{2}}}{(2\pi)^{\frac{n}{2}}} e^{-\frac{1}{2}(\mathbf{x}-\mu)'\Sigma^{-1}(\mathbf{x}-\mu)}, \quad (x_1, \dots, x_n) \in \mathbb{R}^n$$

Si les components del vector son independents, les covariàncies son totes nul·les i Σ es una matriu diagonal amb elements les variàncies de cada component. Així $|\Sigma|^{-1} = \frac{1}{\sigma_1^2 \sigma_2^2 \dots \sigma_n^2}$. A més la forma quadràtica de la equació (3.4) es simplifica i la densitat és:

$$f(x_1, x_2, \dots, x_n) = \frac{1}{\prod_{i=1}^n (2\pi\sigma_i^2)^{\frac{1}{2}}} e^{-\frac{1}{2} \sum_{i=1}^n \left(\frac{x_i - \mu_i}{\sigma_i} \right)^2} = \prod_{i=1}^n \left[\frac{1}{\sqrt{2\pi\sigma_i^2}} e^{-\frac{1}{2} \left(\frac{x_i - \mu_i}{\sigma_i} \right)^2} \right]$$

que no es més que el producte de les densitats de les normals de cadascuna de les components. Per tant en el cas multivariant també la incorrelació implica independència.

La forma quadràtica de l'exponent en una distribució normal multivariant (coneguda com la distància de Mahalanobis) es redueix a la suma clàssica de residus al quadrat ponderats per la variància:

$$(\mathbf{x} - \mu)^T \Sigma^{-1} (\mathbf{x} - \mu) = \sum_{i=1}^n \left(\frac{x_i - \mu_i}{\sigma_i} \right)^2$$

3.2 Distribucions especials: Multinomial, t-Student multivariant, Khi-quadrat, Wishart i Dirichlet.

3.2.1 Distribució Multinomial

En nombroses ocasions observem dades discretes que tenen tres o més valors possibles. La família de distribucions multinomial es una extensió de la família de distribucions binomial, conduint a una distribució multivariant.

Exemple 3.2. Es coneix que hi ha quatre tipus de sang humana, O, A, B i AB. Es selecciona una mostra de persones donants de sang al atzar i podem estar interessats en conèixer la probabilitat de observar un número determinat de cada tipus de sang.

En general, suposem que la població conté k ítems diferents ($k \geq 2$) i la proporció en la població de cada tipus i és p_i , $i = 1, \dots, k$. Assumim que $p_i > 0$ i $\sum_{i=1}^k p_i = 1$. Així, $\mathbf{p} = (p_1, \dots, p_k)$ és el vector de probabilitats

Sigui X_i la variable aleatòria que quantifica el número de ítems seleccionats en n extraccions del tipus i . Si les n extraccions s'han seleccionat amb repetició, la selecció serà independent una d'altra. Si tenim x_i observacions de tipus i en un determinat ordre, al ser independents les extraccions, la probabilitat de la seqüència és $p_1^{x_1} p_2^{x_2} \dots p_k^{x_k}$.

El número de seqüències diferents amb $x_1, x_2, \dots, x_k$ de cada tipus és

$$\binom{n}{x_1, x_2, \dots, x_k} = \frac{n!}{x_1! x_2! \dots x_k!}$$

Definició 3.5. Distribució multinomial

Sigui $\mathbf{X} = (X_1, \dots, X_k)$ el vector aleatori discret on $\mathbf{x} = (x_1, \dots, x_k)$ és el vector de recomptes observats de cada tipus i , $i = 1, \dots, k$ on $\mathbf{p} = (p_1, \dots, p_k)$ és el vector de probabilitat de cadascuna dels ítems. Direm que $\mathbf{X}$ segueix una distribució multinomial amb paràmetres n i $\mathbf{p}$ si la funció de distribució conjunta és:

$$\begin{aligned} f(\mathbf{x}|n, \mathbf{p}) &= \Pr(\mathbf{X} = \mathbf{x}) = \Pr(X_1 = x_1, \dots, X_k = x_k) \\ &= \begin{cases} \binom{n}{x_1, \dots, x_k} p_1^{x_1} \dots p_k^{x_k} & \text{if } x_1 + \dots + x_k = n, \\ 0 & \text{en la resta} \end{cases} \end{aligned}$$

Exemple 3.3. Si recordem l'exemple 3.2 i es sap que $P(O) = 0.479$, $P(A) = 0.360$, $P(B) = 0.123$ i $P(AB) = 0.038$ i es seleccionen dues persones de la població. Quina és la probabilitat de que les dues siguin del mateix tipus. A partir de la definició de probabilitat

$$P(X_O = 2) + P(X_A = 2) + P(X_B = 2) + P(X_{AB} = 2) = \binom{2}{2, 0, 0, 0} (0.479^2 + 0.360^2 + 0.123^2 + 0.038^2) = 0.376$$

Theorem 3.2. Suposem el vector aleatori $\mathbf{X} = (X_1, X_2)$ que té una distribució multinomial amb $n = 2$ i $\mathbf{p} = (p_1, p_2)$ llavors $X_1 \sim \text{Bi}(n, p_1)$ i $X_2 = n - X_1$

Demostració

De la definició de distribució binomial està clar que $X_2 = n - X_1$ i $p_2 = 1 - p_1$. Així que el vector $\mathbf{X}$ està actualment determinat per una variable singular X_1 . A partir de la distribució binomial s'observa que X_1 que és la variable que representa el número de ítems tipus 1 seleccionats de n ítems on hi han 2 tipus de ítems. Així X_1 és el número d'esdeveniments de n experiments Bernoulli amb probabilitat del èxit de cada experiment de p_1 . Així es segueix que $X_1 \sim \text{Bi}(n, p_1)$

Corollary 3.1. Si $\mathbf{X} = (X_1, \dots, X_k)$ és un vector aleatori amb paràmetres n i $\mathbf{p} = (p_1, \dots, p_k)$. La distribució marginal de cada variable X_i , $i = 1, \dots, k$ segueix una distribució binomial amb paràmetre n i p_i

Corollary 3.2. Si $\mathbf{X} = (X_1, \dots, X_k)$ es un vector aleatori amb parametres n i $\mathbf{p} = (p_1, \dots, p_k)$ amb $k \geq 2$. Si $\ell < k$ i $i_1, \dots, i_\ell$ un subconjunt de elements de $(1, \dots, k)$ La distribució de $Y = Y_1 + \dots + Y_k$ segueix una distribució binomial amb parametre n i $p_{i_1} + \dots + p_{i_\ell}$

Theorem 3.3. Esperances, Variàncies i covariàncies

Suposem el vector aleatori $\mathbf{X} = (X_1, \dots, X_k)$ que té una distribució multinomial amb parametres n i $\mathbf{p} = (p_1, \dots, p_k)$ amb $k \geq 2$, llavors els valors esperats, variàncies i covariàncies son

$$\begin{aligned} E[X_i] &= np_i \\ \text{Var}(X_i) &= np_i(1 - p_i) \\ \text{Cov}(X_i, X_j) &= -np_i p_j \end{aligned}$$

Segons hem vist en el corol·lari 3.1 la distribució marginal de cada component es binomial i el valor de l'esperança i la variància son els de l'enunciat del teorema.

Per el corol·lari 3.1 sabem que $X_i + X_j$ segueix una distribució binomial amb paràmetres n i $p_i + p_j$. D'aquí

$$\text{Var}(X_i + X_j) = n(p_i + p_j)(1 - p_i - p_j)$$

Per altra banda de la equació (1.4.3) sabem que

$$\begin{aligned} \text{Var}(X_i + X_j) &= \text{Var}(X_i) + \text{Var}(X_j) + 2\text{Cov}(X_i, X_j) \\ &= np_i(1 - p_i) + np_j(1 - p_j) + 2\text{Cov}(X_i, X_j) \end{aligned}$$

igualant les equacions anterior i aïllant $\text{Cov}(X_i, X_j)$ obtenim el resultat desitjat

$$\begin{aligned} \text{Cov}(X_i, X_j) &= \frac{1}{2}n(p_i + p_j)(1 - p_i - p_j) - np_i(1 - p_i) - np_j(1 - p_j) \\ &= \frac{n}{2} [(p_i + p_j) - (p_i + p_j)^2 - p_i + p_i^2 - p_j + p_j^2] \\ &= \frac{n}{2} [(p_i + p_j - p_i^2 - p_j^2 - 2p_i p_j - p_i + p_i^2 - p_j + p_j^2)] \\ &= \frac{n}{2} (-2p_i p_j) = -np_i p_j \end{aligned}$$

Cal resenyar que la covariància de la distribució multinomial és negativa, el que és natural donat que les n observacions s'han de distribuir en k tipus de ítems. Si augmenta el número d'observacions d'un tipus ha de disminuir el de l'altre donat que la grandària es fixa.

3.2.2 Distribució t-student multivariant

La distribució t-Student multivariant es una generalització de la distribució t-de Student unidimensional. Al igual que aquella serveix pel càlcul de intervals de confiança per a vectors però també per l'ús com distribucions posteriors en estadístiques bayesianes i l'anàlisi conjunt de variables biomèdiques i de finances.

Definició 3.6. Distribució t-student multivariant

Sigui $\mathbf{X} = (X_1, \dots, X_n)$ un vector aleatori de dimensió n , direm que $\mathbf{X}$ segueix una distribució t-multivariant amb mitjana el vector $\mu = (\mu_1, \dots, \mu_n)$, amb la matriu de variàncies-covariàncies Σ i ν graus de llibertat

$$\mathbf{X} \sim t(\mu, \Sigma, \nu)$$

si i només si la funció de densitat de probabilitat és:

$$t(x; \mu, \Sigma, \nu) = \sqrt{\frac{1}{(\nu\pi)^n |\Sigma|}} \frac{\Gamma((\nu+n)/2)}{\Gamma(\nu/2)} \left[1 + \frac{1}{\nu} (x - \mu)^T \Sigma^{-1} (x - \mu) \right]^{-(\nu+n)/2}$$

on $\Gamma()$ es la funció Gamma $\Gamma(z) = \int_0^\infty x^{z-1} e^{-x} dx$

Proposició 3.3. Si el vector aleatori $\mathbf{X} \sim t(\mu, \Sigma, \nu)$ és distribueix com una distribució t-multivariant, la distribució marginal de qualsevol subvector m -dimensional $\mathbf{X}_s$ subconjunt del vector $\mathbf{X}$ segueix una distribució t-multivariant amb vector de mitjanes μ_s i una matriu de variàncies Σ eliminant els valors de les variables no incloses en el subvector.

Demostració

Definim els subconjunt de dimensió $m \times n$ tal que $s_{ij} = 1$ si el j -èsim element de $\mathbf{X}_s$ correspon al i -èsim element de $\mathbf{X}$ i 0 en altre cas. Així $\mathbf{X}_s = S\mathbf{X}$

Podem aplicar el teorema de la transformació lineal a l'expressió anterior així

$$\mathbf{X}_s \sim t(S\mu, S\Sigma S^T, \nu)$$

Si operem es pot veure que $S\mu = \mu_s$ i $S\Sigma S^T = \Sigma_s$

Corollari 3.3. Si $m=1$ en la proposició @marginalt implica que la distribució marginal de una t-multivariant es una distribució t amb mitjana μ_i i variància σ_i^2

Definició 3.7. Sigui $\mathbf{X} = (X_1, \dots, X_n)$ un vector aleatori de dimensió n , direm que $\mathbf{X}$ segueix una distribució t-multivariant standard amb ν graus de llibertat, si la funció de densitat es

$$t(x; n) = \sqrt{\frac{1}{(\nu\pi)^n}} \frac{\Gamma((\nu+n)/2)}{\Gamma(\nu/2)} \left[1 + \frac{1}{\nu} x^T x \right]^{-(\nu+n)/2}$$

La funció de distribució de la distribució t-multivariant estàndard es un distribució t-univariada estàndard amb ν graus de llibertat. Es pot deduir directament que el valor esperat es el vector nul $E[\mathbf{X}] = \mathbf{0}$ i que la matriu de variància es $Var(\mathbf{X}) = \frac{\nu}{\nu-2} I$ on I es la matriu identitat $k \times k$

3.2.3 Distribució khi-quadrat

La distribució khi-quadrat (χ^2) és una distribució de probabilitat molt utilitzada en la resolució de tests de bondat d'ajustament i en altres proves estadístiques. S'utilitza principalment per comparar les freqüències observades amb les freqüències esperades, analitzant les diferències entre ambdues de manera quadràtica. En aquesta secció introduïrem la distribució a partir de vectors aleatoris.

Definició 3.8. Distribució Khi-quadrat Sigui $\mathbf{X} = (X_1, \dots, X_k)$ un vector aleatori de variables aleatòries normals amb mitjana $\mu_i = 0$ i variància $\sigma_i^2 = 1$ es a dir $X_i \sim N(0, 1)$ i $\mathbf{X} \sim N_n(0, \mathbf{I})$ llavors

$$Y = \mathbf{X}^T \mathbf{X} = \sum_{i=1}^k X_i^2 \sim \chi^2(k) \quad 0 < k < \infty$$

Theorem 3.4. La funció de densitat de la variable definida en (3.8) ve definida per

$$f_Y(y) = \frac{1}{2^{k/2} \Gamma(k/2)} y^{k/2-1} \exp[-y/2]$$

Demostració

Per fer la demostració en primer lloc demostrarem que la distribució χ_1^2 és un cas particular de una distribució Gamma con paràmetres $\alpha = \beta = 1/2$

1. *Cas Base* ($k = 1$): *Densitat de* $Y = X_1^2$

Sigui $X_1 \sim N(0, 1)$ on la seva funció de densitat serà:

$$f_{X_1}(x) = \frac{1}{\sqrt{2\pi}} e^{-x^2/2}$$

Volem trobar la densitat de la transformació $Y = X_1^2$. Llavors la funció de probabilitat acumulada serà $y > 0$:

$$F_Y(y) = P(Y \leq y) = P(X_1^2 \leq y) = P(-\sqrt{y} \leq X_1 \leq \sqrt{y})$$

Per la simetria respecte al zero de la distribució normal estàndard, podem reescriure-ho com:

$$F_Y(y) = 2 \cdot P(0 \leq X_1 \leq \sqrt{y}) = 2 \int_0^{\sqrt{y}} \frac{1}{\sqrt{2\pi}} e^{-x^2/2} dx$$

Derivem respecte a y per obtenir la seva densitat $f_Y(y)$:

$$f_Y(y) = \frac{d}{dy} F_Y(y) = 2 \cdot \left(\frac{1}{\sqrt{2\pi}} e^{-(\sqrt{y})^2/2} \right) \cdot \frac{d}{dy} (\sqrt{y})$$

$$f_Y(y) = \frac{2}{\sqrt{2\pi}} e^{-y/2} \cdot \frac{1}{2\sqrt{y}} = \frac{1}{\sqrt{2\pi}} y^{-1/2} e^{-y/2}$$

Sabent que la funció Gamma compleix que $\Gamma(1/2) = \sqrt{\pi}$ i que $\sqrt{2} = 2^{1/2}$, podem reescriure l'expressió anterior com:

$$f_Y(y) = \frac{1}{2^{1/2} \Gamma(1/2)} y^{1/2-1} e^{-y/2}$$

Aquesta expressió coincideix exactament amb la definició d'una distribució **Gamma** amb paràmetre de forma $\alpha = 1/2$ i paràmetre d'escala $\beta = 1/2$. Per tant:

$$Y = X_1^2 \sim \text{Gamma} \left(\alpha = \frac{1}{2}, \beta = 2 \right)$$

2. Generalització per a k variables (La variable d'interès és la suma de k normals estàndard al quadrat independents:

$$Y = \sum_{i=1}^k X_i^2$$

Atès que cada component $X_i^2 \sim \text{Gamma}(\frac{1}{2}, \frac{1}{2})$, apliquem la propietat d'additivitat per a variables Gamma independents. Quan s'utilitza la parametrització per escala, la suma de variables amb la mateixa escala β dona lloc a una nova variable Gamma on els paràmetres de forma α se sumen i els de escala β es manté constant:

$$\alpha_{\text{total}} = \sum_{i=1}^k \alpha_i = \sum_{i=1}^k \frac{1}{2} = \frac{k}{2} \quad \text{i} \quad \beta = \frac{1}{2}$$

D'aquesta manera, obtenim que la suma total es distribueix com:

$$Y \sim \text{Gamma} \left(\alpha = \frac{k}{2}, \beta = \frac{1}{2} \right)$$

Substituïm finalment els paràmetres $\alpha = \frac{k}{2}$ i $\beta = \frac{1}{2}$ en la definició original $f(y|\alpha, \beta) = \frac{\beta^\alpha}{\Gamma(\alpha)} y^{\alpha-1} e^{-\beta y}$:

$$f_Y(y) = \frac{(1/2)^{k/2}}{\Gamma(k/2)} y^{k/2-1} e^{-\frac{1}{2}y}$$

Operant el terme constant del numerador $(\frac{1}{2})^{k/2} = \frac{1}{2^{k/2}}$, arribem exactament a l'expressió del Teorema

$$f_Y(y) = \frac{1}{2^{k/2} \Gamma(k/2)} y^{k/2-1} \exp[-y/2]$$

El valor esperat de la distribució $Y \sim \chi^2(k)$ és $E[Y]=k$ i $\text{Var}(Y)=2k$

3.2.4 Distribució de Whishart

La distribució de Whishart, que deu el seu nom al estadístic escocès John Whishart que la va formular en 1928, es molt utilitzada en el anàlisi de matrius de covariància estimades i en estadística Bayesiana. La distribució de Whishart es la generalització multivariant de la distribució χ^2 univariada.

Definició 3.9. Distribució de Whishart Sigui $\mathbf{X}$ una matriu $n \times p$ que segueix una distribució de matriu normal amb mitjana 0, independent a lo llarg de les files i covarianza entre les columnes Σ es a dir

$$\mathbf{X} \sim \mathcal{MN}_{n \times p}(\mathbf{0}, \mathbf{I}_n, \Sigma)$$

Definim la matriu $\mathbf{S}$ com el producte de $\mathbf{X}$ i la seva transposada

$$\mathbf{S} = \mathbf{X}^T \mathbf{X} = \sum_{i=1}^n \mathbf{x}_i^T \mathbf{x}_i$$

Llavors la matriu $\mathbf{S}$ es diu que segueix la funció de distribució Wishart amb escala la matriu $\mathbf{V}$ i el graus de llibertat n

$$\mathbf{S} \sim \mathcal{W}_p(\Sigma, n)$$

On $n > p-1$ i $\mathbf{V}$ es una matriu simètrica definida positiva $p \times p$

Exemple 3.4. Suposem que volem estudiar **3 característiques físiques** de **5 persones**:

- Alçada (cm)
- Pes (kg)
- Pressió arterial sistòlica (mmHg)

Les dades observades són:

Persona	Alçada (cm)	Pes (kg)	Pressió (mmHg)
1	170	68	120
2	165	62	118
3	180	80	130
4	175	75	125
5	168	65	119

En aquest cas:

- $n = 5$: nombre d'observacions (persones).
- $p = 3$: nombre de variables.

La matriu de dades és

$$X = \begin{pmatrix} 170 & 68 & 120 \\ 165 & 62 & 118 \\ 180 & 80 & 130 \\ 175 & 75 & 125 \\ 168 & 65 & 119 \end{pmatrix}.$$

Per poder assumir que la matriu segueix una distribució normal matricial amb mitjana nul·la, primer es centren les dades restant la mitjana de cada columna.

Les mitjanes són:

- Alçada: 171.6 cm,
- Pes: 70 kg,
- Pressió: 122.4 mmHg.

La matriu centrada és

$$X_c = \begin{pmatrix} -1.6 & -2 & -2.4 \\ -6.6 & -8 & -4.4 \\ 8.4 & 10 & 7.6 \\ 3.4 & 5 & 2.6 \\ -3.6 & -5 & -3.4 \end{pmatrix}.$$

En aquesta matriu:

- cada **fila** representa una persona;
- les **files** es consideren independents entre si;
- les **columnnes** poden estar correlacionades. Per exemple, persones més altes acostumen a tenir també un pes més elevat. Aquesta dependència queda descrita per la matriu de covariàncies Σ .

Finalment, es calcula

$$S = X_c^T X_c,$$

que és una matriu 3×3 de sumes de productes creuats. Si les files de X_c segueixen una distribució normal multivariant,

$$X_i \sim N_3(0, \Sigma)$$

aleshores

$$S \sim W_3(5, \Sigma)$$

és a dir, S segueix una distribució de **Wishart** amb 5 graus de llibertat i matriu de covariàncies Σ .

Si $\mathbf{S} \sim \mathcal{W}_p(\Sigma, n)$ llavors

$$E[M] = n\Sigma$$

i si σ_{ij} es l'element ij - *sim* de Σ i el ij - *sim* element de $\mathbf{S}$ es s_{ij} llavors

$$\text{Var}(m_{ij}) = n(\sigma_{ij}^2 + \sigma_{ii}\sigma_{jj})$$

La demostració surt directament de la definició de la variable

Si $\mathbf{S} \sim \mathcal{W}_p(\Sigma, n)$ i $\mathbf{A}$ és una matriu es fixa $q \times p$ llavors

$$\mathbf{A}\mathbf{S}\mathbf{A}^T \sim \mathcal{W}_q(\mathbf{A}\Sigma\mathbf{A}^T, n)$$

Demostració

De la definició, sea $s = \sum_{i=1}^n X_i X_i^T$ on $X_i \sim N_p(\mathbf{0}, \Sigma)$ llavors ## Propietats de la Distribució Wishart

$$\mathbf{A}\mathbf{S}\mathbf{A}^T = \mathbf{A} \left(\sum_{i=1}^n \mathbf{x}_i \mathbf{x}_i^T \right) \mathbf{A}^T = \sum_{i=1}^n (\mathbf{A}\mathbf{x}_i)(\mathbf{A}\mathbf{x}_i)^T = \sum_{i=1}^n \mathbf{y}_i \mathbf{y}_i^T$$

on definim els nous vectors com:

$$\mathbf{y}_i = \mathbf{A}\mathbf{x}_i \sim N_q(\mathbf{0}, \mathbf{A}\mathbf{A}^T)$$

Aplicant la definició de la distribució Wishart als vectors independents $\mathbf{y}_1, \dots, \mathbf{y}_n$, obtenim directament que:

$$\sum_{i=1}^n \mathbf{y}_i \mathbf{y}_i^T \sim W_q(\mathbf{A}\mathbf{A}^T, n)$$

:::{.proposition}

Si $\mathbf{M}_1 \sim W_p(\cdot, n_1)$ i $\mathbf{M}_2 \sim W_p(\cdot, n_2)$ són dues matrius aleatòries independents, aleshores:

::: **Demostració**

$$\mathbf{M}_1 + \mathbf{M}_2 \sim W_p(\cdot, n_1 + n_2)$$

A partir de la definició de la distribució Wishart, podem representar la primera matriu $\mathbf{M}_1$ com:

$$\mathbf{M}_1 = \sum_{i=1}^{n_1} \mathbf{x}_i \mathbf{x}_i^T$$

I la segona matriu $\mathbf{M}_2$ (que és independent) com:

$$\mathbf{M}_2 = \sum_{i=n_1+1}^{n_1+n_2} \mathbf{x}_i \mathbf{x}_i^\top$$

on tots els vectors $\mathbf{x}_i \sim N_p(\mathbf{0}, \Sigma)$ són independents i idènticament distribuïts per a $i = 1, \dots, n_1 + n_2$.

Si sumem ambdues matrius, obtenim:

$$\mathbf{M}_1 + \mathbf{M}_2 = \sum_{i=1}^{n_1} \mathbf{x}_i \mathbf{x}_i^\top + \sum_{i=n_1+1}^{n_1+n_2} \mathbf{x}_i \mathbf{x}_i^\top = \sum_{i=1}^{n_1+n_2} \mathbf{x}_i \mathbf{x}_i^\top$$

Atès que aquesta expressió és la suma de productes externs de $n_1 + n_2$ vectors normals multivariants independents de mitjana zero i matriu de covariàncies Σ , per la definició mateixa de la distribució Wishart es compleix que:

$$\mathbf{M}_1 + \mathbf{M}_2 \sim W_p(\Sigma, n_1 + n_2) \quad \blacksquare$$

3.2.5 Distribució Dirichlet

La distribució de Dirichlet $Dir(\alpha)$ és una família de probabilitat multivariant parametritzada per un vector α de reals positius. Aquesta distribució és una generalització de la distribució Beta univariant i el seu ús és molt habitual com a prior en estadística bayesiana, en l'ús de processament del llenguatge natural (NLP) o en estudis de simulació d'utilització de recursos.

Definició 3.10. Distribució de Dirichlet

Sigui $\mathbf{X} = (X_1, \dots, X_k)$ un vector aleatori de dimensió k tal que $x_i \in [0, 1] \quad \forall i \in \{1, \dots, k\}$ i $\sum_{i=1}^k x_i = 1$. Aquest vector segueix una distribució de Dirichlet $\mathbf{X} \sim Dir(\alpha)$ on $\alpha = (\alpha_1, \dots, \alpha_k)$ si la funció de densitat ve donada per

$$f(x_1, \dots, x_k; \alpha_1, \dots, \alpha_k) = \frac{1}{B(\alpha)} \prod_{i=1}^k x_i^{\alpha_i - 1}$$

on

$$B(\alpha) = \frac{\prod_{i=1}^k \Gamma(\alpha_i)}{\Gamma(\sum_{i=1}^k \alpha_i)}$$

i Γ és la funció Gamma

Els moments de la distribució de Dirichlet són els següents. Per simplificar les expressions utilitzarem $\alpha_0 = \sum_{i=1}^k \alpha_i$

$$E[X_i] = \frac{\alpha_i}{\sum_{i=1}^k \alpha_i} = \frac{\alpha_i}{\alpha_0}$$

$$Var[X_i] = \frac{\alpha_i (\sum_{i=1}^k \alpha_i - \alpha_i)}{(\sum_{i=1}^k \alpha_i)^2 (\sum_{i=1}^k \alpha_i + 1)} = \frac{\alpha_i (\alpha_0 - \alpha_i)}{\alpha_0^2 (\alpha_0 + 1)}$$

$$Cov[X_i, X_j] = \frac{-\alpha_i \alpha_j}{(\sum_{i=1}^k \alpha_i)^2 (\sum_{i=1}^k \alpha_i + 1)} = \frac{-\alpha_i \alpha_j}{\alpha_0^2 (\alpha_0 + 1)}$$

Finalment la distribució marginal de les components de la distribució de Dirichlet són distribucions Beta

$$X_i \sim \text{Beta}(\alpha_i, \alpha_0 - \alpha_i)$$

El resultat s'obté directament de la proposició de la propietat d'agregació de la distribució Dirichlet

Proposició 3.4. Propietat de agregació *Segui $\mathbf{X}$ un vector aleatori de dimensió k que segueix una distribució de Dirichlet $(X_1, \dots, X_k) \sim \text{Dir}(\alpha_1, \dots, \alpha_k)$. Si les variables i i j són eliminades i reemplaçades per la seva suma la variable resultant és una distribució Dirichlet també.*

$$(X_1, \dots, X_i + X_j, \dots, X_k) \sim \text{Dir}(\alpha_1, \dots, \alpha_i + \alpha_j, \alpha_k)$$

Resta provar aquest lema. Sense pèrdua de generalitat, només cal demostrar-ho per a $r = 2$. Calculem directament la funció de densitat de probabilitat (FDP) de $Y = (X_1 + X_2, X_3, \dots, X_K)$:

$$f_Y(y_1, x_3, \dots, x_{K-1}) = \int_0^{y_1} f_X(y_1 - x_2, x_2, x_3, \dots, x_{K-1}) dx_2$$

Aplicant el canvi de variable $x_2 = y_1 u$ (on $dx_2 = y_1 du$), obtenim:

$$\begin{aligned} f_Y(y_1, x_3, \dots, x_{K-1}) &= \frac{\Gamma(\sum_{i=1}^K \alpha_i)}{\prod_{i=1}^K \Gamma(\alpha_i)} \left(\prod_{i=3}^{K-1} x_i^{\alpha_i-1} \right) x_K^{\alpha_K-1} \int_0^1 (y_1 - y_1 u)^{\alpha_1-1} (y_1 u)^{\alpha_2-1} y_1 du \\ &= \frac{\Gamma(\sum_{i=1}^K \alpha_i)}{\prod_{i=1}^K \Gamma(\alpha_i)} \left(\prod_{i=3}^{K-1} x_i^{\alpha_i-1} \right) x_K^{\alpha_K-1} y_1^{\alpha_1+\alpha_2-1} \int_0^1 u^{\alpha_2-1} (1-u)^{\alpha_1-1} du \\ &= \frac{\Gamma(\sum_{i=1}^K \alpha_i)}{\Gamma(\alpha_1 + \alpha_2) \prod_{i=3}^K \Gamma(\alpha_i)} y_1^{\alpha_1+\alpha_2-1} \left(\prod_{i=3}^{K-1} x_i^{\alpha_i-1} \right) x_K^{\alpha_K-1} \end{aligned}$$

la qual cosa implica que Y segueix la distribució $\text{Dir}(\alpha_1 + \alpha_2, \alpha_3, \dots, \alpha_K)$. ■

3.3 Generació de mostres de distribucions multivariants.

3.3.1 Revisió de mètodes de generació de mostres de variables aleatòries univariants

En l'assignatura de probabilitat I es van introduir els principals mètodes de generació de mostres de variables aleatòries univariants. En aquest apartat anem a generalitzar aquests mètodes al cas multivariant a més de introduir-ne d'algun nou. En general qualsevol algorisme de generació de dades aleatòries segueix el mateix esquema.

- 1- Generem una o més números aleatòries provinents de distribucions uniformes i.i.d. $U(0,1)$
- 2- Transformem i relacionem els valors de la distribució uniforme depenen de la distribució a estudi
- 3- Retornem el valor X de la distribució desitjada

Mètode de la inversió

Aquest mètode es basa en generar un número aleatori u entre 0 i 1 a partir de la distribució uniforme $U(0,1)$ i de la trobar X tal que la funció de distribució acumulada $F_X(x) = U$, es a dir que $X = F_X^{-1}(u)$.

El principal problema d'aquest mètode es la disposició de una formulació directa de la inversa de la funció de distribució.

Així, l'algorisme és:

- 1- Genera un valor u de una distribució $U(0,1)$

2.- Obten el valor $x = F_X^{-1}(u)$

Mètode de la acceptació-rebuig

Aquest mètode s'utilitza quan no es pot (o no es vol) invertir la funció de distribució F_X . Sigui $f(x)$ la funció de densitat de la distribució de la que es vol generar una mostra. Suposem que tenim un altre tipus de variable aleatòria Y amb una densitat $g()$ que es fàcil de simular, per exemple una distribució Normal o Uniforme. A més es sap que existeix una constant M . Tal que

$$\frac{f(x)}{g(x)} \leq M \quad \forall x, \text{ és a dir } f(x) \leq M g(x)$$

L'algorisme segueix els següents passos

1- Genera el valor y de la v.a. Y

2- Genera un valor u de una $U(0,1)$

3- Si $u \leq \frac{f(y)}{Mg(y)}$ accepta $x=y$

4- En cas contrari torna al pas 1 i torna a seleccionar un valor aleatori.

Mètodes de transformacions específics

Mètode de Box-Muller

El algorisme utilitza 2 i.i.d. $U(0,1)$ per produir 2 i.i.d. $N(0,1)$:

1- Genera U_1 i U_2 de dos distribucions i.i.d. $U(0,1)$

2- Calcula $X = \sqrt{-2\log(U(0,1))}\cos(2\pi U_2)$ i $Y = \sqrt{-2\log(U(0,1))}\sin(2\pi U_2)$ on Z_1 i Z_2 son dues $N(0,1)$

Transformació Gamma com a suma d'exponencials (convolució)

Es sap que si $E_i \sim \text{Exp}(\lambda)$, llavors $\sum_{i=1}^k E_i \sim \text{Gamma}(k, \lambda)$

El algorisme serà el següent

1- Obtén k valors de una $U(0,1)$

2- Utilitzant el mètode de la inversió obten k valors e_i de una $\text{Exp}(\lambda)$

3- Suma els valors e_i y obtén el valor $x = \sum_{i=1}^k e_i$ de la distribució Gamma

Métodos de MonteCarlo

Realment no son uns metodes de càlcul de mostra sinó que son tècniques de simulació per aproximar quantitats com probabilitats, valors esperats, integrals, variàncies a partir de mostres simulades.

La idea bàsica es que si $\{X_1, \dots, X_N\}$ son variables i.i.d llavors

$$E[h(x)] \approx \frac{1}{N} \sum_{i=1}^N h(X_i)$$

3.3.2 Generació de variables aleatòries multivariants utilitzant distribucions condicionals

Suposem que donat un Vector aleatori $(X_1, \dots, X_k)$ coneguem la funció de distribució conjunta i les distribucions marginals $F_i(x_i), i = 1, \dots, k$ i les distribucions condicionals $F_j(x_j | X_1, \dots, X_{j-1})$

El algorisme es el següent utilitzant en cada pas l'algorisme d'inversió univariant

1- Genera x_1 (marginalment) de $F_1(x_1)$

2- Genera x_2 (condicionalment de $F_2(x_2 | x_1)$

3- Genera x_3 (condicionalment de $F_3(x_3|x_1, x_2) \dots$
k- Genera x_k (condicionalment de $F_k(x_k|x_1, x_2, \dots, x_{k-1})$
k+1- Retorna el vector $\mathbf{x} = (x_1, \dots, x_k)^T$

Exemple 3.5. Normal Bivariant

Volem generar observacions d'un vector aleatori bidimensional $(X_1, X_2)^T \sim N_2(\mu, \Sigma)$ amb:

$$\mu = \begin{pmatrix} 0 \\ 0 \end{pmatrix}, \quad \Sigma = \begin{pmatrix} 1 & \rho \\ \rho & 1 \end{pmatrix} \quad (|\rho| < 1)$$

Sabem que

- Marginal de X_1 : $X_1 \sim N(0, 1) \implies F_1(x_1) = \Phi(x_1)$
- Condicional de $X_2 | X_1 = x_1$: $X_2 | X_1 = x_1 \sim N(\rho x_1, 1 - \rho^2)$

Si apliquem la generalització del algorisme d'inversió condicional

Per generar un parell (x_1, x_2) :

1. Pas 1 (Generar x_1):

- Generem $U_1 \sim U(0, 1)$.
- Apliquem la inversió: $x_1 = F_1^{-1}(U_1) = \Phi^{-1}(U_1)$.

2. Pas 2 (Generar $x_2 | X_1 = x_1$):


- Generem $U_2 \sim U(0, 1)$ independent de U_1 .
- Apliquem la inversió ajustant per x_1 :

$$x_2 = F_2^{-1}(U_2 | x_1) = \rho x_1 + \sqrt{1 - \rho^2} \cdot \Phi^{-1}(U_2)$$

Implementació en R

```
##           X1           X2
## X1 0.9436775 0.7727192
## X2 0.7727192 0.9971821
```

Simulació i Contorns d'una Normal Bivariant (rho = 0.8)



3.3.3 Generació de vectors aleatoris de una distribució normal multivariant

Suposem que desitgem generar $\mathbf{X} = (X_1, \dots, X_k)$ on $X \sim MN_k(\mathbf{0}, \Sigma)$. Si els valors esperats no són zero no més caldria centrar cadascuna de les variables X_i per que siguin 0 els valors esperats. Sigui $\mathbf{Z} = (Z_1, \dots, Z_k)^T$ on Z_i són i.i.d $N(0, 1)$ per $i = 1, \dots, k$. Si $\mathbf{C}$ es una matriu $(k \times n)$ es segueix que

$$\mathbf{C}^T \mathbf{Z} \sim MVN(\mathbf{0}, \mathbf{C}^T \mathbf{C})$$

L'únic problema es trobar una funció $\mathbf{C}$ tal que $\mathbf{C}^T \mathbf{C} = \Sigma$. Podem utilitzar la descomposició de Cholesky de Σ per trobar la matriu $\mathbf{C}$

Descomposició de Cholesky de una matriu simètrica definida positiva

Un resultat conegut de l'àlgebra que una matriu simètrica definida-positiva M , pot escriure's com $M = U^T D U$ on U és una matriu triangular superior i D és una matriu diagonal amb elements diagonals positius. Com que M és definida positiva

$$= U^T D U = (U^T \sqrt{D})(\sqrt{D} U) = (\sqrt{D} U)^T (\sqrt{D} U)$$

Així la matriu $\mathbf{C} = \sqrt{D} U$ que satisfi $\mathbf{C}^T \mathbf{C} = \Sigma$ que es la descomposició de Cholesky.

Així a l'hora de simular la distribució el algoritme funciona de la següent manera.

- 1- Genera el vector de normals estàndard $Z_i \sim N(0, 1) i = 1, \dots, k$
- 2- Calcula $\mathbf{C}$ según la descomposició de Cholesky tal que $\Sigma = \mathbf{C} \mathbf{C}^T$

3.- Calcula $\mathbf{X} = \mathbf{C}^\top \mathbf{Z}$

Simulació d'una Normal Bivariant mitjançant la Descomposició de Cholesky

Assumim les dades del exemple 3.5 on simulàvem dades d'una distribució binormal

Donada la matriu de covariàncies $\Sigma = \begin{pmatrix} 1 & \rho \\ \rho & 1 \end{pmatrix}$, la seva factorització de Cholesky $\Sigma = \mathbf{C}\mathbf{C}^\top$ produeix la matriu triangular inferior:

$$\mathbf{C} = \begin{pmatrix} 1 & 0 \\ \rho & \sqrt{1-\rho^2} \end{pmatrix}$$

Multiplicant aquesta matriu per un vector $\mathbf{Z} = (Z_1, Z_2)^\top$ de normals estàndard independents ($Z_1, Z_2 \stackrel{iid}{\sim} N(0, 1)$), s'obté:

$$\begin{pmatrix} X_1 \\ X_2 \end{pmatrix} = \mathbf{C} \begin{pmatrix} Z_1 \\ Z_2 \end{pmatrix} = \begin{pmatrix} Z_1 \\ \rho Z_1 + \sqrt{1-\rho^2} Z_2 \end{pmatrix}$$


(Observem que s'obté exactament la mateixa relació que en el mètode de les condicionals).

Implementació en R

```
##           X1           X2
## X1 0.9598590 0.7725724
## X2 0.7725724 0.9671766
```

Simulació Normal Bivariant via Descomposició de Cholesky

$\mu = (0,0)$, $\rho = 0.8$



4 Processos estocàstics: Introducció i conceptes bàsics

4.1 Definició de procés estocàstic.

En el curs de probabilitat I es van estudiar les successions de variables aleatòries, es a dir col·leccions infinites numerables de variables aleatòries i es va centrar l'interès en les diferents convergències d'aquestes variables, sobretot utilitzant la llei dels grans nombres i el teorema central del límit. En aquell moment no es varen analitzar les relacions entre les variables de la successió i altres. En aquest tema introduïrem el concepte de procés estocàstic. De tota manera cal ressenyar que el concepte de procés estocàstic va més enllà de les successions de variables. Es tracta d'un conjunt de variables aleatòries on pot estar indexat per un conjunt no numerable.

Un exemple seria l'estudi de l'ocurrència de un mateix esdeveniment al llarg del temps. Si aquestes ocurrences són independents i el tema d'interès es el temps que transcorre entre esdeveniments, parlarem de la successió $\{X_n\}$ on X_i =(temps que passa entre l'esdeveniment i - i el i). Però, si el que ens interessa es el nombre de vegades que l'esdeveniment ha succeït en l'interval $[0,t]$, la família a considerar és N_t , amb $t>0$ i per descomptat no és numerable.

Definició 4.1. Procés estocàstic

Un procés estocàstic es una colecció de variables aleatòries $\{X_t, t \in T\}$ definides sobre un espai de probabilitat $(\Omega, \mathcal{A}, P)$.

T es un subconjunt de $\mathbb{R}$ que s'anomena **conjunt d'índexs**. S'utilitza la lletra t donat que l'estudi de processos estocàstics surt del estudi de l'evolució temporal de fenòmens aleatoris.

El conjunt de valors $S \subseteq \mathbb{R}$ que poden prendre les variables aleatòries X_t s'anomena **espai d'estats** del procés.

Amb freqüència l'índex $t \in T$ que ordena les variables aleatòries del procés correspon al temps i X_t és l'estat del sistema en estudi a l'instant t .

Exemple 4.1. En una botiga de roba el 65% de les persones que entren compren alguna cosa. En una hora entren 30 clients en la botiga. El procés que indica si el client compra o no compra, és un procés estocàstic bernoulli

$$X_t = \begin{cases} 1, & \text{si el client } t \text{ realitza una compra,} \\ 0, & \text{si el client } t \text{ no realitza una compra.} \end{cases}$$

Si històricament el 65 % dels clients realitzen una compra i suposem que les decisions de comprar dels clients són independents una de l'altra, aleshores

$$X_t \sim \text{Bernoulli}(0.65),$$

Els resultats es mostren en el següent gràfic.

Exemple 4.2. Un jugador comença amb **10 euros** i juga consecutivament **20 partides**. En cada partida aposta 1 euro a cara o creu.

Denotem per X_t els diners que té el jugador després d'haver jugat t partides, on

$$t = 0, 1, \dots, 20. \quad X_0 = 10$$

En cada partida:




Figura 17: Exemple Compra botiga de roba

- amb probabilitat $1/2$ guanya 1 euro;
- amb probabilitat $1/2$ perd 1 euro.

Per tant,

$$X_{t+1} = \begin{cases} X_t + 1, & \text{amb probabilitat } 1/2, \\ X_t - 1, & \text{amb probabilitat } 1/2. \end{cases}$$

En aquest exemple s'observen dues possibles realitzacions del procés estocàstic. Tot i que els dos jugadors comencen amb el mateix capital inicial i juguen el mateix nombre de partides, les seves trajectòries són diferents perquè el resultat de cada partida és aleatori.




Figura 18: Exemple de procés del jugador arruïnat

Exemple 4.3. Suposem que els pacients arriben a un servei d'urgències d'un hospital de manera aleatòria al llarg del temps. Sigui

$$X(t) = \text{nombre de pacients arribats fins a l'instant } t, \quad t \geq 0.$$

Si les arribades segueixen una distribució de Poisson amb una intensitat $\lambda = 3$ pacients per hora, com que t es continu $X(t) \sim \text{Poisson}(\lambda t)$

En el gràfic es mostra una realització del procés en les primeres 8 hores. La trajectòria és una funció esglaonada: roman constant entre dues arribades consecutives i augmenta una unitat cada vegada que arriba un nou pacient.

Arribada de pacients a urgències




Figura 19: Exemple de nombre d'urgències per temps

Exemple 4.4. En una prova d'esforç es mesura el consum d'oxigen d'un esportista (VO_2) cada segon durant 10 minuts i es recull en un procés estocàstic $X(t)$ = valor del VO_2 en l'instant t

En aquest exemple suposem que el consum d'oxigen augmenta progressivament durant l'exercici i que presenta fluctuacions aleatòries.

La línia blava representa una possible realització del procés corresponent a les mesures de VO_2 . La línia vermella discontinua representa la tendència mitjana esperada durant l'exercici. En aquest cas es representa una sèrie temporal biomèdica on clarament les observacions no son independents




Figura 20: Exemple de nombre d'urgències per temps

Un procés estocàstic també pot ser considerat com una funció aleatòria de doble argument $\{X(t, \omega), t \in T, \omega \in \Omega\}$. Si fixem $\omega = \omega_0$ tindrem una *realització* del procés $X(., \omega_0)$ on la seva representació gràfica son le anomenades *trajectòries del procés* que hem representant en els 4 gràfics anteriors.

Si per contra fixem $t = t_0$ estarem parlant de la variable aleatoria $X_{t_0} = X(t_0, .)$ que es la distribució de la variable d'interés en el punt d'observació t .

4.1.1 Funcions de moment d'un procés estocàstic

Com a variable aleatòria de deus dimensions podem definir les següents funcions característiques de un procés estocàstic $\mathbf{X} = \{X_t\}_{t \in T}$

Funció mitjana d'un procés estocàstic

Es defineix com la funció

$$\mu_X(t) = E[X_t], \in T = \begin{cases} \sum_{x \in D_{X_t}} x P(X_t = x) & \text{si } X_t \text{ és discret} \\ \int_{-\infty}^{+\infty} x f_t(x) dx & \text{si } X_t \text{ és continu} \end{cases}$$

Funció de autocorrelació

La funció de autocorrelació del procés $\mathbf{X} = \{X_t\}_{t \in T}$ es defineix com el valor esperat del producte de les variables aleatòries X_{t_1} i X_{t_2} en els instants t_1 i t_2 respectivament, és a dir

$$R(t_1, t_2) = E[X_{t_1} X_{t_2}] = \begin{cases} \sum_{x_1 \in D_{X_{t_1}}, x_2 \in D_{X_{t_2}}} x_1 x_2 P(X_{t_1} = x_1, X_{t_2} = x_2), & \text{si } X_t \text{ és discret,} \\ \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} x_1 x_2 f_{X_{t_1}, X_{t_2}}(x_1, x_2) dx_1 dx_2, & \text{si } X_t \text{ és continu.} \end{cases}$$

Funció de autocovariància

A partir del moment central conjunt de dues variables associades a dos temps qualsevol, t_1 i t_2 , l'autocovariància és

$$C(t_1, t_2) = E[(X_{t_1} - \mu(t_1))(X_{t_2} - \mu(t_2))]$$

ràpidament es dedueix la relació entre la autocorrelació i la autocovariància

$$C(t_1, t_2) = R(t_1, t_2) - \mu(t_1)\mu(t_2)$$

en el cas particular que $t_1 = t_2 = t$ parem de la *funció de variància* $\sigma^2(t) = C(t, t)$

Finalment definim la funció de correlació com

$$\rho(t_1, t_2) = \frac{C(t_1, t_2)}{\sqrt{\sigma^2(t_1)\sigma^2(t_2)}}$$

que obviament pren valors entre $[-1, 1]$. Em el cas de les series temporals es reserva el nom de autocorrelació per aquesta funció.

4.2 Processos estocàstics discrets i continus.

Els processos estocàstics es poden classificar en funció del tipus de variables T i X_t

X_t	T Discret	T Continu
Discret	Cadena	Proc. puntual
Continu	Suc. de v.a.	Proc. continu

-Un procés discret amb el temps discret (**DTDV*+- Discret Time/Discret Values) , que s'anomena cadena, seria l'exemple 4.1 on es veia en 30 clients que entraven en una botiga si compraven o no

-Un procés continu en un temps discret (**DTCV**- Discret Time/Continuous Values)s'anomena un successió de variables. Si en el cas anterior en lloc de mesurar si compra o no compra haguéssim mesurat l'alçada o el pes del client seria un bon exemple

-Un procés puntual com el de l'exemple 4.3 on es mesura el nombre de urgències en un determinat temps és el cas on el procés es discret pero el temps és continu.(**CTDV**+Continuous Time/Discret Values)

-El procés continu es aquell en el que la variable es continua i el temps també(**CTCV**+Continuous Time/Continuous Values) . Es el cas de l'exemple 4.4 on es mesura el VO_2 d'un esportista en 10 minuts d'esforç

4.3 Processos estocàstics estacionaris i no estacionaris.

Definició 4.2. Distribucions finito-dimensionals En general les variables aleatòries del procés $\mathbf{X} = \{X_t\}_{t \in T}$ no son independents entre elles. Si $\{t_1, t_2, \dots, t_n\} \subset T$ és un subconjunt finit de qualsevol dels índex, la distribució conjunta del vector $(X_{t_1}, X_{t_2}, \dots, X_{t_n})$ vindrà donada per

$$F_{t_1, t_2, \dots, t_n}(x_1, \dots, x_n) = P(X_{t_1} \leq x_1, X_{t_2} \leq x_2, \dots, X_{t_n} \leq x_n)$$

Aquesta distribució rep el nom de distribució finito-dimensional del procés. També es poden expressar aquestes distribucions a partir de les funcions de densitat i probabilitat conjuntes del vector.

Un procés estocàstic es pot descriure especificant les seves distribucions finito-dimensionals, que permeten obtenir la probabilitat de qualsevol esdeveniment involucrat en el procés. Cal remarcar que el conjunt de distribucions finito-dimensionals no determinen per complet les característiques del procés, i en ocasions cal definir certes característiques o propietats addicionals. Si el procés es pot especificar completament a partir de les distribucions finites, es diu que el procés es *separable*.

Definició 4.3. Processos de variables independents

sea $\mathbf{X} = \{X_t\}_{t \in T}$ es diu que es un procés estocàstic de variables aleatòries independents si X_m i X_n son independents para todo $n, m \leq 0$ con $n \neq m$

L'exemple 4.1 del procés on es vol saber si un client que entra en una botiga compra o no es tracta de un procés de variables independents

Definició 4.4. Processos amb increments independents

sigui $\mathbf{X} = \{X_t\}_{t \in T}$ es diu que es un procés estocàstic que té increments independents si per a qualsevol $t_0 < t_1 < \dots < t_n$, $t_i \in T$ les variables aleatòries:

$$X_{t_1} - X_{t_0}, X_{t_2} - X_{t_1}, \dots, X_{t_n} - X_{t_{n-1}}$$

són independents.

En l'exemple 4.3 sobre el nombre d'urgències, el nombre de urgències en la primera hora és independent del de la segona hora i de la tercera hora.

Definició 4.5. Processos de Markov

Sea $\mathbf{X} = \{X_t\}_{t \in T}$ es diu que es un procés estocàstic de Markov si satisfà la propietat de Markov, és a dir

$$P(X_{t_n} = x_n | X_{t_{n-1}} = x_{n-1}, \dots, X_{t_0} = x_0) = P(X_{t_n} = x_n | X_{t_{n-1}} = x_{n-1})$$

amb $t_0 < t_1 < \dots < t_n, t_i \in T$

Aquest tipus de processos son aquells on l'evolució futura depén només del estat present del procés.

L'exemple 4.3 sobre el nombre d'urgències també es un procés de Markov. Per calcular el nombre de urgències en l'instant t , necessitem saber quants hi ha en t (present), donat que les arribades futures són independents de les passades i saber en quin temps estem no aporta cap informació. en la primera hora és independent del de la segona hora i de la tercera hora.

Definició 4.6. Processos estacionaris forts

El procés $\mathbf{X} = \{X_t\}_{t \in T}$ es fortament estacionari si les famílies de les variables aleatòries

$$(X_{t_1}, X_{t_2}, \dots, X_{t_n}) \quad (i) \quad (X_{t_1+h}, X_{t_2+h}, \dots, X_{t_n+h})$$

tenen la mateixa distribució conjunta per a tot $h > 0$, tots $\{t_1, \dots, t_n\} \subset T$ i $n \geq 1$

Theorem 4.1. *La funció mitjana d'un procés estocàstic estacionari es constant*

Demostració

$$\mu_X(t) = \int_{-\infty}^{+\infty} x f_t(x) dx = \int_{-\infty}^{+\infty} x f(x) dx = m(x)$$

Més en general, qualsevol propietat de una variable singular d'un procés estacionari es invariant al temps

Definició 4.7. Processos estacionaris dèbil

El procés $\mathbf{X} = \{X_t\}_{t \in T}$ es dèbilment estacionari si per a tot t_1 i $t_2 \in T$ i tot $h > 0$,

$$E[X_{t_1}] = E[X_{t_2}] \quad \text{i} \quad Cov(X_{t_1}, X_{t_2}) = Cov(X_{t_1+h}, X_{t_2+h})$$

Una forma equivalent de definir l'estacionarietat dèbil és dir que un procés es dèbilment estacionari si i només si te esperança constant i la covariància entre X_{t_1} i X_{t_2} només depén de $t_2 - t_1$. La estacionarietat dèbil implica la estacionarietat forta.

5 Principals tipus de Processos estocàstics.

En el tema passat hem introduït els principals conceptes dels processos estocàstics, que neixen de la necessitat d'analitzar col·leccions de variables aleatòries ordenades cronològicament. En la pràctica modelar la dependència temporal es un repte, i els models es simplifiquen utilitzant diverses propietats per tal de no avaluar l'història completa que normalment es matemàticament inviable. En aquest tema avaluarem alguns tipus de processos estocàstics que s'ajusten a nombroses situacions reals.

5.1 Cadenes de Markov.

En el tema anterior vàrem definir un procés de Markov com aquell que per conèixer l'estat futur del procés només cal conèixer l'estat actual i oblidar-nos del passat.

$$P(X_{t_n} = x_n | X_{t_{n-1}} = x_{n-1}, \dots, X_{t_0} = x_0) = P(X_{t_n} = x_n | X_{t_{n-1}} = x_{n-1})$$

Definició 5.1. Cadena de Markov

Si un procés estocàstic DTDV, és a dir discret amb el temps i amb un nombre finit d'estats compleix la propietat de Markov es una cadena de Markov

Es costum designar com a X_0 l'inici de la cadena. Considerem com espai d'estats de la cadena al suport de les variables del procés X_n , $S = (s_1, \dots, s_k)$ on $n \in \mathbb{N} \cup \{0\}$

Per caracteritzar les cadenes de Markov necessitem definir les probabilitats inicials i de transició.

Probabilitats inicials

Les probabilitats inicials són les probabilitats de cada un dels possibles estat a l'inici del procés

$$\pi_i = P(X_0 = s_i), \quad \pi_i \geq 0, \forall i = 1, \dots, k, \quad \sum_i \pi_i = 1$$

Probabilitats de transició

Designarem com a probabilitats de transició d'un pas a ,la probabilitat condicionada de estar en un estat s_j en un moment $n + 1$ sabent que s'estava en un estat s_i en el moment anterior n

$$\pi_{ij} = P(X_{n+1} = s_j \mid X_n = s_i)$$

Si el valor de la probabilitat de transició π_{ij} no depen del tems, es a dir la probabilitat de passar d'un estat a un altre només depen de l'estat i no del temps, tenim probabilitats de **transició estacionaries ó homogènies**.

$$p_{ij} = P(X_{n+1} = s_j \mid X_n = s_i) \quad \text{per a } n=0,1,2,\dots$$

A més les distribucions finito-dimensionals s'obtenen fàcilment a partir de les probabilitats de transició si fem us de la propietat de Markov i el teorema de factorització

$$\begin{aligned} & P(X_n = s_{i_n}, X_{n-1} = s_{i_{n-1}}, \dots, X_0 = s_{i_0}) \\ &= P(X_n = s_{i_n} \mid X_{n-1} = s_{i_{n-1}}, \dots, X_0 = s_{i_0}) \cdots P(X_1 = s_{i_1} \mid X_0 = s_{i_0}) P(X_0 = s_{i_0}) \\ &= P(X_n = s_{i_n} \mid X_{n-1} = s_{i_{n-1}}) \cdots P(X_1 = s_{i_1} \mid X_0 = s_{i_0}) P(X_0 = s_{i_0}) \\ &= p_{i_{n-1}, i_n} \cdot p_{i_{n-2}, i_{n-1}} \cdots p_{i_0, i_1} \cdot \pi_{i_0} \end{aligned}$$

Definició 5.2. Matriu de transició

La cadena de Markov discreta, X_n , queda completament especificada amb les probabilitats inicials i l'anomenada matriu de transició d'un pas, que recull les probabilitats del mateix nom:

$$P = \begin{pmatrix} p_{11} & p_{12} & \cdots & p_{1k} \\ p_{21} & p_{22} & \cdots & p_{2k} \\ \vdots & \vdots & \ddots & \vdots \\ p_{k1} & p_{k2} & \cdots & p_{kk} \end{pmatrix}$$

D'acord con el significat de p_{ij} , les files de la matriu sumen la unitat:

$$\sum_j p_{ij} = 1, \quad \forall i = 1, \dots, k$$

Definició 5.3. Una matriu quadrada amb tots els elements no negatius i tals que la suma dels elements de cada fila sigui 1 s'anomena matriu estocàstica. La matriu de transició $\mathbf{P}$ d'una cadena de Markov es una matriu estocàstica

Exemple 5.1. Imaginem que ens anem de vacances al poble i suposem que el clima del poble pot estar en un d'aquets tres estats possibles Sol(S), Nuvolat(N) ó Pluja(P)

El procés X_n que determina el temps que farà cadascun dels 30 dies de vacances seria un procés de Markov donat que el clima de demà no més depén del que hagi fet avui. En la figura 21 es mostra la representació gràfica del procés on cada nus es un posible estat i les fletxes marquen les probabilitats de transició entre estats:

- Si avui fa sol la probabilitat de que demà faci sol és el 60%, de que estigui nuvolat el 30% i de que plougui el 10%.
- Si avui està núvol la probabilitat de que demà faci sol és el 40%, de que estigui nuvolat el 40% i de que plougui el 20%.
- Si avui plou la probabilitat de que demà faci sol és el 20%, de que estigui nuvolat el 40% i de que plougui el 40%.

Aquestes probabilitats condicionals son independents del dia que les mesurem.

Cadena de markov: Clima amb 3 Estats




Figura 21: Exemple de cadena de Markov del clima al poble

A continuació es mostren les probabilitats en forma de matriu de transició.

$$P = \begin{pmatrix} p_{SS} & p_{SN} & p_{SP} \\ p_{NS} & p_{NN} & p_{NP} \\ p_{PS} & p_{PN} & p_{PP} \end{pmatrix} = \begin{pmatrix} 0.6 & 0.3 & 0.1 \\ 0.4 & 0.4 & 0.2 \\ 0.2 & 0.4 & 0.4 \end{pmatrix}$$

Probabilitats de transició a n passos

En una cadena de Markov les probabilitats de transició a n passos son fàcils d'obtenir.

$$p_{ij}(n) = P(X_{n+k} = s_j \mid X_k = s_i) \forall n \geq 0$$

Com en una cadena de Markov les transicions no depenen del temps k i podem calcular

$$p_{ij}(n) = P(X_{n+k} = s_j \mid X_k = s_i)P(X_n = s_j \mid X_0 = s_i) \quad \forall n \geq 0 \text{ i } \forall k \geq 0$$

Si $n = 2$ podem escriure

$$\begin{aligned} P(X_2 = s_j \mid X_0 = s_i) &= P\left(\{X_2 = s_j\} \cap \left(\bigcup_k \{X_1 = s_k\}\right) \mid X_0 = s_i\right) \\ &= \sum_k P(X_2 = s_j, X_1 = s_k \mid X_0 = s_i) \\ &= \sum_k \frac{P(X_2 = s_j, X_1 = s_k, X_0 = s_i)}{P(X_0 = s_i)} \\ &= \sum_k \frac{P(X_2 = s_j \mid X_1 = s_k, X_0 = s_i)P(X_1 = s_k \mid X_0 = s_i)P(X_0 = s_i)}{P(X_0 = s_i)} \\ &= \sum_k P(X_2 = s_j \mid X_1 = s_k)P(X_1 = s_k \mid X_0 = s_i) \\ &= \sum_k p_{ik}p_{kj} \end{aligned}$$

Així podem escriure que la transició a 2 temps es $\mathbf{P}(2) = \mathbf{P}\mathbf{P} = \mathbf{P}^2$

Aplicant el mateix raonament podem generalitzar a n passos.

$$\mathbf{P}(n) = \mathbf{P}(n-1)\mathbf{P} = \mathbf{P}^n$$

En general $\mathbf{P}(n+m) = \mathbf{P}^n\mathbf{P}^m$ que terme a terme ho expressem com

$$p_{ij}(n+m) = \sum_k p_{ik}(n)p_{kj}(m), \quad n, m > 0, \forall (s_i, s_j) \in S$$

Aquestes expressions son conegudes com les equacions de **Chapman-Kolmogorov**

Probabilitats dels estats després de n passos

Si π_i eren els probabilitats dels estats inicials es fàcil deduir que la probabilitat després de n passos és:

$$\begin{aligned} \pi_i(n) &= P(X_n = s_i) \\ &= P\left(\bigcup_j \{X_n = s_i \cap X_{n-1} = s_j\}\right) \\ &= \sum_j P(X_n = s_i \cap X_{n-1} = s_j) \\ &= \sum_j P(X_n = s_i \mid X_{n-1} = s_j)P(X_{n-1} = s_j) \\ &= \sum_j \pi_j(n-1)p_{ji} \end{aligned}$$

resultat que podem expressar en forma matricial,

$$\pi(n) = \pi(n-1)P$$

Aplicant recursivament la fórmula anterior podem relacionar $\pi(n)$ amb $\pi = \pi(0)$,

$$\pi(n) = \pi P^n$$

Exemple 5.2. Seguint les dades del exemple 5.1 del clima al poble volem obtenir la matriu de transició per a un canvi de 2 dies i a partir de les dades generals .

Per trobar les probabilitats de transició d'ací a dos dies, multipliquem la matriu per si mateixa ($P^2 = P \times P$).

Matriu de transició a 2 dies (P^2):

```
##          Sol Núvol Pluja
## Sol      0.50  0.34  0.16
## Núvol    0.44  0.36  0.20
## Pluja    0.36  0.38  0.26
```

Si se sap que el 50% dels dies hi ha sol, el 30% esta nuvolat i el 20% hi ha pluja i no tenim informació del dia que fa avui, ¿quina es la probabilitat que en 5 dies faci sol?. ¿Y de que faci pluja?

Per conèixer la distribució del clima en un horitzó temporal m, concretament d'ací a cinc dies, hem d'aplicar de manera iterativa el teorema de Chapman-Kolmogorov. Això implica que la probabilitat de transició després de cinc passos es calcula elevant la matriu original a la cinquena potència ($P^5 = P \cdot P \cdot P \cdot P \cdot P$). La matriu resultant ens indicarà les probabilitats de passar d'un estat climàtic a un altre al cap de cinc dies, mostrant com evoluciona la dependència del clima respecte al dia inicial. Combinant el vector de la distribució del clima actual amb la matriu de transició a cinc passos mitjançant el producte matricial, obtenim el vector d'estat futur projectat:

$$\pi(5) = \pi(0) \cdot P^5$$

Matriu de transició d'ací a 5 dies (P^5):

```
##          Sol  Núvol  Pluja
## Sol      0.45352 0.35428 0.19220
## Núvol    0.45120 0.35496 0.19384
## Pluja    0.44792 0.35592 0.19616
```

Vector de probabilitats d'ací a 5 dies (pi(5)):

```
##          Sol  Núvol  Pluja
## [1,] 0.451704 0.354812 0.193484
```

- **Probabilitat de Sol d'ací a 5 dies:** La probabilitat de tenir un dia assolellat és del **45.17%**(un valor de 0.4517).
- **Probabilitat de Pluja d'ací a 5 dies:** La probabilitat que plogui d'ací a cinc dies és del **19.35%** (un valor de 0.1935).

Exemple 5.3. Si X_n és la variable que indica si el n -ésim client en una botiga compra o no compra, es tracta d'una cadena de Markov discreta amb espai d'estats $S = \{0 = \text{no compra}, 1 = \text{compra}\}$ i matriu de transició:

$$P = \begin{pmatrix} 1-\alpha & \alpha \\ \beta & 1-\beta \end{pmatrix}$$

On:

- α : probabilitat de passar de *No Compra* a *Compra*.
- β : probabilitat de passar de *Compra* a *No Compra*.

La matriu de transició d'ordre n ve donada per:

$$P^n = \frac{1}{\alpha + \beta} \begin{pmatrix} \beta & \alpha \\ \beta & \alpha \end{pmatrix} + \frac{(1 - \alpha - \beta)^n}{\alpha + \beta} \begin{pmatrix} \alpha & -\alpha \\ -\beta & \beta \end{pmatrix}$$

El seu límit quan $n \rightarrow \infty$ és:

$$\lim_{n \rightarrow \infty} P^n = \frac{1}{\alpha + \beta} \begin{pmatrix} \beta & \alpha \\ \beta & \alpha \end{pmatrix}$$

Per exemple, si $\alpha = 1/10$ i $\beta = 2/10$, en el límit tenim:

$$\lim_{n \rightarrow \infty} P^n = \begin{pmatrix} 2/3 & 1/3 \\ 2/3 & 1/3 \end{pmatrix}$$

El procés gaudeix a més d'una interessant propietat. Si la distribució inicial és:

$$\pi_0 = (p_0 \quad 1 - p_0)$$

aplicant la propietat de multiplicació per la matriu límit, podem obtenir la distribució límit de l'espai d'estats:

$$\lim_{n \rightarrow \infty} \pi^{(n)} = \pi_0 \left(\lim_{n \rightarrow \infty} P^n \right) = (p_0 \quad 1 - p_0) \begin{pmatrix} 2/3 & 1/3 \\ 2/3 & 1/3 \end{pmatrix} = (2/3 \quad 1/3)$$

la qual **no depèn de la distribució inicial**.

Definició 5.4. Equilibri d'una cadena de Markov El que hem vist en l'exemple significa que una cadena de Markov tendeix a una situació estacionària a mesura que n augmenta.

Si en general

$$\lim_n p_{ij}(n) = \pi_j^{(e)}, \quad \forall i.$$

la conseqüència és que

$$\lim_n \pi_j^{(n)} = \sum_i \pi_j^{(e)} \pi_i = \pi_j^{(e)}, \quad \forall j$$

Així la distribució sobre l'espai d'estats ten a una distribució fixa independent de la distribució inicial π . Es diu que la cadena ha arribat a l'equilibri o a una situació estable. La distribució $\pi^{(e)}$ rep el nom de *distribució d'equilibri o estacionària*.

Per obtenir la distribució d'equilibri $\pi^{(e)}$ no fa falta resoldre el límit. Es prou en resoldre el sistema d'equacions,

$$\pi^{(e)} = \pi^{(e)} P$$

amb la condició adicional de $\sum_i \pi_i^{(e)} = 1$

Exemple 5.4. Continuació del exemple 5.3

La distribució estacionària també es pot obtenir utilitzant l'equació (5.4). Si $\pi^{(e)} = [\pi_0^{(e)}, \pi_1^{(e)}]$ aleshores el sistema d'equacions que cal resoldre és

$$\begin{aligned}\pi_0^{(e)} &= (1 - \alpha)\pi_0^{(e)} + \beta\pi_1^{(e)}, \\ \pi_1^{(e)} &= \alpha\pi_0^{(e)} + (1 - \beta)\pi_1^{(e)}.\end{aligned}$$

Aquest sistema es redueix a una única equació, $\alpha\pi_0^{(e)} = \beta\pi_1^{(e)}$ que, juntament amb la condició de normalització $\pi_0^{(e)} + \pi_1^{(e)} = 1$

permet obtenir la distribució estacionària

$$\pi_0^{(e)} = \frac{\beta}{\alpha + \beta} = 2/3 \quad \pi_1^{(e)} = \frac{\alpha}{\alpha + \beta} = 1/3$$

5.1.1 Classificació dels estats i comunicacions d'una cadena de Markov

Les cadenes de Markov es poden classificar segons els diferents tipus de matrius de transició que te interès per què permet entendre el paper que juga cadascun dels possibles estats del procés i de l'altra per què alguns tipus de matriu admeten un límit quan n tendeix a ∞ .

Sigui $\{X_n\}_{n \geq 1}$ una cadena de Markov amb estats $\{1, 2, 3, \dots, m\}$ i amb matriu de transició $P = (p_{ij})_{1 \leq i, j \leq m}$

Definició 5.5. Un **camí** $i \rightarrow j$ és una seqüència de transicions entre estats que porta de l'estat i a l'estat j .

Definició 5.6. L'estat j es un **estat accessible** des d' i si existeix un camí $i \rightarrow j$ que porta de i a j . En aquest cas existeix un k tal que $p_{ij}^{(k)} > 0$.

Definició 5.7. Els estats i i j són **estats comunicats** si existèix un camí de i a j i un altre de j a i . Ho representarem com $i \leftrightarrow j$

Definició 5.8. Definim una **classe d'estats o de comunicació** es un subconjunt de estats del que cada parell d'estats (considerant el mateix estat) estan comunicats. La comunicació es una relació d'equivalència que indueix una partició en l'espai d'estats.

Definició 5.9. Es diu que un cadena de Markov és **irreductible** quant tots els seus estats comuniquen. És a dir $\forall i, j \quad \exists k$ tal que $p_{ij}^{(k)} > 0$. En aquest cas només hi ha una classe de comunicació.

Definició 5.10. Un estat i és absorbent si $p_{ii} = 1$. El que vol dir és que si ens situem en un estat absorbent ens hi quedarem

Definició 5.11. Un estat i és **transitori** si existeix un estat j i una camí $i \rightarrow j$ i no existeix cap camí $j \rightarrow i$. que ho escriuem com $j \nrightarrow i$. Això vol dir que


i es transitori si existeix j, n tals que $p_{ij}^{(n)} > 0$ i $p_{ji}^{(k)} = 0$ per a tot k

Definició 5.12. Un estat i que no és transitori s'anomena **estat recurrent**. En un estat recurrent la probabilitat de (eventualment) regresar a i es u es a dir $P(X_n = s_i \mid X_0 = s_i) = 1$ per algú $n \geq 1$

Exemple 5.5. Sigui una cadena de Markov amb els estats 0,1,2,3,4 Tenim la matriu de transició

$$P = \begin{array}{c|ccccc} & 0 & 1 & 2 & 3 & 4 \\ \hline 0 & 1 & 0 & 0 & 0 & 0 \\ 1 & 1-p & 0 & p & 0 & 0 \\ 2 & 0 & 1-p & 0 & p & 0 \\ 3 & 0 & 0 & 1-p & 0 & p \\ 4 & 0 & 0 & 0 & 0 & 1 \end{array}$$

La representació de la cadena de Markov és la següent:



Tenim que:

- Els estats **0** i **4** són **absorbents**.
- Els estats **1**, **2** i **3** són **transitoris**.
- Els estats **0** i **4** són **recurrents**.
- Les parelles d'estats **(1,2)**, **(1,3)** i **(2,3)** es comuniquen.

Definició 5.13. Una classe A s'anomena **tancada** si quan es comença en qualsevol estat d' A sempre ens quedem a A . És a dir

$$\text{Si } y \in A \text{ llavors } P(A|y) = 1$$

o equivalent

$$\text{Si } y \in A \text{ llavors } P(X_{n+1} \in A | X_n \in A) = 1$$

Definició 5.14. Direm que l'estat i és **periòdic** amb període $k > 1$ si k és l'enter més petit tal que la longitud de qualsevol camí de $i \leftarrow i$ es múltiple de k .

Dit d'una altra manera

$k = \text{màxim comú divisor } \{n \mid p_{i,i}^{(n)} > 0\} \text{ i } k > 1$


Definició 5.15. Un estat que no és periòdic s'anomena **aperiòdic**. És aquell estat i per al que existeix un enter positiu r tal que $p_{i,i}^r > 0$ i $p_{i,i}^{r+1} > 0$

Definició 5.16. Una cadena de Markov es **ergòdica** si és irreductible i aperiòdica

A continuació es mostren alguns exemples de cadenes definides a partir de la seva matriu de transició on es representa la cadena i es classifiquen els estats segons les definicions previes.

Primera Cadena

$$P_1 = \begin{pmatrix} 0 & 1 & 0 \\ 0 & 0 & 1 \\ 1 & 0 & 0 \end{pmatrix}$$




$$\{n \mid p_{i,i}^{(n)} > 0\} = \{3, 6, 9, 12, \dots\}$$

En aquest cas tots els estats són periòdics amb període $k = 3$.

Segona Cadena


$$P_2 = \begin{pmatrix} 0.4 & 0.6 & 0 & 0 & 0 \\ 0.5 & 0.5 & 0 & 0 & 0 \\ 0 & 0 & 0.3 & 0.7 & 0 \\ 0 & 0 & 0.5 & 0.4 & 0.1 \\ 0 & 0 & 0 & 0.8 & 0.2 \end{pmatrix}$$



Fixem-nos que $p_{i,i} > 0$ per tot i i per tant tots els estats són aperiòdics.

Tercera Cadena

$$P_3 = \begin{pmatrix} 1 & 0 & 0 & 0 & 0 \\ 1-p & 0 & p & 0 & 0 \\ 0 & 1-p & 0 & p & 0 \\ 0 & 0 & 1-p & 0 & p \\ 0 & 0 & 0 & 0 & 1 \end{pmatrix}$$




Quan $i = 1, 2, 3$ llavors

$$\{n \mid p_{i,i}^{(n)} > 0\} = \{2, 4, 6, 8, \dots\}$$

i per tant els estats 1, 2, 3 són periòdics amb període $k = 2$.

Quarta cadena




$$\{n \mid p_{i,i}^{(n)} > 0\} = \{4, 6, 8, 10, \dots\}$$

amb període 2

Cinquena Cadena

$$P_5 = \begin{pmatrix} 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 1 \\ .5 & 0.5 & 0 & 0 \end{pmatrix}$$




$$\{n \mid p_{1,1}^{(n)} > 0\} = \{4, 7, 8, 10, \dots\} \quad \text{amb període 1.}$$

Sisena Cadena

Considerem un problema amb la següent matriu de transició :

$$P_6 = \begin{array}{c|ccccccccc} & 1 & 2 & 3 & 4 & 5 & 6 & 7 & 8 & 9 \\ \hline 1 & 0 & 0 & 0.6 & 0.4 & 0 & 0 & 0 & 0 & 0 \\ 2 & 0 & 0 & 0.6 & 0.4 & 0 & 0 & 0 & 0 & 0 \\ 3 & 0 & 0 & 0 & 0 & 0.6 & 0.2 & 0 & 0 & 0.2 \\ 4 & 0 & 0 & 0 & 0 & 0.6 & 0.4 & 0 & 0 & 0 \\ 5 & 0.6 & 0.3 & 0 & 0 & 0 & 0 & 0 & 0.1 & 0 \\ 6 & 0.6 & 0.4 & 0 & 0 & 0 & 0 & 0 & 0 & 0 \\ 7 & 0 & 0 & 0 & 0 & 0 & 0 & 0.7 & 0.3 & 0 \\ 8 & 0 & 0 & 0 & 0 & 0 & 0 & 1 & 0 & 0 \\ 9 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 1 \end{array}$$

la representació gràfica de la cadena de Markov es



Veiem doncs que tenim 3 classes:


- Classe 1 formada pels estats $\{1, 2, \dots, 6\}$. És transitòria.
- Classe 2 formada pels estats $\{7, 8\}$. És recurrent.
- Classe 3 formada pels estats $\{9\}$. És absorbent

Setena cadena

Considerem la següent matriu de transició

$$P_7 = \begin{pmatrix} 0.5 & 0.5 & 0 \\ 0 & 0.3 & 0.7 \\ 0.8 & 0 & 0.2 \end{pmatrix}$$

On la seva representació gràfica es



La cadena de Markov es ergòdica ja que es aperiòdica al ser tots els $p_{ii} > 0$ i es irreductible per que tots els nodes estan comunicats entre si.

5.2 Passeig o Caminades aleatòries.

Imagineu un caminant que es mou al atzar cap a la dreta o cap a l'esquerra. Suposem que el caminant llança una moneda amb una probabilitat p d'obtenir una cara. Si surt cara va cap a dreta (amb probabilitat p) i si surt creu va cap a l'esquerra (amb probabilitat $q = 1 - p$). Estarem interessats en conèixer quina es la situació S_n després de n passos del caminant que direm que esta seguint un passeig o caminada aleatòria.

Definició 5.17. Sigui $\{Y_1, \dots\}$ una successió de variables aleatòries independents idènticament distribuïdes que prenen els valors 1 i -1 amb una probabilitat $p \in [0, 1]$ i $q = 1 - p$, respectivament. La **caminada aleatòria** ("random walk") simple amb paràmetre p es la successió

$$S_n = S_0 + Y_1 + Y_2 + \dots + Y_n, \quad n \geq 0$$

on S_0 és una variable aleatòria que pren valors a $\mathcal{Z}$ i que és independent de la successió $\{Y_1, \dots\}$. També podem definir la caminada aleatòria de forma recursiva

$$S_n = S_{n+1} + Y_n, \quad n \geq 1$$

Si suposem que $P(S_0 = 0) = 1$, la funció de probabilitat de S_n de terminar en la posició k és:

$$\Pr(S_n = k) = \binom{n}{\frac{n+k}{2}} p^{\frac{n+k}{2}} (1-p)^{\frac{n-k}{2}}, \quad k \in \{-n, -n+2, \dots, n-2, n\}.$$

i per tant $E[S_n] = n(2p - 1)$ i la variància és $Var(S_n) = 4p(1 - p)$

Demostració

Si definim $X_j = \frac{1}{2}(Y_j + 1)$ per $j \in \mathbb{N}$, X_j es una variable aleatòria amb distribució Bernoulli amb una probabilitat d'èxit de p i $\{X_1, X_2, \dots\}$ és una successió de variables aleatòries independents i idènticament distribuïdes que en termes del caminant indicant si el pas j -èsim ha estat a la dreta.

Llavors $Y_j = 2X_j - 1$ i directament de la transformació de una distribució Bernoulli $E[Y_j] = 2p - 1$ y $Var(Y_j) = 4p(1 - p)$

Si definim $Z_n = \sum_{j=1}^n X_j$ per $n \in \mathbb{N}$ té una distribució $Bi(n, p)$. Z_n és el nombre de passos a la dreta dins dels n primers passos.

com hem suposat que $P(S_0 = 0) = 1$ llavors podem expressar $S_n = 2Z_n - n$ i com els valors de Z_n per definició són $0, \dots, n$ llavors els valors de S_n són $k \in \{-n, -n+2, \dots, n-2, n\}$ i $P(S_n = k) = P(Z_n = (n+k)/2)$. Així

$$\Pr(S_n = k) = \binom{n}{\frac{n+k}{2}} p^{\frac{n+k}{2}} (1-p)^{\frac{n-k}{2}}, \quad k \in \{-n, -n+2, \dots, n-2, n\}.$$

Les expressions de la esperança i variància surten directes.

La caminata aleatòria simple satisfà les propietats de

- *Homogeneïtat espacial:* $P(S_n = k \mid S_0 = a)P(S_n = k+b \mid S_0 = a+b)$
- *Homogeneïtat temporal:* $P(S_n = k \mid S_0 = a)P(S_{n+m} = k \mid S_m = a)$
- *Propietat de Markov:* Per a $0 < i_0 < i_1 < \dots < i_m < n$ llavors

$$P(S_n = k \mid S_{i_0} = a_0, S_{i_1} = a_1, \dots, S_{i_m} = a_m) = P(S_n = k \mid S_{i_m} = a_m)$$

Exemple 5.6. Suposem que $p=1/2$. En aquest cas es diu que S_n es una **caminata aleatòria simple simètrica**. En aquest cas el vector aleatori $\mathbf{Y}^n = \{Y_1, \dots, Y_n\}$ es distribueix uniformement en $\Omega = \{-1, 1\}^n$. Així el nombre de combinacions serà 2^n que serà el número de camins diferents.


I seguint l'equació (5.2) la probabilitat de S_n és:

$$\Pr(S_n = k) = \binom{n}{\frac{n+k}{2}} \frac{1}{2^n}, \quad k \in \{-n, -n+2, \dots, n-2, n\}.$$

En la taula i la gràfica gràfica és mostra una caminata aleatòria de longitud $n = 200$ on el valor final és $S_{200} = 14$ i la probabilitat d'obtenir aquest valor és $P(S_{200} = 14) = 0.0345913$

```
## [1] 0 -1 -2 -1 0 -1 0 -1 -2 -3 -2 -3 -4 -3 -4 -3 -2 -3 -4 -3 -2 -1 0 -1 0
## [26] 1 0 -1 0 -1 0 -1 0 1 2 1 0 1 0 -1 -2 -3 -4 -3 -2 -3 -2 -1 0 1
## [51] 0 -1 -2 -1 0 1 0 1 0 1 2 3 2 1 2 1 2 3 2 1 2 1 0 1 2
## [76] 3 2 3 2 1 2 1 0 1 2 1 0 -1 -2 -3 -4 -3 -4 -3 -2 -1 -2 -1 0 1
## [101] 0 -1 -2 -3 -2 -3 -2 -3 -4 -3 -4 -3 -2 -3 -2 -1 -2 -1 0 -1 0 1 0 1 0
## [126] 1 2 3 4 5 4 5 4 5 6 7 6 7 6 7 6 7 8 9 10 11 12 11 10 11
## [151] 10 11 10 9 8 9 10 9 10 11 12 11 12 11 10 9 8 9 10 9 8 9 8 7 8
## [176] 9 10 11 12 13 14 13 14 15 14 15 14 13 12 11 12 13 14 13 14 15 14 15
## [201] 14
```

Passeig Aleatori Simple Simètric (S_n)



Considerem una representació d'un passeig aleatori simple en el pla cartesià amb el parell de coordenades (n, S_n) , $n \in \mathbb{N}$

Sigui $N_n(a, b)$ el nombre de camins que porten de la posició $(0, a)$ a la posició (n, b) . Aleshores

$$N_n(a, b) = \binom{n}{\frac{n+b-a}{2}}$$

Per altra banda si $P(S_0 = 0) = 1$, qualsevol dels camins anteriors té probabilitat $p^{\frac{n+b-a}{2}} (1-p)^{\frac{n-b+a}{2}}$

Principi de reflexió Siguin $a, b > 0$ i $N_n^0(a, b)$ el nombre de camins que porten de $(0, a)$ a (n, b) de manera que passen per 0, es a dir visiten algun punt de la forma $(k, 0)$. Aleshores $N_n^0(a, b) = N_n(-a, b)$

Demostració

Per a cada camí d'aquest tipus, sigui

$$\tau = \min k \geq 0 : S_k = 0$$

el primer instant en què el camí arriba al nivell (0).

Construïm ara un nou camí reflectint respecte del nivell (0) la part del camí anterior a $(\tau, 0)$. És a dir, definim

$$S_k^* = \{-S_k, \quad 0 \leq k \leq \tau, S_k, k > \tau.\}$$

Com que el primer tram del camí ha estat reflectit, el punt inicial passa de ser $(0, a)$ a $(0, -a)$ mentre que el punt final continua essent (n, b) ja que la reflexió només afecta el tram anterior al primer contacte amb el nivell 0.

Aquesta transformació és una bijecció. En efecte, si tornem a reflectir el primer tram del nou camí fins al seu primer contacte amb el nivell 0, recuperem exactament el camí original. Per tant, existeix una correspondència un a un entre els camins que van de $(0, a)$ a (n, b) i visiten el nivell 0, i els camins que van de $(0, -a)$ a (n, b) .

En conseqüència, ambdós conjunts tenen el mateix nombre d'elements.

Aquesta propietat és coneguda com el principi de reflexió i constitueix una eina fonamental en l'estudi dels passeigs aleatoris, ja que permet comptar camins amb restriccions transformant-los en un problema equivalent sense restriccions.

Theorem 5.1. Recompte de camins que no creuen el 0 Si $b > 0$ el nombre de camins que porten de $(0, 0)$ a (n, b) sense tornar a tocar l'eix d'abscisses és $(b/n)N_n(0, b)$

El problema de les paperetes (Ballot Problem)

En una votació hi ha dos candidats, A i B . Suposem que el candidat A rep α vots i el candidat B rep β vots, amb $\alpha > \beta$. Suposant que les paperetes es compten en un ordre completament aleatori, es vol determinar la probabilitat que durant tot l'escrutini el candidat A vagi sempre per davant del candidat B .

Aquest és un problema històricament molt conegut, anomenat en anglès *Ballot Problem*, resolt per Joseph Louis Bertrand l'any 1887. Constitueix una aplicació clàssica del principi de reflexió en els passeigs aleatoris. Sigui $n = \alpha + \beta$ el nombre total de vots. Per a $j = 0, 1, \dots, n$, definim S_j = nombre de vots d'avantatge del candidat A sobre B després d'haver comptat els primers j vots. Cada vot per al candidat A representa un increment de $+1$, mentre que cada vot per al candidat B representa un increment de -1 . En conseqüència, $S_0 = 0$, $S_n = \alpha - \beta$. Si representem l'escrutini al pla mitjançant els punts (j, S_j) , $j = 0, 1, \dots, n$, cada possible ordre de recompte correspon a un camí d'un passeig aleatori que uneix els punts $(0, 0)$ i $(n, \alpha - \beta)$. El nombre total d'escrutinis possibles és $N_n(0, \alpha - \beta)$ i tots són equiprobables.

Per altra banda, els escrutinis en què el candidat A es manté sempre estrictament per davant del candidat B , és a dir, $S_j > 0$, $j = 1, \dots, n$, corresponen, segons el teorema anterior a $\frac{\alpha - \beta}{n} N_n(0, \alpha - \beta)$ camins. Per tant, la probabilitat que el candidat A vagi sempre per davant durant tot l'escrutini és $P(A \text{ sempre va per davant}) = \frac{\alpha - \beta}{\alpha + \beta}$.

La distribució del primer retorn a l'origen

Suposem $P(S_0=0)=1$. Sigui T el moment del primer retorn a 0:

$$T = \min\{n \in \mathbb{N}_+ : S_n = 0\}$$

Cal observar que el retorn a 0 només pot passar per instants parells. També es possible que el passeig aleatori mai torni a 0. Per T pren valors $\{2, 4, \dots\} \cup \{\infty\}$

Theorem 5.2. La funció de probabilitat de T_{2n} ve donada per

$$\Pr(T = 2n) = \frac{1}{2n-1} \Pr(S_{2n} = 0) = \frac{1}{2n-1} \binom{2n}{n} p^n (1-p)^n, \quad n \in \mathbb{N}_+.$$

Demostració La prova és la següent. Per a $n \in \mathbb{N}_+$,

$\Pr(T = 2n) = \Pr(T = 2n, S_{2n} = 0) = \Pr(T = 2n | S_{2n} = 0) \Pr(S_{2n} = 0)$ Però $\Pr(T = 2n | S_{2n} = 0)$ és la probabilitat d'anar de la posició $(0, 0)$ inicial a la posició $(2n-1, 1)$ (la immediatament anterior a la $(2n, 0)$ sense haver tocat l'eix d'abscisses. Pel problema del recompte de vots sabem que aquesta probabilitat és $1/(2n-1)$, i el resultat queda provat.

Theorem 5.3. *Primer retorn després de n etapes.

Suposem $P(S_0 = 0) = 1$, aleshores

$$P(S_1 \cdot S_2 \cdots S_n \neq 0, S_n = k) = \frac{|k|}{n} P(S_n = k, k \in \mathbb{Z})$$

Suposem $k > 0$. Pel teorema del recompte de camins que no creuen el zero, el nombre de camins que van de $(0, 0)$ a (n, k) és $\binom{n}{k} N_n(0, k)$. Cadascun té probabilitat $p^{(n+k)/2} (1-p)^{(n-k)/2}$. Aleshores la probabilitat demanada és:

$$\frac{k}{n} N_n(0, k) p^{(n+k)/2} (1-p)^{(n-k)/2}$$

però

$$P(S_n = k) = N_n(0, k) p^{(n+k)/2} (1-p)^{(n-k)/2}$$

La posició màxima

Considerem de nou el passeig aleatori simple simètric. A la posició màxima a la que arriba el procés en els primers n passos la denotarem per $M_n = \max\{S_0, S_1, \dots, S_n\}$, que pren valors en el conjunt $\{0, 1, \dots, n\}$. La distribució de M_n es pot obtenir a partir del principi de reflexió.

Theorem 5.4. (Màxim). Suposem $P(S_0 = 0) = 1$ i $p = 1/2$. La funció de probabilitat del màxim M_n és per a $m \geq 1$

$$P(M_n = m) = \begin{cases} \Pr(S_n = m), & \text{si } (n - m) \text{ és parell,} \\ \Pr(S_n = m + 1), & \text{si } (n - m) \text{ és senar.} \end{cases}$$

Per a $M = 0$, $P(M_n = 0) = P(S_n \leq 0)$

Cal observar que per a qualsevol n , la funció de probabilitat de M_n és decreixent. En particular el valor més probable per al màxim (i per tant la moda de la distribució) és 0.

L'última visita a l'origen

Considerem de nou el passeig aleatori simple simètric. Ens ocupem ara de l'última visita a 0 durant els primers $2n$ passos:

$$L_{2n} = \max\{j \in \{0, 2, \dots, 2n\} : S_j = 0\} \quad n \in \mathbb{N}$$

Observeu que, donat que les visites a 0 només pot passar en instants parells, L_{2n} preu els valors del conjunt $\{0, 2, \dots, 2n\}$. Aquesta variable aleatòria té una distribució coneguda com a *distribució arcsinus discreta*

Theorem 5.5. Llei de l'arcsinus per l'última visita a l'origen. suposem $P(S_0 = 0) = 1$ i $p = 1/2$. Aleshores, per $k \in \{0, 1, \dots, n\}$

$$P(L_{2n} = 2k) = P(S_{2k} = 0) P(S_{2n-2k} = 0) = \binom{2k}{k} \binom{2n-2k}{n-k} \frac{1}{2^{2n}}$$

a més a més, la seva funció de distribució $P(L_{2n} \leq 2k)$ s'aproxima bé per $(2/\pi) \arcsin \sqrt{k/n}$

La funció de probabilitat de L_{2n} és simètrica respecte a n i té la forma:

$$P(L_{2n} = 2k) = P(L_{2n} = 2n - 2k),$$

$P(L_{2n} = 2j) > P(L_{2n} = 2k)$ si i només si $j < k$ i $2k \leq n$

En particular, 0 i $2n$ són els valors més probables. La distribució arcinus és bastant sorprenent. Com que estem llançant una moneda a l'aire per determinar els passos del caminant, és fàcil pensar que el passeig aleatori ha de ser positiu la meitat del temps i negatiu l'altra meitat, i que ha de tornar a 0 freqüentment. Però, en realitat, la llei arcsinus implica que amb probabilitat $1/2$, no hi haurà retorn a 0 durant la segona meitat del passeig, des de $n + 1$ fins a $2n$, independentment del valor que tingui n , i si no és estrany que el passeig se mantingui en valors positius (o negatius) durant tot el temps d'1 a $2n$.

Nota: La funció $F(x) = (2/\pi)\arcsin\sqrt{x}$, $x \in [0, 1]$, és la funció de distribució associada a la densitat

$$f(x) = \frac{1}{\pi\sqrt{x(1-x)}}$$

La distribució de probabilitat amb aquesta densitat rep el nom de distribució arcinus contínua. Observeu que un cas particular d'aquesta distribució Beta amb paràmetres $a = b = 1/2$

Cal observar que la funció de probabilitat L_{2n} (amb distribució arcsinus discreta) té una forma similar a la de la funció de densitat de la distribució arcsinus contínua.

Probabilitat de visitar una posició donada

Considerem un caminant que es mou segons un passeig aleatori simple $\{S_n : n \geq 0\}$ amb probabilitats p i $q = 1 - p$ de moviment a dreta i esquerra respectivament. Suposem que $P(S = 0) = 1$. Ens preguntem aquí per la probabilitat que el caminant torni alguna vegada a l'origen, el seu punt de partida. També ens interessa saber amb quina probabilitat visitarà alguna vegada una posició fixada r

Theorem 5.6.

- La probabilitat que el caminant torni alguna vegada a l'origen és $1 - |p - q|$.
- El cas del passeig aleatori simple simètric ($p = q = 1/2$). En aquest cas el temps fins al primer retorn és una variable aleatòria no negativa amb esperança infinita
- Sigui $r > 0$. La probabilitat que el caminant visiti alguna vegada la posició r és $(\min\{1, p/q\})^r$
- En el cas del passeig aleatori simple simètric ($p = q = 1/2$) és segur que es visitarà la posició $r > 0$. També ho és si $p > q$.

5.3 Processos de Poisson.

Considerem una successió d'ocurrències d'un determinat esdeveniment al llarg del temps. Sigui X_1 el temps d'espera necessari per a que el esdeveniment passi per primera vegada, X_2 el temps d'espera entre la primera i la segona ocurrència, i en general X_i el temps entre les ocurrències $i - 1$ i i . El model formal que descriu aquest fenomen es una successió de variables aleatòries definides sobre un determinat espai de probabilitat.

Un altra característica d'interés lligada al fenomen anterior es el nombre d'esdeveniments que han ocorregut en un determinat interval de temps $[t_1, t_2]$. Per exemple, per a $t_1 = 0$ i $t_2 = t$ definim la variable $N_t = N_t = \{\text{nombre d'esdeveniments ocorreguts fins al temps } t\}$. Aquest procés $N_t; t \geq 0$ en temps continu te espai d'estats discret $\{S = \{0, 1, 2, \dots\}\}$ i verifica que $N(0) = 0$ i que no es decreixent en el temps, $N_s \leq N_t$, si $s < t$. Aquest tipus de processos s'anomenen **processos comptadors(count process)**

Definició 5.18. Un procés comptador es un **procés de Poisson amb intensitat** λ que compleix les següents propietats

- 1.No poden ocórrer dues esdeveniments alhora
- 2.En cada interval finit de temps el nombre d'esdeveniments observables es finit
- 3.Els temps d'espera són independents i idènticament distribuïts segons una distribució $Exp(\lambda)$

Per estudiar el comportament probabilístic de les variables N_t es convenient recórrer a una nova successió de variables S_n que representa el temps transcorreguts fins l'observació del n-èsim esdeveniment. com a conseqüència de les dues primeres propietats la successió es estrictament creixent

$$0 = S_0 < S_1 < S_2 < \dots, \sup_n S_n = \infty$$

En la següent figura es mostra gràficament la relació entre les variables S_n, X_i i N_t que caracteritzen el procés de Poisson




Figura 22: Representació gràfica de les funcions relacionades amb un procés de Poisson

La distribució de S_n al ser suma d'exponencials independents i idènticament distribuïdes amb el mateix paràmetre λ ve donat per la distribució d'Erlang $G(n, 1/\lambda)$ cuya densitat és:

$$g_n(t) = \lambda \frac{(\lambda t)^{n-1}}{(n-1)!} e^{-\lambda t}, \quad t \geq 0$$

i la funció de distribució és

$$G_n(t) = \sum_{k \geq n} e^{-\lambda t} \frac{(\lambda t)^k}{k!} = 1 - e^{-\lambda t} \sum_{k=0}^{n-1} \frac{(\lambda t)^k}{k!}$$

El número N_t d'esdeveniments ocorreguts en l'interval $]0, t]$ és el major n tal que $S_n < t$

$$N_t = \max\{n : S_n \leq t\}$$

d'on es fàcil deduir que

$$\{N_t \geq n\} = \{S_n \leq t\}$$

i combinat l'equació anterior i (5.3) tenim

$$P(N_t \geq n) = G_n(t) = \sum_{k \geq n} e^{-\lambda t} \frac{(\lambda t)^k}{k!}$$

d'ací es fàcil deduir que

$$P(N_t = n) = e^{-\lambda t} \frac{(\lambda t)^n}{n!}$$

que es la distribució de Poisson. Així $N_t \sim Po(\lambda t)$, que justifica como es diu el procés. A més el resultat ens permet identificar el paràmetre λ perquè si recordem $E[N_t] = \lambda t$, es dedueix que λ és el nombre de esdeveniments que ocorren per unitat de temps.

:::{.exemple}

En l'exemple @ref(exm: #ppuntual) es mostrava la realització d'un procés de Poisson on es volia avaluar el nombre de pacients que arribaven en un determinat temps a un servei d'urgències amb $\lambda = 3$ per hora.

:::

*Increments Independents i Estacionaris

La successió de temps acumulats S_n s'obté com a suma de variables exponencials IID i presenta increments independents i estacionaris.

Atesa la relació entre N_t i S_n , és natural pensar que el procés de Poisson comparteix aquesta propietat. Tanmateix, la justificació no és immediata: en un interval $(t, t + s]$, el primer temps d'espera pot haver-se iniciat abans de t , quedant-ne només una part (Y_{N_t+1}) dins de l'interval.

1. Per la **propietat de falta de memòria**, el temps restant Y_{N_t+1} manté la mateixa distribució: $Y_{N_t+1} \sim \text{Exp}(\lambda)$.
2. Com que Y_{N_t+1} només depèn de $t - S_{N_t}$, és independent de tots els temps d'espera posteriors (X_{N_t+k} per a $k \geq 2$).

D'aquesta manera, l'increment $N_{t+s} - N_t = m$ es determina com la suma:

$$Y_{N_t+1} + \sum_{k=2}^m X_{N_t+k}$$

A la pràctica, equival a traslladar l'origen de temps a t :

$$P(N_{t+s} - N_t = m) = P(N_s = m) = \frac{e^{-\lambda s} (\lambda s)^m}{m!}$$

En general, per a $t_2 > t_1$:

$$N_{t_2} - N_{t_1} \sim \text{Po}(\lambda(t_2 - t_1))$$

La distribució depèn només de la durada de l'interval $(t_2 - t_1)$ i no de la seva posició. Per tant, els increments són estacionaris.

Respecte a les funcions de moments.

Mitjana del procés: Com ja hem vist anteriorment:

$$\mu(t) = \lambda t$$

Funció d'autocorrelació: Per a dos instants qualsevol tals que $t_2 > t_1$, fent ús de la estacionarietat i independència dels increments:

$$\begin{aligned} E[N_{t_1} N_{t_2}] &= E[(N_{t_1} + (N_{t_2} - N_{t_1})) N_{t_1}] \\ &= E[N_{t_1}^2] + E[N_{t_2} - N_{t_1}] E[N_{t_1}] \\ &= (\lambda t_1 + \lambda^2 t_1^2) + \lambda(t_2 - t_1) \lambda t_1 \\ &= \lambda t_1 + \lambda^2 t_1 t_2 \end{aligned}$$

Si $t_1 > t_2$, intercanviàrem t_1 i t_2 en l'expressió anterior. En conseqüència, la funció d'autocorrelació val:

$$R(t_1, t_2) = E[N_{t_1} N_{t_2}] = \lambda \min(t_1, t_2) + \lambda^2 t_1 t_2$$

Funció d'autocovariància: De la relació entre $R(t_1, t_2)$ i $C(t_1, t_2)$ es dedueix:

$$C(t_1, t_2) = R(t_1, t_2) - \mu(t_1)\mu(t_2) = \lambda \min(t_1, t_2)$$

Variància del procés: Per a $t_1 = t_2 = t$ obtenim la variància del procés que, com en el cas de la distribució de Poisson, coincideix amb la mitjana:

$$\sigma^2(t) = \lambda t$$

Procés de Poisson i Arribades a l'Atzar

El procés de Poisson permet modelar la suma d'esdeveniments que succeeixen al llarg del temps (com les partícules que arriben a un comptador Geiger). En aquests fenòmens es parla d'arribades a l'atzar.

Distribució condicional de les arribades:

Si observem un procés en l'interval $(0, t]$ i sabem que s'han après n esdeveniments ($N_t = n$), la probabilitat que k d'ells hagin tingut lloc en un subinterval $(0, t_1]$ és:

$$\begin{aligned} P(N_{t_1} = k \mid N_t = n) &= \frac{P(N_{t_1} = k, N_t = n)}{P(N_t = n)} = \frac{P(N_{t_1} = k, N_{t-t_1} = n-k)}{P(N_t = n)} \\ &= \frac{\left[\frac{e^{-\lambda t_1} (\lambda t_1)^k}{k!} \right] \left[\frac{e^{-\lambda(t-t_1)} (\lambda(t-t_1))^{n-k}}{(n-k)!} \right]}{\frac{e^{-\lambda t} (\lambda t)^n}{n!}} \\ &= \binom{n}{k} \left(\frac{t_1}{t} \right)^k \left(\frac{t-t_1}{t} \right)^{n-k} \end{aligned}$$

Per tant, $N_{t_1} \mid N_t = n \sim \text{Binomial}(n, p)$ amb $p = \frac{t_1}{t}$.

Conclusió: Condicionat a haver-hi n esdeveniments en $(0, t]$, aquests es distribueixen de forma uniforme i independent al llarg de l'interval.

Simulació d'un Procés de Poisson

Gràcies a la propietat de distribució uniforme condicional, podem simular la trajectòria d'un procés de Poisson de paràmetre λ en un interval $(0, t]$ de forma molt senzilla:

Algorisme de simulació:

1. Generar el nombre d'arribades: Simultàniament es genera un valor n_0 d'una variable aleatòria $\text{Po}(\lambda t)$.
2. Generar els temps d'arribada: Si el valor simulat és n_0 , es generen n_0 valors independents d'una distribució uniforme $U(0, t)$.
3. Ordenar els temps: S'ordenen els n_0 valors obtinguts de menor a major per obtenir els temps d'arribada $S_1, S_2, \dots, S_{n_0}$.

Codi en R:

```
simular_poisson <- function(lambda, t) {
  # 1. Nombre de successos
  n0 <- rpois(1, lambda * t)
  # 2. Temps d'arribada uniformes
  if (n0 > 0) {
    S <- sort(runif(n0, min = 0, max = t))
  } else {
    S <- numeric(0)
  }
}
```

```

return(list(n_events = n0, temps_arribada = S))
}

```

5.4 Moviment Brownià.

La caminada aleatòria (*random walk*) presentada en un apartat anterior era la suma de desplaçaments independents a dreta i a esquerra, de forma que només estaven permesos salts de un sentit a un altre en cada interval de temps. Imaginem ara desplaçaments petits de longitud Δ que es produeixen en intervals de temps petit de longitud τ . En el límit, quan tant la longitud dels desplaçaments com la durada dels intervals de temps tendeixen a zero, s'obté un procés estocàstic les realitzacions del qual són funcions contínues del temps.

El matemàtic Norbert Wiener estipulo las següents assumpcions para un procés aleatori estacionari $W(.,.)$ amb increments independents en 1923

Definició 5.19. Moviment Brownià

Un procés estocàstic $W(t)$ s'anomena moviment Brownià si

1. *Independència:* $W(t + \Delta t) - W(t)$ es independent de $\{W(s) : s \leq t\}$
2. *Estacionarietat:* La distribució de $W(t + \Delta t) - W(t)$ no depen de t
3. *Continuïtat:* $\lim_{\Delta t \rightarrow 0} \frac{P(|W(t + \Delta t) - W(t)| \geq \delta)}{\Delta t} = 0 \quad \forall \delta > 0$
4. Per a qualsevol $\Delta t > 0$, l'increment del procés verifica

$$W(t + \Delta t) - W(t) \sim \mathcal{N}(\mu \Delta t, \sigma^2 \Delta t).$$

Propietats del moviment Brownià

- El valor esperat és $E[W(t)] = \mu t$
- La variància és $Var[W(t)] = \sigma^2 t$
- La funció de autocovariància és $E[(W(t) - \mu t)(W(\tau) - \mu \tau)] = \sigma^2 \min(t, \tau)$ que coincideix en la autocorrelació.
- la variació total de un moviment Brownià sobre un interval finit $[0, T]$ és ∞
- La suma de quadrats de un “drift-free” moviment Brownià es determinístic.

$$\lim_{N \rightarrow \infty} \sum_{k=1}^N \left(W\left(\frac{kT}{N}\right) - W\left(\frac{(k-1)T}{N}\right) \right)^2 = \sigma^2 T.$$

Definició 5.20. Un moviment Brownià es estàndard si.

$$W(0) = 0$$

$$E[W(t)] = 0; \mu = 0$$

$$E[W^2(t)] = t; \sigma^2 = 1$$

Fluctuacions del cabal d'un riu

Suposem que volem estudiar les petites fluctuacions del cabal d'un riu al llarg d'un dia. Tot i que el cabal presenta una tendència general estable, les variacions de la pluja, el vent, l'obertura de comportes i altres factors ambientals provoquen petites oscil·lacions contínues i imprevisibles.

Per descriure aquestes fluctuacions, suposem que $W(t)$ és un moviment brownià estàndard, on t representa el temps en hores des de l'inici del dia. El procés compleix les propietats següents:


- El nivell inicial és conegut: $W(0) = 0$.
- Els increments del procés en intervals disjunts són independents.
- En qualsevol interval de longitud Δt , la variació del cabal és una variable aleatòria normal

$$W(t + \Delta t) - W(t) \sim N(0, \Delta t).$$

Això significa que, com més llarg és l'interval de temps, més gran és la variabilitat esperada de les fluctuacions. No obstant això, les variacions positives i negatives són igualment probables, de manera que l'esperança dels increments és zero.

La figura següent mostra una possible realització d'un moviment brownià durant les 24 hores d'un dia.

Dues realitzacions independents d'un moviment brownià



En aquest exemple la trajectòria representa les fluctuacions acumulades del cabal respecte del valor inicial. Es pot observar que la funció és contínua, però extremadament irregular: presenta nombrosos canvis de direcció i no és derivable en cap punt. Aquest és un dels trets característics del moviment brownià.