

Procesos Estocásticos

Raúl Jiménez y Rosario Romera

UC3M

Diciembre 2008

Procesos Estocásticos

El paso del tiempo juega un papel esencial en el complejo mundo que observamos. Es por eso la mayoría de los modelos matemáticos consideran cantidades que cambian aleatoriamente con el tiempo. Tales modelos son llamados *procesos estocásticos* y hay de muchos tipos.

Muchos fenómeno reales de la naturaleza, de las finanzas, de la ingeniería motivan las reglas de los procesos específicos que vamos a considerar en este curso. Ellos son:

- 1 Cadenas de Markov a tiempo discreto
- 2 Martingalas
- 3 Procesos de Poisson y de renovación
- 4 Cadenas de Markov a tiempo continuo y procesos de colas
- 5 Movimiento Browniano y difusiones

Definición general

Un **proceso estocástico** es una familia de variables aleatorias $\{X_t, t \in T\}$ definidas sobre un mismo espacio de probabilidad $(\Omega, \mathcal{F}, P)$ y con valores en un mismo espacio, llamado **espacio de estados** y comúnmente denotado por S .


En este curso T siempre será un conjunto de números reales.

- Si $T = \{0, 1, 2, \dots\}$, decimos que $\{X_t, t \in T\}$ es un proceso a tiempo discreto.
- Si T es un intervalo de número reales, decimos que es a tiempo continuo.
- Si $T \subset R^n$ con $n > 1$, el proceso se denomina *campo aleatorio*.

Cada $\omega \in \Omega$, define una función $T \rightarrow S$, $t \rightarrow X_t(\omega)$, que llamaremos **trayectoria del proceso estocástico**.

Cadenas de Markov

Hace más de un siglo se escribió el primer trabajo seminal sobre Cadenas de Markov y aún siguen siendo un instrumento tremendamente útil de modelación estocástica.



Su importancia obedece a dos razones:

- ① Muchos ejemplos físicos, biológicos, económicos y sociales pueden ser descritos con ellas.
- ② Son modelos sencillos y su teoría está bien desarrollada.

Definición

El proceso $\{X_n\}$ es una **Cadena de Markov** (CM) si para cualquier $n \in \mathbb{N}, j, i, i_{n-1}, \dots, i_0 \in S$ (espacio de estados)

$$P(X_{n+1} = j | X_n = i, X_{n-1} = i_{n-1}, \dots, X_0 = i_0) = P(X_{n+1} = j | X_n = i)$$

Esta expresión es llamada *propiedad de Markov* y establece que dado el presente cualquier otra información del pasado es irrelevante para predecir el futuro.

Nos restringiremos al caso **temporalmente homogéneo**, en el cual la probabilidad

$$P(X_{n+1} = j | X_n = i) = p(i, j)$$

no depende del tiempo n . La matriz P con componente $[P]_{i,j} = p(i, j)$ es llamada **matriz de transición** de la cadena $\{X_n\}$.


Ejemplo 1: Ruina del jugador

A y B son jugadores que tienen k y $N - k$ euros respectivamente. Lanza una moneda repetidamente y en cada turno B le paga a A un euro si es cara. En caso contrario A le paga un euro a B . El juego termina cuando uno de los jugadores se arruina. La cantidad de euros que A tiene luego de n turnos es una CM con probabilidades de transición

$$p(i, i-1) = p(i, i+1) = \frac{1}{2}, \quad \text{si } 0 < i < N,$$

$$p(0,0) = p(N,N) = 1 \text{ y } p(i,j) = 0 \text{ en caso contrario}$$

A veces es útil representar la cadena por un diagrama. Para el ejemplo anterior, con $N = 4$, sería



Ejemplo 2: Urnas de Ehrenfest

Considere la CM que toma valores en $\{0, 1, \dots, a\}$ con probabilidades de transición

$$P(X_{n+1} = j | X_n = i) = \begin{cases} 1 - \frac{i}{a} & \text{si } j = i + 1 \\ \frac{i}{a} & \text{si } j = i - 1 \\ 0 & \text{en cualquier otro caso} \end{cases}$$

En forma matricial, para $a = 5$,

	0	1	2	3	4	5
0	0	1	0	0	0	0
1	$\frac{1}{5}$	0	$\frac{4}{5}$	0	0	0
2	0	$\frac{2}{5}$	0	$\frac{3}{5}$	0	0
3	0	0	$\frac{3}{5}$	0	$\frac{2}{5}$	0
4	0	0	0	$\frac{1}{5}$	0	$\frac{1}{5}$
5	0	0	0	0	1	0

Se tienen dos urnas, con a bolas repartidas dentro de ellas, y en cada etapa se escoge una bola al azar y se cambia de urna. La cadena X_n representa el número de bolas de una de las urnas tras n etapas.

Ecuaciones de Chapman-Kolmogorov

Usando la propiedad de Markov y la homogeneidad temporal, es fácil comprobar que la **probabilidad de ir de i a j en m etapas** es

$$P(X_m = j | X_0 = i) = \sum_k p(i, k) P(X_{m-1} = j | X_0 = k)$$

Iterando, se obtiene que

$$P(X_m = j | X_0 = i) = p^m(i, j)$$

Es decir, la probabilidad de ir de i a j en m etapas es el elemento (i, j) de P^m . La esencia de las ecuaciones anteriores está recogida en las **ecuaciones de Chapman-Kolmogorov**

$$p^{m+n}(i, j) = \sum_k p^m(i, k) p^n(k, j)$$

Conjuntos cerrados e irreducibles

Decimos que:

- i se comunica con j ($i \rightarrow j$) si, para algún n , $p^n(i, j) > 0$
- los **estados** i y j **se comunican** entre si ($i \leftrightarrow j$) si $i \rightarrow j$ y $j \rightarrow i$.

Un conjunto de estados es:

- **cerrado** si no existe ningún estado dentro del conjunto que se comunique con alguno afuera. Es decir, una CM no puede *escapar* de un conjunto cerrado.
- **irreducible**, si todos los estados del conjunto se comunican entre si. Si el conjunto de estados de una CM es irreducible entonces la cadena *puede visitar* cualquier estado del conjunto.

Como ejemplo, considere la CM asociada a la ruina del jugador con N euros en juego. Entonces, $\{0, N\}$ es cerrado pero no es irreducible y $\{1, \dots, N-1\}$ es irreducible pero no es cerrado.

Estados recurrentes y transitorios

Sea $T_i = \min\{n \geq 1 : X_n = i\}$ **tiempo de primera pasada por i** (sin contar de donde partió). Entonces, la probabilidad de que $\{X_n\}$ **regrese a i** es $\rho_i = P(T_i < \infty | X_0 = i)$.

La propiedad de Markov implica que la probabilidad de que $\{X_n\}$ retorne a i n veces es ρ_i^n . Por lo que

- Si $\rho_i < 1$ la probabilidad de que $\{X_n\}$ pase por i infinitas veces es cero. En ese caso, la cadena eventualmente **no regresa** a i y decimos que el estado i es **transitorio**.
- Si $\rho_i = 1$ la cadena regresa a i infinitas veces. En este caso decimos que el estado i es **recurrente**.

Un estado i se denomina **absorbente** si $p(i, i) = 1$. Por supuesto, si i es absorbente entonces es recurrente.

Siguiendo con el ejemplo anterior de la ruina del jugador, 0 y N son absorbentes mientras que $1, \dots, N - 1$ son transitorios.

Caracterización de conjuntos de estados recurrentes

Proposición 1. Si el espacio de estados de una cadena es finito entonces puede **partirse** en $T, C_1, \dots, C_k$, donde T es el conjunto de todos los estados transitorios mientras que $C_1, \dots, C_k$ son conjuntos irreducibles y cerrados de estados recurrentes.

Proposición 2. Si C es un conjunto de estados finito, cerrado e irreducible entonces todos los estados de C son recurrentes.

La prueba de la proposición 2 pasa por demostrar algunas propiedades útiles de los estados recurrentes y transitorios:

- Si i es recurrente y $i \rightarrow j$ entonces j es recurrente.
- Si $i \rightarrow j$ pero j no se comunica con i entonces i es transitorio.
- En todo conjunto cerrado finito hay al menos un estado recurrente.

Estados periódicos y aperiódicos

Otra definición, desafortunadamente muy técnica pero necesaria para poder enunciar un importante resultado asintótico, es:

El **período del estado** i se define por

$$d(i) = \text{m.c.d.} \{n \geq 1 : p_{ii}^n > 0\}$$

Si $d(i) = 1$, el estado i se denomina **aperiódico**.

En la ruina del jugador, los estados transitorios tienen período 2 mientras que los absorbentes son aperiódicos. En la mayoría de los casos nos encontraremos (o diseñaremos) CM con estados aperiódicos. Para verificar cuáles son aperiódicos, son útiles las siguientes propiedades:

- Si $p(i, i) > 0$ entonces i es aperiódico
- Si $i \leftrightarrow j$ entonces $d(i) = d(j)$

Distribución estacionaria

- La cadena $\{X_n\}$ es **estacionaria** si la distribución de X_n es la misma para todo n .
- Decimos que una función de probabilidades π es **una distribución estacionaria** para la cadena $\{X_n\}$ si

cuando $X_0 \sim \pi$ entonces $X_n \sim \pi$ para todo n .

Ahora bien, sabemos que si $X_n \sim \pi$ entonces $X_{n+1} \sim \pi P$. Es decir:

Una **distribución estacionaria** es una solución de la ecuación $\pi = \pi P$. O lo que es lo mismo, verifica

$$\pi(j) = \sum_i \pi(i)p(i,j) \text{ para cualquier estado } j$$

Si la cadena alcanza la distribución estacionaria, es común decir que la cadena está en *estado de equilibrio*.

Comportamiento asintótico

Teorema 1. Consideremos una CM con matriz de transición P y con espacio de estados irreducible y aperiódico. Si π es una distribución estacionaria entonces para todo par de estados i, j se tiene

$$\lim_{n \rightarrow \infty} p^n(i, j) = \pi(j)$$

Esto es, no importa de donde parta la cadena, asintóticamente alcanza el equilibrio. Los resultados que siguen tienen que ver con la unicidad y existencia de π .

Teorema 2. Si el espacio de estados es irreducible entonces de existir una distribución estacionaria sería única.

Teorema 3. Si el espacio de estados es finito entonces existe al menos una distribución estacionaria.

Distribución estacionaria y tiempos de retorno

La conexión entre la distribución estacionaria y los tiempos de primera visita, en este caso de **primer retorno**, viene dada por el siguiente teorema.

Teorema 4. Si la CM es irreducible, aperiódica, y tiene distribución estacionaria π entonces

$$\pi(i) = \frac{1}{E[T_i | X_0 = i]}$$

Por simplicidad tipográfica, denotaremos por μ_i al tiempo esperado del primer retorno a i , esto es $\mu_i = E[T_i | X_0 = i]$.

Decimos que i es **positivo recurrente** si $\mu_i < \infty$. Si el estado i es recurrente pero no es positivo recurrente (i.e. si $\rho_i = 1$ pero $\mu_i = \infty$) entonces decimos que i es **nulo recurrente**.

Existencia de π cuando el espacio de estados es infinito

La clasificación anterior de estados recurrentes en nulo y positivos permite extender el teorema de existencia para el caso finito (Teorema 3) al caso infinito.

Teorema 5. Si una cadena es irreducible las siguientes proposiciones son equivalentes:

- 1 Al menos un estado es positivo recurrente
- 2 Todos los estados son positivos recurrentes
- 3 Existe una distribución estacionaria

La recurrencia positiva puede ser difícil de demostrar en ejemplos concretos. En la práctica, lo que hacemos es resolver $\pi = \pi P$ y aplicar que si $X_n \sim \pi$ entonces $X_m \sim \pi$ para todo $m \geq n$.

Ley de grandes números para CM

Una propiedad importante de las distribuciones estacionarias es que son la *fracción límite del tiempo de ocupación*. Más precisamente, si $N_n(i)$ el número de visitas al estado i hasta el instante n entonces

$$\lim_{n \rightarrow \infty} \frac{N_n(i)}{n} = \pi(i)$$

La formalización de este resultado la presentamos en una forma más general y útil para diversas aplicaciones:

Teorema 6. Sea $\{X_n\}$ una CM irreducible con matriz de transición p y distribución estacionaria π . Sea $G(i)$ la ganancia obtenida cada vez que la cadena alcanza el valor i . Supongamos que $\sum_i |G(i)|\pi(i) < \infty$. Entonces, cuando $n \rightarrow \infty$

$$\frac{1}{n} \sum_{k=1}^n G(X_k) \rightarrow \sum_i G(i)\pi(i)$$

Martingalas

Vamos a estudiar una clase de procesos que pueden verse como la fortuna de un jugador que juega repetidamente un *juego justo*. Así que pensemos que M_n es la fortuna del jugador luego de jugar n turnos del juego.

Decimos que $M_0, M_1, \dots$ es una **martingala** si para cualquier $n \geq 0$

- ① $E|M_n| < \infty$
- ② para cualquier sucesión de posibles valores $m_0, m_1, \dots, m_n$

$$E[M_{n+1} | M_0 = m_0, M_1 = m_1, \dots, M_n = m_n] = m_n$$

La segunda propiedad es equivalente a

$$E[M_{n+1} - M_n | M_0 = m_0, M_1 = m_1, \dots, M_n = m_n] = 0.$$

Es decir, condicionando al pasado, la ganancia neta esperada luego del turno siguiente es cero. Esto es, el juego es justo.

Esperanza condicional

Como el estudio de martingalas recae fuertemente en el concepto de esperanza condicional es conveniente extenderla en un sentido más general. En los cursos introductorios de probabilidad, si X, Y son variables aleatorias, la esperanza de X dado $Y = y$ se entiende como el valor esperado de la distribución de X dado $Y = y$,

$$E[X|Y = y] = \begin{cases} \sum_x x P(X = x|Y = y) & \text{caso discreto} \\ \int x f_{X|Y=y}(x) dx & \text{caso continuo} \end{cases}$$

Sea ψ tal que, para cada posible valor y de Y se tiene

$$\psi(y) = E[X|Y = y]$$

La **variable aleatoria** $\psi(Y)$ es llamada **esperanza condicional de X dado Y** y se denota por $E[X|Y]$.

Definición

Usando el concepto revisado de esperanza condicional, volvemos a la definición de martingala:

Decimos que $M_0, M_1, \dots$ es una **martingala** si para cualquier $n \geq 0$

- 1 $E|M_n| < \infty$

- 2 $E[M_{n+1}|M_0, M_1, \dots, M_n] = M_n$

Si en vez de la igualdad en 2 tenemos lo que ocurre en la mayoría de los juegos de casino

$$E(M_{n+1}|M_0, M_1, \dots, M_n) \leq M_n$$

decimos entonces que $\{M_n\}$ es una **supermartingala**. Si por el contrario, el juego es a favor del jugador y

$$E[M_{n+1}|M_0, M_1, \dots, M_n] \geq M_n$$

decimos que es una **submartingala**.

Ejemplos

- **Paseos aleatorios.** Sean $X_1, X_2, \dots$ variables aleatorias independientes y $M_n = M_0 + X_1 + \dots + X_n$. Ya que

$$E[M_{n+1} - M_n | M_0, M_1, \dots, M_n] = E[X_{n+1}],$$

M_n es una supermartingala si $E[X_i] \leq 0$, una martingala si $E[X_i] = 0$ y una submartingala si $E[X_i] \geq 0$.

- **Black-Scholes discreto.** Sean $Z_1, Z_2, \dots$ variables aleatorias independientes normales $N(\mu, \sigma^2)$ y definamos $M_n = M_0 e^{Z_1} \dots e^{Z_n}$. Entonces,

$$E[M_{n+1} | M_0, M_1, \dots, M_n] = M_n E[e^{Z_{n+1}}],$$

Así que M_n es una supermartingala si $E[e^{Z_i}] \leq 1$, un martingala si $E[e^{Z_i}] = 1$ y una submartingala si $E[e^{Z_i}] \geq 1$.

Modelo Binomial de precios de acciones

Sean $Z_1, Z_2, \dots$ variables aleatorias independientes, con

$$P\left(Z_i = \frac{(1+t)}{e^r}\right) = p \text{ y } P\left(Z_i = \frac{1}{(1+t)e^r}\right) = 1 - p,$$

y definamos los precios por $M_{n+1} = M_0 Z_1 \cdots Z_n$, $n \geq 1$. La constante r es la *tasa de interés* (descontamos por no ganar intereses) y el factor $(1+t)$ y $1/(1+t)$ modela las variaciones del mercado y garantiza que el precio tiene la forma $M_0(1+t)^ze^{-nr}$, con $|z| \leq n$. La *volatilidad* está asociada a p . Entonces,

$$E[M_{n+1} | M_0, M_1, \dots, M_n] = M_n E[Z_{n+1}],$$

Así que M_n es una supermartingala si $E[Z_i] \leq 1$, un martingala si $E[Z_i] = 1$ y una submartingala si $E[Z_i] \geq 1$.

Martingalas respecto a CM

Decimos que $M_0, M_1, \dots$ es una **martingala** respecto a $X_0, X_1, \dots$ si para cualquier $n \geq 0$, $E|M_n| < \infty$ y

$$E[M_{n+1} - M_n | X_0, X_1, \dots, X_n] = 0$$

Esta nueva definición no es un simple capricho matemático, se justificará cuando enunciemos el teorema de muestreo opcional. Por ahora, mencionamos que en la mayoría de los ejemplos $\{X_n\}$ es una CM y $M_n = g(X_n, n)$ para alguna función g .

Teorema 1 Sea $\{X_n\}$ una CM con espacio de estados S y matriz de probabilidades de transición P . Sea $g : S \times \mathbb{N} \rightarrow \mathbb{R}$ tal que

$$g(i, n) = \sum_{j \in S} p(i, j) g(j, n+1)$$

Entonces $M_n = g(X_n, n)$ es una martingala.

Ejemplos

- **Martingala cuadrática.** Sean $X_1, X_2, \dots$ variables aleatorias independientes con $E[X_i] = 0$ y $E[X_i^2] = \sigma^2$. Considere el paseo $S_n = S_0 + X_1 + \dots + X_n$, con S_0 constante, y

$$M_n = g(S_n, n) = S_n^2 - n\sigma^2$$

Entonces M_n es una martingala con respecto a $S_0, S_1, \dots$.

- **Martingala exponencial.** Sean $Z_1, Z_2, \dots$ variables aleatorias independientes con función generatriz de momentos $\psi(\alpha) = E[\exp(\alpha Z_i)]$. Definamos $S_n = S_0 + X_1 + \dots + X_n$, con S_0 constante. Entonces

$$M_n = g(S_n, n) = \frac{e^{\alpha S_n}}{\psi^n(\alpha)}$$

es una martingala con respecto a $S_0, S_1, \dots$.

Propiedades elementales

Antes de discutir los resultados centrales de la teoría de martingalas, es conveniente aclarar algunos resultados elementales:

- ① Si $\{X_n\}$ es una martingala (super-martingala) con respecto a $\{Y_n\}$ entonces $E[X_{n+k} | Y_0, \dots, Y_n] = X_n$ (" $\leq$ ") para todo $k \geq 0$.
- ② Si $\{X_n\}$ es una martingala (supermartingala) con respecto a $\{Y_n\}$ entonces para $0 \leq k \leq n$ se satisface

$$E[X_n] = E[X_k] \quad (\text{resp. } E[X_n] \leq E[X_k])$$

- ③ Si $\{X_n\}$ es una martingala con respecto a $\{Y_n\}$ y ϕ es una función convexa entonces $\{\phi(X_n)\}$ es una submartingala con respecto a $\{Y_n\}$.

Tiempos de parada

Decimos que la variable aleatoria T es un **tiempo de parada** para el proceso $\{X_n\}$ si la ocurrencia o no del evento $\{T = n\}$ (que se entiende como *paramos el proceso en el instante n*) puede ser determinado conociendo sólo los valores $X_0, X_1, \dots, X_n$ (no se requiere conocer ni X_{n+1} , ni $X_{n+2}, \dots$).

Ejemplo. Si X_n es una CM que representa nuestro capital en euros luego de jugar n veces, el instante (aleatorio) T en el que por primera vez tenemos m euros es un tiempo de parada:

$$\{T = n\} = \{X_0 \neq m, \dots, X_{n-1} \neq m, X_n = m\}$$

Podríamos pensar en enriquecernos apostando en un casino y **parando** de jugar cuando alcancemos la suma deseada. Veamos que dice el resultado central de la teoría de martingalas.

Teorema del muestreo opcional

Teorema 2. Si M_n es una martingala respecto a $\{X_n\}$ y T es un tiempo de parada (también respecto a $\{X_n\}$) entonces el **proceso parado en T** , a saber $\{M_{\min(T,n)}, n \geq 0\}$, es también una martingala respecto a $\{X_n\}$. Si adicionalmente, $P(T < \infty) = 1$ y existe una $c \in \mathbb{R}^+$ tal que $|M_{\min(T,n)}| \leq c$ para todo n entonces

$$E[M_T] = M_0$$

La versión del teorema anterior para súper y submartingalas es:

Teorema 3. Si M_n es una supermartingala respecto a $\{X_n\}$ (respectivamente submartingala) y T es un tiempo de parada (también respecto a $\{X_n\}$) entonces el proceso parado en T es una supermartingala respecto a $\{X_n\}$ (respectivamente submartingala).

Comportamiento asintótico

Teorema 4. Si $\{M_n\}$ es una martingala tal que para todo n se satisface $E|M_n| \leq c$, para algún $c < \infty$, entonces $\lim_{n \rightarrow \infty} M_n$ existe casi siempre y es finito.

Corolario. Si $\{M_n\}$ es una martingala no negativa entonces $\lim_{n \rightarrow \infty} M_n$ existe casi siempre y es finito.

Teorema 5. Sea $\{M_n\}$ una martingala con incrementos acotados, es decir, para todo n , $|M_{n+1} - M_n| < c$ para algún $c < \infty$. Sea

$$\sigma_n^2 = E[(M_{n+1} - M_n)^2 | M_0, M_1, \dots, M_n]$$

y definamos $n(s) = \min \{n : \sum_{i=1}^n \sigma_i^2 \geq s\}$. Entonces

$$\lim_{s \rightarrow \infty} \frac{M_{n(s)}}{\sqrt{s}} \Rightarrow \mathcal{N}(0, 1)$$

Procesos de Renovación y el Proceso de Poisson

Sean $T_1, T_2, \dots$ variables aleatorias i.i.d no negativas y

$$S_n = T_1 + \dots + T_n \text{ si } n \geq 1 \text{ y } S_0 = 0$$

Pensemos en $\{S_n\}$ como los tiempos en los que se reporta una incidencia (fallo, reclamo, etc.) en un sistema. El proceso que representa el total de incidencias hasta el tiempo t , definido por

$$N(t) = \max\{n : S_n \leq t\},$$

se conoce como **proceso de renovación**. El caso particular en el que **los tiempos entre incidencias** $T_1, T_2, \dots$ son variables exponenciales con media $\lambda > 0$ se denomina **proceso de Poisson** con intensidad λ . A partir de la fórmula de convolución para la suma de variables independientes, se demuestra que $N(t)$ es una variable aleatoria Poisson con media λt .

Propiedades

Teorema. $\{N(t), t \geq 0\}$ es un proceso de Poisson con intensidad λ si y sólo si

- ① $N(0) = 0$
- ② $N(t) - N(s) \sim \text{Poisson}(\lambda(t - s))$, para todo $0 \leq s < t$
- ③ $\{N(t), t \geq 0\}$ tiene incrementos independientes. Es decir, si $t_0 < t_1 < \dots < t_m$ entonces

$$N(t_1) - N(t_0), N(t_2) - N(t_1), \dots, N(t_n) - N(t_{n-1})$$

son variables aleatorias independientes

Además de ser un proceso de renovación y un proceso con incrementos independientes, veremos más adelante que el proceso de Poisson y otros procesos basados en él son ejemplos de Procesos de Markov y Martingalas a tiempo continuo.

Proceso de Poisson no homogéneo

En numerosas situaciones es realista suponer que hay más incidencias a ciertas *horas* que a otras. Para modelar esta situación, es conveniente la siguiente generalización del Proceso de Poisson:

Decimos que $\{N(t), t \geq 0\}$ es un proceso de Poisson **no homogéneo** con intensidad $\lambda(t)$ si

- 1 $N(0) = 0$
- 2 $N(t) - N(s) \sim \text{Poisson} \left(\int_s^t \lambda(t) \right)$, para todo $0 \leq s < t$
- 3 $\{N(t), t \geq 0\}$ tiene incrementos independientes

Los tiempos entre ocurrencias asociados a un Proceso de Poisson no homogéneo no tienen por que ser exponenciales. Es suficiente calcular la distribución del tiempo de la primera incidencia

$$P(T_1 \leq t) = 1 - P(N(t) = 0) = 1 - e^{-\int_0^t \lambda(s) ds}$$

Proceso de Poisson compuesto

Podemos asociar variables a cada incidencia que representen costos de atención o reclamos. Así, si Y_i representa el costo de atención de la incidencia i -ésima, el proceso

$$S(t) = \begin{cases} 0 & \text{si } N(t) = 0 \\ Y_1 + \cdots + Y_{N(t)} & \text{si } N(t) \geq 1 \end{cases} \quad (1)$$

representa el costo acumulado a tiempo t . Cuando los reclamos $\{Y_i\}$ sean i.i.d., un supuesto común en teoría del riesgo, y el proceso $N(t)$ en (1) es de Poisson, el proceso $\{S(t), t \geq 0\}$ se conoce como **Proceso de Poisson Compuesto**. La media y la varianza de $S(t)$ se puede calcular para el caso más general:

$$ES(t) = EN(t) \cdot EY_i$$

$$Var(S(t)) = EN(t)Var(Y_i) + Var(N(t))(EY_i)^2$$

Proceso de Riesgo Colectivo

Consideremos una cartera de seguros que recibe un ingreso por primas de c euros por unidad de tiempo. Denotemos por Y_i el monto del reclamo del siniestro i y sea $N(t)$ el proceso que registra el número de reclamos a tiempo t . El balance de la cartera a tiempo t es

$$X(t) = X(0) + ct - S(t),$$

siendo $\{S(t), t \geq 0\}$ el proceso definido en (1)


El tiempo de ruina es

$$\tau = \inf_t \{t > 0 : X(t) < 0\}$$

y la probabilidad de ruina

$$\psi(x) = P(\tau < \infty | X(0) = x)$$

Problema clásico: calcular $\psi(x)$



Definición

Para extender la propiedad de Markov a tiempo continuo se requiere definir la probabilidad condicional dado que conocemos el proceso en un intervalo continuo $[0, s]$ del tiempo, es decir, condicionar respecto a eventos del tipo $\{X_t, 0 \leq t \leq s\}$.

Decimos que el proceso estocástico $\{X_t, t \geq 0\}$ es una **Cadena de Markov a tiempo continuo** si para cualesquiera instantes del tiempo $0 \leq s_0 < s_1 < \dots < s_n < s$ y cualquier conjunto de estados $i_0, \dots, i_n, i, j$ se verifica

$$P(X_{t+s} = j | X_s = i, X_{s_n} = i_n, \dots, X_{s_0} = i_0) = P(X_{t+s} = j | X_s = i)$$

Esto es, *dado el presente, cualquier otra información pasada del proceso es redundante para hacer pronósticos del futuro.*

Ejemplo

Sea $\{N(t), t \geq 0\}$ el proceso de Poisson con intensidad constante λ y $\{Y_n\}$ un CM a tiempo discreto con matriz de transición P . Entonces, el proceso definido por $X_t = Y_{N(t)}$ es una cadena de Markov a tiempo continuo.

Si $S_1, S_1, \dots$ son los momentos de renovación del proceso $N(t)$, entonces $\{X_0, X_{S_1}, \dots\}$ es una CM a tiempo discreto con la misma ley que $\{Y_n\}$ dado $Y_0 = X_0$. Los tiempos transcurridos ($T_i = S_i - S_{i-1}$) entre los instantes de actualización del proceso X_t son variables i.i.d exponenciales.

La propiedad de **pérdida de memoria** de la distribución exponencial es la clave para que la cadena descrita sea de Markov.

La **probabilidad de transición** de esta cadena es

$$P(X_t = j | X_0 = i) = \sum_{n \geq 0} e^{-\lambda t} \frac{(\lambda t)^n}{n!} p^n(i, j)$$

Probabilidades y tasas de transición

Como en el caso discreto, supondremos que la cadena es homogénea,

$$P(X_{s+t} = j | X_s = i) = P(X_t = j | X_0 = i)$$

y llamaremos matriz de **probabilidades de transición** a la matriz P_t con componente i, j definida por

$$[P_t]_{i,j} = p_t(i, j) = P(X_t = j | X_0 = i)$$

Las probabilidades de transición satisfacen las **ecuaciones de Chapman-Kolmogorov**, que para el caso continuo son

$$p_{s+t}(i, j) = \sum_k p_s(i, k) p_t(k, j)$$

La tasa con la cual la cadena salta de i a j se denomina **tasa de transición** y se denota por $q(i, j)$. Como la cadena es homogénea se tiene que

$$q(i, j) = \lim_{t \rightarrow 0^+} \frac{p_t(i, j)}{t}$$

Construcción de la CM a partir de las tasas de transición

La tasa con la cual la cadena *deja* el estado i la denotamos por λ_i :

$$\lambda_i = \sum_{j \neq i} q(i, j)$$

Decimos que un estado i es **absorbente** si $\lambda_i = 0$, estable si $0 < \lambda_i < \infty$ e **instantáneo** si $\lambda_i = \infty$. La cadena deja los estados instantáneos de forma inmediata, así que siempre asumiremos $\lambda_i < \infty$. Si $\lambda_i > 0$ definimos las probabilidades de transición

$$r(i, j) = q(i, j) / \lambda_i$$

Si $X(s) = i$ y el estado i es absorbente, la cadena permanecerá en i por siempre. Por el contrario, si el estado es estable, la cadena permanecerá en i un tiempo distribuido exponencialmente con tasa λ_i y luego *saltará* a otro estado con probabilidad de transición $r(i, j)$. Usando recursivamente este procedimiento **construimos** la cadena.

Ecuaciones diferenciales de Kolmogorov

Hemos discutido como a partir de las tasas de transición podemos construir la cadena a tiempo continuo. Ya que la cadena está determinada por las probabilidades de transición, entonces deberíamos poderlas calcular estas últimas a partir de las tasa de transición. La formalización de esta construcción se expresa en el siguiente resultado:

Teorema 1. Supongamos que ningún estado es instantáneo. Entonces, las probabilidades de transición son diferenciables en t y para cualquier par de estados i, j se tiene

$$\frac{dp_t}{dt}(i, j) = \sum_{k \neq i} q(i, k)p_t(k, j) - \lambda_i p_t(i, j) \quad \text{Backward equation}$$

$$\frac{dp_t}{dt}(i, j) = \sum_{k \neq j} q(k, j)p_t(i, k) - \lambda_j p_t(i, j) \quad \text{Forward equation}$$

Comportamiento asintótico

Para el estudio asintótico de las cadenas de Markov a tiempo continuo no requerimos la condición de aperiodicidad. Vamos a definir algunos conceptos para el caso continuo antes de enunciar los resultados más importantes.

- ① Una cadena continua es irreducible si puede saltar de un estado a otro en un número finito de saltos. Más formalmente, para todo par de estados i, j existe una sucesión finita de estados $i = k_1, k_2, \dots, k_n, k_{n+1} = j$ con $q(k_m, k_{m+1}) > 0$ para todo $1 \leq m \leq n$.
- ② Llamamos **generador infinitesimal de la cadena** a la matriz Q definida por

$$Q(i, j) = \begin{cases} q(i, j) & \text{si } j \neq i \\ -\lambda_i & \text{si } j = i \end{cases}$$

Distribución estacionaria

Decimos que π es una distribución estacionaria si para todo $t > 0$ es una solución de $\pi = \pi P_t$. O bien, elemento a elemento, si para todo j y $t > 0$

$$\pi(j) = \sum_i \pi(i) p_t(i, j)$$

Verificar por definición que una función de probabilidad es una distribución estacionaria es en general difícil ya que, por un lado, tiene que cumplirse $\pi = \pi P_t$ para todo $t > 0$ y, por otro, el cálculo de P_t puede ser complicado. El siguiente teorema resuelve el problema.

Teorema 2. π es una distribución estacionaria para la cadena si $\pi Q = 0$. O lo que es lo mismo, si y sólo si

$$\sum_{i \neq j} \pi(i) q(i, j) = \lambda_j \pi(j)$$

Teorema de convergencia

Al igual que en el caso discreto, sin importar el estado inicial, la cadena alcanza el estado de equilibrio asintóticamente. Es por ello que la distribución estacionaria es un objeto clave en el estudio de modelos markovianos:

Teorema 3. Supongamos que la cadena a tiempo continuo $\{X_t, t > 0\}$ es irreducible y que tiene distribución estacionaria π . Entonces,

$$\lim_{t \rightarrow \infty} p_t(i, j) = \pi(j)$$

Adicionalmente, si $G(i)$ es la ganancia obtenida cada vez que la cadena alcanza el estado i y $\sum_j |G(j)|\pi(j) < \infty$, se tiene

$$\frac{1}{t} \int_0^t G(X_s) ds \rightarrow \sum_j G(j)\pi(j), \text{ cuando } t \rightarrow \infty$$

Condición de balance detallado

Decimos que π satisface una **condición de balance detallado** si

$$\pi_i q(i, j) = \pi(j) q(j, i), \text{ para todo par de estados } i, j \quad (2)$$

sumando sobre todos los estados $i \neq j$, de la ecuación anterior resulta

$$\sum_{i \neq j} \pi_i q(i, j) = \lambda_j \pi_j \Rightarrow \sum_{i \neq j} \pi_i q(i, j) - \lambda_j \pi_j = [\pi Q]_j = 0$$

Es decir, si π satisface (1) entonces es una distribución estacionaria. Es sencillo construir ejemplos para constatar que el recíproco no es necesariamente cierto.

Las **ecuaciones de balance detallado** (1) son en general sencillas de resolver y se satisfacen para muchos modelos importantes.

Cadenas de nacimiento y muerte

Consideremos la cadena a tiempo continuo con espacio de estados $\{0, 1, \dots\}$ con $q(n, n+1) = \lambda_n$ para $n \geq 0$ y $q(n, n-1) = \mu_n$ para $n > 0$.

El proceso se denomina de **nacimiento y muerte**, λ_n representa la **tasa de nacimiento** cuando hay n individuos en el sistema y μ_n la **tasa de muerte**.

Las ecuaciones de balance detallado de la cadena de nacimiento y muerte son

$$\pi(n-1)\lambda_{n-1} = \pi(n)\mu_n, \text{ para } n \geq 1$$

Usando recurrencia se obtiene

$$\pi(n) = \frac{\lambda_{n-1}\lambda_{n-2}\cdots\lambda_0}{\mu_n\mu_{n-1}\cdots\mu_1}\pi(0)$$

Ejemplos de Colas

- ① **M/M/1.** Es la cola en un sistema con un servidor, tiempos entre llegadas exponenciales con tasa λ y tiempos de servicio exponenciales con tasa μ . Corresponde a un proceso de nacimiento y muerte con $\lambda_n = \lambda$ y $\mu_n = \mu$. Si la **tasa de tráfico** $\rho = \lambda/\mu < 1$, su distribución estacionaria es la distribución geométrica desplazada

$$\pi(n) = (1 - \rho)\rho^n \text{ para } n \geq 0$$

- ② **M/M/s.** El mismo caso que antes pero con s servidores. Es el proceso de nacimiento y muerte con $\lambda_n = \lambda$ y

$$\mu_n = \begin{cases} n\mu & 1 \leq n \leq s \\ s\mu & n > s \end{cases}$$

Si $\rho < s$ la cola tiene una distribución estacionaria que satisface

$$\pi(s + n) = \left(\frac{\lambda}{s\mu}\right)^{n+1} \pi(s - 1)$$

Movimiento Browniano

- El botánico R. Brown (1773-1858) observó, a través de un microscopio, que pequeñas partículas de polen suspendidas en agua realizaban un movimiento particularmente irregular. El propio Brown descubrió que partículas muy finas de varios minerales seguían el mismo movimiento.
- En 1900, L. Bachelier introdujo un proceso para modelar las fluctuaciones financieras.
- También Einstein (1905) dio una explicación del fenómeno
- Wiener (1894-1964) logró dar un modelo preciso y riguroso para las trayectorias irregulares de las partículas, como funciones continuas pero no diferenciables en ningún punto.
- Desde entonces, las contribuciones teóricas y aplicaciones a otras áreas de las ciencias no han cesado.

Definición

El proceso estocástico $\{B(t), t \geq 0\}$ es un **Movimiento Browniano** (MB) con varianza σ^2 si cumple las siguientes condiciones:

- ① $B(0) = 0$
- ② Tiene incrementos independientes
- ③ Para todo $s < t$, $B(t) - B(s) \sim \mathcal{N}(0, \sigma^2(t - s))$
- ④ Las trayectorias del proceso $t \rightarrow B_t$ son funciones continuas.

Si $\sigma = 1$ decimos que el movimiento es estándar. Note que si $B(t)$ es estándar entonces $\beta B(t)$ es un MB con varianza β^2 . Así que de ahora en adelante asumiremos sin pérdida de generalidad que $B(t)$ es estándar.

Otra propiedad útil es la de reescalamiento. Esta es, para cualquier $\alpha > 0$,

$$\{B(\alpha t), t \geq 0\} \equiv \{\sqrt{\alpha}B(t), t \geq 0\}$$

El MB como un Proceso Gaussiano

El Movimiento Browniano es un caso particular de los procesos Gaussianos. Es decir

$$(B(t_1), B(t_2), \dots, B(t_n)) \sim \mathcal{N}(\mu, \Sigma)$$

cualesquiera que sean $\{t_1, t_2, \dots, t_n\}$. La forma de Σ es sencilla, sigue de la siguiente importante propiedad

$$E[B(t)B(s)] = \min(t, s)$$

Otros Procesos Gaussianos derivados del MB son

- **Puente Browniano:** $B(t) - tB(1)$, para $0 \leq t \leq 1$.
- **Proceso de Ornstein-Uhlenback:** $e^{-t}B(e^{2t})$, para $-\infty < t < \infty$.
- **Proceso de Ito:** $\int_0^t \mu(t)dt + \int_0^t \sigma(t)dB(t)$, para $0 \leq t$.

Fórmula de Ito

Aún cuando las trayectorias brownianas no son diferenciables en ningún punto, existe un proceso con trayectorias continuas que tiene la misma distribución que la aproximación límite por sumas de Riemann-Stieltjes del proceso de Ito

$$dX_t = \mu(t)dt + \sigma(t)dB(t)$$

Lo anterior es la clave para definir el cálculo estocástico. Como para el cálculo diferencial estándar requerimos de la regla de la cadena, en este contexto requerimos de una regla operativa conocida como **fórmula de Ito**. La fórmula establece que, para cualquier f con derivada de segundo orden continua, el proceso $f(X_t)$ es de Ito y satisface la **ecuación diferencial estocástica**

$$df(X_t) = f'(X_t)\sigma(t)dB(t) + \left(f'(X_t) + \frac{1}{2}f''(X_t)\sigma^2 \right) dt$$

Fórmula de Black-Scholes

Una aplicación selecta de la fórmula de Ito es la famosa fórmula de Black-Scholes. En su versión original supone que los precios de las acciones siguen un movimiento browniano exponencial

$$dX_t = X_t(\mu dt + \sigma dB_t)$$

Si el valor de la acción a tiempo t es $f(t, X_t)$ y r es la tasa de interés entonces

$$\frac{\partial f}{\partial t} + \frac{1}{2}\sigma^2 X_t^2 \frac{\partial^2 f}{\partial X_t^2} + rX_t \frac{\partial f}{\partial X_t} - r f = 0$$

Usando la fórmula de Black-Scholes, el cálculo de la llamada opción europea $(X_T - K)^+$ resulta

$$X_0 \Phi(\sigma\sqrt{t} - \alpha) - e^{-rt} K \Phi(\alpha)$$

Siendo $\alpha = (\log(K/X_0) - \mu t)/\sigma\sqrt{t}$ y $\Phi(x) = P(\mathcal{N}(0,1) \leq x)$